

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora, Alex Felipe Mancilla Antay,
Herbert Antonio Meléndez García y Dennis Jack Paitán Cano
Maestría en Inteligencia Artificial, Universidad Nacional de Ingeniería

Curso de Procesamiento de Lenguaje Natural, Grupo 4, semestre académico 2026–1
Lima, Perú

luis.koc@gmail.com amancillaa@uni.pe
hamg.94@gmail.com dennis.paitan.c@uni.pe

Resumen—La revisión manual de videos extensos dificulta localizar lenguaje dañino cuando los subtítulos contienen modismos, ironía, ruido y categorías poco frecuentes. Este trabajo diseña y evalúa, mediante ciencia del diseño, un moderador semiautomático para videos peruanos de YouTube: produce alertas ligadas a intervalos temporales y conserva la decisión final en una persona supervisora. El corpus v2.1 contiene 173 240 chunks elegibles de 4 906 videos, con cinco salidas aprendidas: SEGURO y cuatro daños multietiqueta; 14 163 chunks presentan al menos un daño. La evaluación compara 28 modelos individuales y cinco ensambles sobre 10 600 filas de validación y cinco pliegues agrupados por video. El criterio predeclarado usa como métrica primaria la exactitud balanceada (BA) de cualquier daño, protege el desempeño por categoría mediante macro-AUPRC y congela un promedio suave de regresión logística, cascada E5 y Qwen3–0.6B adaptado mediante LoRA. En validación, el ensemble obtiene BA 0,84, macro-AUPRC 0,55 y macro-F1 0,57; mejora al mejor individuo en 0,0086 de BA y 0,039 de macro-AUPRC, aunque el contraste pareado no establece superioridad estadística. En la apertura única del test con prevalencia natural (22 684 chunks; 7,9 % con daño), la compuerta alcanza BA 0,85 y sensibilidad 0,91. La política selectiva deriva 35 % a revisión y, sobre el 65 % automático, obtiene BA 0,94. El sistema ofrece desempeño competitivo y trazable para priorización; la evidencia no autoriza bloqueo o sanción automáticos.

Index Terms—moderación semiautomática, procesamiento del lenguaje natural, clasificación multietiqueta, lenguaje dañino, YouTube, Qwen, LoRA, ensemble, clasificación selectiva

I. INTRODUCCIÓN

La moderación de contenido no se reduce a asignar una etiqueta: también decide qué material se revisa primero, qué evidencia recibe la persona moderadora y qué errores quedan fuera de observación. A escala de plataforma, estas decisiones combinan reglas, trabajo humano y sistemas automáticos, con exigencias de contexto, transparencia y responsabilidad [1]. Los sistemas semiautomáticos pueden concentrar la revisión en casos dañinos o inciertos [2]; en video, además, una alerta útil debe conservar el fragmento y el instante que la originan.

El problema se intensifica en subtítulos peruanos por modismos, ironía, citas, errores de transcripción y clases

poco frecuentes. Estas dificultades también aparecen en pruebas funcionales de odio, estudios de sesgo lingüístico y análisis de subtítulos automáticos [3]–[5]. Una solución técnicamente correcta debe evitar la fuga entre fragmentos del mismo video, usar métricas apropiadas para desbalance, separar selección de evaluación y declarar cuánto trabajo queda para la persona supervisora.

Este estudio diseña, compara y empaqueta un moderador textual semiautomático mediante ciencia del diseño (DSR) [6], [7]. La Fig. 1 organiza el problema en tres niveles: la revisión completa es inviable en el nivel observable; el desbalance, la ambigüedad y la procedencia heterogénea actúan en el nivel subyacente; y el nivel modelado requiere clasificación multietiqueta, calibración, abstención y trazabilidad.

El trabajo aporta cuatro resultados vigentes: 1) un corpus v2.1 de 173 240 chunks y 4 906 videos, con cinco salidas aprendidas y separación por video; 2) una comparación común de 28 candidatos individuales y cinco ensambles mediante predicciones fuera de pliegue; 3) un artefacto congelado que combina regresión logística, una cascada E5 y Qwen3–LoRA, evaluado una sola vez sobre 22 684 chunks de test; y 4) una política de revisión con cobertura, errores y carga humana explícitos, integrada con evidencia temporal y registro de correcciones.

Los intentos anteriores con cuatro daños y SEGURO derivado sirvieron para detectar debilidades de contrato, ampliar datos y probar estructuras. No se mezclan sus métricas con las actuales. El artículo se concentra en el protocolo v2.1, donde SEGURO es una quinta salida aprendida y las cuatro categorías de daño pueden coexistir.

II. BASES TEÓRICAS Y ANTECEDENTES

II-A. Moderación, datos y contexto

La moderación de una plataforma combina reglas, trabajo humano y sistemas automáticos. La predicción de un modelo no resuelve por sí sola la política, la interpretación ni la responsabilidad de una decisión [1]. La calidad de un clasificador de lenguaje abusivo depende de cómo se define el daño, cómo se toma la muestra y quién asigna las etiquetas; los errores de esas etapas pueden pasar al modelo [8]. Los *data statements* y las *data cards* proponen




Figura 1. Problema estudiado en tres niveles. El estado deseado es priorizar evidencia para una decisión humana informada, no sancionar automáticamente. Elaboración propia.

documentar el origen, el idioma, la recolección, la anotación, los usos previstos y los límites de un conjunto de datos [9], [10].

II-B. Enfoques de solución y trabajos comparables

El estado del arte resuelve la detección de lenguaje dañino como una cadena y no como la elección aislada de un algoritmo. Primero delimita corpus, población, taxonomía y procedimiento de anotación; después representa el texto mediante rasgos léxicos o modelos contextuales; combina clasificadores cuando sus errores son complementarios; evalúa con métricas sensibles al desbalance y pruebas por fenómeno; y deriva los casos inciertos a revisión humana [3], [8], [9], [11]–[14]. Esta secuencia organiza el diseño del presente trabajo: datos locales documentados, tres familias de representación, ensemble, test con prevalencia explícita y supervisión humana.

Los corpus previos muestran distintas formas de construir la tarea. Wulczyn *et al.* estudian ataques personales a gran escala [15]; HateXplain añade el blanco del abuso y explicaciones humanas [16]; y HateCheck muestra que una métrica agregada puede ocultar fallas funcionales [3]. La literatura también advierte que las marcas de identidad o las variedades lingüísticas pueden confundirse con toxicidad [4]. En YouTube, Bertaglia *et al.* analizan lenguaje abusivo en comentarios en inglés [17]; este estudio usa, en cambio, habla transcrita en español y conserva el intervalo temporal de cada evidencia.

La Tabla I ubica seis antecedentes empleados para interpretar el resultado final. Sus cifras no forman una clasificación común: cambian la unidad de análisis, el idioma, el muestreo, la prevalencia, las categorías y la partición. Ninguno de estos datos o modelos interviene en el entrenamiento del proyecto.

NaijaHate evidencia que el desempeño aparente y la carga de revisión pueden cambiar entre muestras representativas y enriquecidas [22]. Por ello el resultado principal de este proyecto corresponde al test con prevalencia natural del corpus, mientras una vista secundaria 4:1 se deriva de las mismas predicciones únicamente para contextualizar trabajos que emplean muestras enriquecidas.

II-C. Taxonomía de daño y adaptación peruana

Para ordenar el espacio de daño se parte de dos distinciones académicas. Waseem *et al.* separan el abuso dirigido a una persona o entidad del dirigido a un grupo, y el abuso explícito del implícito [23]. Banko *et al.* recomiendan categorías finas, criterios de inclusión y excepciones; su tipología distingue, entre otros, ataque por identidad, insulto, doxeo, agresión sexual y amenaza de violencia [24]. El proyecto combina estas distinciones generales

con antecedentes sociales e institucionales pertinentes al contexto peruano.

II-C1. Aportes para la adaptación al contexto peruano:

Para racismo y discriminación, Juan Carlos Callirgos examinó la construcción del otro en el racismo peruano, y Gonzalo Portocarrero relacionó racismo y mestizaje con prácticas e imaginarios sociales [25], [26]. Víctor Vich sintetizó la propuesta de Portocarrero mediante el fundamento invisible, el fantasma del patrón y la utopía del blanqueamiento, tres formas de explicar cómo la jerarquización persiste y cambia en el Perú [27]. Virginia Zavala y Roberto Zariquiey estudiaron la segregación discursiva justificada mediante supuestas carencias de educación o cultura, mientras el volumen editado por Virginia Zavala y Michele Back reunió análisis sobre los vínculos entre racismo y lenguaje [28], [29]. En espacios políticos y digitales, Virginia Zavala y Claudia Almeida mostraron que “motoso” y “terruco” pueden racializar y silenciar a actores políticos; Roberto Brañez Medina documentó el uso de la ortografía para construir las identidades “amixer” y “no-amixer” y justificar racismo cultural; y Verónica Salem describió cómo el insulto, la parodia, la ironía y el humor reproducen estereotipos raciales en Facebook [30]–[32]. Estos aportes orientaron las distinciones entre racismo étnico explícito, racialización lingüística, clasismo racial, discriminación regional y racismo encubierto.

Para género, Francisco Rodríguez-Sánchez y coautores aportan el esquema computacional de EXIST para identificar sexismo en redes, y Philine Zeinert, Nanna Inie y Leon Derczynski proponen criterios de anotación de misoginia en línea [21], [33]. Christian Monge-Olivarria, Juan Guerra-Corales y Fernando Bringas-Castro analizan la feminización como insulto y formas de acoso directo, invasión de privacidad y exclusión en Twitter; su estudio aporta mecanismos generales de violencia digital que complementan las fuentes locales [34]. En el ámbito peruano, Denisse Albornoz y Marieliv Flores caracterizan modalidades, consecuencias y respuestas frente a la violencia de género en línea, y la Defensoría del Pueblo sistematiza su tipología, impactos y vías institucionales de atención [35], [36]. Estas fuentes orientan misoginia/acoso de género y, junto con la tipología general, las distinciones sexuales explícitas, de cosificación y no consentidas.

Para orientación sexual e identidad de género, Bharathi Raja Chakravarthi construyó un corpus multilingüe de comentarios de YouTube y referencias de clasificación para homofobia y transfobia [37]. En Lima, Jan Marc Rottenbacher de Rojas relacionó conservadurismo e intolerancia a la ambigüedad con homofobia y prejuicio hacia grupos transgénero en una muestra universitaria [38]. Carolina Mirian Lovón-Cueva y Marco Lovón-Cueva identificaron en

Tabla I
TRABAJOS RELACIONADOS, ÁMBITO DE APLICACIÓN Y RELACIÓN CON EL ESTUDIO

Trabajo	País o ámbito	Datos, tarea y resultado publicado	Semejanza y diferencia principal
DETOXIS [18]	España; español	4359 comentarios a noticias sobre inmigración; detección binaria de toxicidad; mejor F1 de 0,6461.	Coincide en idioma y daño textual. Cambian la unidad, el dominio temático y el contrato binario.
HatEval [19]	Tarea internacional; Twitter en español e inglés	Odio contra mujeres e inmigrantes, con rasgos de agresividad y blanco; mejor macro-F1 en español de 0,730.	Comparte categorías de racismo y género, pero usa mensajes breves y muestreo dirigido al blanco.
OffendES [20]	España; español	47 128 comentarios de YouTube, Instagram y Twitter alrededor de influenciadores jóvenes; macro-F1 binario de 0,7839.	Es el antecedente más próximo por YouTube y español; clasifica comentarios escritos, no habla transcrita ni evidencia temporal.
EXIST [21]	Tarea internacional; español e inglés	Más de 11 000 textos de Twitter y Gab; identificación y categorización de sexismo; mejor F1 español de 0,7944.	Se aproxima a género/identidad y emplea supervisión experta; no cubre los otros tres daños del proyecto.
HateXplain [16]	Twitter y Gab en inglés; autores de India y Alemania	Cerca de 20 mil publicaciones con tres clases, blanco y racionales humanos; macro-F1 de 0,687 para BERT-HateXplain.	Comparte la necesidad de ligar decisión y evidencia; usa racionales por token, no intervalos de video ni español peruano.
NaijaHate [22]	Nigeria; Twitter	35 976 tuits y una muestra representativa; AP cercana a 0,34 en la muestra aleatoria frente a 0,83–0,90 en conjuntos enriquecidos.	Comparte la preocupación por dominio local y prevalencia; país, idioma, etiqueta y diseño muestral impiden comparar AP de forma directa.

ciberforos peruanos un repertorio de lexemas lesbofóbicos y los interpretaron como violencia simbólica y actos de lenguaje de odio [39]. En conjunto, estas fuentes ofrecen un primer acercamiento al tratamiento del odio y la discriminación en entornos peruanos desde los estudios culturales, la sociolingüística, la psicología social, los estudios de género y la documentación institucional [29], [30], [35], [36], [38], [39]. Orientaron criterios de inclusión, exclusión y revisión; la cobertura exacta y los nombres finales constituyen una adaptación operacional del proyecto.

El odio implícito puede expresarse con lenguaje indirecto o codificado [40]; ironía y sarcasmo plantean una tarea específica de interpretación [41]; y un estudio peruano muestra insulto, parodia, ironía y humor en la construcción del estereotipo *amixer* [32]. La anotación de abuso también puede cambiar al disponer de mensajes circundantes [42]. Estos antecedentes motivan tres señales de revisión, distintas de las categorías de moderación. El informe sobre moderación en quechua documenta carencias de datos y capacidad de revisión para esa familia lingüística [43]; el corpus del proyecto se limita al español. Para contenido sexual, la tipología académica y las fuentes peruanas respaldan separar agresión sexual y difusión íntima no consentida [24], [35], [36]; la política de YouTube aporta la frontera operativa entre contenido explícito, sexualización no consentida y excepciones informativas o documentales [44]. En conjunto, estas fuentes sostienen una primera taxonomía operacional adaptada al estudio y preparada para validación experta posterior.

II-D. Modelos de texto y aprendizaje multietiqueta

II-D1. Modelos clásicos: TF-IDF representa cada texto mediante la frecuencia de sus términos y reduce el peso de los que aparecen en muchos documentos [11], [45]. Es rápido y conserva vocabulario visible, pero produce vectores dispersos y no modela el contexto. Sobre esos rasgos, la regresión logística estima una probabilidad mediante una frontera lineal; es eficiente y sus coeficientes son interpretables, aunque no capta relaciones no lineales sin crear nuevos rasgos [46]. La SVM busca un margen amplio entre clases y suele funcionar bien con texto disperso de alta dimensión; su salida no es una probabilidad y requiere

calibración para interpretar el score [47]. Complement Naive Bayes corrige los conteos con información de las clases complementarias, lo que favorece datos textuales desbalanceados; su bajo costo se obtiene a cambio de una fuerte hipótesis de independencia entre rasgos [48].

La descomposición en valores singulares (SVD) proyecta TF-IDF a un espacio latente más pequeño [49]. Sobre esa proyección, *gradient boosting* combina árboles que corrigen errores sucesivos y puede modelar interacciones no lineales, pero aumenta el ajuste y pierde parte del detalle léxico [50]. *fastText* promedia representaciones de palabras y subpalabras antes de aplicar un clasificador lineal; las subpalabras ayudan ante variantes morfológicas y términos poco frecuentes, pero el promedio conserva poco orden y contexto distante [51].

II-D2. Transformers compactos: Los Transformers usan atención para representar cada token según los demás tokens del fragmento [12]; BERT establece el ajuste bidireccional de un modelo preentrenado para una tarea concreta [52]. Sentence-BERT obtiene un vector de oración que permite comparar y clasificar textos con menor costo que procesar cada par por separado [53]. MiniLM destila relaciones de autoatención de una red mayor y ofrece un codificador compacto [54]. El checkpoint multilingüe `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` transfiere ese espacio entre idiomas [55], [56]. Su ventaja es el equilibrio entre contexto y costo; sus límites son la longitud finita de entrada y la pérdida de información al resumir el fragmento en un vector.

E5 aprende representaciones con contraste débilmente supervisado y separa consultas y textos mediante prefijos [57]. Su extensión multilingüe respalda `intfloat/multilingual-e5-small` y el prefijo `query`: usado en el proyecto [58], [59]. El entrenamiento contrastivo favorece similitud semántica con un tamaño moderado, pero el resultado depende del formato de entrada y el vector agrupado también actúa como cuello de botella.

II-D3. LLM Qwen3 con adaptación LoRA: Qwen3 es una familia de modelos de lenguaje autorregresivos con versiones densas y de mezcla de expertos, preentrenadas en varios idiomas [60]. El estudio usa el checkpoint denso `Qw`

en/Qwen3-0.6B-Base por su escala, licencia e integración con Transformers [61]. Una cabeza multietiqueta convierte la representación final en scores de las categorías. LoRA introduce matrices de bajo rango en capas seleccionadas y permite ajustar una fracción pequeña de los parámetros [62]. Esta combinación ofrece más capacidad contextual que los modelos compactos, pero exige más memoria y tiempo, y sus scores todavía requieren calibración. *Qwen3-LoRA* designa este clasificador ajustado, no un sinónimo genérico de LLM.

El diseño experimental integra estas representaciones con las estructuras planas, en cascada y jerárquicas descritas en la metodología.

Un fragmento puede activar varias categorías de modelación, por lo que la tarea es multietiqueta [63], [64]. Las jerarquías pueden representar una puerta general y clases hijas [65]; los modelos conscientes de jerarquía motivan explotar dependencias entre etiquetas [66]. El aprendizaje multitarea puede compartir representaciones entre objetivos relacionados [67]. Sin embargo, esa estructura es una hipótesis a evaluar, no una garantía de mejora.

II-E. Selección, calibración y abstención

Precisión, recobrado y F1 resumen aspectos distintos de una matriz de confusión; ninguna medida basta para todos los tipos de clasificación [68]. En datos desbalanceados, las curvas precisión-recobrado describen la clase positiva de forma más informativa que las curvas ROC [69], [70]. El código usa `average_precision_score`: $AP = \sum_n (R_n - R_{n-1}) P_n$, donde P_n y R_n corresponden al umbral n [71]. El artículo la denomina *precisión promedio*; algunos artefactos preliminares usan el nombre PR-AUC, aunque calculan precisión promedio y no un área trapezoidal. Las salidas se calibran por etiqueta con regresión sigmoide [72], [73]; la calibración de redes modernas requiere comprobación empírica [74]. La regla de selección y los umbrales usan validación para limitar el sesgo de selección [75]. El protocolo vigente congela selección, calibración y umbrales antes de una única apertura de test.

Una clasificación selectiva puede abstenerse en casos dudosos [76], [77]; el aprendizaje con derivación extiende esa idea al decidir cuándo entregar el caso a una persona experta [14]. En la política del proyecto, el recobrado de enrutamiento es la fracción de chunks dañinos enviados a alerta o revisión; la precisión es la fracción dañina entre los enviados; la tasa de revisión es la fracción total enviada; y el valor predictivo negativo es la fracción realmente segura entre los casos que permanecen en la ruta automática. El análisis también cuenta los falsos negativos. Estas definiciones se aplican al enrutamiento, no sustituyen las métricas por categoría ni la decisión del supervisor [68].

II-F. Ontología y trazabilidad terminológica

Una ontología explícita conceptos compartidos y sus relaciones [78]; OWL 2 formaliza clases, propiedades e individuos con significado definido [79]. El proyecto usa una ontología liviana para evitar que *etiqueta*, *predicción*, *alerta*, *seguro* y *decisión* se traten como sinónimos. La versión legible por máquina acompaña al artículo y define las relaciones necesarias para enlazar evidencia y artefactos

versionados. Sus metadatos de trazabilidad aplican de forma parcial los principios FAIR de datos localizables, accesibles, interoperables y reutilizables [80]. El Apéndice C reúne el grafo y el vocabulario controlado que fijan esas relaciones.

III. PROBLEMAS Y OBJETIVOS

El problema general es la ausencia de una cadena local, reproducible y evaluada que transforme subtítulos públicos en alertas temporales comparables y, después, en una decisión humana informada. El objetivo general consiste en construir y evaluar esa cadena con datos peruanos, modelos de distintas familias, una regla de selección predeclarada y una interfaz de operación supervisada.

El primer problema específico es la falta de un corpus local versionado que conserve texto, intervalo, fuente, etiqueta y procedencia. La definición, el muestreo y la anotación condicionan los clasificadores de lenguaje abusivo [8]; los *data statements* y *data cards* recomiendan documentar recolección, anotación, usos y límites [9], [10]. El primer objetivo específico es construir y auditar el corpus v2.1 con particiones agrupadas por video.

El segundo problema es la falta de una comparación común entre modelos clásicos, Transformers y Qwen. En datos desbalanceados, los promedios pueden ocultar la clase positiva y las curvas precisión-recobrado resultan especialmente informativas [68], [69]. El segundo objetivo es comparar todas las familias bajo la misma validación, con exactitud balanceada de cualquier daño como criterio primario y macro-AUPRC de daños como salvaguarda.

El tercer problema es que una decisión obligatoria oculta incertidumbre y carga humana. La clasificación selectiva permite abstenerse, y el aprendizaje para diferir extiende esa decisión al envío a una persona experta [14], [76], [77]. El tercer objetivo es congelar calibradores, umbrales y una política `NEEDS_REVIEW` bajo capacidad declarada antes de abrir test.

El cuarto problema es el aislamiento entre datos, pesos, predicciones y operación. DSR exige demostrar y evaluar el artefacto construido [6], [7]; en moderación, la automatización no sustituye el gobierno ni la responsabilidad humana [1]. El cuarto objetivo es integrar los tres ganadores por tipo y el ensamble congelado con evidencia temporal, revisión y registro trazable. La Tabla II relaciona los cuatro problemas con el método y la evidencia que permite examinarlos.


IV. METODOLOGÍA

IV-A. Diseño de investigación

La investigación sigue DSR: identifica una necesidad, define objetivos, construye el artefacto, lo demuestra, lo evalúa y comunica los resultados [6], [7]. Cada iteración produjo evidencia versionada de datos, etiquetas, modelos o operación. Los experimentos anteriores con un contrato distinto se usan únicamente como antecedentes de diseño; la evaluación reportada en este artículo pertenece al snapshot v2.1 y a la comparación 03_07. La Fig. 2 resume las iteraciones que conducen desde el corpus hasta la evaluación y el demostrador vigentes.

Tabla II
RELACIÓN ENTRE PROBLEMAS, OBJETIVOS Y EVIDENCIA VIGENTE

	Problema específico	Objetivo específico	Evidencia de verificación
P1/O1	Datos locales dispersos y riesgo de fuga entre fragmentos.	Construir y documentar el corpus v2.1.	173 240 chunks, 4 906 videos, cinco salidas y partición agrupada.
P2/O2	Resultados no comparables entre familias.	Comparar candidatos bajo un protocolo común.	28 individuos + 5 ensambles; validación OOF de cinco pliegues.
P3/O3	Decisiones forzadas sin carga humana explícita.	Calibrar, congelar y evaluar una política selectiva.	Test abierto una vez; 65 % automático y 35 % a revisión.
P4/O4	Modelos y evidencia aislados de la operación.	Integrar ganadores, ensamble, tiempos y correcciones.	Registro congelado, frontend de producción y artefactos versionados.



Las iteraciones anteriores informan el diseño; solo los artefactos v2.1 sustentan los resultados vigentes.

Figura 2. Ciclo DSR aplicado al corpus v2.1, comparación común, congelación, apertura única de test y demostrador. Elaboración propia basada en Peffers *et al.* [7].

IV-B. Adquisición, limpieza y unidad de análisis

El universo de adquisición comprende videos públicos de YouTube vinculados con el Perú y con subtítulos disponibles en español. La búsqueda incluye periodismo, política, opinión, humor, entretenimiento, deportes, gastronomía y viajes, además de búsquedas dirigidas para aumentar categorías poco frecuentes. El alcance previo a exclusiones reunió 182 461 chunks, 5 385 videos y 322 canales. Por ello el corpus permite entrenar y comparar, pero no estima la prevalencia de daño de toda la plataforma. La documentación de origen, anotación y límites sigue las recomendaciones de *data statements* y *data cards* [9], [10].

Las pistas VTT se recuperan con *yt-dlp* o YouTube Transcript API [81], [82]. No se descarga audio ni se ejecuta reconocimiento de voz propio. La limpieza usa normalización Unicode NFKC [83], unifica espacios y elimina repeticiones consecutivas del VTT. La unidad de análisis es el chunk: texto contiguo con *video_id*, tiempos inicial/final, posición, canal y procedencia. La segmentación se cierra al alcanzar 30 segundos o 600 caracteres y exige al menos 90 caracteres; no introduce solapamiento deliberado. La Fig. 3 muestra la transformación y los controles que separan datos, particiones, selección y test.

El tamaño temporal se selecciona en un ejercicio independiente con los mismos videos de referencia y ventanas de 15, 20, 25, 30 y 35 segundos. Los modelos se vuelven a entrenar y la decisión usa solo validation; 1 000 réplicas pareadas por video cuantifican la incertidumbre. La ventana de 30 segundos alcanza AP macro de daño de 0,12, IC95 % [0,11, 0,14], en el perfil clásico robusto y queda congelada antes de consultar test. Las comprobaciones con MiniLM y un modelo generativo no aportan evidencia suficiente para sustituirla. Esta elección conserva más contexto que las ventanas cortas sin asumir que una duración observada es

óptima fuera del corpus [69], [75].

La construcción enfrenta tres dificultades principales: disponibilidad cambiante o incompleta de subtítulos; concentración por canal y búsquedas dirigidas que impiden interpretar el corpus como muestra probabilística; y modismos, ironía, humor, contexto truncado y daños coexistentes que vuelven insuficiente la coincidencia de palabras. La materialización de las transcripciones, las exclusiones trazables, la separación por video, las señales de revisión y la conservación del texto con sus tiempos controlan estos riesgos sin eliminarlos.

IV-C. Corpus v2.1

Después de deduplicar y excluir 9 221 decisiones no elegibles (5,1 % del alcance), el snapshot contiene 173 240 chunks de 4 906 videos y 276 canales efectivos. Hay 159 077 chunks **SEGURO** (92 %) y 14 163 con al menos un daño (8,2 %), una relación de 11:1; estos últimos reúnen 17 052 asignaciones y 2 709 casos multietiqueta. La Tabla III muestra la distribución operacional.

La distribución por fuente presenta una cola larga. Un video aporta en promedio 35 chunks, con mediana de 19 y máximo de 767; un canal aporta en promedio 630, con mediana de 26 y máximo de 33 203. Esta diferencia entre media y mediana revela concentración y justifica informar los canales principales (Tabla IV) y evaluar en el futuro generalización hacia canales no observados.

IV-D. Taxonomía y contrato de salida

El contrato contiene cinco salidas principales: **SEGURO**, **RACISMO**, **ATAQUE-G/I**, **ACOSO-AMENAZA** y **SEXUAL**. La primera es mutuamente excluyente con cualquier daño; las cuatro restantes pueden coexistir. Una salida vacía, la coexistencia seguro-daño o un score próximo al umbral activa revisión y no crea una sexta clase. Catorce etiquetas




Figura 3. Flujo vigente de datos, etiquetado, entrenamiento, selección y operación. El test permanece sellado hasta congelar candidato, calibradores, umbrales y política. Elaboración propia.

Tabla III
TAMAÑO Y DISTRIBUCIÓN DEL CORPUS V2.1

Componente	Total
Videos / canales efectivos	4 906 / 276
Chunks elegibles	173 240
SEGURO	159 077
Algún daño	14 163
RACISMO	2 570
ATAQUE-G/I	2 331
ACOSO-AMENAZA	8 276
SEXUAL	3 875
Chunks con más de un daño	2 709

Nota: los cuatro daños son multietiqueta y no suman “algún daño”. SEGURO es excluyente.

Tabla IV
CANALES CON MAYOR NÚMERO DE CHUNKS ELEGIBLES Y CONCENTRACIÓN ACUMULADA

Canal o grupo	Chunks	Fracción
Hablando Huevadas	33 203	19 %
Arde Troya con Juliana Oxenford	12 295	7,1 %
Nunca MAS	11 364	6,6 %
Goblinciano	8 166	4,7 %
Nada Espacial	6 224	3,6 %
Primeros cinco	71 252	41 %
Primeros diez	96 845	56 %

finas y tres flags de ironía, humor o contexto preservan detalle para auditoría y objetivos auxiliares.

Las dimensiones generales se apoyan en tipologías de abuso y contenido dañino de Waseem *et al.* y Banko *et al.* [23], [24]. La adaptación al contexto peruano incorpora los antecedentes de la Tabla V. Las fuentes sustentan fenómenos y exclusiones; los nombres, fusiones y reglas finales son decisiones operativas del proyecto y no se atribuyen como taxonomía exacta a esos autores.

IV-E. Etiquetado y control de calidad

La preanotación combina definiciones versionadas, salida JSON validable y revisión por etapas. Un modelo amplio propone categorías; una segunda revisión atiende daños, baja confianza y negativos difíciles; la cola final permite aceptar, rechazar o modificar cada propuesta. El historial conserva 55 966 eventos. Un panel estratificado congelado contiene 16 694 chunks y la huella combinada de auditoría

alcanza 17 635 chunks únicos (10 % del universo elegible). Estas cifras representan decisiones asistidas y trazables; no equivalen a doble anotación humana independiente ni autorizan reportar acuerdo interanotador general.

La precedencia es revisión final asistida sobre las propuestas anteriores. Los casos sin resolución suficiente se excluyen del entrenamiento. Las etiquetas finas y flags actúan como objetivos auxiliares en modelos que los soportan; nunca se entregan como predictores *gold* durante la inferencia.

IV-F. Partición y muestras de entrenamiento

La separación se realiza por `video_id`; ningún video cruza train, validation y test. El snapshot conserva la prevalencia de cada partición (Tabla VI). Para el ajuste y la comparación se mantienen todos los daños y se seleccionan cuatro seguros por cada chunk dañino mediante hash y semilla declarada. Así, train usa 51 205 filas (10 241 daños + 40 964 seguros) y validation 10 600 (2 120 + 8 480). El test permanece completo y sellado con 22 684 filas. Tras una sola inferencia se produce también una vista secundaria 4:1, sin reabrir test.

IV-G. Familias de modelos

La comparación incluye 28 candidatos individuales procedentes de tres familias y cinco reglas de ensemble. Todos producen cinco scores principales; cuando la arquitectura lo permite, añade 14 etiquetas finas y tres flags, para un total de 22 logits con pérdidas enmascaradas. La implementación usa scikit-learn para los modelos clásicos [84] y PyTorch/Transformers para las redes [85], [86]. La Fig. 4 contrasta los mecanismos de las tres familias y anticipa su composición en el ensemble.

IV-G1. Modelos clásicos: La vista base concatena TF-IDF de palabras (1–2 gramas) y caracteres internos (3–5 gramas), siguiendo la ponderación de frecuencia inversa de documento [11]. Una transformación uno-contra-resto enmascarada entrena cabezas con *Dummy*, Complement Naive Bayes, regresión logística, SVM lineal calibrada o SGD logístico [46]–[48]. Una vista adicional incorpora indicadores léxicos auditables derivados de la política de etiquetado; continúa siendo aprendizaje supervisado y no *prompting*.

El mejor clásico según el ranking común es una regresión logística con $C = 0,5$. Su interés no se limita al costo: aporta una señal léxica distinta a las redes y permite inspeccionar n-gramas, por lo que resulta un miembro complementario del ensemble.

Tabla V
DEFINICIÓN Y SUSTENTO DE LA TAXONOMÍA OPERATIVA

Salida	Definición operacional	Autores y fuentes utilizados
SEGURO	Ausencia de evidencia suficiente para los cuatro daños. Es una salida aprendida y exclusiva; ambigüedad o conflicto obliga revisión.	Regla operacional del proyecto, diferenciada de las dimensiones dañinas de Waseem <i>et al.</i> y Banko <i>et al.</i> [23], [24].
Racismo	Ataque o inferiorización por identidad étnico-racial, origen regional, variedad lingüística o clase racializada; una mención identitaria no basta.	Calligros; Zavala y Zariquiey; Zavala y Back; Brañez; Almeida y Zavala; Salem; Vich [25], [27]–[32].
Ataque-G/I	Ataque, exclusión o degradación por género, orientación, identidad o expresión; puede coexistir con acoso.	Rodríguez-Sánchez <i>et al.</i> ; Zeinert, Inie y Derczynski; Albornoz y Flores; Defensoría del Pueblo; Chakravarthi <i>et al.</i> ; Rottenbacher; Lovón-Cueva y Lovón-Cueva [21], [33], [35]–[39].
Acoso-Amenaza	Hostigamiento o ataque dirigido a una persona identificable, exposición privada o amenaza de daño. La unión conserva subtipos finos.	Waseem <i>et al.</i> ; Wulczyn, Thain y Dixon; Banko <i>et al.</i> ; Defensoría del Pueblo [15], [23], [24], [36].
Sexual	Descripción sexual gráfica sin fin informativo, cosificación o referencia a material íntimo no consentido; el sistema observa texto, no imagen.	Banko <i>et al.</i> ; Zeinert, Inie y Derczynski; Albornoz y Flores; Defensoría del Pueblo; política de YouTube [24], [33], [35], [36], [44].




Figura 4. Familias comparadas y composición del ensemble congelado. Los tres miembros conservan arquitecturas y errores diferentes. Elaboración propia.

Tabla VI
PARTICIÓN NATURAL DEL SNAPSHOT POR VIDEO

Split	Chunks	Videos	Daño	Seguro
Train	123 239	3 478	10 241	112 998
Validation	27 317	754	2 120	25 197
Test	22 684	674	1 802	20 882

IV-G2. Transformers compactos y cascada ganadora:

Los modelos planos usan `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` o `intfloat/multilingual-e5-small` [54], [56]–[59]. Se ajustan con AdamW, entropía cruzada binaria ponderada y parada temprana [87]–[89]. También se evaluaron una cascada suave, una cabeza denominada multitarea y una cascada v2 orientada a seguridad.

La mejor configuración Transformer es la cascada v2. Una primera red E5 aprende `ANY_DAMAGE` y auxiliares; una segunda red E5 produce `SEGURO` y los cuatro daños. Sea $g(x)$ el score de daño de la compuerta y τ su umbral. La compuerta declara seguro solo cuando $g(x) < \tau$; en otro caso usa los cinco scores de la rama. En validation se escoge el mayor τ que cumple simultáneamente

$$\text{Recall}_{\text{daño}}(\tau) \geq 0,99,$$

$$P(y = \text{SEGURO} \mid g(x) < \tau) \geq 0,99.$$

Si ningún umbral con cobertura positiva satisface ambas condiciones, todo pasa a la rama. La arquitectura separa detección amplia y tipificación, una decisión relacionada con antecedentes de clasificación jerárquica [65]. Sin embargo, ejecuta dos Transformers y puede propagar errores de la compuerta; sus valores 0,99 describen validation y no una garantía poblacional.

IV-G3. Qwen3-LoRA: El estudio usa `Qwen/Qwen3-0.6B-Base`, un modelo denso multilingüe de 0,6 mil millones de parámetros [60], [61]. LoRA congela el backbone e inserta matrices entrenables de bajo rango [62]. La configuración ganadora coloca adaptadores en `q_proj`, `k_proj`, `v_proj` y `o_proj`, con rango 8, $\alpha = 16$, `dropout` 0,05 y tasa 10^{-4} , hasta cuatro épocas. Una cabeza de 22 logits produce las cinco salidas principales y auxiliares. Este Qwen es un clasificador: no recibe la taxonomía Markdown ni genera JSON durante la inferencia.

Qwen3-LoRA es el mejor candidato individual de la comparación. Su representación más amplia aporta contexto; la adaptación eficiente evita ajustar todos los parámetros. El costo de memoria y latencia es superior al de regresión

logística y E5, razón adicional para conservar las tres familias en el artefacto.

IV-H. Calibración y predicciones fuera de pliegue

Cada candidato produce scores sobre validation mediante cinco pliegues **GroupKFold** por video [90]. En cada pliegue, cuatro quintos ajustan calibradores sigmoidales de Platt y umbrales; el quinto produce predicciones fuera de pliegue (OOF) [72], [73]. Así, la exactitud balanceada y la macro-AUPRC OOF no evalúan una fila con un calibrador ajustado sobre esa misma fila. Después de seleccionar, los calibradores y umbrales de despliegue se ajustan con toda validation y quedan congelados.

Para una categoría k , la precisión promedio resume la curva precisión-recobrado, $AP_k = \sum_n (R_n - R_{n-1})P_n$, y el promedio macro asigna igual peso a los cuatro daños [69], [71]. La compuerta **ANY_DAMAGE** se evalúa con exactitud balanceada (BA), media de sensibilidad y especificidad, para no favorecer la clase segura mayoritaria.

IV-I. Elección e interpretación de las métricas

Las métricas responden a decisiones distintas. La métrica principal del ranking es la BA de **ANY_DAMAGE** OOF a cobertura completa: mide por igual la capacidad de detectar daño y reconocer contenido seguro. Una BA de 0,84 no significa que 84% de todos los chunks sean correctos, sino que el promedio entre sensibilidad y especificidad es 0,84 [91]. La macro-AUPRC promedia sin ponderación la precisión promedio de los cuatro daños a través de los umbrales; un valor de 0,55 no es un porcentaje de aciertos y solo se compara directamente sobre el mismo panel y prevalencia. La macro-F1 promedia por daño $2PR/(P+R)$ después de fijar umbrales y describe el compromiso entre precisión y recobrado, sin usar verdaderos negativos [68].

La exactitud ordinaria y los promedios micro o ponderados no gobiernan el ranking porque la abundancia de **SEGURO** y de las etiquetas con mayor soporte puede ocultar omisiones en daños raros. ROC-AUC se conserva como diagnóstico secundario; ante positivos escasos, la curva precisión-recobrado muestra de forma más directa cuántas alertas relevantes aparecen entre las predicciones positivas [69], [70]. Tampoco se suman BA, FNR, FPR, AUPRC y F1 en una nota única: varias cantidades comparten errores y sus escalas no representan la misma utilidad. El riesgo $R_{0,67} = 0,67 \text{ FNR} + 0,33 \text{ FPR}$ expresa la decisión local de penalizar aproximadamente el doble una omisión que una falsa alerta, mientras la tasa de revisión mide capacidad humana y se interpreta junto con el error de la ruta automática.

IV-J. Ensemble por promedio de probabilidades

El ensemble congelado combina los mejores representantes de cada familia: regresión logística $C = 0,5$, cascada E5 v2 y Qwen3-LoRA. Para cada salida k , promedia los tres scores sin pesos y calibra el promedio:

$$\bar{s}_k(x) = \frac{1}{3} \sum_{m=1}^3 s_{mk}(x), \quad \hat{p}_k(x) = \sigma(a_k \bar{s}_k(x) + b_k).$$

La decisión compara $\hat{p}_k$ con un umbral θ_k fijado en validation. Esta fusión suave aprovecha que las señales

léxicas, contextuales y autoregresivas no fallan siempre en los mismos casos; los ensembles y el voto mayoritario cuentan con antecedentes generales [13], [92]. El experimento también evalúa promedio ponderado por validation, mayoría dura, unión (máximo) e intersección (mínimo). Solo el promedio simple se congela para test. El Apéndice A conserva los identificadores, calibradores, umbrales y demás parámetros necesarios para reconstruirlo.

IV-K. Criterio de selección e inferencia estadística

La política de selección es lexicográfica y no suma métricas redundantes. Primero maximiza BA **ANY_DAMAGE** OOF a cobertura completa. Luego exige una salvaguarda de macro-AUPRC de daños frente al mejor individuo, con margen de no inferioridad predeclarado de 0,10; conserva la frontera de Pareto BA-macro-AUPRC; y desempata por menor riesgo $R_{0,67} = 0,67 \text{ FNR} + 0,33 \text{ FPR}$, seguido de mayor macro-AUPRC. El margen 0,10 es permisivo y se conserva como limitación, no como prueba de equivalencia.

La aplicación al resultado final muestra la función de cada paso. El promedio simple obtiene BA 0,840, frente a 0,838 del promedio ponderado y 0,831 de Qwen3-LoRA; por ello lidera el criterio primario. Su macro-AUPRC es 0,555, superior en 0,039 a 0,516 del mejor individuo, de modo que supera la salvaguarda. El promedio ponderado alcanza AUPRC 0,556 pero BA menor, por lo que ambos ensembles permanecen en la frontera de Pareto: ninguno mejora simultáneamente las dos coordenadas. Si se requiere el desempate de costo, el promedio simple tiene $R_{0,67} = 0,67(0,127) + 0,33(0,193) = 0,149$, menor que 0,152 del ponderado. Estas operaciones se aplican en secuencia; no se suman en una puntuación compuesta.

Las diferencias se estiman con 2000 réplicas bootstrap pareadas por video y ajuste de Holm [93]–[95]. El remuestreo respeta la correlación entre chunks de un mismo video; no sustituye la variación entre semillas.

IV-L. Política selectiva y test sellado

NEEDS_REVIEW es una política posterior al modelo. Se activa por conflicto seguro-daño, salida vacía, incoherencia compuerta-categoría o proximidad a los umbrales. La capacidad máxima declarada fue 40% y validation eligió un margen $\delta = 0,03$, con 33% de revisión. Candidato, miembros, calibradores, umbrales y política se almacenaron en **seleccion_congelada.json** antes de test.

El test natural contiene 22684 chunks y se abrió una sola vez. Los tres miembros se infirieron en esa apertura y sus scores se reutilizaron para calcular la vista secundaria 4:1; no hubo reinferencia, reajuste ni cambio de ganador. Este diseño separa selección y estimación final, y reduce el sesgo de selección discutido por Cawley y Talbot [75].

IV-M. Artefacto de demostración

El frente de producción carga el registro de los tres ganadores por tipo y del ensemble. Acepta texto o URL con subtítulos, genera chunks temporales, permite elegir el modelo y muestra scores, categorías, razones de revisión y procedencia. Las acciones humanas se registran para auditoría y para una futura versión de entrenamiento separada. La Fig. 5 resume esta arquitectura y el Apéndice D

Tabla VII
MEJOR CANDIDATO POR TIPO EN VALIDATION OOF

Tipo	BA	AUPRC	F1	FNR	FPR
Clásico, logística $C = 0,5$	0,80	0,48	0,50	0,18	0,22
Transformer, cascada v2	0,82	0,45	0,52	0,16	0,21
Qwen3-LoRA	0,83	0,52	0,55	0,17	0,17
Ensemble, promedio suave	0,84	0,55	0,57	0,13	0,19

Nota: AUPRC y F1 son promedios macro de los cuatro daños; BA, FNR y FPR corresponden a ANY_DAMAGE OOF a cobertura completa.

Tabla VIII
ESTRATEGIAS DE ENSEMBLE EN VALIDATION OOF

Regla	BA	Macro-AUPRC	Macro-F1
Promedio suave	0,84	0,55	0,57
Promedio ponderado	0,84	0,56	0,57
Unión / máximo	0,83	0,52	0,56
Mayoría dura	0,83	0,46	0,57
Intersección / mínimo	0,82	0,52	0,54

documenta las interfaces. El demostrador opera localmente o en modo sombra; no está autorizado para afectar usuarios sin revisión.

V. RESULTADOS

Todos los resultados pertenecen al contrato v2.1 de cinco salidas y al mismo snapshot. Validation determina candidato, calibradores, umbrales y política; test solo estima el desempeño del artefacto ya congelado.

V-A. Comparación global en validation

La comparación contiene 28 candidatos individuales y cinco ensembles. La Tabla VII presenta el mejor representante de cada tipo según el ranking lexicográfico común. Qwen3-LoRA es el mejor individuo; el promedio suave ocupa el primer lugar general. Frente a Qwen, el ensemble aumenta 0,0086 la BA y 0,039 la macro-AUPRC OOF de daños. La Fig. 6 muestra los 33 candidatos.

Las cinco estrategias usan los mismos tres miembros (Tabla VIII). El promedio ponderado obtiene una macro-AUPRC y F1 apenas mayores, pero una BA 0,0017 menor. La mayoría dura maximiza F1, aunque reduce AUPRC. Como la política no suma estas métricas, el promedio simple conserva la prioridad por BA y queda congelado.

V-B. Frontera de Pareto e incertidumbre

El retador elegible más cercano es el promedio ponderado. En 2000 réplicas pareadas por video, la diferencia de BA retador menos referencia es $-0,0017$, IC95% $[-0,0044, 0,00083]$, con $p_{\text{Holm}} = 0,23$. El intervalo incluye cero; por ello el estado congelado es *empate estadístico o evidencia inconclusa*, no superioridad universal. La Fig. 7 conserva la frontera completa.

V-C. Desempeño del ensemble por salida

Con los calibradores de despliegue ajustados en toda validation, el ensemble alcanza macro-AUPRC 0,57 y macro-F1 0,57 sobre los cuatro daños (Tabla IX). Contenido sexual obtiene el mayor F1 (0,63) y género/identidad el menor (0,46). La diferencia orienta expansión focalizada, no exclusión de la categoría.

Tabla IX
ENSEMBLE SELECCIONADO POR CATEGORÍA EN VALIDATION

Salida	Soporte	AUPRC	Prec.	Rec.	F1
SEGURO	8 480	0,97	0,89	0,96	0,92
RACISMO	382	0,57	0,58	0,66	0,62
ATAQUE-G/I	374	0,39	0,41	0,52	0,46
ACOSO-AMENAZA	1 146	0,61	0,54	0,60	0,57
SEXUAL	633	0,69	0,71	0,57	0,63

Tabla X
DESEMPEÑO POR SALIDA EN EL TEST NATURAL

Salida	Soporte	AUPRC	Prec.	Rec.	F1
SEGURO	20 882	0,99	0,96	0,95	0,96
RACISMO	308	0,36	0,28	0,63	0,39
ATAQUE-G/I	283	0,27	0,24	0,54	0,33
ACOSO-AMENAZA	1 063	0,45	0,35	0,64	0,45
SEXUAL	519	0,58	0,52	0,63	0,57

Los mejores candidatos dependen de la categoría. Qwen3-LoRA con contexto 256 lidera AUPRC en racismo (0,57) y género/identidad (0,40); el promedio ponderado lidera acoso/amenaza (0,61) y SEGURO (0,97); el promedio simple lidera contenido sexual (0,69). La Fig. 8 muestra AUPRC y F1 de esos especialistas. El detalle de ganadores por métrica se conserva en el Apéndice B. Para operación se mantiene un único ensemble global, evitando reglas por categoría elegidas *post hoc*.

V-D. Apertura única de test natural

El test contiene 22 684 chunks, 1 802 con algún daño (7,9%). La compuerta congelada identifica 1 632 y omite 170: sensibilidad 0,91, especificidad 0,79 y BA 0,85. La diferencia de BA respecto de validation OOF es $(+0,0059)$; no se usa para recalibrar ni cambiar el modelo.

En la tarea multietiqueta completa, la macro-AUPRC de daños es 0,42 y la macro-F1 0,44. La caída respecto de la vista 4:1 se concentra en precisión y AUPRC porque el test natural contiene 12 seguros por daño; sensibilidad y BA de la compuerta se mantienen. La Tabla X localiza esa variación por salida. Esta diferencia confirma que AUPRC debe interpretarse junto con la prevalencia [22].

V-E. Política de revisión humana

La política congelada deriva 7 888 chunks (35%) y deja 14 796 (65%) en la ruta automática. Dentro de esta ruta, la sensibilidad es 0,94, la especificidad 0,94 y la BA 0,94; quedan 60 daños como falsos negativos automáticos. La Tabla XI compara la cobertura completa con esta ruta selectiva. La mejora no procede de cambiar el clasificador, sino de reservar para revisión los conflictos y márgenes inciertos. La carga queda por debajo del máximo predeclarado de 40%, pero sigue siendo material y debe contrastarse con capacidad real.

VI. DISCUSIÓN

VI-A. Valor de la combinación de familias

El resultado principal no es que una arquitectura sustituya a las demás, sino que tres representaciones complementarias mejoran la decisión global. La regresión




Figura 5. Arquitectura operacional vigente: tres modelos por tipo, ensemble suave, política selectiva y decisión humana. Elaboración propia.




Figura 6. Comparación global de 28 individuos y cinco ensembles en validation. La BA determina el orden primario y la macro-AUPRC actúa como salvaguarda. Elaboración propia desde 03_07a.

Tabla XI

COMPUERTA COMPLETA Y RUTA AUTOMÁTICA EN TEST NATURAL

Vista	Cobertura	BA	Sens.	Espec.	FN
Compuerta completa	100 %	0,85	0,91	0,79	170
Ruta automática	65 %	0,94	0,94	0,94	60

logística aporta señales léxicas rápidas e inspeccionables; la cascada E5 separa detección y tipificación con una compuerta conservadora; Qwen3-LoRA aporta la mejor combinación individual de BA, AUPRC y F1. El promedio suave aumenta simultáneamente BA y macro-AUPRC frente al mejor individuo, sin añadir un metamodelo opaco. La mejora puntual es moderada y el contraste con el promedio ponderado es inconcluso, pero el artefacto

congelado conserva una regla simple, reproducible y fácil de implementar.

La comparación por tipo también evita una lectura simplista del ranking. El Transformer ganador supera al clásico en BA y FNR, pero no en macro-AUPRC; Qwen supera a ambos en el balance global; y los ensembles cambian el compromiso entre sensibilidad, falsas alarmas y F1. Esta diversidad justifica mostrar los tres modelos individuales junto con el ensemble en producción, siempre que el usuario pueda distinguir predicción, desacuerdo y decisión humana.

VI-B. Desempeño por categoría

Contenido sexual y racismo alcanzan los mayores F1 del ensemble en validation; género/identidad conserva la mayor dificultad y el menor soporte. En test natural,




Figura 7. Frontera BA–macro-AUPRC en validation. La estrella identifica el candidato congelado y el retador cercano permanece compatible con la evidencia. Elaboración propia.

contenido sexual mantiene el mayor AUPRC de daño (0,58) y género/identidad el menor (0,27). Estas diferencias son accionables: la siguiente adquisición debe priorizar casos fronterizos, lenguaje implícito y contextos locales de género e identidad. Las métricas agregadas no sustituyen pruebas funcionales por fenómeno, como muestra HateCheck [3], ni auditorías de sesgo lingüístico [4].

La unión operacional de acoso personal y amenaza directa aumenta soporte y estabilidad, pero no establece equivalencia conceptual o legal. Los subtipos finos preservan esa distinción para auditoría. De forma análoga, **SEGURO** significa ausencia de evidencia suficiente dentro del texto observado, no una certificación universal del video.

VI-C. Comparación contextual con el estado del arte

Los trabajos relacionados reportan cifras altas en tareas y corpus distintos: EXIST informa aproximadamente 0,79 de F1 en su tarea de sexismo [21]; OffendES, 0,78 [20]; HatEval, 0,73 [19]; HateXplain, 0,69 [16]; y DETOXIS, 0,65 [18]. En la vista secundaria 4:1 del presente test, el F1 binario de cualquier daño es 0,66, dentro del intervalo formado por DETOXIS y HateXplain. Esta posición muestra competitividad contextual, no equivalencia experimental: cambian idioma, unidad, categorías, partición y prevalencia.

La diferencia entre la vista 4:1 y el test natural refuerza esa cautela. NaijaHate muestra que la precisión promedio puede caer de rangos 0,83–0,90 en conjuntos enriquecidos a cerca de 0,34 en una muestra representativa [22]. Aquí,

el mismo conjunto de predicciones produce macro-AUPRC de daños 0,57 en la vista 4:1 y 0,42 en la vista natural. La BA de la compuerta permanece cerca de 0,85 porque pondera por igual sensibilidad y especificidad. Por ello el aporte más defendible es la combinación de corpus local, evaluación con prevalencia explícita, evidencia temporal y derivación humana, no una cifra aislada.

El trabajo es comparable con el estado del arte en el objeto científico —clasificación de lenguaje dañino en contenido social—, en el uso de F1 y métricas de ranking, y en la magnitud del F1 binario contextual. También se alinea con prácticas actuales que fortalecen un sistema aplicado: separación y remuestreo por entidad, predicciones fuera de muestra, test sellado con prevalencia explícita, análisis por categoría, calibración y revisión humana. Su diferenciación favorable procede de integrar taxonomía peruana, habla transcrita, evidencia temporal y modelos clásico, Transformer y Qwen en un único flujo verificable.

Esta evidencia no demuestra liderazgo en un benchmark internacional común. Para sostener una afirmación de estado del arte predictivo se necesita evaluar el artefacto congelado sobre un conjunto externo compartido o una cohorte temporal de canales no observados, repetir el entrenamiento con varias semillas, incorporar doble anotación humana independiente, ejecutar pruebas funcionales y de sesgo por subgrupo, y contrastar texto con señales de audio e imagen. Un piloto en modo sombra debe añadir latencia, costo, tasa de desacuerdo y falsos negativos residuales. Por tanto, el




Figura 8. Mejor desempeño por categoría en validation entre candidatos que superan la salvaguarda global. Elaboración propia.

resultado es competitivo y metodológicamente alineado con el estado del arte aplicado, pero la superioridad general permanece pendiente de evidencia externa.

VI-D. Utilidad operativa

La compuerta completa detecta 91 % de los chunks dañinos del test y la política selectiva eleva la BA de la ruta automática a 0,94. El sistema permite que la mayoría de chunks siga una ruta automática y concentra 35 % en revisión. Esta proporción es mucho menor que revisar todos los subtítulos, pero no es trivial: una operación real debe convertirla en horas, dotación y tiempos de respuesta. La clasificación selectiva es útil precisamente porque hace visible ese costo [14], [77].

El artefacto puede ensayarse en modo sombra: procesa texto o una URL con subtítulos, localiza intervalos, muestra los cuatro modelos vigentes y registra correcciones. No ejecuta sanciones ni reemplaza las políticas de plataforma. Esa separación entre evidencia automática y responsabilidad humana es coherente con la literatura de moderación [1], [2].

VI-E. Mejora respecto de los intentos previos

La línea anterior trataba **SEGURO** como complemento de cuatro daños y mezclaba pruebas procedentes de contratos diferentes. La versión actual aprende las cinco salidas, aumenta el corpus a 173 240 chunks, separa todos los splits por video, usa OOF para calibración, compara 33 candidatos, congela una política y abre test una sola vez. Esta evolución explica el diseño, pero las métricas históricas no participan en la conclusión vigente.

VII. LIMITACIONES Y TRABAJO FUTURO

La evaluación tiene cinco límites principales.

1. **Población y etiquetas.** “Natural” describe la prevalencia del split completo, no una muestra probabilística de YouTube. La adquisición incluye búsquedas dirigidas y los rótulos son mayormente asistidos; se

requiere una cohorte temporal con doble revisión humana independiente y acuerdo por categoría [96], [97].

2. **Incertidumbre del ranking.** El bootstrap agrupa por video, pero no mide variación entre semillas. El empate con el retador impide declarar superioridad estadística. Deben repetirse entrenamientos y evaluarse estabilidad temporal [75], [98].
3. **Salvaguarda permisiva.** El margen de no inferioridad de macro-AUPRC fue 0,10. Aunque estaba congelado antes de test, es amplio para una escala 0–1; una réplica confirmatoria debería fijar un margen sustantivo más estricto.
4. **Capacidad humana.** La tasa de revisión de 35 % satisface el máximo experimental de 40 %, pero todavía no se ha traducido en dotación, duración ni costo. El piloto debe medir tiempo por alerta, falsos negativos residuales y desacuerdo humano.
5. **Modalidad y deriva.** El sistema observa subtítulos y metadatos, no imagen, audio ni conducta de red. Cambios de canal, plataforma o periodo pueden degradar calibración; se requiere monitoreo de deriva, latencia, privacidad y seguridad [5], [99].

VIII. CONCLUSIONES

El estudio construye un moderador semiautomático medible que transforma subtítulos en alertas temporales, compara representaciones complementarias y deriva la incertidumbre a una persona. La distancia tecnológica se reduce hasta un artefacto funcional para priorización y apoyo a la decisión; la sanción autónoma permanece fuera de su alcance.

La carencia de un objeto de estudio integrado se reduce mediante un corpus v2.1 de 173 240 chunks y 4 906 videos, con cinco salidas, 14 163 chunks dañinos y 2 709 casos multietiqueta. La separación por video y los 55 966 eventos de revisión permiten reconstruir la procedencia de cada

unidad. La doble anotación humana independiente, todavía ausente, queda como requisito de una cohorte prospectiva.

La falta de una comparación común se resuelve para la instantánea v2.1 con 28 individuos y cinco ensembles bajo la misma validation OOF. El promedio suave obtiene BA 0,84, macro-AUPRC 0,55 y macro-F1 0,57; mejora puntualmente al mejor individuo en 0,0086 de BA y 0,039 de AUPRC. El promedio simple y el ponderado forman la frontera de Pareto: el primero lidera BA y presenta menor $R_{0,67}$ (0,149 frente a 0,152), mientras el segundo alcanza AUPRC 0,556. Como el contraste pareado permanece inconcluso, el resultado sustenta una selección reproducible mediante la regla lexicográfica, no un ganador universal.

La apertura única de 22 684 chunks de test sitúa la BA de la compuerta en 0,85 y su sensibilidad en 0,91. La política deriva 35 % y deja 65 % en la ruta automática con BA 0,94; de este modo, la incertidumbre y la carga humana pasan de supuestos a cantidades observables. La capacidad real, el tiempo por alerta y el costo siguen pendientes de medición en un piloto en modo sombra.

La integración reúne la regresión logística, la cascada E5, Qwen3-LoRA y el ensemble suave con calibradores, umbrales, evidencia temporal y registro de revisión. La verificación funcional local confirma que la interfaz invoca los tres miembros y devuelve también el promedio suave congelado. La combinación conserva una señal léxica rápida, una arquitectura contextual de dos etapas y un modelo de lenguaje adaptado, mientras mantiene la decisión final bajo supervisión humana.

En conjunto, el sistema presenta un desempeño competitivo para detección y priorización de contenido peruano: BA 0,85 y sensibilidad 0,91 bajo la prevalencia natural del corpus. En la vista secundaria 4:1 obtiene F1 binario 0,66, comparable en magnitud con resultados publicados de tareas relacionadas, pero esta cifra no gobierna el ranking. Su principal fortaleza es sistémica: datos auditables, comparación común, selección congelada, test separado y supervisión humana conviven en un mismo flujo. Esta combinación está alineada con el estado del arte aplicado, aunque la superioridad predictiva sobre un benchmark externo común permanece sin demostrar. El siguiente paso es validar el flujo prospectivamente con canales no observados, doble anotación independiente, varias semillas, capacidad, costos y deriva reales.

Durante la demostración local, la interfaz de etiquetado y el frontend de producción permiten recorrer el control humano y comparar los tres ganadores por tipo con el ensemble congelado. Estas direcciones requieren que los servicios del proyecto estén activos en el equipo del lector; documentan el artefacto, pero no sustituyen una validación de campo.

DISPONIBILIDAD Y ÉTICA

El código y la documentación están en GitHub; el corpus, los pesos y los artefactos grandes, en Drive controlado (Apéndice E). Los subtítulos requieren revisar términos, privacidad, licencias y derechos [99], [100]; la alerta no reemplaza la decisión humana.

APÉNDICE A
ESPECIFICACIÓN DEL ENSEMBLE CONGELADO

El artefacto `seleccion_congelada.json`, esquema 4.0.0, fija la firma de comparación, el hash del dataset, los tres miembros, calibradores, umbrales y política de revisión. La Tabla XII detalla la composición. Los nombres cortos usados en el cuerpo corresponden a identificadores inmutables de candidato.

Tabla XII
MIEMBROS DEL ENSEMBLE DE PRODUCCIÓN

Tipo	Identificador	Arquitectura	BA	AUPRC	F1
Clásico	classical-logistic_regression_c0p5-54f7971c6000	TF-IDF palabra 1-2 + carácter 3-5; OVR enmascarado; logística $C = 0,5$.	0,80	0,48	0,50
Transformer	cascade_v2-af78eba77883	E5 compuerta ANY_DAMAGE + E5 rama de cinco salidas; enrutamiento seguro.	0,82	0,45	0,52
Qwen	qwen_lora-4aa5ce04df05	Qwen3-0.6B-Base; LoRA ($r = 8$, $\alpha = 16$, $p = 0,05$) en Q/K/V/O; cabeza de 22 logits.	0,83	0,52	0,55
Ensemble	ensemble_soft_mean	Media simple de los tres scores por salida y calibración sigmoideal posterior.	0,84	0,55	0,57

La Tabla XIII permite reconstruir la salida final. Para cada categoría se calcula $\hat{p}_k = \sigma(a_k \bar{s}_k + b_k)$ y se activa cuando $\hat{p}_k \geq \theta_k$. La compuerta de cualquier daño usa además un corte congelado de 0,05817 sobre el máximo de las cuatro salidas dañinas calibradas.

Tabla XIII
CALIBRADORES Y UMBRALES DEL ENSEMBLE CONGELADO

Salida	a_k	b_k	θ_k
SEGURO	6,2826	-2,9738	0,39
RACISMO	7,1743	-5,2129	0,20
ATAQUE-G/I	5,9253	-4,9025	0,19
ACOSO-AMENAZA	5,7678	-4,2600	0,32
SEXUAL	6,9926	-4,9314	0,50

El promedio ponderado, retador más cercano, usa pesos 0,3317, 0,3110 y 0,3573 para clásico, Transformer y Qwen, respectivamente. La diferencia de BA frente al promedio simple es $-0,0017$, con IC95 % que cruza cero. Por tanto, el promedio simple se conserva por el criterio predeclarado, no por una afirmación de superioridad absoluta.

APÉNDICE B
RESULTADOS AMPLIADOS

La Tabla XIV separa los líderes por salida y métrica sin reemplazar el ganador global usado en producción.

Tabla XIV
GANADORES POR CATEGORÍA EN VALIDATION, RESTRINGIDOS A CANDIDATOS QUE SUPERAN LA SALVAGUARDA GLOBAL

Salida	Mejor AUPRC	Valor	Mejor F1	Valor	Mejor recall	Valor	Prec.
SEGURO	Ensemble ponderado	0,97	Qwen ctx256	0,92	SVM $C = 2$	0,97	0,86
Racismo	Qwen ctx256	0,57	Qwen ctx256	0,62	Qwen ctx256	0,68	0,57
Ataque-G/I	Qwen ctx256	0,40	Mayoría dura	0,47	Ensemble ponderado	0,55	0,39
Acoso-Amenaza	Ensemble ponderado	0,61	Unión	0,58	Unión	0,63	0,54
Sexual	Promedio simple	0,69	Unión	0,64	Unión	0,64	0,64

La Tabla XV compara la vista natural y la secundaria 4:1 obtenidas de la misma inferencia, por lo que sus diferencias no proceden de otro modelo ni de una reapertura de test.

Tabla XV
MÉTRICAS GLOBALES DE LAS DOS VISTAS DERIVADAS DE UNA SOLA APERTURA DE TEST

Vista	Filas	BA	F1 any	AUPRC daño	F1 daño	F1 cinco	ECE	Brier
Natural	22 684	0,85	0,41	0,42	0,43	0,54	0,018	0,028
4:1 secundaria	9 010	0,85	0,66	0,57	0,56	0,63	0,011	0,045

La vista 4:1 selecciona de forma determinista 7 208 seguros y conserva los 1 802 daños. Reutiliza exactamente los scores de la vista natural. La diferencia de F1 y AUPRC refleja prevalencia, no otro modelo ni otra inferencia. La Tabla XVI conserva los conteos exactos que explican la compuerta completa y la ruta selectiva.

Tabla XVI
MATRIZ BINARIA DE CUALQUIER DAÑO EN TEST NATURAL

Política	TP	FN	FP	TN
Compuerta completa	1 632	170	4 466	16 416
Ruta automática selectiva	912	60	813	13 012

APÉNDICE C

ONTOLOGÍA Y VOCABULARIO CONTROLADO

La ontología liviana distingue evidencia, anotación, categoría operativa, predicción, decisión humana y registro reentrenable. El archivo `ontologia_moderacion.ttl` conserva la versión legible por máquina; la Fig. 9 resume las relaciones empleadas por el artículo y el demostrador.

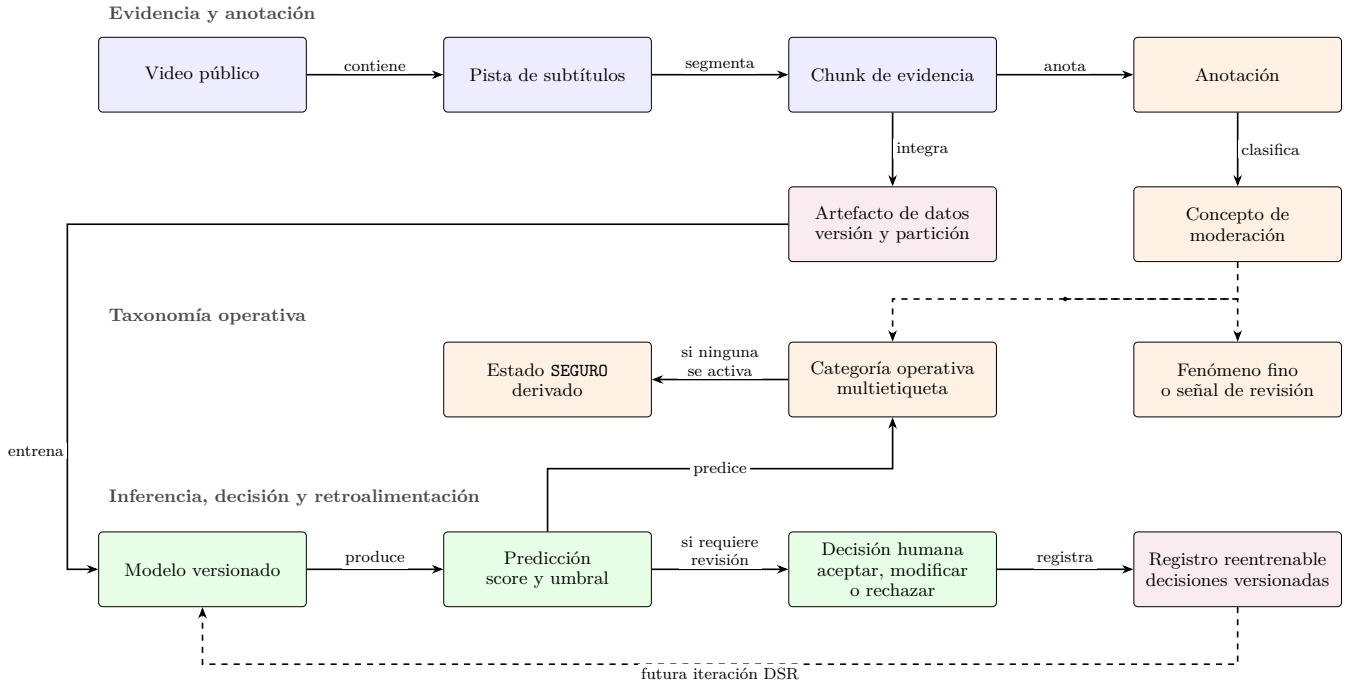


Figura 9. Ontología de trazabilidad desde el video hasta la decisión humana y la retroalimentación. Elaboración propia.

APÉNDICE D

INTERFACES DE ANOTACIÓN Y OPERACIÓN

La Fig. 10 documenta el entorno de etiquetado: texto, intervalo, propuesta previa, categorías y acciones quedan visibles antes de guardar. La Fig. 11 muestra la interfaz de producción, que conserva una única entrada para texto o URL y permite seleccionar los tres ganadores por tipo o el ensemble congelado. La verificación funcional confirma que cada resultado identifica modelo, versión, scores, umbrales y razón de revisión.

Validación humana - 3 114 casos

Categorías gruesas: propuesta Prio visible flags transversales separados

3063/3114 resueltos · incluidos 3012 · excluidos 51

Vista Todas

Iniciales REV

Guía

Descargar final

Flujo rápido: la propuesta del LLM ya está visible y precargada. **Aceptar** la incluye tal cual; **rechazar** excluye el chunk del entrenamiento; si cambias categorías o flags, usa **guardar versión humana**. Las decisiones anteriores se conservan como decisiones humanas migradas.

Segunda corrida / ampliación (5779)

Sin abrir

1/1 · Arde Troya con Juliana Oxenford · ARDE TROYA WITH JULIANA OXFENFORD: JUNE 10, 2026 PROGRAM · 48:41-49:13 · validation

Abrir video

CONTEXTO ANTERIOR

de estado, ¿no? Y habiendo explicado este asunto juristas no solamente nacionales sino internacionales con suma facilidad [resoplido] y que la prensa sigue en eso. La prensa fue la que permanentemente buscó dar el golpe de estado, ¿no?, con el Congreso de la República contra Pedro Castillo. Esa es la verdad. Claro que este cumpliendo un deseo de la ultraderecha que no podía ver a Pedro Castillo sentado en el sillón presidencial. Esa es la verdad.

CHUÑE A VALIDAR

sillón presidencial. Esa es la verdad. Hablar lo contrario, ¿no? A la verdad, a lo que está demostrado, lo que está acreditado nacional e internacionalmente lo hace quedar mal al Perú. Porque vemos allí, ¿no?, a un entrevistador, periodista y a un entrevistado diciendo lo que está demostrando que no es. Es como ver allí, ¿no?, a un entrevistador que realmente se presenta como un macaco y el entrevistado como otro macaco, repitiendo lo mismo, lo mismo, lo mismo

CONTEXTO POSTERIOR

repitiendo lo mismo, lo mismo, lo mismo y lo mismo. Eso es lo que vemos en el Perú. ¿Qué fue entonces lo que vimos todos? ¿Qué fue lo que escuchamos? que Pedro Castillo leyó ese discurso que no constituye este delito de rebelión, no constituye este golpe de estado, no se ha demostrado en el proceso de que haya habido conspiración, porque por conspiración quiere decir que se reúnen dos o tres por lo menos no para acordar levantarse en armas. Bueno, estaba

Propuesta del LLM · DeepSeek Pro

visible antes de decidir

RACISMO DISCRIMINACION

ACOSO PERSONAL

Confianza declarada: 0.95

Etiquetas finas (solo referencia): racismo_etnico_explicito, acoso_personal

Justificación: El término 'macaco' es un insulto racial dirigido a personas, en este caso al entrevistador y entrevistado, inferiorizándolos por su apariencia o comportamiento asociado a estereotipos étnicos (Callirgos, 1993). Además, al ser dirigido a individuos identificables en el contexto del programa, constituye acoso personal.

Notas Pro: Uso de 'macaco' como insulto racial y ataque a periodista y entrevistado.

Origen de selección: Adquisición: high_yield_channel - objetivo: ACOSO_PERSONALAMENAZA_DIRECTA

✓ Aceptar LLM e incluir

✗ Rechazar y excluir

Guardar versión modificada por humano

Aceptar y rechazar avanzan al siguiente pendiente. Para modificar, cambia primero las opciones precargadas.

CATEGORÍA BASE

☐ SEGURO

No hay ataque, amenaza ni sexualización dañina; lo citado, informativo o crítico sin daño tan bien sea seguro.

☒ RACISMO DISCRIMINACION

Inferiorización o exclusión por etnia, rasgos racializados, acento, clase asociada o procedencia regional.

☐ ACOSO GENERO IDENTIDAD

Ataque o degradación por género, m (logine, orientación sexual) o identidad de género.

☒ ACOSO PERSONAL

Insulto, hostigamiento o degradación dirigido a una persona identificable.

☐ AMENAZA DIRECTA

Intención explícita o inequívoca de causar daño físico, sexual, patrimonial o equivalente.

☐ CONTENIDO SEXUAL

Contenido sexual explícito dañado, coacción sexual o material no consensual.

FLAG TRANSVERSALES (SOLO CON DAÑO)

☐ ironía ambigua

La ironía no permite decidir con seguridad si hay daño genuino.

☐ humor encubridor

El humor funciona como cobertura para normalizar o minimizar el daño.

☐ contexto necesario

Aun con los vecinos mostrados, se requiere revisar más contexto del video.

NOTA HUMANA OPCIONAL

Útil para justificar una modificación o una exclusión.

Anterior

Diferir con nota

Siguiente pendiente

Atajos: [A] aceptar · [R] rechazar · [Ctrl]+[Enter] guardar modificación · [↩] navegar.

Figura 10. Entorno de revisión de etiquetas: contexto, propuesta y controles para aceptar, rechazar o modificar. Captura del artefacto del proyecto.

Figura 11. Frontend de producción: entrada textual o URL, selección de modelo, categorías, scores y evidencia temporal. La versión funcional se alinea con los candidatos congelados de 03_07.

APÉNDICE E
TRAZABILIDAD Y DISPONIBILIDAD

La Tabla XVII identifica la fuente canónica usada para cada bloque del manuscrito y separa resultados, selección y evaluación final.

Tabla XVII
ARTEFACTOS FUENTE DE LOS RESULTADOS VIGENTES

Artefacto	Contenido	Uso en el artículo
docs/artefactos/auditoria_estado_final_182461.json	Totales elegibles, etiquetas, videos, particiones y huella de auditoría.	Corpus y etiquetado.
docs/OPTIMIZACION_LONGITUD_CHUNKS.md y docs/ROBUSTEZ_NEURONAL_LONGITUD_CHUNKS.md	Comparación de 15–35 s, perfiles clásico y neuronal, bootstrap y decisión congelada.	Longitud temporal de 30 s.
resultados/modelos/comparacion_individual_ensemble_validation.json	Ranking, OOF, calibración, Pareto, bootstrap y cinco ensembles.	Selección en validation.
resultados/modelos/seleccion_congelada.json	Miembros, calibradores, umbrales y política NEEDS_REVIEW.	Especificación desplegable.
resultados/modelos/test_final_abierto_una_vez.json	Test natural, vista 4:1 y métricas selectivas.	Evaluación final.
resultados/modelos/REPORTE_COMPARACION_MODELOS_03_07.md	Tablas y análisis crítico legible.	Control editorial y reproducibilidad.

GitHub (https://github.com/lkoc/Trabajo_PLN-MIA-Grupo4) conserva scripts, cuadernos y documentación. Google Drive (<https://drive.google.com/drive/folders/1H3PKr7CWd-RwavZgEnfLhh94eq-NO9P3>) conserva corpus, pesos y artefactos de mayor tamaño bajo acceso controlado. La disponibilidad técnica no concede por sí sola permiso de reutilización; deben revisarse licencias, privacidad y términos de YouTube [99], [100].

REFERENCIAS

- [1] R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>
- [2] J. S. Andersen, O. Zukunft, and W. Maalej, "REM: Efficient semi-automated real-time moderation of online forums," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2021, pp. 142–149. [Online]. Available: <https://aclanthology.org/2021.acl-demo.17/>
- [3] P. Röttger, B. Vidgen, D. Nguyen *et al.*, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>
- [4] M. Sap, D. Card, S. Gabriel *et al.*, "The risk of racial bias in hate speech detection," in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2019, pp. 1668–1678. [Online]. Available: <https://aclanthology.org/P19-1163/>
- [5] R. Tatman, "Gender and dialect bias in YouTube's automatic captions," in *Proceedings of the First ACL Workshop on Ethics in Natural Language Processing*. Association for Computational Linguistics, 2017, pp. 53–59. [Online]. Available: <https://aclanthology.org/W17-1606/>
- [6] A. R. Hevner, S. T. March, J. Park *et al.*, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>
- [7] K. Peffers, T. Tuunanen, M. A. Rothenberger *et al.*, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.
- [8] B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0243300>
- [9] E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: <https://aclanthology.org/Q18-1041/>
- [10] M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: https://facctconference.org/static/pdfs_2022/facct-22-3533231.pdf
- [11] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>
- [12] A. Vaswani, N. Shazeer, N. Parmar *et al.*, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>
- [13] T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.
- [14] H. Moazzam and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/moazzam20b.html>
- [15] E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399.
- [16] B. Mathew, P. Saha, S. M. Yimam *et al.*, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14 867–14 875. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17745>
- [17] T. Bertaglia, A. Grigoriu, M. Dumontier *et al.*, "Abusive Language on Social Media Through the Legal Looking Glass," in *Proceedings of the Fifth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2021, pp. 191–200. [Online]. Available: <https://aclanthology.org/2021.woah-1.20/>
- [18] M. Taulé, A. Ariza, M. Nofre *et al.*, "Overview of DETOXIS at IberLEF 2021: DETECTION of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6390>
- [19] V. Basile, C. Bosco, E. Fersini *et al.*, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://aclanthology.org/S19-2007/>
- [20] F. M. Plaza-del Arco, A. Montejo-Ráez, L. A. Ureña-López *et al.*, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: <https://aclanthology.org/2021.ranlp-1.123/>
- [21] F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza *et al.*, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>
- [22] M. Tonneau, P. Quinta De Castro, K. Lasri *et al.*, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://aclanthology.org/2024.acl-long.488/>
- [23] Z. Waseem, T. Davidson, D. Warmusley *et al.*, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>
- [24] M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>
- [25] J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993.
- [26] G. Portocarrero Maisch, *Racismo y mestizaje y otros ensayos*. Lima: Fondo Editorial del Congreso del Perú, 2009, reimpresión de la edición de 2007.
- [27] V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>
- [28] V. Zavala and R. Zariquiey, "“Yo te segrego a ti porque tu falta de educación me ofende”: una aproximación al discurso racista en el Perú contemporáneo," in *Racismo y discurso en América Latina*, T. A. van Dijk, Ed. Barcelona: Gedisa, 2007, pp. 333–370.
- [29] V. Zavala and M. Back, Eds., *Racismo y lenguaje*. Lima: Fondo Editorial de la Pontificia Universidad Católica del Perú, 2017. [Online]. Available: <https://repositorio.pucp.edu.pe/index.php/handle/123456789/170315>
- [30] V. Zavala and C. Almeida, "“Motoso y terruco”: ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/lexis/article/view/26332>
- [31] R. F. Brañez Medina, "La construcción discursiva de las identidades “amixer” y “no-amixer” en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú, 2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/1618>
- [32] V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf
- [33] P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting*

- of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers). Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://aclanthology.org/2021.acl-long.247/>
- [34] C. Monge-Olivarria, J. Guerra-Corrales, and F. Bringas-Castro, “Violencia de género en Twitter: feminización como forma de insulto en la conversación digital,” *Orkopata. Revista de Lingüística, Literatura y Arte*, vol. 2, no. 2, pp. 7–16, 2023. [Online]. Available: <https://revistas.inudi.edu.pe/ro/es/article/view/425>
- [35] D. Albornoz and M. Flores, “Conocer para resistir: violencia de género en línea en Perú,” *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnorendencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf
- [36] Defensoría del Pueblo del Perú, “Violencia de género contra las mujeres en línea,” Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>
- [37] B. R. Chakravarthi, “Detection of homophobia and transphobia in YouTube comments,” *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s41060-023-00400-0>
- [38] J. M. Rottenbacher de Rojas, “Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima,” *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>
- [39] C. M. Lovón-Cueva and M. Lovón-Cueva, “Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums,” *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://whatever.cirque.unipi.it/index.php/journal/article/view/156>
- [40] M. ElSherief, C. Ziemis, D. Muchlinski *et al.*, “Latent hatred: A benchmark for understanding implicit hate speech,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 345–363. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.29/>
- [41] S. Ilić, E. Marrese-Taylor, J. Balazs *et al.*, “Deep contextualized word representations for detecting sarcasm and irony,” in *Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*. Association for Computational Linguistics, 2018, pp. 2–7. [Online]. Available: <https://aclanthology.org/W18-6202/>
- [42] T. Bourgeade, Z. Li, F. Benamara *et al.*, “Humans need context, what about machines? investigating conversational context in abusive language detection,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. ELRA and ICCL, 2024, pp. 8438–8452. [Online]. Available: <https://aclanthology.org/2024.lrec-main.740/>
- [43] D. Thakur, “Moderación de contenido en quechua en redes sociales,” Center for Democracy & Technology, Tech. Rep., Jun. 2025. [Online]. Available: <https://cdt.org/wp-content/uploads/2025/06/2025-Quechua-Report-Spanish-final-1.pdf>
- [44] YouTube, “Política sobre desnudos y contenido sexual,” Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>
- [45] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.
- [46] D. R. Cox, “The regression analysis of binary sequences,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.
- [47] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995.
- [48] J. D. M. Rennie, L. Shih, J. Teevan *et al.*, “Tackling the poor assumptions of naive bayes text classifiers,” in *Proceedings of the 20th International Conference on Machine Learning*, 2003, pp. 616–623. [Online]. Available: <https://people.csail.mit.edu/jrennie/papers/icml03-nb.pdf>
- [49] S. Deerwester, S. T. Dumais, G. W. Furnas *et al.*, “Indexing by latent semantic analysis,” *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.
- [50] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [51] A. Joulin, E. Grave, P. Bojanowski *et al.*, “Bag of tricks for efficient text classification,” in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*. Association for Computational Linguistics, 2017, pp. 427–431. [Online]. Available: <https://aclanthology.org/E17-2068/>
- [52] J. Devlin, M.-W. Chang, K. Lee *et al.*, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Association for Computational Linguistics, 2019, pp. 4171–4186. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [53] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using siamese BERT-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Association for Computational Linguistics, 2019, pp. 3982–3992. [Online]. Available: <https://aclanthology.org/D19-1410/>
- [54] W. Wang, F. Wei, L. Dong *et al.*, “MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [55] N. Reimers and I. Gurevych, “Making monolingual sentence embeddings multilingual using knowledge distillation,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2020, pp. 4512–4525. [Online]. Available: <https://aclanthology.org/2020.emnlp-main.365/>
- [56] Sentence Transformers, “Model card: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2,” Hugging Face Hub, 2026, checkpoint revision used: e8f8c211226b894fcb81acc59f3b34ba3efd5f42; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2/blob/e8f8c211226b894fcb81acc59f3b34ba3efd5f42/README.md>
- [57] L. Wang, N. Yang, X. Huang *et al.*, “Text embeddings by weakly-supervised contrastive pre-training,” *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>
- [58] —, “Multilingual E5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>
- [59] intfloat, “Model card: intfloat/multilingual-e5-small,” Hugging Face Hub, 2026, checkpoint revision used: 614241f622f53c4eeff9890bdc4f31cfec418b3; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/intfloat/multilingual-e5-small/blob/614241f622f53c4eeff9890bdc4f31cfec418b3/README.md>
- [60] A. Yang, A. Li, B. Yang *et al.*, “Qwen3 technical report,” *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>
- [61] Qwen Team, “Model card: Qwen/Qwen3-0.6B-Base,” Hugging Face Hub, 2025, checkpoint revision used: da87bfb608c14b7cf20ba1ce41287e8de496c0cd; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/Qwen/Qwen3-0.6B-Base/blob/da87bfb608c14b7cf20ba1ce41287e8de496c0cd/README.md>
- [62] E. J. Hu, Y. Shen, P. Wallis *et al.*, “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>
- [63] G. Tsoumakas and I. Katakis, “Multi-label classification: An overview,” *International Journal of Data Warehousing and Mining*, vol. 3, no. 3, pp. 1–13, 2007.
- [64] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014.
- [65] C. N. J. Silla and A. A. Freitas, “A survey of hierarchical

- classification across different application domains,” *Data Mining and Knowledge Discovery*, vol. 22, no. 1–2, pp. 31–72, 2011.
- [66] J. Zhou, C. Ma, D. Long *et al.*, “Hierarchy-aware global model for hierarchical text classification,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 1106–1117. [Online]. Available: <https://aclanthology.org/2020.acl-main.104/>
- [67] R. Caruana, “Multitask learning,” *Machine Learning*, vol. 28, pp. 41–75, 1997.
- [68] M. Sokolova and G. Lapalme, “A systematic analysis of performance measures for classification tasks,” *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [69] T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>
- [70] J. Davis and M. Goadrich, “The relationship between precision-recall and ROC curves,” in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240.
- [71] scikit-learn developers, “scikit-learn average precision score api,” scikit-learn API Reference, 2026, accessed: 2026-07-29. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html
- [72] J. C. Platt, “Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods,” in *Advances in Large Margin Classifiers*, A. J. Smola, P. L. Bartlett, B. Schölkopf *et al.*, Eds. Cambridge, MA, USA: MIT Press, 1999, pp. 61–74.
- [73] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proceedings of the 22nd International Conference on Machine Learning*. Association for Computing Machinery, 2005, pp. 625–632.
- [74] C. Guo, G. Pleiss, Y. Sun *et al.*, “On calibration of modern neural networks,” in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>
- [75] G. C. Cawley and N. L. C. Talbot, “On over-fitting in model selection and subsequent selection bias in performance evaluation,” *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>
- [76] C. K. Chow, “On optimum recognition error and reject tradeoff,” *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [77] Y. Geifman and R. El-Yaniv, “Selective classification for deep neural networks,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
- [78] T. R. Gruber, “A translation approach to portable ontology specifications,” *Knowledge Acquisition*, vol. 5, no. 2, pp. 199–220, 1993.
- [79] W3C OWL Working Group, “OWL 2 Web Ontology Language: Document overview (second edition),” World Wide Web Consortium, W3C Recommendation, Dec. 2012, 11 December 2012. [Online]. Available: <https://www.w3.org/TR/owl2-overview/>
- [80] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg *et al.*, “The FAIR guiding principles for scientific data management and stewardship,” *Scientific Data*, vol. 3, p. 160018, 2016. [Online]. Available: <https://www.nature.com/articles/sdata201618>
- [81] yt-dlp contributors, “yt-dlp: A feature-rich command-line audio/video downloader,” GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/yt-dlp/yt-dlp>
- [82] J. Depoix and contributors, “YouTube Transcript API: Python api for retrieving youtube transcripts and subtitles,” GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/jdepoix/youtube-transcript-api>
- [83] Unicode Consortium, “Unicode normalization forms,” Unicode Consortium, Unicode Standard Annex #15 Revision 57, Jul. 2025, ed. Ken Whistler; Unicode 17.0.0; Jul. 30, 2025. [Online]. Available: <https://www.unicode.org/reports/tr15/tr15-57.html>
- [84] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, “Scikit-learn: Machine learning in python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- [85] A. Paszke, S. Gross, F. Massa *et al.*, “PyTorch: An imperative style, high-performance deep learning library,” in *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 8024–8035. [Online]. Available: <https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html>
- [86] T. Wolf, L. Debut, V. Sanh *et al.*, “Transformers: State-of-the-art natural language processing,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2020, pp. 38–45. [Online]. Available: <https://aclanthology.org/2020.emnlp-demos.6/>
- [87] I. Loshchilov and F. Hutter, “Decoupled weight decay regularization,” in *International Conference on Learning Representations*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>
- [88] PyTorch contributors, “BCEWithLogitsLoss api,” PyTorch documentation, 2026, accessed Jul. 29, 2026. [Online]. Available: <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>
- [89] L. Prechelt, “Early stopping—but when?” in *Neural Networks: Tricks of the Trade*, ser. Lecture Notes in Computer Science, G. B. Orr and K.-R. Müller, Eds. Berlin, Heidelberg: Springer, 1998, vol. 1524, pp. 55–69. [Online]. Available: https://doi.org/10.1007/3-540-49430-8_3
- [90] scikit-learn developers, “scikit-learn GroupKFold api,” scikit-learn API Reference, 2026, accessed Jul. 29, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html
- [91] K. H. Brodersen, C. S. Ong, K. E. Stephan *et al.*, “The balanced accuracy and its posterior distribution,” in *2010 20th International Conference on Pattern Recognition*. IEEE, 2010, pp. 3121–3124.
- [92] L. Lam and C. Y. Suen, “Application of majority voting to pattern recognition: An analysis of its behavior and performance,” *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997.
- [93] B. Efron, “Bootstrap methods: Another look at the jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- [94] C. A. Field and A. H. Welsh, “Bootstrapping clustered data,” *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.
- [95] S. Holm, “A simple sequentially rejective multiple test procedure,” *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.
- [96] R. Artstein and M. Poesio, “Inter-coder agreement for computational linguistics,” *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.
- [97] J. G. Moreno-Torres, T. Raeder, R. Alaiz-Rodríguez *et al.*, “A unifying view on dataset shift in classification,” *Pattern Recognition*, vol. 45, no. 1, pp. 521–530, 2012.
- [98] R. Dror, G. Baumer, S. Shlomov *et al.*, “The hitchhiker’s guide to testing statistical significance in natural language processing,” in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>
- [99] a. s. franzke, A. Bechmann, M. Zimmer *et al.*, “Internet research: Ethical guidelines 3.0,” Association of Internet Researchers, Tech. Rep., 2020, approved by the AoIR membership Oct. 6, 2019. [Online]. Available: <https://aoir.org/reports/ethics3.pdf>
- [100] YouTube, “Terms of service,” YouTube official terms, Nov. 2023, effective Nov. 6, 2023; accessed Jul. 29, 2026. [Online]. Available: <https://www.youtube.com/t/terms>