

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora, Alex Felipe Mancilla Antay,
Herbert Antonio Meléndez García y Dennis Jack Paitán Cano
Maestría en Inteligencia Artificial, Universidad Nacional de Ingeniería

Curso de Procesamiento de Lenguaje Natural, Grupo 4, semestre académico 2026–1
Lima, Perú

luis.koc@gmail.com amancillaa@uni.pe
hamg.94@gmail.com dennis.paitan.c@uni.pe

Resumen—La revisión manual de videos extensos dificulta localizar lenguaje dañino cuando los subtítulos contienen modismos, ironía, ruido y categorías poco frecuentes. Este trabajo diseña y evalúa, mediante ciencia del diseño, un moderador semiautomático para videos peruanos de YouTube. Produce alertas ligadas a intervalos temporales y conserva la decisión final en una persona supervisora. El corpus usado contiene 173 240 chunks elegibles de 4 906 videos peruanos de YouTube, con cinco salidas aprendidas: SEGURO y cuatro daños multietiqueta; 14 163 chunks presentan al menos un daño. La comparación reúne 16 modelos clásicos, seis Transformers compactos y seis variantes basadas en Qwen, además de cinco reglas base de ensemble y dos ensembles optimizados. Las siete variantes de ensemble se reevalúan sobre 10 600 filas del conjunto de validación mediante un protocolo anidado y agrupado por video. El criterio predeclarado usa como métrica primaria la exactitud balanceada (BA) de cualquier daño, protege el desempeño por categoría mediante el área macro bajo la curva de precisión-recobrado (macro-AUPRC) y selecciona un ensemble convexo de regresión logística, cascada E5 y Qwen3–0.6B adaptado mediante adaptación de bajo rango (LoRA), con pesos optimizados de 0,10/0,65/0,25. En validación anidada, el ensemble obtiene BA 0,837, macro-AUPRC 0,551 y macro-F1 0,562. La fórmula se aplicó a las puntuaciones verificadas de la única apertura del test natural (22 684 chunks; 7,9 % con daño) y alcanzó BA 0,846 y sensibilidad 0,894. La política selectiva deriva 27,3 % a revisión y, sobre el 72,7 % automático, obtiene BA 0,925. El sistema ofrece desempeño competitivo y trazable para priorización; la evidencia no autoriza bloqueo o sanción automáticos.

Index Terms—moderación semiautomática, procesamiento del lenguaje natural, lenguaje dañino, clasificación multietiqueta, YouTube, Qwen, ensemble optimizado, calibración probabilística, clasificación selectiva

video, además, una alerta útil debe conservar el fragmento y el instante que la originan.

El problema se intensifica en subtítulos peruanos por modismos, ironía, citas, errores de transcripción y clases poco frecuentes. Estas dificultades también aparecen en pruebas funcionales de odio, estudios de sesgo lingüístico y análisis de subtítulos automáticos [3]–[5]. Una solución técnicamente correcta debe evitar la fuga entre fragmentos del mismo video, usar métricas apropiadas para el desbalance, separar selección de evaluación y declarar el trabajo remanente que requiere la acción de la persona supervisora.

Este estudio diseña, compara y empaqueta un moderador textual semiautomático mediante ciencia del diseño (DSR) [6], [7]. La Fig. 1 organiza el problema en tres niveles: la revisión completa es inviable en el nivel observable; el desbalance, la ambigüedad y la procedencia heterogénea actúan en el nivel subyacente; y el nivel modelado requiere clasificación multietiqueta, calibración, abstención y trazabilidad.

El trabajo entrega un corpus de 173 240 chunks y 4 906 videos, con cinco salidas aprendidas y separación por video. Sobre ese corpus compara 28 candidatos individuales de tres familias —modelos clásicos, Transformers y modelos grandes de lenguaje (LLM)—, cinco reglas base de ensemble y dos ensembles optimizados mediante predicciones fuera de pliegue. El artefacto final integra regresión logística, una cascada E5 segura y Qwen3–LoRA con pesos aprendidos; la fórmula congelada se aplica sin reajuste a las matrices de la única apertura de 22 684 chunks de test. El cuarto aporte es una política de revisión que informa cobertura, errores y carga humana, junto con evidencia temporal y un registro de correcciones.

I. INTRODUCCIÓN

La moderación de contenido no se reduce a asignar una etiqueta, también decide qué material se revisa primero, qué evidencia recibe la persona moderadora y qué errores quedan fuera de observación. A escala de plataforma, estas decisiones combinan reglas, trabajo humano y sistemas automáticos, con exigencias de contexto, transparencia y responsabilidad [1]. Los sistemas semiautomáticos pueden concentrar la revisión en casos dañinos o inciertos [2]; en

II. BASES TEÓRICAS Y ANTECEDENTES

II-A. Moderación, datos y contexto

La moderación de una plataforma combina reglas, trabajo humano y sistemas automáticos. La predicción de un modelo no resuelve por sí sola la política, la interpretación ni la responsabilidad de una decisión [1]. La calidad de un clasificador de lenguaje abusivo depende de cómo se define el daño, cómo se toma la muestra y quién asigna las etiquetas; los errores de esas etapas pueden




Figura 1. Problema estudiado en tres niveles. El estado deseado es priorizar evidencia para una decisión humana informada, no sancionar automáticamente. Fuente: elaboración propia.

pasar al modelo [8]. Los *data statements* y las *data cards* proponen documentar el origen, el idioma, la recolección, el etiquetado, los usos previstos y los límites de un conjunto de datos [9], [10].

II-B. Enfoques de solución y trabajos comparables

El estado del arte resuelve la detección de lenguaje dañino como una cadena y no como la elección aislada de un algoritmo. Primero delimita corpus, población, taxonomía y procedimiento de etiquetado; después representa el texto mediante rasgos léxicos o modelos contextuales; combina clasificadores cuando sus errores son complementarios; evalúa con métricas sensibles al desbalance y pruebas por fenómeno de daño o seguro; y deriva los casos inciertos a revisión humana [3], [8], [9], [11]–[14]. Esta secuencia organiza el diseño del presente trabajo mediante datos locales documentados, tres familias de modelos —clásicos, Transformers y LLM—, ensembles de sus mejores representantes, test con prevalencia explícita y supervisión humana.

Los corpus previos muestran distintas formas de construir la tarea. Wulczyn *et al.* estudian ataques personales a gran escala [15]; HateXplain añade el blanco del abuso y explicaciones humanas [16]; y HateCheck muestra que una métrica agregada puede ocultar fallas funcionales [3]. La literatura también advierte que las marcas de identidad o las variedades lingüísticas pueden confundirse con toxicidad [4]. En YouTube, Bertaglia *et al.* analizan lenguaje abusivo en comentarios en inglés [17]; este estudio usa, en cambio, habla transcrita en español y conserva el intervalo temporal de cada evidencia.

La Tabla I ubica seis antecedentes empleados para interpretar el resultado final. Sus cifras no forman una clasificación común; pues cambian la unidad de análisis, el idioma, el muestreo, la prevalencia, las categorías y la partición. Ninguno de estos datos o modelos interviene en el entrenamiento del proyecto.

NaijaHate evidencia que el desempeño aparente y la carga de revisión pueden cambiar entre muestras representativas y enriquecidas [22]. En este proyecto, el resultado principal corresponde al test con prevalencia natural del corpus. La vista secundaria 4:1 usa las mismas predicciones y solo sirve para contextualizar trabajos con muestras enriquecidas.

II-C. Taxonomía de daño y adaptación peruana

Para ordenar el espacio de daño se parte de dos distinciones académicas. Waseem *et al.* separan el abuso dirigido a una persona o entidad del dirigido a un grupo, y el abuso explícito del implícito [23]. Banko *et al.* recomiendan categorías finas, criterios de inclusión y excepciones; su tipología distingue, entre otros, ataque por identidad, insulto, doxeo, agresión sexual y amenaza de violencia

[24]. El proyecto combina estas distinciones generales con antecedentes sociales e institucionales pertinentes al contexto peruano.

II-C1. Aportes para la adaptación al contexto peruano:

Para racismo y discriminación, Juan Carlos Callirgos examinó la construcción del otro en el racismo peruano, y Gonzalo Portocarrero relacionó racismo y mestizaje con prácticas e imaginarios sociales [25], [26]. Víctor Vich sintetizó la propuesta de Portocarrero mediante el fundamento invisible, el fantasma del patrón y la utopía del blanqueamiento, tres formas de explicar cómo la jerarquización persiste y cambia en el Perú [27]. Virginia Zavala y Roberto Zariquiey estudiaron la segregación discursiva justificada mediante supuestas carencias de educación o cultura, mientras el volumen editado por Virginia Zavala y Michele Back reunió análisis sobre los vínculos entre racismo y lenguaje [28], [29]. En espacios políticos y digitales, Virginia Zavala y Claudia Almeida mostraron que “motoso” y “terruco” pueden racializar y silenciar a actores políticos; Roberto Brañez Medina documentó el uso de la ortografía para construir las identidades “amixer” y “no-amixer” y justificar racismo cultural; y Verónica Salem describió cómo el insulto, la parodia, la ironía y el humor reproducen estereotipos raciales en Facebook [30]–[32]. Estos aportes orientaron las distinciones entre racismo étnico explícito, racialización lingüística, clasismo racial, discriminación regional y racismo encubierto.

Para asuntos de género, Francisco Rodríguez-Sánchez y coautores aportan el esquema computacional de EXIST para identificar sexismo en redes, y Philine Zeinert, Nanna Inie y Leon Derczynski proponen criterios de etiquetado de misoginia en línea [21], [33]. Christian Monge-Olivarria, Juan Guerra-Corrales y Fernando Bringas-Castro analizan la feminización como insulto y formas de acoso directo, invasión de privacidad y exclusión en Twitter; su estudio aporta mecanismos generales de violencia digital que complementan las fuentes locales [34]. En el ámbito peruano, Denisse Albornoz y Marieliv Flores caracterizan modalidades, consecuencias y respuestas frente a la violencia de género en línea, y la Defensoría del Pueblo del Perú sistematiza su tipología, impactos y vías institucionales de atención [35], [36]. Estas fuentes orientan misoginia/acoso de género y, junto con la tipología general, las distinciones sexuales explícitas, de cosificación y no consentidas.

Para orientación sexual e identidad de género, Bharathi Raja Chakravarthi construyó un corpus multilingüe de comentarios de YouTube y referencias de clasificación para homofobia y transfobia [37]. En Lima, Jan Marc Rottenbacher de Rojas relacionó conservadurismo e intolerancia a la ambigüedad con homofobia y prejuicio hacia grupos transgénero en una muestra universitaria [38]. Carolina

Tabla I
TRABAJOS RELACIONADOS, ÁMBITO DE APLICACIÓN Y RELACIÓN CON EL ESTUDIO. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LAS PUBLICACIONES CITADAS EN CADA FILA.

Trabajo	País o ámbito	Datos, tarea y resultado publicado	Semejanza y diferencia principal
DETOXIS [18]	España; español	4359 comentarios a noticias sobre inmigración; detección binaria de toxicidad; mejor F1 de 0,6461.	Coincide en idioma y daño textual. Cambian la unidad, el dominio temático y el contrato binario.
HatEval [19]	Tarea internacional; Twitter en español e inglés	Odio contra mujeres e inmigrantes, con rasgos de agresividad y blanco; mejor macro-F1 en español de 0,730.	Comparte categorías de racismo y género, pero usa mensajes breves y muestreo dirigido al blanco.
OffendES [20]	España; español	47 128 comentarios de YouTube, Instagram y Twitter alrededor de influenciadores jóvenes; macro-F1 binario de 0,7839.	Es el antecedente más próximo por YouTube y español; clasifica comentarios escritos, no habla transcrita ni evidencia temporal.
EXIST [21]	Tarea internacional; español e inglés	Más de 11 000 textos de Twitter y Gab; identificación y categorización de sexismo; mejor F1 español de 0,7944.	Se aproxima a género/identidad y emplea supervisión experta; no cubre los otros tres daños del proyecto.
HateXplain [16]	Twitter y Gab en inglés; autores de India y Alemania	Cerca de 20 mil publicaciones con tres clases, blanco y racionales humanos; macro-F1 de 0,687 para su modelo contextual.	Comparte la necesidad de ligar decisión y evidencia; usa racionales por token, no intervalos de video ni español peruano.
NaijaHate [22]	Nigeria; Twitter	35 976 tuits y una muestra representativa; precisión promedio (AP) cercana a 0,34 en la muestra aleatoria frente a 0,83–0,90 en conjuntos enriquecidos.	Comparte la preocupación por dominio local y prevalencia; país, idioma, etiqueta y diseño muestral impiden comparar AP de forma directa.

Mirian Lovón-Cueva y Marco Lovón-Cueva identificaron en ciberforos peruanos un repertorio de lexemas lesbofóbicos y los interpretaron como violencia simbólica y actos de lenguaje de odio [39]. Estas fuentes ofrecen un primer acercamiento al tratamiento del odio y la discriminación en entornos peruanos desde los estudios culturales, la sociolingüística, la psicología social, los estudios de género y la documentación institucional [29], [30], [35], [36], [38], [39]. A su vez, fueron usadas para orientar los criterios de inclusión, exclusión y revisión; la cobertura exacta y los nombres finales de las etiquetas de daño son una adaptación operacional del proyecto.

El odio implícito puede expresarse con lenguaje indirecto o codificado [40]; ironía y sarcasmo plantean una tarea específica de interpretación [41]. Estudios peruanos muestran que el insulto, la parodia, la ironía y el humor *amixer* [32], así como la información contextual [42], forman parte de la construcción de estereotipos. Estos antecedentes motivan tres señales de revisión, distintas de las categorías de moderación.

Para contenido sexual, la tipología académica y las fuentes peruanas respaldan separar agresión sexual y difusión íntima no consentida [24], [35], [36]; la política de YouTube aporta la frontera operativa entre contenido explícito, sexualización no consentida y excepciones informativas o documentales [43]. Con este sustento se formuló una primera taxonomía operacional, que aún requiere validación experta.

II-D. Modelos de texto y aprendizaje multietiqueta

II-D1. Modelos clásicos: La frecuencia de término-frecuencia inversa de documento (TF-IDF) representa cada trozo de texto mediante la frecuencia de sus términos y reduce el peso de los que aparecen en muchos documentos [11], [44]. Es rápida y conserva vocabulario visible, pero produce vectores dispersos y no modela el contexto. Sobre esos rasgos, la regresión logística estima una probabilidad mediante una frontera lineal; es eficiente y sus coeficientes son interpretables, aunque no capta relaciones no lineales sin crear nuevos rasgos [45]. La máquina de vectores de

soporte (SVM) busca un margen amplio entre clases y suele funcionar bien con textos dispersos de alta dimensión; su salida no es una probabilidad y requiere calibración para interpretar el score [46]. Complement Naive Bayes corrige los conteos con información de las clases complementarias, lo que favorece datos textuales desbalanceados; su bajo costo se obtiene a cambio de una fuerte hipótesis de independencia entre rasgos [47].

La descomposición en valores singulares (SVD) proyecta TF-IDF a un espacio latente más pequeño [48]. Sobre esa proyección, *gradient boosting* combina árboles que corrigen errores sucesivos y puede modelar interacciones no lineales, pero aumenta el ajuste y pierde parte del detalle léxico [49]. *fastText* promedia representaciones de palabras y subpalabras antes de aplicar un clasificador lineal; las subpalabras ayudan ante variantes morfológicas y términos poco frecuentes, pero el promedio conserva poco orden y contexto distante [50].

II-D2. Transformers compactos: Los Transformers usan atención para representar cada token según los demás tokens del fragmento [12]; el modelo *Bidirectional Encoder Representations from Transformers* (BERT) establece el ajuste bidireccional de un modelo preentrenado para una tarea concreta [51]. Sentence-BERT obtiene un vector de oración que permite comparar y clasificar textos con menor costo que procesar cada par por separado [52]. MiniLM destila relaciones de autoatención de una red mayor y ofrece un codificador compacto [53]. El checkpoint multilingüe **sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2** transfiere ese espacio entre idiomas [54], [55]. Su ventaja es el equilibrio entre contexto y costo; sus límites son la longitud finita de entrada y la pérdida de información al resumir el fragmento en un vector.

E5 aprende representaciones con contraste débilmente supervisado y separa consultas y textos mediante prefijos [56]. Su extensión multilingüe respalda **intfloat/multilingual-e5-small** y el prefijo **query**: usado en el proyecto [57], [58]. El entrenamiento contrastivo favorece similitud semántica con un tamaño moderado, pero el resultado depende del formato de entrada y el vector agrupado

también actúa como cuello de botella.

II-D3. LLM Qwen3 con adaptación LoRA: Qwen3 es una familia de modelos de lenguaje autorregresivos con versiones densas y de mezcla de expertos, preentrenadas en varios idiomas [59]. El estudio usa el checkpoint denso **Qwen/Qwen3-0.6B-Base** por su escala, licencia e integración con Transformers [60]. Una cabeza multietiqueta convierte la representación final en scores de las categorías. LoRA introduce matrices de bajo rango en capas seleccionadas y permite ajustar una fracción pequeña de los parámetros [61]. Esta combinación ofrece más capacidad contextual que los modelos compactos, pero exige más memoria y tiempo, y sus scores todavía requieren calibración. *Qwen3-LoRA* designa este clasificador ajustado, no un sinónimo genérico de LLM.

El diseño experimental integra estas representaciones con las estructuras planas, en cascada y jerárquicas descritas en la metodología.

Un fragmento puede activar varias categorías de moderación, por lo que la tarea es multietiqueta [62], [63]. Las jerarquías pueden representar una puerta general y clases hijas [64]; los modelos conscientes de jerarquía motivan explotar dependencias entre etiquetas [65].

II-E. Selección, calibración y abstención

Precisión, recobrado y F1 resumen aspectos distintos de una matriz de confusión; una sola métrica es insuficiente para todos los tipos de clasificación [66]. En datos desbalanceados, las curvas precisión-recobrado describen la clase positiva de forma más informativa que las curvas de característica operativa del receptor (ROC) [67], [68]. La implementación calcula la precisión promedio como $AP = \sum_n (R_n - R_{n-1})P_n$, donde P_n y R_n corresponden al umbral n [69]. Las salidas se calibran por etiqueta con regresión sigmoide [70], [71]; la calibración de redes modernas requiere comprobación empírica [72]. Por ello, la regla de selección y los umbrales usan el conjunto de validación para limitar el sesgo de selección [73], y el protocolo congela la selección, la calibración y los umbrales antes de correr los modelos con los datos de test.

Una clasificación selectiva puede abstenerse en casos dudosos [74], [75]; por ejemplo, el aprendizaje con derivación extiende esa idea al decidir cuándo entregar el caso a una persona experta [14]. En la política del proyecto, el recobrado de enrutamiento es la fracción de chunks dañinos enviados a alerta o revisión; la precisión es la fracción dañina entre los enviados; la tasa de revisión es la fracción total enviada; y el valor predictivo negativo es la fracción realmente segura entre los casos que permanecen en la ruta automática. El análisis también cuenta los falsos negativos. Estas definiciones se aplican al enrutamiento, no sustituyen las métricas por categoría ni la decisión del supervisor [66].

II-F. Ontología y trazabilidad terminológica

Una ontología explícita conceptos compartidos y sus relaciones [76]; el lenguaje de ontologías web 2 (OWL 2) formaliza clases, propiedades e individuos [77], y el sistema simple de organización del conocimiento (SKOS) asocia términos y definiciones controladas [78]. En el vocabulario del proyecto, el *video fuente* es la unidad pública; la

pista de subtítulos, su transcripción temporal; el *chunk de evidencia*, un intervalo textual con video y marcas de tiempo; y el *etiquetado*, la referencia asignada al chunk. Una *categoría operativa* es una salida multietiqueta entrenable; un *fenómeno fino* o *señal de revisión* es un subtipo de auditoría, no otra salida. *SEGURO* se deriva cuando el texto no activa un daño y no certifica el video completo. Estas definiciones operativas siguen prácticas de documentación y taxonomía [9], [10], [24].

La *predicción* reúne los scores de un modelo versionado; la *alerta* supera un umbral o activa revisión; la *decisión humana* acepta, modifica o rechaza la alerta; y la *retroalimentación* o *registro reentrenable* conserva evidencia, predicción y decisión para una iteración futura. El *artefacto de datos* enlaza chunks, fuente, intervalo y partición; el *artefacto de modelo*, arquitectura, pesos, calibradores, umbrales y linaje. Son definiciones propuestas por el trabajo, no categorías jurídicas, y separan automatización y responsabilidad humana [1], [14]. La representación legible por máquina aplica parcialmente los principios de datos localizables, accesibles, interoperables y reutilizables (FAIR) [79]. El Apéndice C presenta el grafo.

III. PROBLEMAS Y OBJETIVOS

El problema general es la ausencia de una cadena local, reproducible y evaluada que transforme subtítulos públicos en alertas temporales comparables y, después, en una decisión humana informada. El objetivo general consiste en construir y evaluar esa cadena con datos peruanos, modelos de distintas familias, una regla de selección predeclarada y una interfaz de operación supervisada.

La primera brecha es la falta de un corpus local versionado que conserve texto, intervalo, fuente, etiqueta y procedencia. La definición, el muestreo y el etiquetado condicionan los clasificadores de lenguaje abusivo [8]; los *data statements* y *data cards* recomiendan documentar la recolección, el etiquetado, los usos y los límites [9], [10]. De esta brecha se deriva el objetivo de construir y auditar el corpus de datos con particiones agrupadas por video.

La segunda brecha es la ausencia de una comparación común entre modelos clásicos, Transformers y Qwen. En datos desbalanceados, los promedios pueden ocultar la clase positiva y las curvas precisión-recobrado resultan especialmente informativas [66], [67]. El objetivo correspondiente es comparar todas las familias bajo la misma validación, con la exactitud balanceada de cualquier daño como criterio primario y la macro-AUPRC de daños como salvaguarda.

La tercera brecha aparece cuando el sistema debe emitir una decisión incluso si el caso es incierto, pues así se ocultan tanto la duda como la carga humana. La clasificación selectiva permite abstenerse, y el aprendizaje para diferir extiende esa decisión al envío a una persona experta [14], [74], [75]. El objetivo es congelar calibradores, umbrales y una política **NEEDS_REVIEW** bajo una capacidad declarada antes de abrir el test.

La última brecha es el aislamiento entre los datos, los pesos, las predicciones y la operación. La metodología DSR exige demostrar y evaluar el artefacto construido [6], [7]; en moderación, la automatización no sustituye el gobierno ni la responsabilidad humana [1]. El objetivo es integrar los

ganadores de las tres familias en un ensemble que mantenga la evidencia temporal, la revisión y un registro trazable. La Tabla II relaciona las cuatro brechas con el método y con la evidencia usada para examinarlas.

IV. METODOLOGÍA

IV-A. Diseño de investigación

La investigación sigue la metodología DSR: identifica una necesidad, define objetivos, construye el artefacto, lo demuestra, lo evalúa y comunica los resultados [6], [7]. Cada iteración produjo evidencia versionada de datos, etiquetas, modelos y operación. La Fig. 2 resume las iteraciones que conducen desde el corpus hasta la evaluación y el demostrador vigentes.

IV-B. Adquisición, limpieza y unidad de análisis

El universo de adquisición comprende videos públicos de YouTube vinculados con el Perú y con subtítulos disponibles en español. La búsqueda incluye periodismo, política, opinión, humor, entretenimiento, deportes, gastronomía y viajes, además de consultas dirigidas para aumentar categorías poco frecuentes. Antes de las exclusiones se reunieron 182 461 chunks, 5 385 videos y 322 canales. El corpus permite entrenar y comparar modelos, pero no estima la prevalencia de daño en toda la plataforma. La documentación del origen, el etiquetado y los límites sigue las recomendaciones de *data statements* y *data cards* [9], [10].

Los subtítulos en formato WebVTT (VTT) se recuperan con la librería *yt-dlp* de Python o con la librería *youtube-transcript-api* de Python [80], [81]. No se descarga audio ni se ejecuta reconocimiento de voz propio. La limpieza usa la librería *unicodedata* de Python para aplicar la forma de normalización de compatibilidad canónica (NFKC) definida por Unicode [82], [83]; además, unifica espacios y elimina repeticiones consecutivas del VTT. La unidad de análisis es el texto troceado o chunk: texto contiguo con *video_id*, tiempos inicial/final, posición, canal y procedencia. La segmentación se cierra al alcanzar 30 segundos o 600 caracteres y exige al menos 90 caracteres; no introduce solapamiento deliberado. La Fig. 3 muestra la transformación y los controles que separan datos, particiones, selección y test.

El tamaño temporal se selecciona en un ejercicio independiente con los mismos videos de referencia y ventanas de 15, 20, 25, 30 y 35 segundos. Los modelos se vuelven a entrenar y la decisión usa solo el conjunto de validación; 1 000 réplicas pareadas por video cuantifican la incertidumbre. La ventana de 30 segundos alcanza AP macro de daño de 0,12, con un intervalo de confianza del 95 % (IC95 %) de [0,11, 0,14], en el perfil clásico robusto y queda congelada antes de consultar el conjunto de test. Las comprobaciones con MiniLM y un modelo generativo no aportan evidencia suficiente para sustituirla. Esta elección conserva más contexto que las ventanas cortas sin asumir que una duración observada es óptima fuera del corpus [67], [73].

La construcción enfrenta tres dificultades principales: disponibilidad cambiante o incompleta de subtítulos; concentración por canal y búsquedas dirigidas que impiden interpretar el corpus como muestra probabilística;

y modismos, ironía, humor, contexto truncado y daños coexistentes que vuelven insuficiente la coincidencia de palabras. La materialización de las transcripciones, las exclusiones trazables, la separación por video, las señales de revisión y la conservación del texto con sus tiempos controlan estos riesgos sin eliminarlos.

IV-C. Corpus del proyecto

Después de deduplicar y excluir 9 221 decisiones no elegibles (5,1 % del alcance), el corpus final contiene 173 240 chunks de 4 906 videos y 276 canales efectivos. Hay 159 077 chunks **SEGURO** (92 %) y 14 163 con al menos un daño (8,2 %), una relación de 11:1; estos últimos reúnen 17 052 asignaciones y 2 709 casos multietiqueta. La Tabla III muestra la distribución operacional.

La distribución por fuente presenta una cola larga. Cada video aporta en promedio 35 chunks, con una mediana de 19 y un máximo de 767; por canal, el promedio es 630, la mediana 26 y el máximo 33 203. La distancia entre las medias y las medianas revela concentración. Por esa razón, la Tabla IV informa los canales principales, y una evaluación futura deberá medir la generalización hacia canales no observados.

IV-D. Taxonomía y contrato de salida

El contrato contiene cinco salidas principales: **SEGURO**, **RACISMO**, **ATAQUE-G/I**, **ACOSO-AMENAZA** y **SEXUAL**. La primera es mutuamente excluyente con cualquier daño; las cuatro restantes pueden coexistir. Una salida vacía, la coexistencia seguro-daño o un score próximo al umbral activa revisión y no crea una sexta clase. Catorce etiquetas finas y tres flags de ironía, humor o contexto preservan detalle para auditoría y objetivos auxiliares.


Las dimensiones generales se apoyan en tipologías de abuso y contenido dañino de Waseem *et al.* y Banko *et al.* [23], [24]. La adaptación al contexto peruano incorpora los antecedentes de la Tabla V. Las fuentes sustentan fenómenos y exclusiones; los nombres, fusiones y reglas finales son decisiones operativas del proyecto y no se atribuyen como taxonomía exacta a esos autores.

IV-E. Etiquetado y control de calidad

El preetiquetado combina definiciones controladas, salida en notación de objetos de JavaScript (JSON) validable y revisión por etapas. DeepSeek Flash realizó la primera propuesta y DeepSeek Pro atendió la revisión dirigida mediante la interfaz de programación de aplicaciones (API) del proveedor, con salida estructurada y razonamiento desactivado [84]–[86]. El cliente local se ejecutó en un equipo GMKtec NucBox K8 Plus con procesador AMD Ryzen 7 8845HS, 28,8 GiB de memoria y sin usar la unidad de procesamiento gráfico (GPU) Radeon integrada; el proveedor no expuso el acelerador remoto. La cola final permite aceptar, rechazar o modificar cada propuesta. El historial conserva 55 966 eventos. Un panel estratificado congelado contiene 16 694 chunks y la huella combinada de auditoría alcanza 17 635 chunks únicos (10 % del universo elegible). Estas cifras representan decisiones asistidas y trazables; no equivalen a doble etiquetado humano independiente ni autorizan reportar un acuerdo general entre etiquetadores.

Tabla II
RELACIÓN ENTRE PROBLEMAS, OBJETIVOS Y EVIDENCIA VIGENTE. FUENTE: ELABORACIÓN PROPIA.

	Problema específico	Objetivo específico	Evidencia de verificación
P1/O1	Datos locales dispersos y riesgo de fuga entre fragmentos.	Construir y documentar el corpus final.	173 240 chunks, 4 906 videos, cinco salidas y partición agrupada.
P2/O2	Resultados no comparables entre familias.	Comparar candidatos bajo un protocolo común.	28 individuos + 5 reglas base + 2 ensembles optimizados; validación anidada por video.
P3/O3	Decisiones forzadas sin carga humana explícita.	Calibrar, congelar y evaluar una política selectiva.	Test abierto una vez; 72,7 % automático y 27,3 % a revisión.
P4/O4	Modelos y evidencia aislados de la operación.	Integrar ganadores, ensemble, tiempos y correcciones.	Registro congelado, frontend de producción y artefactos versionados.



Las iteraciones anteriores informan el diseño; solo los artefactos finales sustentan los resultados vigentes.

Figura 2. Ciclo DSR aplicado al corpus, comparación común, congelación, apertura única de test y demostrador. Fuente: elaboración propia basada en Peffers *et al.* [7].




Figura 3. Flujo vigente de datos, etiquetado, entrenamiento, selección y operación. El test permanece sellado hasta congelar candidato, calibradores, umbrales y política. Fuente: elaboración propia.

Tabla III
TAMAÑO Y DISTRIBUCIÓN DEL CORPUS DEL PROYECTO. FUENTE: ELABORACIÓN PROPIA.

Componente	Total
Videos / canales efectivos	4 906 / 276
Chunks elegibles	173 240
SEGURO	159 077
Algún daño	14 163
RACISMO	2 570
ATAQUE-G/I	2 331
ACOSO-AMENAZA	8 276
SEXUAL	3 875
Chunks con más de un daño	2 709

Nota: los cuatro daños son multietiqueta y no suman “algún daño”. SEGURO es excluyente.

La precedencia es revisión final asistida sobre las propuestas anteriores. Los casos sin resolución suficiente se excluyen del entrenamiento. Las etiquetas finas y flags actúan como objetivos auxiliares en modelos que los soportan; nunca se

Tabla IV
CANALES CON MAYOR NÚMERO DE CHUNKS ELEGIBLES Y CONCENTRACIÓN ACUMULADA. FUENTE: ELABORACIÓN PROPIA.

Canal o grupo	Chunks	Fracción
Hablando Huevadas	33 203	19 %
Arde Troya con Juliana Oxenford	12 295	7,1 %
Nunca MAS	11 364	6,6 %
Goblinciano	8 166	4,7 %
Nada Espacial	6 224	3,6 %
Primeros cinco	71 252	41 %
Primeros diez	96 845	56 %

entregan como predictores *gold* durante la inferencia.

IV-F. Partición y muestras de entrenamiento

La separación se realiza por `video_id`; ningún video cruza los conjuntos de entrenamiento, validación y test. El corpus conserva la prevalencia de cada partición (Tabla VI). Para el ajuste y la comparación se mantienen todos los daños y se seleccionan cuatro seguros por cada chunk

Tabla V

DEFINICIÓN Y SUSTENTO DE LA TAXONOMÍA OPERATIVA. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LAS REFERENCIAS CITADAS POR SALIDA; NOMBRES, FUSIONES Y REGLAS SON ADAPTACIÓN DEL PROYECTO.

Salida	Definición operacional	Autores y fuentes utilizados
SEGURO	Ausencia de evidencia suficiente para los cuatro daños. Es una salida aprendida y exclusiva; ambigüedad o conflicto obliga revisión.	Regla operacional del proyecto, diferenciada de las dimensiones dañinas de Waseem <i>et al.</i> y Banko <i>et al.</i> [23], [24].
Racismo	Ataque o inferiorización por identidad étnico-racial, origen regional, variedad lingüística o clase racializada; una mención identitaria no basta.	Callirgos; Zavala y Zariquiey; Zavala y Back; Brañez; Almeida y Zavala; Salem; Vich [25], [27]–[32].
Ataque-G/I	Ataque, exclusión o degradación por género, orientación, identidad o expresión; puede coexistir con acoso.	Rodríguez-Sánchez <i>et al.</i> ; Zeinert, Inie y Derczynski; Albornoz y Flores; Defensoría del Pueblo; Chakravarthi <i>et al.</i> ; Rottenbacher; Lovón-Cueva y Lovón-Cueva [21], [33], [35]–[39].
Acoso-Amenaza	Hostigamiento o ataque dirigido a una persona identificable, exposición privada o amenaza de daño. La unión conserva subtipos finos.	Waseem <i>et al.</i> ; Wulczyn, Thain y Dixon; Banko <i>et al.</i> ; Defensoría del Pueblo [15], [23], [24], [36].
Sexual	Descripción sexual gráfica sin fin informativo, cosificación o referencia a material íntimo no consentido; el sistema observa texto, no imagen.	Banko <i>et al.</i> ; Zeinert, Inie y Derczynski; Albornoz y Flores; Defensoría del Pueblo; política de YouTube [24], [33], [35], [36], [43].

Tabla VI

PARTICIÓN NATURAL DEL CORPUS POR VIDEO. FUENTE: ELABORACIÓN PROPIA.

Partición	Chunks	Videos	Daño	Seguro
Entrenamiento	123 239	3 478	10 241	112 998
Conjunto de validación	27 317	754	2 120	25 197
Test	22 684	674	1 802	20 882

daño mediante hash y semilla declarada. Así, el conjunto de entrenamiento usa 51 205 filas (10 241 daños + 40 964 seguros) y el conjunto de validación, 10 600 (2 120 + 8 480). El test permanece completo y sellado con 22 684 filas. Tras una sola inferencia se produce también una vista secundaria 4:1, sin reabrir test.

IV-G. Familias de modelos

La comparación incluye 28 candidatos individuales de tres familias, cinco reglas base de ensemble y dos variantes optimizadas. Cada candidato produce cinco scores principales. Cuando la arquitectura lo permite, también genera 14 etiquetas finas y tres flags, para un total de 22 logits con pérdidas enmascaradas. La implementación usa la librería scikit-learn de Python para los modelos clásicos [87], y las librerías PyTorch y Transformers de Python para las redes [88], [89]. La Fig. 4 contrasta los mecanismos de las tres familias y muestra cómo se integran en el ensemble.

IV-G1. Modelos clásicos: La vista base concatena TF-IDF de palabras (1–2 gramas) y caracteres internos (3–5 gramas), siguiendo la ponderación de frecuencia inversa de documento [11]. Una transformación uno-contra-resto enmascarada entrena cabezas con *Dummy*, Complement Naive Bayes, regresión logística, SVM lineal calibrada o descenso de gradiente estocástico (SGD) logístico [45]–[47]. Una vista adicional incorpora indicadores léxicos auditables derivados de la política de etiquetado; continúa siendo aprendizaje supervisado y no *prompting*.

El mejor clásico según el ranking común es una regresión logística con $C = 0,5$. Su interés no se limita al costo: aporta una señal léxica distinta a las redes y permite inspeccionar n-gramas, por lo que resulta un miembro complementario del ensemble.

IV-G2. Transformers compactos y cascada ganadora: Los modelos planos usan `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` o `intfloat/multilingual-e5-small` [53], [55]–[58]. MiniLM tiene 12 capas, dimensión oculta 384, 12 cabezas de atención y 117 653 760 parámetros en el *backbone*; la cabeza local de 22 salidas eleva el total a 117 662 230. El candidato final procesa hasta 128 tokens y ajusta toda la red; solo el piloto previo de longitud usa el encoder congelado. Se ajusta con AdamW, entropía cruzada binaria (BCE) ponderada y parada temprana [90]–[92]. No se aplica cuantización de 4 u 8 bits: el formato bfloat16 (BF16), cuando el acelerador lo admite, es precisión mixta de cálculo y no cuantización. También se evaluaron una cascada suave, una cabeza denominada multitarea y una cascada orientada a la seguridad.

La mejor configuración Transformer es la cascada E5 segura. Una primera red E5 aprende `ANY_DAMAGE` y auxiliares; una segunda red E5 produce `SEGURO` y los cuatro daños. Sea $g(x)$ el score de daño de la compuerta y τ su umbral. La compuerta declara seguro solo cuando $g(x) < \tau$; en otro caso usa los cinco scores de la rama. En el conjunto de validación se escoge el mayor τ que cumple simultáneamente

$$\begin{aligned} \text{Recall}_{\text{daño}}(\tau) &\geq 0,99, \\ P(y = \text{SEGURO} \mid g(x) < \tau) &\geq 0,99. \end{aligned}$$

Si ningún umbral con cobertura positiva satisface ambas condiciones, todo pasa a la rama. La arquitectura separa detección amplia y tipificación, una decisión relacionada con antecedentes de clasificación jerárquica [64]. Sin embargo, ejecuta dos Transformers y puede propagar errores




Figura 4. Familias comparadas y composición del ensemble congelado. Los tres miembros conservan arquitecturas y errores diferentes. Fuente: elaboración propia.

de la compuerta; sus valores 0,99 describen el conjunto de validación y no una garantía poblacional.

IV-G3. Qwen3-LoRA: El estudio usa **Qwen/Qwen3-0.6B-Base**, un modelo causal denso multilingüe con 596 049 920 parámetros de base —0,44 mil millones sin los *embeddings*—, 28 capas, dimensión oculta 1024 y atención agrupada con 16 cabezas de consulta y ocho de clave/valor [59], [60]. LoRA congela el *backbone* e inserta matrices entrenables de bajo rango [61]. Todas las variantes LoRA colocan adaptadores en **q_proj**, **k_proj**, **v_proj** y **o_proj**, con rango 8, $\alpha = 16$ y *dropout* 0,05. La cabeza de 22 logits y los adaptadores suman 2316 288 parámetros entrenables, equivalentes a 0,39 % del clasificador completo, y el archivo local del adaptador ocupa 9,29 MB.

El entrenamiento base usa secuencias de 128 tokens, BCE ponderada por frecuencia positiva con valores recortados al intervalo [1, 20], cinco salidas principales con peso 1, 14 etiquetas finas con peso 0,3 y tres banderas con peso 0,2; las auxiliares no observadas quedan enmascaradas. El muestreo conserva una razón **SEGURO**:daño de 4:1 en el conjunto de entrenamiento (51 205 filas) y el conjunto de validación (10 600), con agrupación por video. La tasa es 10^{-4} , el lote efectivo ocho y el máximo cuatro épocas. La parada temprana con paciencia uno detuvo el ajuste tras la época 3 y restauró la época 2, que maximizó macro-AUPRC de daño. Aunque el modelo seleccionado se entrenó con 128 tokens, el evaluador y el registro de producción tokenizan hasta 256; esta diferencia se declara para no confundir longitud de entrenamiento con límite operativo.

Se probaron dos continuaciones. Primero, el adaptador base se amplió a 256 tokens, con optimizador y *scheduler* nuevos y hasta cuatro épocas adicionales. El truncamiento bajó de 56,1 % a 0,002 %; macro-AUPRC aumentó de 0,516 a 0,523 y macro-F1 de 0,553 a 0,572, pero BA descendió de 0,831 a 0,830, por lo que no ganó bajo el criterio primario. Segundo, se restauró el mismo adaptador de 128 tokens y se entrenaron tres brazos LoRA de una época, tasa 2×10^{-5} y $\lambda \in \{0; 0,02; 0,05\}$ en la penalización $\lambda p(\text{SEGURO}) \max_k p(\text{daño}_k)$. El brazo $\lambda = 0$ controla la época adicional; los otros aíslan la regularización de coherencia. El mejor estructurado fue $\lambda = 0,05$ (BA 0,819; macro-AUPRC 0,500), inferior al base. Una corrida histórica separada sí ajustó todo el *backbone*, sin LoRA, durante cuatro épocas con $\lambda = 0,2$; su macro-AUPRC

0,243 y tasa de falso seguro 0,775 motivaron descartarla del ranking definitivo.

La implementación usa LoRA estándar sin cuantización de 4 u 8 bits. En una máquina virtual de Google Colab con una unidad de procesamiento gráfico (GPU) NVIDIA A100-SXM4 de 40 GB, el entrenamiento usa precisión mixta BF16: las multiplicaciones aptas se ejecutan con números flotantes de 16 bits, mientras las operaciones y los estados sensibles conservan punto flotante de 32 bits (FP32). BF16 mantiene ocho bits de exponente, como FP32, pero reduce la mantisa; disminuye memoria y tiempo sin convertir los pesos a enteros. El adaptador publicado conserva tensores FP32. En inferencia sobre una unidad central de procesamiento (CPU), la carga estándar opera sin cuantización, salvo que un artefacto futuro la declare y la valide explícitamente. Este Qwen es un clasificador: no recibe la taxonomía Markdown ni genera JSON durante la inferencia.

Qwen3-LoRA base es el mejor candidato individual de la comparación. La continuación de 256 tokens lidera AUPRC en racismo y género/identidad, pero el base gana la familia por BA y es el miembro incorporado al ensemble. Su representación más amplia aporta contexto; la adaptación eficiente evita ajustar todos los parámetros. El costo de memoria y latencia es superior al de regresión logística y E5, razón adicional para conservar las tres familias en el artefacto.

IV-H. Calibración y predicciones fuera de pliegue

Cada candidato produce scores sobre el conjunto de validación mediante cinco pliegues **GroupKFold** por video [93]. En cada pliegue, cuatro quintos ajustan calibradores sigmoideales de Platt y umbrales; el quinto produce predicciones fuera de pliegue (OOF) [70], [71]. Así, la exactitud balanceada y la macro-AUPRC OOF no evalúan una fila con un calibrador ajustado sobre esa misma fila. Después de seleccionar, los calibradores y umbrales de despliegue se ajustan con todo el conjunto de validación y quedan congelados.

Para una categoría k , la precisión promedio resume la curva precisión-recobrado, $AP_k = \sum_n (R_n - R_{n-1}) P_n$, y el promedio macro asigna igual peso a los cuatro daños [67], [69]. La compuerta **ANY_DAMAGE** se evalúa con exactitud

balanceada (BA), media de sensibilidad y especificidad, para no favorecer la clase segura mayoritaria.

IV-I. Elección e interpretación de las métricas

Las métricas responden a decisiones distintas. La métrica principal del ranking es la BA de ANY_DAMAGE OOF a cobertura completa: mide por igual la capacidad de detectar daño y reconocer contenido seguro. Una BA de 0,84 no significa que 84% de todos los chunks sean correctos, sino que el promedio entre sensibilidad y especificidad es 0,84 [94]. La macro-AUPRC promedia sin ponderación la precisión promedio de los cuatro daños a través de los umbrales; un valor de 0,55 no es un porcentaje de aciertos y solo se compara directamente sobre el mismo panel y prevalencia. La macro-F1 promedia por daño $2PR/(P+R)$ después de fijar umbrales y describe el compromiso entre precisión y recobrado, sin usar verdaderos negativos [66].

La exactitud ordinaria y los promedios micro o ponderados no gobiernan el ranking porque la abundancia de SEGURO y de las etiquetas con mayor soporte puede ocultar omisiones en daños raros. El área bajo la curva ROC (ROC-AUC) se conserva como diagnóstico secundario; ante positivos escasos, la curva precisión-recobrado muestra de forma más directa cuántas alertas relevantes aparecen entre las predicciones positivas [67], [68]. Tampoco se suman BA, tasa de falsos negativos (FNR), tasa de falsos positivos (FPR), AUPRC y F1 en una nota única: varias cantidades comparten errores y sus escalas no representan la misma utilidad.

El riesgo $R_{0,67} = 0,67 \text{ FNR} + 0,33 \text{ FPR}$ combina ambos tipos de error. Un valor menor es preferible. La razón $0,67/0,33 \simeq 2,03$ asigna a una omisión aproximadamente el doble del peso de una falsa alerta; es una preferencia operacional predeclarada, no una probabilidad ni un costo económico estimado. Para $\lambda = 0,50$, $R_{0,50} = 0,5(\text{FNR} + \text{FPR}) = 1 - \text{BA}$; usar 0,67 desplaza el desempate hacia evitar daño omitido. La tasa de revisión mide otra decisión —capacidad humana— y se interpreta junto con el error de la ruta automática.

IV-J. Ensembles y optimización

Los ensembles integran los mejores representantes de cada familia: regresión logística $C = 0,5$, cascada E5 segura y Qwen3-LoRA. Primero se transforma el score crudo s_{mk} del miembro m y salida k mediante un calibrador de Platt ajustado sin fuga, $p_{mk} = \sigma(a_{mk}s_{mk} + b_{mk})$. Sobre esas probabilidades se comparan cinco reglas base. El ensemble de promedio suave usa $E_k = \sum_m p_{mk}/3$; el ensemble ponderado usa $E_k = \sum_m w_m p_{mk}$, con pesos proporcionales a la macro-AUPRC del conjunto de validación; el ensemble de mayoría dura promedia decisiones $\mathbf{1}(p_{mk} \geq t_{mk})$; y los ensembles de unión e intersección usan, respectivamente, $\max_m p_{mk}$ y $\min_m p_{mk}$. Los ensembles suaves y de voto duro aprovechan errores diversos y tienen fundamento general en la literatura de combinación de clasificadores [13], [95]. La ponderación proporcional a AUPRC y las reglas máximo/mínimo son diseños exploratorios propuestos en este trabajo; no se atribuyen a una referencia específica.

Para evitar favorecer al ganador preliminar, se optimizan todos los ensembles con grados de libertad: uno suave y

otro de votos duros. En ambos casos se buscan pesos no negativos que sumen uno,

$$E_k(x; \mathbf{w}) = \sum_{m=1}^3 w_m z_{mk}(x), \quad w_m \geq 0, \quad \sum_m w_m = 1,$$

donde $z_{mk} = p_{mk}$ en el ensemble suave y $z_{mk} = \mathbf{1}(p_{mk} \geq t_{mk})$ en el duro. Este ensemble aprendido corresponde al principio de *stacked generalization*/Super Learner [96], [97]; la función objetivo concreta es una propuesta del trabajo: maximizar lexicográficamente BA, minimizar $R_{0,67}$ y maximizar macro-AUPRC. La búsqueda exhaustiva recorre el simplex con paso 0,025 (861 ternas) y, si persiste un empate, prefiere la solución más próxima a pesos iguales. Los ensembles de unión e intersección se recalibran y reevalúan, pero no se “optimizan” porque no poseen coeficientes.

La evaluación usa validación anidada GroupKFold por video para separar el ajuste de hiperparámetros de su estimación y reducir el sesgo de selección [73], [93]. En cada uno de cinco pliegues externos, los cuatro quintos de entrenamiento se dividen nuevamente en cinco pliegues internos. Las predicciones internas OOF sirven para: (i) ajustar los calibradores de Platt y los umbrales de cada miembro, (ii) evaluar las 861 ternas del simplex, y (iii) escoger pesos con BA, $R_{0,67}$ y macro-AUPRC en orden lexicográfico. Esos pesos y umbrales se aplican una sola vez al quinto externo no usado en el ajuste; al concatenar los cinco quintos se obtienen las métricas anidadas de la comparación. Después de elegir la regla, un ajuste final sobre todo el conjunto de validación fija $\mathbf{w}$, los calibradores de miembro y los umbrales de despliegue. El análisis reproduce desde las tres predicciones originales los hashes, la búsqueda, el bootstrap y la actualización. El Apéndice A conserva fórmulas, coeficientes y resultados de todos los casos.

IV-K. Criterio de selección e inferencia estadística

La política de selección es lexicográfica y no suma métricas redundantes. Primero maximiza BA ANY_DAMAGE OOF a cobertura completa. Luego exige una salvaguarda de macro-AUPRC de daños frente al mejor individuo, con margen de no inferioridad predeclarado de 0,10; conserva la frontera de Pareto BA-macro-AUPRC; y desempata por menor riesgo $R_{0,67} = 0,67 \text{ FNR} + 0,33 \text{ FPR}$, seguido de mayor macro-AUPRC. El margen 0,10 es permisivo y se conserva como limitación, no como prueba de equivalencia.

La comparación actualizada aplica esa regla a siete variantes de ensemble bajo el mismo protocolo anidado. El ensemble suave optimizado obtiene BA 0,8366, $R_{0,67} = 0,1587$ y macro-AUPRC 0,5506; el ensemble ponderado heurístico obtiene 0,8360, 0,1612 y 0,5614. El primero ocupa el rango uno, aunque no domina todas las métricas. Las operaciones se aplican en secuencia y no se suman en una puntuación compuesta.

Las diferencias se estiman con 2000 réplicas bootstrap pareadas por video [98], [99]. El remuestreo respeta la correlación entre chunks de un mismo video; no sustituye la variación entre semillas. Frente al ponderado heurístico, la diferencia de BA es 0,00059, IC95% $[-0,00367, 0,00509]$,

por lo que la selección expresa la regla lexicográfica y no superioridad estadística demostrada.

IV-L. Política selectiva y test sellado

NEEDS_REVIEW es una política posterior al modelo. Se activa por conflicto seguro-daño, salida vacía, incoherencia compuerta-categoría o proximidad a los umbrales. La capacidad máxima declarada fue 40 % y la validación conservó un margen máximo de $\delta = 0,03$. Candidato, miembros, calibradores, pesos, umbrales y política se almacenaron en un archivo `seleccion_congelada.json` antes de aplicar la fórmula actualizada a test.

El test natural contiene 22 684 chunks y se abrió una sola vez. Los tres miembros se infirieron en esa apertura; tras congelar la comparación ampliada exclusivamente con el conjunto de validación, sus matrices verificadas se recombinaron con la nueva fórmula. No hubo nueva inferencia ni ajuste con test, y la vista secundaria 4:1 reutiliza esos mismos scores. Este diseño separa selección y estimación final, y reduce el sesgo discutido por Cawley y Talbot [73].

IV-M. Artefacto de demostración

El frente de producción carga el registro de los tres ganadores por tipo y del ensemble. Acepta texto o una dirección web con subtítulos, genera chunks temporales, permite elegir el modelo y muestra scores, categorías, razones de revisión y procedencia. Las acciones humanas se registran para auditoría y para una futura iteración de entrenamiento separada. La Fig. 5 resume esta arquitectura y el Apéndice D documenta las interfaces.

V. RESULTADOS

Todos los resultados pertenecen al contrato de cinco salidas y al mismo corpus final. El conjunto de validación determina candidato, calibradores, umbrales y política; el test solo estima el desempeño del artefacto ya congelado.

V-A. Comparación global en el conjunto de validación

La comparación contiene 28 candidatos individuales y cinco reglas base de ensemble; la actualización añade la optimización simétrica de los ensembles suave y duro dentro del mismo flujo. Qwen3-LoRA es el mejor individuo y el ensemble suave optimizado ocupa el primer lugar actual. Su evaluación anidada obtiene BA 0,8366 y macro-AUPRC 0,5506; frente a Qwen OOF, las diferencias descriptivas son +0,0052 y +0,0349. Las Tablas VII y VIII presentan los resultados vigentes y el hardware empleado, sin intercalar un segundo ranking histórico.

Las siete variantes usan los mismos tres miembros y se reevalúan con calibración interna idéntica (Tabla VIII). La optimización cambia el resultado: el ensemble suave aprendido pasa al rango uno. El ensemble ponderado heurístico conserva mayor macro-AUPRC y F1, pero tiene BA y riesgo inferiores según el orden predeclarado. Los ensembles de unión e intersección carecen de coeficientes; por eso solo se recalibran.

Los coeficientes congelados del ganador se muestran en la Tabla IX; se aplican a probabilidades ya calibradas por miembro y suman uno.

Tabla VII

MEJOR CANDIDATO POR TIPO EN EL CONJUNTO DE VALIDACIÓN OOF. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LOS REGISTROS DE LA COMPARACIÓN INTEGRADA.

Tipo	BA	AUPRC	F1	FNR	FPR
Clásico, logística $C = 0,5$	0,80	0,48	0,50	0,18	0,22
Transformer, cascada segura	0,82	0,45	0,52	0,16	0,21
Qwen3-LoRA	0,83	0,52	0,55	0,17	0,17
Ensemble suave optimizado	0,837	0,551	0,562	0,150	0,177

Nota: AUPRC y F1 son promedios macro de los cuatro daños; BA, FNR y FPR corresponden a ANY_DAMAGE OOF a cobertura completa. Hardware de ajuste: clásico, CPU Intel x86_64 con cuatro hilos; Transformer, NVIDIA L4 de 23 GiB en BF16; Qwen, NVIDIA A100-SXM4 de 40 GB en BF16; ensemble, CPU AMD Ryzen 7 8845HS. Las GPU corresponden a sesiones independientes de Google Colab y no trabajaron en paralelo.

Tabla VIII

COMPARACIÓN DE LAS SIETE VARIANTES DE ENSEMBLE MEDIANTE VALIDACIÓN ANIDADA. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL CUADERNO REPRODUCIBLE DE OPTIMIZACIÓN.

Regla	BA	$R_{0,67}$	Macro-AUPRC	Macro-F1
Ensemble suave optimizado	0,8366	0,1587	0,5506	0,5618
Ensemble ponderado AUPRC	0,8360	0,1612	0,5614	0,5675
Ensemble de unión	0,8334	0,1684	0,5369	0,5621
Ensemble de promedio suave	0,8328	0,1673	0,5604	0,5703
Ensemble duro optimizado	0,8272	0,1731	0,4547	0,5584
Ensemble de mayoría dura	0,8272	0,1731	0,4415	0,5638
Ensemble de intersección	0,8149	0,1887	0,5131	0,5373

V-B. Frontera de Pareto e incertidumbre

El retador más cercano es el ensemble ponderado por AUPRC. En 2000 réplicas pareadas por video, la diferencia de BA entre el ganador y el retador es 0,00059, con IC95 % $[-0,00367, 0,00509]$ y $p = 0,80$ sin corrección. El intervalo incluye cero. La regla lexicográfica selecciona `ensemble_soft_optimized` como único ganador, pero el contraste no demuestra superioridad estadística. Los pesos suaves también varían entre los pliegues externos, sobre todo el peso del Transformer; el Apéndice A cuantifica esa variación.

V-C. Desempeño del ensemble por salida

Con los calibradores de despliegue ajustados en todo el conjunto de validación, el ensemble optimizado alcanza macro-AUPRC 0,55 y macro-F1 0,55 sobre los cuatro daños (Tabla X). Contenido sexual obtiene el mayor F1 (0,63) y género/identidad el menor (0,42). Estos valores descriptivos del ajuste final no reemplazan la estimación anidada usada para seleccionar.

Los mejores candidatos dependen de la categoría. Qwen3-LoRA con contexto 256 lidera AUPRC en racismo (0,57) y género/identidad (0,40); el ensemble ponderado lidera acoso/amenaza (0,61) y SEGURO (0,97); el ensemble de promedio simple lidera contenido sexual (0,69). La Fig. 6 muestra AUPRC y F1 de esos especialistas. El detalle de ganadores por métrica se conserva en el Apéndice B. Para operación se mantiene un único ensemble global, evitando reglas por categoría elegidas *post hoc*.

V-D. Apertura única de test natural

El test contiene 22 684 chunks, 1 802 con algún daño (7,9 %). La compuerta optimizada identifica 1 611 y omite




Figura 5. Arquitectura operativa vigente: tres modelos por tipo, ensemble suave optimizado, política selectiva y decisión humana. Fuente: elaboración propia.




Figura 6. Mejor desempeño por categoría en el conjunto de validación entre candidatos que superan la salvaguarda global. Fuente: elaboración propia a partir de la comparación integrada.

Tabla IX
COEFICIENTES DEL ÚNICO ENSEMBLE GANADOR ACTUAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL AJUSTE FINAL SOBRE EL CONJUNTO DE VALIDACIÓN.

Miembro	w_m
Regresión logística $C = 0,5$	0,10
Cascada E5 segura	0,65
Qwen3-LoRA	0,25
Suma	1,00

Tabla X
DESEMPEÑO DEL ENSEMBLE SELECCIONADO POR CATEGORÍA EN EL CONJUNTO DE VALIDACIÓN. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL AJUSTE FINAL.

Salida	Soporte	AUPRC	Prec.	Rec.	F1
SEGURO	8 480	0,98	0,89	0,95	0,92
RACISMO	382	0,55	0,51	0,69	0,59
ATAQUE-G/I	374	0,37	0,36	0,52	0,42
ACOSO-AMENAZA	1 146	0,60	0,59	0,53	0,56
SEXUAL	633	0,68	0,73	0,56	0,63

191: sensibilidad 0,894, especificidad 0,798 y BA 0,846. Frente al ensemble de promedio simple, la BA cambia solo +0,00004; disminuyen los falsos positivos (4 466 a 4 221), pero aumentan los falsos negativos (170 a 191). Estas cifras no se usaron para recalibrar ni volver a escoger el modelo.

En la tarea multietiqueta completa, la macro-AUPRC de daños es 0,412 y la macro-F1 0,423. La caída respecto de

la vista 4:1 se concentra en precisión y AUPRC porque el test natural contiene 12 seguros por daño; la sensibilidad y la BA de la compuerta se mantienen. La Tabla XI localiza la variación por salida. El contraste entre ambas vistas confirma que AUPRC debe interpretarse junto con la prevalencia [22].

Tabla XI

DESEMPEÑO POR SALIDA DEL ENSEMBLE OPTIMIZADO EN EL TEST NATURAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LA APERTURA ÚNICA DE TEST.

Salida	Soporte	AUPRC	Prec.	Rec.	F1
SEGURO	20 882	0,99	0,96	0,95	0,95
RACISMO	308	0,36	0,25	0,65	0,36
ATAQUE-G/I	283	0,27	0,22	0,54	0,31
ACOSO-AMENAZA	1 063	0,45	0,37	0,58	0,45
SEXUAL	519	0,58	0,53	0,62	0,57

Tabla XII

COMPUERTA COMPLETA Y RUTA AUTOMÁTICA EN TEST NATURAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LA POLÍTICA CONGELADA Y LA APERTURA ÚNICA DE TEST.

Vista	Cobertura	BA	Sens.	Espec.	FN
Compuerta completa	100 %	0,846	0,894	0,798	191
Ruta automática	72,7 %	0,925	0,902	0,948	96

V-E. Política de revisión humana

La política congelada deriva 6 184 chunks (27,3 %) y deja 16 500 (72,7 %) en la ruta automática. Dentro de esta ruta, la sensibilidad es 0,902, la especificidad 0,948 y la BA 0,925; quedan 96 daños como falsos negativos (FN) automáticos. La Tabla XII compara la cobertura completa con esta ruta selectiva. La mejora no procede de cambiar el clasificador, sino de reservar para revisión los conflictos y márgenes inciertos. La carga queda por debajo del máximo predeclarado de 40 %, pero sigue siendo material.

VI. DISCUSIÓN

VI-A. Valor del ensemble de familias

El hallazgo principal es la complementariedad de las tres representaciones, no la sustitución de una arquitectura por otra. La regresión logística aporta señales léxicas rápidas e inspeccionables; la cascada E5 separa la detección de la tipificación mediante una compuerta conservadora; y Qwen3-LoRA ofrece el mejor desempeño individual en BA, AUPRC y F1. El ensemble suave optimizado aumenta BA y macro-AUPRC frente al mejor individuo sin añadir un metamodelo opaco. La mejora es moderada y el contraste con el ensemble ponderado por AUPRC es inconcluso, pero la regla congelada sigue siendo simple, reproducible y fácil de implementar.

La comparación por tipo también evita una lectura simplista del ranking. El Transformer ganador supera al clásico en BA y FNR, pero no en macro-AUPRC; Qwen supera a ambos en el balance global; y los ensembles cambian el compromiso entre sensibilidad, falsas alarmas y F1. Esta diversidad justifica mostrar los tres modelos individuales junto con el ensemble en producción, siempre que el usuario pueda distinguir predicción, desacuerdo y decisión humana.

VI-B. Desempeño por categoría

Contenido sexual y racismo alcanzan los mayores F1 del ensemble en el conjunto de validación; género/identidad conserva la mayor dificultad y el menor soporte. En el test natural, contenido sexual mantiene el mayor AUPRC

de daño (0,58) y género/identidad el menor (0,27). Estas diferencias son accionables: la siguiente adquisición debe priorizar casos fronterizos, lenguaje implícito y contextos locales de género e identidad. Las métricas agregadas no sustituyen pruebas funcionales por fenómeno, como muestra HateCheck [3], ni auditorías de sesgo lingüístico [4].

La unión operacional de acoso personal y amenaza directa aumenta soporte y estabilidad, pero no establece equivalencia conceptual o legal. Los subtipos finos preservan esa distinción para auditoría. De forma análoga, **SEGURO** significa ausencia de evidencia suficiente dentro del texto observado, no una certificación universal del video.

VI-C. Comparación contextual con el estado del arte

Los trabajos relacionados reportan cifras altas en tareas y corpus distintos: EXIST informa aproximadamente 0,79 de F1 en su tarea de sexismo [21]; OffendES, 0,78 [20]; HatEval, 0,73 [19]; HateXplain, 0,69 [16]; y DETOXIS, 0,65 [18]. En la vista secundaria 4:1 del presente test, el F1 binario de cualquier daño es 0,66, dentro del intervalo formado por DETOXIS y HateXplain. Esta posición muestra competitividad contextual, no equivalencia experimental: cambian idioma, unidad, categorías, partición y prevalencia.

La diferencia entre la vista 4:1 y el test natural refuerza esa cautela. NaijaHate muestra que la precisión promedio puede caer de rangos 0,83–0,90 en conjuntos enriquecidos a cerca de 0,34 en una muestra representativa [22]. En este estudio, el mismo conjunto de predicciones produce macro-AUPRC de daños 0,57 en la vista 4:1 y 0,42 en la vista natural. La BA de la compuerta permanece cerca de 0,85 porque pondera por igual la sensibilidad y la especificidad. La lectura más prudente se apoya en el corpus local, la prevalencia explícita, la evidencia temporal y la derivación humana, no en una cifra aislada.

El trabajo es comparable con el estado del arte en el objeto científico —clasificación de lenguaje dañino en contenido social—, en el uso de F1 y métricas de ranking, y en la magnitud del F1 binario contextual. También se alinea con prácticas actuales que fortalecen un sistema aplicado: separación y remuestreo por entidad, predicciones fuera de muestra, test sellado con prevalencia explícita, análisis por categoría, calibración y revisión humana. Su diferenciación favorable procede de integrar taxonomía peruana, habla transcrita, evidencia temporal y modelos clásico, Transformer y Qwen en un único flujo verificable.

La evidencia no demuestra liderazgo en un benchmark internacional común. Una afirmación de estado del arte predictivo exigiría evaluar el artefacto congelado en un conjunto externo compartido o en una cohorte temporal de canales no observados. También harían falta varias semillas, doble etiquetado humano independiente, pruebas funcionales y de sesgo por subgrupo, y un contraste del texto con señales de audio e imagen. Un piloto en modo sombra debería medir latencia, costo, desacuerdo y falsos negativos residuales. El resultado es competitivo y sigue prácticas del estado del arte aplicado, pero la superioridad general necesita evidencia externa.

VI-D. Utilidad operativa

La compuerta completa detecta 89,4 % de los chunks dañinos del test y la política selectiva eleva la BA de la ruta automática a 0,925. El 72,7 % de los chunks sigue esa ruta y el 27,3 % queda para revisión. La proporción es mucho menor que una revisión completa, aunque sigue siendo una carga material: una operación real debe traducirla en horas, dotación y tiempos de respuesta. La clasificación selectiva hace visible ese costo [14], [75].

El artefacto puede ensayarse en modo sombra: procesa texto o una dirección web con subtítulos, localiza intervalos, muestra los cuatro modelos vigentes y registra correcciones. No ejecuta sanciones ni reemplaza las políticas de plataforma. Esa separación entre evidencia automática y responsabilidad humana es coherente con la literatura de moderación [1], [2].

VII. LIMITACIONES Y TRABAJO FUTURO

La evaluación tiene cinco limitaciones principales.

1. **Población y etiquetas.** “Natural” describe la prevalencia del split completo, no una muestra probabilística de YouTube. La adquisición incluye búsquedas dirigidas y los rótulos son mayormente asistidos; se requiere una cohorte temporal con doble revisión humana independiente y acuerdo por categoría [100], [101].
2. **Incertidumbre del ranking.** El bootstrap agrupa por video, pero no mide variación entre semillas. El empate con el retador impide declarar superioridad estadística. Deben repetirse entrenamientos y evaluarse estabilidad temporal [73], [102].
3. **Salvaguarda permisiva.** El margen de no inferioridad de macro-AUPRC fue 0,10. Aunque estaba congelado antes de test, es amplio para una escala 0–1; una réplica confirmatoria debería fijar un margen sustantivo más estricto.
4. **Capacidad humana.** La tasa de revisión de 27,3 % satisface el máximo experimental de 40 %, pero todavía no se ha traducido en dotación, duración ni costo. El piloto debe medir tiempo por alerta, falsos negativos residuales y desacuerdo humano.
5. **Modalidad y deriva.** El sistema observa subtítulos y metadatos, no imagen, audio ni conducta de red. Cambios de canal, plataforma o periodo pueden degradar calibración; se requiere monitoreo de deriva, latencia, privacidad y seguridad [5], [103].

VIII. CONCLUSIONES

El trabajo presenta un moderador semiautomático que transforma subtítulos en alertas temporales, compara representaciones complementarias y deriva los casos inciertos a una persona. El artefacto sirve para priorizar contenido y apoyar la decisión; no aplica sanciones de manera autónoma.

El corpus utilizado define el objeto empírico del estudio: contiene 173 240 chunks de 4 906 videos, con cinco salidas, 14 163 chunks dañinos y 2 709 casos multietiqueta. La separación por video y los 55 966 eventos de revisión permiten reconstruir la procedencia de cada unidad. Una

futura cohorte prospectiva deberá incorporar el doble etiquetado humano independiente, todavía ausente.

La comparación común reúne 28 modelos individuales, cinco reglas base y dos ensembles optimizados mediante una sola validación OOF anidada. El ensemble suave optimizado es el único ganador actual: obtiene BA 0,8366, macro-AUPRC 0,5506, macro-F1 0,5618 y $R_{0,67} = 0,1587$, con pesos clásico/Transformer/Qwen 0,10/0,65/0,25. El ensemble ponderado por AUPRC conserva una mayor macro-AUPRC (0,5614), pero queda segundo por BA (0,8360). Como el contraste pareado permanece inconcluso, el resultado respalda una selección reproducible mediante la regla lexicográfica, no una superioridad estadística universal.

La apertura única de los 22 684 chunks de test sitúa la BA de la compuerta en 0,846 y su sensibilidad en 0,894. La política deriva el 27,3 % y deja el 72,7 % en la ruta automática, cuya BA es 0,925. Estas proporciones permiten estimar la incertidumbre y la carga humana. La capacidad real, el tiempo por alerta y el costo deberán medirse en un piloto en modo sombra.

El sistema integra la regresión logística, la cascada E5 segura, Qwen3–LoRA y el ensemble suave optimizado. También conserva los calibradores, pesos, umbrales, intervalos de evidencia y registros de revisión. La verificación funcional local confirma que la interfaz invoca los tres miembros y devuelve el ensemble congelado. Así se integran una señal léxica rápida, una arquitectura contextual de dos etapas y un modelo de lenguaje adaptado, mientras la decisión final permanece bajo supervisión humana.

El sistema alcanza un desempeño competitivo para detectar y priorizar contenido peruano: BA 0,846 y sensibilidad 0,894 bajo la prevalencia natural del corpus. En la vista secundaria 4:1 obtiene un F1 binario de 0,662, comparable en magnitud con resultados publicados en tareas relacionadas, aunque esta cifra no gobierna el ranking. Su principal fortaleza está en el flujo completo: datos auditables, comparación común, selección congelada, test separado y supervisión humana. El diseño sigue prácticas del estado del arte aplicado, pero no demuestra superioridad predictiva en un benchmark externo común. El siguiente paso es validarlo prospectivamente con canales no observados, doble etiquetado independiente, varias semillas y mediciones reales de capacidad, costos y deriva.

Durante la demostración local, la interfaz de etiquetado y el frontend de producción permiten recorrer el control humano y comparar los tres ganadores por tipo con el ensemble congelado. Estas direcciones requieren que los servicios del proyecto estén activos en el equipo del lector; documentan el artefacto, pero no sustituyen una validación de campo.

DISPONIBILIDAD Y ÉTICA

El código, los cuadernos y las configuraciones están en GitHub; el dataset final documentado, en un ZIP de Google Drive (Apéndice E). Ambos bastan para repetir el entrenamiento: no se requieren subtítulos crudos ni estados anteriores al JSON final. La reutilización exige revisar términos, privacidad, licencias y derechos [103], [104]; la alerta no reemplaza la decisión humana.

APÉNDICE A
ESPECIFICACIÓN DEL ENSEMBLE CONGELADO

El artefacto `seleccion_congelada.json` fija la firma de comparación, el hash del dataset, los tres miembros, calibradores, pesos, umbrales y política de revisión. Los scores crudos se calibran por miembro y salida, $p_{mk} = \sigma(a_{mk}s_{mk} + b_{mk})$, antes de integrarlos. Esta capa común evita que la escala propia de un modelo domine el ensemble y sigue el uso de calibración sigmoide descrito por Platt y por Niculescu-Mizil y Caruana [70], [71]. La Tabla XIII identifica los cuatro artefactos publicados y resume la arquitectura y el desempeño de cada miembro y del ensemble.

Tabla XIII
MIEMBROS Y ARTEFACTO DEL ENSEMBLE DE PRODUCCIÓN. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL REGISTRO CONGELADO Y LA COMPARACIÓN INTEGRADA.

Tipo	Identificador	Arquitectura	BA	AUPRC	F1
Clásico	<code>classical-logistic_regression_c0p5-54f7971c6000</code>	TF-IDF palabra 1-2 + carácter 3-5; uno contra el resto (OVR) enmascarado; logística $C = 0,5$.	0,80	0,48	0,50
Transformer	<code>cascade_v2-af78eba77883</code>	Cascada E5 segura: compuerta ANY_DAMAGE + rama E5 de cinco salidas.	0,82	0,45	0,52
Qwen	<code>qwen_lora-4aa5ce04df05</code>	Qwen3-0.6B-Base; LoRA ($r = 8$, $\alpha = 16$, $p = 0,05$) en Q/K/V/O; cabeza de 22 logits.	0,83	0,52	0,55
Ensemble	<code>ensemble_soft_optimized</code>	Ensemble convexo de probabilidades calibradas: 0,10 clásico +0,65 Transformer +0,25 Qwen.	0,837	0,551	0,562

La optimización se ejecuta en cinco pliegues externos `GroupKFold` por video. Dentro de cada entrenamiento externo, otros cinco pliegues generan probabilidades calibradas OOF y votos $D_{mk} = \mathbf{1}(p_{mk} \geq t_{mk})$. Sobre estas predicciones internas se enumeran las 861 ternas no negativas que suman uno en un simplex de paso 0,025; para cada terna se vuelven a estimar los umbrales y se ordena por mayor BA, menor $R_{0,67}$, mayor macro-AUPRC y, solo ante empate, menor distancia a pesos iguales. La terna elegida se evalúa en el pliegue externo intacto, y la concatenación de los cinco pliegues produce los resultados de la Tabla XIV. Este esquema anidado reduce el optimismo de escoger y evaluar hiperparámetros sobre los mismos datos [73]; el ensemble convexo aprendido sigue el principio de *stacking*/Super Learner [96], [97]. La malla, el orden lexicográfico y el desempate son decisiones propuestas por este trabajo. Los ensembles de máximo y mínimo no tienen coeficientes aplicables. En la tabla, C/T/Q denota clásico/Transformer/Qwen.

Tabla XIV
FÓRMULAS, COEFICIENTES Y RESULTADOS DE LAS SIETE VARIANTES DE ENSEMBLE. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL CUADERNO REPRODUCIBLE DE OPTIMIZACIÓN.

Caso	Fórmula por salida k	Pesos C/T/Q	BA	$R_{0,67}$	AP	F1
Ensemble suave optimizado	$\sum_m w_m p_{mk}$	0,100 / 0,650 / 0,250	0,8366	0,1587	0,5506	0,5618
Ensemble ponderado por AUPRC	$\sum_m w_m p_{mk}$	0,3317 / 0,3110 / 0,3573	0,8360	0,1612	0,5614	0,5675
Ensemble de unión	$\max_m p_{mk}$	No aplica	0,8334	0,1684	0,5369	0,5621
Ensemble de promedio suave	$\sum_m p_{mk} / 3$	0,3333 / 0,3333 / 0,3333	0,8328	0,1673	0,5604	0,5703
Ensemble duro optimizado	$\sum_m w_m D_{mk}$	0,300 / 0,325 / 0,375	0,8272	0,1731	0,4547	0,5584
Ensemble de mayoría dura	$\sum_m D_{mk} / 3$	0,3333 / 0,3333 / 0,3333	0,8272	0,1731	0,4415	0,5638
Ensemble de intersección	$\min_m p_{mk}$	No aplica	0,8149	0,1887	0,5131	0,5373

Nota: AP y F1 son macro sobre los cuatro daños. Todas las cifras son OOF de los cinco pliegues externos anidados. Los ensembles ponderado por AUPRC, de unión y de intersección son propuestas exploratorias del trabajo; los ensembles convexos se fundamentan en *stacking*/Super Learner [96], [97].

La Tabla XV reporta los coeficientes efectivamente aprendidos. La dispersión del peso Transformer en el ensemble suave (0,15–0,775 entre pliegues) muestra que la ventaja es sensible a la partición; el ajuste completo 0,10/0,65/0,25 es el único congelado para inferencia. El ensemble duro resulta mucho más estable.

Tabla XV

COEFICIENTES OPTIMIZADOS POR PLIEGUE EXTERNO Y AJUSTE FINAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LA VALIDACIÓN ANIDADA 5×5 .

	Suave C/T/Q			Duro C/T/Q		
Pliegue 1	0,225	0,200	0,575	0,300	0,325	0,375
Pliegue 2	0,250	0,150	0,600	0,300	0,325	0,375
Pliegue 3	0,225	0,200	0,575	0,325	0,300	0,375
Pliegue 4	0,075	0,775	0,150	0,325	0,300	0,375
Pliegue 5	0,250	0,175	0,575	0,300	0,325	0,375
Ajuste final	0,100	0,650	0,250	0,300	0,325	0,375

Para reproducir la fórmula ganadora se necesitan además los 15 calibradores de miembro (Tabla XVI). Cada celda informa (a_{mk}, b_{mk}) en $p_{mk} = \sigma(a_{mk}s_{mk} + b_{mk})$.

Tabla XVI

CALIBRADORES DE PLATT DEL ENSEMBLE SUAVE OPTIMIZADO. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL AJUSTE FINAL SOBRE EL CONJUNTO DE VALIDACIÓN.

Salida	Clásico (a, b)	Transformer (a, b)	Qwen (a, b)
SEGURO	(6,0625; -2,0469)	(4,0245; -1,5720)	(5,5516; -2,9069)
RACISMO	(7,0045; -5,3929)	(5,1196; -4,5488)	(5,6182; -4,8838)
ATAQUE-G/I	(5,6545; -5,0496)	(4,2140; -4,3563)	(4,7506; -4,5481)
ACOSO-AMENAZA	(6,0887; -4,5669)	(3,8781; -3,4135)	(4,7328; -3,9405)
SEXUAL	(7,0710; -5,2304)	(4,8414; -4,2777)	(5,4669; -4,2870)

La salida final es $E_k = 0,10p_{Ck} + 0,65p_{Tk} + 0,25p_{Qk}$. Los umbrales de categoría son 0,46 (SEGURO), 0,17 (RACISMO), 0,18 (ATAQUE-G/I), 0,39 (ACOSO-AMENAZA) y 0,47 (SEXUAL); la compuerta de cualquier daño usa 0,072919 sobre el máximo de las cuatro salidas dañinas. Estos valores, junto con $\delta = 0,03$, se fijaron con el conjunto de validación antes de recombinar los checkpoints del test.

APÉNDICE B
RESULTADOS AMPLIADOS

La Tabla XVII separa los líderes por salida y métrica sin reemplazar el ganador global usado en producción.

Tabla XVII

GANADORES POR CATEGORÍA EN EL CONJUNTO DE VALIDACIÓN, RESTRINGIDOS A CANDIDATOS QUE SUPERAN LA SALVAGUARDA GLOBAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LA COMPARACIÓN INTEGRADA.

Salida	Mejor AUPRC	Valor	Mejor F1	Valor	Mejor recall	Valor	Prec.
SEGURO	Ensemble ponderado	0,97	Qwen ctx256	0,92	SVM $C = 2$	0,97	0,86
Racismo	Qwen ctx256	0,57	Qwen ctx256	0,62	Qwen ctx256	0,68	0,57
Ataque-G/I	Qwen ctx256	0,40	Ensemble de mayoría dura	0,47	Ensemble ponderado	0,55	0,39
Acoso-Amenaza Sexual	Ensemble ponderado	0,61	Ensemble de unión	0,58	Ensemble de unión	0,63	0,54
	Ensemble de promedio simple	0,69	Ensemble de unión	0,64	Ensemble de unión	0,64	0,64

La Tabla XVIII compara la vista natural y la secundaria 4:1 obtenidas de la misma inferencia, por lo que sus diferencias no proceden de otro modelo ni de una reapertura de test. También informa el error esperado de calibración (ECE) y la puntuación de Brier.

Tabla XVIII

MÉTRICAS GLOBALES DE LAS DOS VISTAS DERIVADAS DE UNA SOLA APERTURA DE TEST. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LOS MISMOS SCORES CONGELADOS.

Vista	Filas	BA	F1 any	AUPRC	daño	F1	daño	F1	cinco	ECE	Brier
Natural	22 684	0,846	0,422		0,412	0,423	0,531	0,025	0,027		
4:1 secundaria	9 010	0,846	0,662		0,564	0,545	0,621	0,019	0,047		

La vista 4:1 selecciona de forma determinista 7 208 seguros y conserva los 1 802 daños. Reutiliza exactamente los scores de la vista natural. La diferencia de F1 y AUPRC refleja prevalencia, no otro modelo ni otra inferencia. La Tabla XIX conserva los conteos exactos que explican la compuerta completa y la ruta selectiva: verdaderos positivos (TP), falsos negativos (FN), falsos positivos (FP) y verdaderos negativos (TN).

Tabla XIX

MATRIZ BINARIA DE CUALQUIER DAÑO EN TEST NATURAL. FUENTE: ELABORACIÓN PROPIA A PARTIR DE LA APERTURA ÚNICA DE TEST Y LA POLÍTICA CONGELADA.

Política	TP	FN	FP	TN
Compuerta completa	1 611	191	4 221	16 661
Ruta automática selectiva	886	96	814	14 705

APÉNDICE C

ONTOLOGÍA Y VOCABULARIO CONTROLADO

La ontología liviana distingue evidencia, etiquetado, categoría operativa, predicción, decisión humana y registro reentrenable. El archivo `ontologia_moderacion.ttl` conserva la representación legible por máquina; la Fig. 7 resume las relaciones definidas en el marco teórico y empleadas por el artículo y el demostrador.




Figura 7. Ontología de trazabilidad desde el video hasta la decisión humana y la retroalimentación. Fuente: elaboración propia.

APÉNDICE D

INTERFACES DE ETIQUETADO Y OPERACIÓN

La Fig. 8 documenta el entorno de etiquetado: texto, intervalo, propuesta previa, categorías y acciones quedan visibles antes de guardar. La Fig. 9 muestra la interfaz de producción, que conserva una única entrada para texto o una dirección web y permite seleccionar los tres ganadores por tipo o el ensemble congelado. La verificación funcional confirma que cada resultado identifica modelo, linaje, scores, umbrales y razón de revisión.

Validación humana - 3 114 casos

3063/3114 resueltos · incluidos 3012 · excluidos 51

Vista Todas

Iniciales

REV

Guía

Descargar final

Flujo rápido: la propuesta del LLM ya está visible y precargada. **Aceptar** la incluye tal cual; **rechazar** excluye el chunk del entrenamiento; si cambias categorías o flags, usa **guardar versión humana**. Las decisiones anteriores se conservan como decisiones humanas migradas.

Segunda corrida / ampliación (1.779)

Sin abrir

1/1 · Arde Troya con Juliana Oxenford · ARDE TROYA WITH JULIANA OXFENFORD: JUNE 10, 2026 PROGRAM · 48:41-49:13 · validation [Abrir video](#)

CONTEXTO ANTERIOR

de estado, ¿no? Y habiendo explicado este asunto juristas no solamente nacionales sino internacionales con suma facilidad [resoplido] y que la prensa sigue en eso. La prensa fue la que permanentemente buscó dar el golpe de estado, ¿no?, con el Congreso de la República contra Pedro Castillo. Esa es la verdad. Claro que este cumpliendo un deseo de la ultraderecha que no podía ver a Pedro Castillo sentado en el sillón presidencial. Esa es la verdad.

CHUÑE A VALIDAR

sillón presidencial. Esa es la verdad. Hablar lo contrario, ¿no? A la verdad, a lo que está demostrado, lo que está acreditado nacional e internacionalmente lo hace quedar mal al Perú. Porque vemos allí, ¿no?, a un entrevistador, periodista y a un entrevistado diciendo lo que está demostrando que no es. Es como ver allí, ¿no?, a un entrevistador que realmente se presenta como un macaco y el entrevistado como otro macaco, repitiendo lo mismo, lo mismo, lo mismo

CONTEXTO POSTERIOR

repitiendo lo mismo, lo mismo, lo mismo y lo mismo. Eso es lo que vemos en el Perú. ¿Qué fue entonces lo que vimos todos? ¿Qué fue lo que escuchamos? que Pedro Castillo leyó ese discurso que no constituye este delito de rebelión, no constituye este golpe de estado, no se ha demostrado en el proceso de que haya habido conspiración, porque por conspiración quiere decir que se reúnen dos o tres por lo menos no para acordar levantarse en armas. Bueno, estaba

Propuesta del LLM · DeepSeek Pro

visible antes de decidir

RACISMO DISCRIMINACION

ACOSO PERSONAL

Confianza declarada: 0.95

Etiquetas finas (solo referencia): racismo_etnico_explicito, acoso_personal

Justificación: El término 'macaco' es un insulto racial dirigido a personas, en este caso al entrevistador y entrevistado, inferiorizándolos por su apariencia o comportamiento asociado a estereotipos étnicos (Callirgos, 1993). Además, al ser dirigido a individuos identificables en el contexto del programa, constituye acoso personal.

Notas Pro: Uso de 'macaco' como insulto racial y ataque a periodista y entrevistado.

Origen de selección: Adquisición: high_yield_channel - objetivo: ACOSO_PERSONAL|AMENAZA_DIRECTA

✓ Aceptar LLM e incluir

✗ Rechazar y excluir

Guardar versión modificada por humano

Aceptar y rechazar avanzan al siguiente pendiente. Para modificar, cambia primero las opciones precargadas.

CATEGORÍA BASE

☐ SEGURO

No hay ataque, amenaza ni sexualización dañina; lo citado, informativo o crítico sin daño tan bien sea seguro.

☒ RACISMO DISCRIMINACION

Inferiorización o exclusión por etnia, rasgos racializados, acento, clase asociada o procedencia regional.

☐ ACOSO GENERO IDENTIDAD

Ataque o degradación por género, identidad, orientación sexual o identidad de género.

☒ ACOSO PERSONAL

Insulto, hostigamiento o degradación dirigido a una persona identificable.

☐ AMENAZA DIRECTA

Intención explícita o inequívoca de causar daño físico, sexual, patrimonial o equivalente.

☐ CONTENIDO SEXUAL

Contenido sexual explícito de finno, coacción sexual o material no consensual.

FLAG TRANSVERSALES (SOLO CON DAÑO)

☐ ironía ambigua

La ironía no permite decidir con seguridad si hay daño genuino.

☐ humor encubridor

El humor funciona como cobertura para normalizar o minimizar el daño.

☐ contexto necesario

Aun con los vecinos mostrados, se requiere revisar más contexto del video.

NOTA HUMANA OPCIONAL

Útil para justificar una modificación o una exclusión.

— Anterior

Diferir con nota

Siguiente pendiente

Atajos: [A] aceptar · [R] rechazar · [Ctrl]+[Enter] guardar modificación · [↩] navegar.

Figura 8. Entorno de revisión de etiquetas: contexto, propuesta y controles para aceptar, rechazar o modificar. Fuente: captura propia del artefacto del proyecto.

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Operación comparada de clásico, Transformer, Qwen y ensemble

Trabajo final del curso de Procesamiento de Lenguaje Natural (PLN) de la Maestría en Inteligencia Artificial de la Universidad Nacional de Ingeniería (UNI) — Semestre 2026-1

Grupo 4: Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay · Herbert Antonio Meléndez García · Dennis Jack Paitán Cano

Moderador local · Perú

Modo sombra

Estadísticas

Exportar revisiones

Dataset para reentrenar

Ayuda

¿Qué quieres analizar?

Escribe una frase o pega un enlace de YouTube; nunca se descarga audio o video.

Texto o <https://www.youtube.com/watch?v=...>

Respuesta

Ensemble ganador · mezcla suave optimizada

Tipo automático

Texto · automático

Analizar

Ajustes

Contrato **moderacion_peru_5_salidas_v2**. Mejor modelo clásico: classical-logistic_regression_c0p5-54f7971c6000 · Mejor Transformer: cascade_v2-af78eba77883 · Mejor Qwen ajustado: qwen_lora-4aa5ce04df05 · Ensemble ganador · mezcla suave optimizada: ensemble_soft_optimized. Operación en modo sombra; ensemble congelado disponible: **sf**.

Figura 9. Frontend de producción: entrada textual o dirección web, selección de modelo, categorías, scores y evidencia temporal. Fuente: captura propia del artefacto alineado con la selección congelada.

APÉNDICE E
TRAZABILIDAD Y DISPONIBILIDAD

La Tabla XX identifica la fuente canónica usada para cada bloque del manuscrito y separa resultados, selección y evaluación final.

Tabla XX
ARTEFACTOS CANÓNICOS QUE SUSTENTAN CADA BLOQUE DE RESULTADOS VIGENTE. FUENTE: ELABORACIÓN PROPIA A PARTIR DEL INVENTARIO REPRODUCIBLE DEL PROYECTO.

Artefacto	Contenido	Uso en el artículo
docs/artefactos/auditoria_estado_final_182461.json	Totales elegibles, etiquetas, videos, particiones y huella de auditoría.	Corpus y etiquetado.
docs/OPTIMIZACION_LONGITUD_CHUNKS.md y docs/ROBUSTEZ_NEURONAL_LONGITUD_CHUNKS.md	Comparación de 15–35 s, perfiles clásico y neuronal, bootstrap y decisión congelada.	Longitud temporal de 30 s.
Matrices de comparación individual y optimización de ensembles	Ranking y comparación anidada de siete variantes, pesos, bootstrap y hashes de entrada.	Selección en el conjunto de validación.
resultados/modelos/seleccion_congelada.json	Miembros, calibradores, umbrales y política NEEDS_REVIEW.	Especificación desplegable.
resultados/modelos/test_final_abierto_una_vez.json	Test natural, vista 4:1 y métricas selectivas.	Evaluación final.
Reporte reproducible de comparación de modelos	Tablas y análisis crítico legible.	Control editorial y reproducibilidad.

Para replicar el entrenamiento solo se requieren los cuadernos y configuraciones y el ZIP del dataset final documentado. El ZIP ocupa 63 408 649 bytes (SHA-256: e34f96c8777262f55cb7eafff5b6f2482981ba181fca4217b3f097f876545c24) e incluye el JSON de 396 581 052 bytes (SHA-256: f0661dc3778b5e42a1e65e844a5c5db70fcee414685a44fb9738e17657859a49), su esquema y el validador. La Tabla XX localiza los parámetros finales. No se requieren subtítulos crudos, cachés, corpus intermedios ni pesos del proyecto. La reutilización exige revisar licencias, privacidad y términos de YouTube [103], [104].

REFERENCIAS

- [1] R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://doi.org/10.1177/2053951719897945>
- [2] J. S. Andersen, O. Zukunft, and W. Maalej, "REM: Efficient semi-automated real-time moderation of online forums," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2021, pp. 142–149. [Online]. Available: <https://doi.org/10.18653/v1/2021.acl-demo.17>
- [3] P. Röttger, B. Vidgen, D. Nguyen *et al.*, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://doi.org/10.18653/v1/2021.acl-long.4>
- [4] M. Sap, D. Card, S. Gabriel *et al.*, "The risk of racial bias in hate speech detection," in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2019, pp. 1668–1678. [Online]. Available: <https://doi.org/10.18653/v1/P19-1163>
- [5] R. Tatman, "Gender and dialect bias in YouTube's automatic captions," in *Proceedings of the First ACL Workshop on Ethics in Natural Language Processing*. Association for Computational Linguistics, 2017, pp. 53–59. [Online]. Available: <https://doi.org/10.18653/v1/W17-1606>
- [6] A. R. Hevner, S. T. March, J. Park *et al.*, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://doi.org/10.2307/25148625>
- [7] K. Peffers, T. Tuunanen, M. A. Rothenberger *et al.*, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007. [Online]. Available: <https://doi.org/10.2753/MIS0742-1222240302>
- [8] B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://doi.org/10.1371/journal.pone.0243300>
- [9] E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: https://doi.org/10.1162/tacl_a_00041
- [10] M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: <https://doi.org/10.1145/3531146.3533231>
- [11] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>
- [12] A. Vaswani, N. Shazeer, N. Parmar *et al.*, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>
- [13] T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15. [Online]. Available: https://doi.org/10.1007/3-540-45014-9_1
- [14] H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/mozannar20b.html>
- [15] E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399. [Online]. Available: <https://doi.org/10.1145/3038912.3052591>
- [16] B. Mathew, P. Saha, S. M. Yimam *et al.*, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14 867–14 875. [Online]. Available: <https://doi.org/10.1609/aaai.v35i17.17745>
- [17] T. Bertaglia, A. Grigoriu, M. Dumontier *et al.*, "Abusive Language on Social Media Through the Legal Looking Glass," in *Proceedings of the Fifth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2021, pp. 191–200. [Online]. Available: <https://doi.org/10.18653/v1/2021.waoah-1.20>
- [18] M. Taulé, A. Ariza, M. Nofre *et al.*, "Overview of DETOXIS at IberLEF 2021: DEtection of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://doi.org/10.26342/2021-67-18>
- [19] V. Basile, C. Bosco, E. Fersini *et al.*, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://doi.org/10.18653/v1/S19-2007>
- [20] F. M. Plaza-del Arco, A. Montejo-Ráez, L. A. Ureña-López *et al.*, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: https://doi.org/10.26615/978-954-452-072-4_123
- [21] F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza *et al.*, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://doi.org/10.26342/2021-67-17>
- [22] M. Tonneau, P. Quinta De Castro, K. Lasri *et al.*, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://doi.org/10.18653/v1/2024.acl-long.488>
- [23] Z. Waseem, T. Davidson, D. Warmusley *et al.*, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://doi.org/10.18653/v1/W17-3012>
- [24] M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://doi.org/10.18653/v1/2020.alw-1.16>
- [25] J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993. [Online]. Available: https://biblioteca.una.p.edu.pe/opac_css/index.php?lvl=notice_display&id=8721
- [26] G. Portocarrero Maisch, *Racismo y mestizaje y otros ensayos*. Lima: Fondo Editorial del Congreso del Perú, 2009, reimpresión de la edición de 2007. [Online]. Available: <https://www2.congreso.gob.pe/Sicr/FondoEditorial/SIFonEd.insf/Catalogomateria?OpenForm>
- [27] V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://doi.org/10.18800/debatesensociologia.201802.008>
- [28] V. Zavala and R. Zariquiey, "Yo te segrego a ti porque tu falta de educación me ofende": una aproximación al discurso racista en el Perú contemporáneo," in *Racismo y discurso en América Latina*, T. A. van Dijk, Ed. Barcelona: Gedisa, 2007, pp. 333–370. [Online]. Available: <https://dialnet.unirioja.es/servlet/libro?codigo=270993>
- [29] V. Zavala and M. Back, Eds., *Racismo y lenguaje*. Lima: Fondo Editorial de la Pontificia Universidad Católica del Perú, 2017. [Online]. Available: <https://www.fondoeditorial.pucp.edu.pe/linguistica/525-racismo-y-lenguaje.html>
- [30] V. Zavala and C. Almeida, "Motoso y terruco": ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://doi.org/10.18800/lexis.202202.002>
- [31] R. F. Brañez Medina, "La construcción discursiva de las identidades "amixer" y "no-amixer" en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú,

2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/1618>
- [32] V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf
- [33] P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://doi.org/10.18653/v1/2021.acl-long.247>
- [34] C. Monge-Olivarria, J. Guerra-Correa, and F. Bringas-Castro, "Violencia de género en Twitter: feminización como forma de insulto en la conversación digital," *Orkopata. Revista de Lingüística, Literatura y Arte*, vol. 2, no. 2, pp. 7–16, 2023. [Online]. Available: <https://doi.org/10.35622/j.ro.2023.02.001>
- [35] D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnorestencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf
- [36] Defensoría del Pueblo del Perú, "Violencia de género contra las mujeres en línea," Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>
- [37] B. R. Chakravarthi, "Detection of homophobia and transphobia in YouTube comments," *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://doi.org/10.1007/s41060-023-00400-0>
- [38] J. M. Rottenbacher de Rojas, "Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima," *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>
- [39] C. M. Lovón-Cueva and M. Lovón-Cueva, "Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums," *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://doi.org/10.13131/2611-657X.whatever.v5i1.156>
- [40] M. ElSherief, C. Ziems, D. Muchlinski *et al.*, "Latent hatred: A benchmark for understanding implicit hate speech," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 345–363. [Online]. Available: <https://doi.org/10.18653/v1/2021.emnlp-main.29>
- [41] S. Ilić, E. Marrese-Taylor, J. Balazs *et al.*, "Deep contextualized word representations for detecting sarcasm and irony," in *Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*. Association for Computational Linguistics, 2018, pp. 2–7. [Online]. Available: <https://doi.org/10.18653/v1/W18-6202>
- [42] T. Bourgeade, Z. Li, F. Benamara *et al.*, "Humans need context, what about machines? investigating conversational context in abusive language detection," in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. ELRA and ICCL, 2024, pp. 8438–8452. [Online]. Available: <https://aclanthology.org/2024.lrec-main.740/>
- [43] YouTube, "Política sobre desnudos y contenido sexual," Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>
- [44] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988. [Online]. Available: [https://doi.org/10.1016/0306-4573\(88\)90021-0](https://doi.org/10.1016/0306-4573(88)90021-0)
- [45] D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958. [Online]. Available: <https://doi.org/10.1111/j.2517-6161.1958.tb00292.x>
- [46] C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995. [Online]. Available: <https://doi.org/10.1007/BF00994018>
- [47] J. D. M. Rennie, L. Shih, J. Teevan *et al.*, "Tackling the poor assumptions of naive bayes text classifiers," in *Proceedings of the 20th International Conference on Machine Learning*, 2003, pp. 616–623. [Online]. Available: <https://people.csail.mit.edu/jrennie/papers/icml03-nb.pdf>
- [48] S. Deerwester, S. T. Dumais, G. W. Furnas *et al.*, "Indexing by latent semantic analysis," *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990. [Online]. Available: [https://doi.org/10.1002/\(SICI\)1097-4571\(199009\)41:6<391::AID-AS11>3.0.CO;2-9](https://doi.org/10.1002/(SICI)1097-4571(199009)41:6<391::AID-AS11>3.0.CO;2-9)
- [49] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001. [Online]. Available: <https://doi.org/10.1214/aos/1013203451>
- [50] A. Joulin, E. Grave, P. Bojanowski *et al.*, "Bag of tricks for efficient text classification," in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*. Association for Computational Linguistics, 2017, pp. 427–431. [Online]. Available: <https://doi.org/10.18653/v1/E17-2068>
- [51] J. Devlin, M.-W. Chang, K. Lee *et al.*, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Association for Computational Linguistics, 2019, pp. 4171–4186. [Online]. Available: <https://doi.org/10.18653/v1/N19-1423>
- [52] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence embeddings using siamese BERT-networks," in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Association for Computational Linguistics, 2019, pp. 3982–3992. [Online]. Available: <https://doi.org/10.18653/v1/D19-1410>
- [53] W. Wang, F. Wei, L. Dong *et al.*, "MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [54] N. Reimers and I. Gurevych, "Making monolingual sentence embeddings multilingual using knowledge distillation," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2020, pp. 4512–4525. [Online]. Available: <https://doi.org/10.18653/v1/2020.emnlp-main.365>
- [55] Sentence Transformers, "Model card: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2," Hugging Face Hub, 2026, checkpoint revision used: e8f8c211226b894fcb81acc59f3b34ba3efd5f42; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2/blob/e8f8c211226b894fcb81acc59f3b34ba3efd5f42/README.md>
- [56] L. Wang, N. Yang, X. Huang *et al.*, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://doi.org/10.48550/arXiv.2212.03533>
- [57] —, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://doi.org/10.48550/arXiv.2402.05672>
- [58] intfloat, "Model card: intfloat/multilingual-e5-small," Hugging Face Hub, 2026, checkpoint revision used: 614241f622f53c4eeff9890bdc4f31cfec418b3; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/intfloat/multilingual-e5-small/blob/614241f622f53c4eeff9890bdc4f31cfec418b3/README.md>
- [59] A. Yang, A. Li, B. Yang *et al.*, "Qwen3 technical report," *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://doi.org/10.48550/arXiv.2505.09388>
- [60] Qwen Team, "Model card: Qwen/Qwen3-0.6B-Base," Hugging Face Hub, 2025, checkpoint revision used: da87bfb608c14b7cf20ba1ce41287e8de496c0cd; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/Qwen/Qwen3-0.6B-Base/blob/da87bfb608c14b7cf20ba1ce41287e8de496c0cd/README.md>
- [61] E. J. Hu, Y. Shen, P. Wallis *et al.*, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>

- [62] G. Tsoumakas and I. Katakis, "Multi-label classification: An overview," *International Journal of Data Warehousing and Mining*, vol. 3, no. 3, pp. 1–13, 2007. [Online]. Available: <https://doi.org/10.4018/jdwm.2007070101>
- [63] M.-L. Zhang and Z.-H. Zhou, "A review on multi-label learning algorithms," *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014. [Online]. Available: <https://doi.org/10.1109/TKDE.2013.39>
- [64] C. N. J. Silla and A. A. Freitas, "A survey of hierarchical classification across different application domains," *Data Mining and Knowledge Discovery*, vol. 22, no. 1–2, pp. 31–72, 2011. [Online]. Available: <https://doi.org/10.1007/s10618-010-0175-9>
- [65] J. Zhou, C. Ma, D. Long *et al.*, "Hierarchy-aware global model for hierarchical text classification," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 1106–1117. [Online]. Available: <https://doi.org/10.18653/v1/2020.acl-main.104>
- [66] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009. [Online]. Available: <https://doi.org/10.1016/j.ipm.2009.03.002>
- [67] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://doi.org/10.1371/journal.pone.0118432>
- [68] J. Davis and M. Goadrich, "The relationship between precision-recall and ROC curves," in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240. [Online]. Available: <https://doi.org/10.1145/1143844.1143874>
- [69] scikit-learn developers, "scikit-learn average precision score api," scikit-learn API Reference, 2026, accessed: 2026-07-29. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html
- [70] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, A. J. Smola, P. L. Bartlett, B. Schölkopf *et al.*, Eds. Cambridge, MA, USA: MIT Press, 1999, pp. 61–74.
- [71] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning*. Association for Computing Machinery, 2005, pp. 625–632. [Online]. Available: <https://doi.org/10.1145/1102351.1102430>
- [72] C. Guo, G. Pleiss, Y. Sun *et al.*, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>
- [73] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>
- [74] C. K. Chow, "On optimum recognition error and reject tradeoff," *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970. [Online]. Available: <https://doi.org/10.1109/TIT.1970.1054406>
- [75] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
- [76] T. R. Gruber, "A translation approach to portable ontology specifications," *Knowledge Acquisition*, vol. 5, no. 2, pp. 199–220, 1993. [Online]. Available: <https://doi.org/10.1006/knac.1993.1008>
- [77] W3C OWL Working Group, "OWL 2 Web Ontology Language: Document overview (second edition)," World Wide Web Consortium, W3C Recommendation, Dec. 2012, 11 December 2012. [Online]. Available: <https://www.w3.org/TR/owl2-overview/>
- [78] A. Miles and S. Bechhofer, "SKOS simple knowledge organization system reference," World Wide Web Consortium, W3C Recommendation, Aug. 2009. [Online]. Available: <https://www.w3.org/TR/skos-reference/>
- [79] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg *et al.*, "The FAIR guiding principles for scientific data management and stewardship," *Scientific Data*, vol. 3, p. 160018, 2016. [Online]. Available: <https://doi.org/10.1038/sdata.2016.18>
- [80] yt-dlp contributors, "yt-dlp: A feature-rich command-line audio/video downloader," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/yt-dlp/yt-dlp>
- [81] J. Depoix and contributors, "YouTube Transcript API: Python api for retrieving youtube transcripts and subtitles," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/jdepoix/youtube-transcript-api>
- [82] Python Software Foundation, "unicodedata—unicode database," Python Standard Library Documentation, 2026, accessed Aug. 17, 2026. [Online]. Available: <https://docs.python.org/3/library/unicodedata.html>
- [83] Unicode Consortium, "Unicode normalization forms," Unicode Consortium, Unicode Standard Annex #15 Revision 57, Jul. 2025, ed. Ken Whistler; Unicode 17.0.0; Jul. 30, 2025. [Online]. Available: <https://www.unicode.org/reports/tr15/tr15-57.html>
- [84] DeepSeek, "DeepSeek V4 Preview Release," DeepSeek API Documentation, Apr. 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://api-docs.deepseek.com/news/news260424/>
- [85] —, "JSON Output," DeepSeek API Documentation, 2026, accessed: Aug. 8, 2026. [Online]. Available: https://api-docs.deepseek.com/guides/json_mode/
- [86] —, "Thinking Mode," DeepSeek API Documentation, 2026, accessed: Aug. 8, 2026. [Online]. Available: https://api-docs.deepseek.com/guides/thinking_mode/
- [87] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- [88] A. Paszke, S. Gross, F. Massa *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 8024–8035. [Online]. Available: <https://proceedings.neurips.cc/paper/2019/hash/bdbca288fee7f92f2bfa9f7012727740-Abstract.html>
- [89] T. Wolf, L. Debut, V. Sanh *et al.*, "Transformers: State-of-the-art natural language processing," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2020, pp. 38–45. [Online]. Available: <https://doi.org/10.18653/v1/2020.emnlp-demos.6>
- [90] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>
- [91] PyTorch contributors, "BCEWithLogitsLoss api," PyTorch documentation, 2026, accessed Jul. 29, 2026. [Online]. Available: <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>
- [92] L. Prechelt, "Early stopping—but when?" in *Neural Networks: Tricks of the Trade*, ser. Lecture Notes in Computer Science, G. B. Orr and K.-R. Müller, Eds. Berlin, Heidelberg: Springer, 1998, vol. 1524, pp. 55–69. [Online]. Available: https://doi.org/10.1007/3-540-49430-8_3
- [93] scikit-learn developers, "scikit-learn GroupKFold api," scikit-learn API Reference, 2026, accessed Jul. 29, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html
- [94] K. H. Brodersen, C. S. Ong, K. E. Stephan *et al.*, "The balanced accuracy and its posterior distribution," in *2010 20th International Conference on Pattern Recognition*. IEEE, 2010, pp. 3121–3124. [Online]. Available: <https://doi.org/10.1109/ICPR.2010.764>
- [95] L. Lam and C. Y. Suen, "Application of majority voting to pattern recognition: An analysis of its behavior and performance," *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997. [Online]. Available: <https://doi.org/10.1109/34.68.618255>
- [96] D. H. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992. [Online]. Available: [https://doi.org/10.1016/S0893-6080\(05\)80023-1](https://doi.org/10.1016/S0893-6080(05)80023-1)
- [97] M. J. van der Laan, E. C. Polley, and A. E. Hubbard, "Super learner," *Statistical Applications in Genetics and*

- Molecular Biology*, vol. 6, no. 1, 2007. [Online]. Available: <https://doi.org/10.2202/1544-6115.1309>
- [98] B. Efron, “Bootstrap methods: Another look at the jackknife,” *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979. [Online]. Available: <https://doi.org/10.1214/aos/1176344552>
- [99] C. A. Field and A. H. Welsh, “Bootstrapping clustered data,” *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007. [Online]. Available: <https://doi.org/10.1111/j.1467-9868.2007.00593.x>
- [100] R. Artstein and M. Poesio, “Inter-coder agreement for computational linguistics,” *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008. [Online]. Available: <https://doi.org/10.1162/coli.07-034-R2>
- [101] J. G. Moreno-Torres, T. Raeder, R. Alaiz-Rodríguez *et al.*, “A unifying view on dataset shift in classification,” *Pattern Recognition*, vol. 45, no. 1, pp. 521–530, 2012. [Online]. Available: <https://doi.org/10.1016/j.patcog.2011.06.019>
- [102] R. Dror, G. Baumer, S. Shlomov *et al.*, “The hitchhiker’s guide to testing statistical significance in natural language processing,” in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://doi.org/10.18653/v1/P18-1128>
- [103] a. s. franzke, A. Bechmann, M. Zimmer *et al.*, “Internet research: Ethical guidelines 3.0,” Association of Internet Researchers, Tech. Rep., 2020, approved by the AoIR membership Oct. 6, 2019. [Online]. Available: <https://aoir.org/reports/ethics3.pdf>
- [104] YouTube, “Terms of service,” YouTube official terms, Nov. 2023, effective Nov. 6, 2023; accessed Jul. 29, 2026. [Online]. Available: <https://www.youtube.com/t/terms>