

Moderacion Textual Local de Contenido en Videos Peruanos de YouTube

Grupo 4

Curso de Procesamiento de Lenguaje Natural

Maestria en Inteligencia Artificial, Universidad Nacional de Ingenieria

Koc Gongora, Luis Enrique; Mancilla Antay, Alex Felipe; Melendez Garcia, Herbert Antonio; Paitan Cano, Dennis Jack

Resumen—La revision manual de videos publicos en plataformas sociales requiere procesar gran volumen de texto, lenguaje local y expresiones ambiguas. Este trabajo propone un flujo local para moderacion textual de videos peruanos de YouTube basado en recoleccion sin APIs, limpieza, segmentacion en fragmentos, etiquetado humano y entrenamiento de un clasificador reproducible. El artefacto prioriza evidencia textual revisable y no reemplaza la decision humana. La propuesta se orienta a construir un corpus peruano inicial y un baseline local que permita evaluar categorias como contenido seguro, acoso, contenido sexual, racismo y riesgos contextuales.

Index Terms—Procesamiento de lenguaje natural, moderacion de contenido, clasificacion de texto, YouTube, corpus peruano.

I. INTRODUCCION

Los videos de YouTube concentran opinion politica, periodismo, entretenimiento, farandula y conversaciones informales. En el contexto peruano, la interpretacion automatica del texto puede ser dificil por modismos, ironia, apodos, referencias culturales y cambios de registro entre canales. Un clasificador generico puede identificar patrones de toxicidad, pero no necesariamente entrega evidencia suficiente para revisar casos locales.

Este trabajo aborda la construccion de un moderador textual local para videos publicos de YouTube. El sistema procesa titulos, descripciones, subtítulos o transcripciones, genera fragmentos auditables y sugiere categorias de moderacion. La salida debe apoyar revision humana mediante el fragmento activador, la categoria sugerida y un score interpretable.

Las contribuciones iniciales son: (i) un flujo reproducible sin APIs para preparar texto de videos publicos; (ii) una estructura de etiquetado humano para moderacion textual; (iii) un baseline local de clasificacion; y (iv) una regla de agregacion de riesgo por video basada en evidencia textual.

II. TRABAJO RELACIONADO

Los modelos Transformer han mejorado la representacion de lenguaje mediante preentrenamiento bidireccional, como BERT [1]. Para espanol, BETO ofrece una alternativa preentrenada sobre corpus en espanol [2]. En tareas de transcripcion, Whisper permite reconocimiento automatico de voz con un enfoque robusto de supervision debil [3].

La evaluacion de modelos de lenguaje no debe limitarse a exactitud global. CheckList propone pruebas de comportamiento para analizar capacidades, invariancias y casos limite [4]. En moderacion textual, los datasets de ataques personales

y lenguaje abusivo muestran que el etiquetado humano, la definicion de categorias y el sesgo del corpus son factores criticos [5], [6].

III. CORPUS Y RECOLECCION

El corpus se construye a partir de canales peruanos candidatos en politica, periodismo, humor, farandula y viajes. La diversidad de registros es necesaria para que el clasificador no aprenda solo lenguaje agresivo o solo lenguaje formal. La recoleccion se realiza con herramientas locales como `yt-dlp`, Selenium o parsers HTML cuando corresponda, sin usar APIs externas.

Cada registro debe conservar, como minimo, identificador de video, canal, URL, titulo, fecha, duracion, fuente del texto, estado de descarga y observaciones de descarte. Los canales sin URL oficial verificada se mantienen como candidatos y no entran a descarga automatica hasta documentar su fuente.

IV. METODO

La Fig. 1 resume el flujo propuesto. El texto se obtiene desde subtítulos disponibles o transcripcion local. Luego se normaliza, se segmenta en chunks y se entrega a un frontend HTML para etiquetado humano. La data etiquetada alimenta un baseline local con TF-IDF y un clasificador lineal. Si el corpus crece, se evalua una extension con BETO o RoBERTa.

IV-A. Categorias de Moderacion

La primera version usa pocas categorias para aumentar acuerdo entre anotadores. La Tabla I resume el conjunto minimo.

Tabla I
CATEGORIAS MVP DE MODERACION TEXTUAL

Categoria	Criterio breve
Seguro	Texto informativo, humor sin ataque directo o descripcion neutral.
Acoso Sexual	Insulto, burla, humillacion o ataque personal. Lenguaje sexual explicito, acoso sexual o insinuacion no pertinente.
Racismo	Ataque por origen, etnia, nacionalidad o color de piel.
Contexto sensible	Cita, ironia, parodia o noticia que requiere revision adicional.




Figura 1. Pipeline local para construir un corpus etiquetado y un clasificador de moderación textual con evidencia revisable.

IV-B. Agregación por Video

La unidad mínima de etiqueta es el chunk textual. El video se marca con riesgo si varios fragmentos superan el umbral de una categoría o si un fragmento crítico supera una probabilidad alta. La salida final debe incluir categoría, score, fragmentos activadores y evidencia textual.

V. EVALUACION

La evaluación se organiza en tres niveles. Primero, se mide acuerdo entre anotadores con Cohen's kappa sobre una muestra del corpus. Segundo, se entrena un baseline con división de entrenamiento, validación y prueba. Tercero, se analizan errores por categoría, canal y tipo de lenguaje.

Las métricas principales son F1 macro, precisión y recall por categoría. Debido al desbalance esperado, la exactitud global no debe ser la métrica central. La revisión manual de top-fragmentos permite verificar si la evidencia presentada por el sistema es útil para el moderador humano.

VI. DISCUSION

El artefacto tiene límites importantes. La moderación propuesta es textual, por lo que no evalúa imágenes, gestos o contexto visual. También puede fallar con ironía, sarcasmo, citas y referencias locales ambiguas. Por ello, la salida debe tratarse como alerta de priorización y no como sanción automática.

El sesgo por fuente es otro riesgo. Un corpus concentrado en pocos canales puede hacer que el clasificador confunda estilo de comunicación con categoría de riesgo. Para reducir este problema, la selección de fuentes debe mezclar registros formales, informales, humorísticos y descriptivos.

VII. CONCLUSIONES

Este trabajo propone una estructura inicial para construir un moderador textual local de videos peruanos de YouTube. La contribución principal es integrar recolección sin APIs, chunks auditable, etiquetado humano, entrenamiento local y evidencia revisable. Como trabajo futuro se plantea ampliar el corpus, mejorar la guía de anotación, calibrar umbrales y comparar el baseline con modelos Transformer en español.

REFERENCIAS

- [1] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of NAACL-HLT*, 2019, pp. 4171–4186. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [2] J. Canete, G. Chaperon, R. Fuentes, J.-H. Ho, H. Kang, and J. Perez, "Spanish pre-trained BERT model and evaluation data," in *PML4DC at ICLR*, 2020. [Online]. Available: <https://users.dcc.uchile.cl/~jperez/papers/pml4dc2020.pdf>
- [3] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, "Robust speech recognition via large-scale weak supervision," *arXiv preprint arXiv:2212.04356*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.04356>

- [4] M. T. Ribeiro, T. Wu, C. Guestrin, and S. Singh, "Beyond accuracy: Behavioral testing of NLP models with CheckList," in *Proceedings of ACL*, 2020, pp. 4902–4912. [Online]. Available: <https://aclanthology.org/2020.acl-main.442/>
- [5] E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*, 2017, pp. 1391–1399.
- [6] B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020.