

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora, Alex Felipe Mancilla Antay,
Herbert Antonio Meléndez García y Dennis Jack Paitán Cano
Maestría en Inteligencia Artificial, Universidad Nacional de Ingeniería

Curso de Procesamiento de Lenguaje Natural, Grupo 4, semestre académico 2026–1
Lima, Perú

luis.koc@gmail.com amancillaa@uni.pe
hamg.94@gmail.com dennis.paitan.c@uni.pe

Resumen—Revisar videos extensos de forma manual hace difícil localizar a tiempo el lenguaje dañino, sobre todo cuando los subtítulos contienen modismos, ironía, ruido y categorías poco frecuentes. Este trabajo diseña y evalúa, mediante ciencia del diseño, un moderador semiautomático para videos peruanos de YouTube. Los modelos generan un diagnóstico preliminar y señalan los intervalos con posibles daños; un supervisor conserva la decisión final. El corpus reúne 117 244 fragmentos de 3 230 videos públicos con subtítulos; 7 063 contienen algún daño después de la adquisición, segmentación y supervisión asistida por etapas. Una partición común agrupada por video permite comparar modelos clásicos, codificadores Transformer compactos y un modelo de lenguaje de gran escala (LLM), Qwen3–0.6B, ajustado mediante adaptación de bajo rango (Qwen3–LoRA). La evaluación abarca decisiones planas, en cascada y jerárquicas. En la prueba enriquecida a 20 % de daño, Qwen3–LoRA plano alcanza 0,55 de precisión promedio macro no interpolada y 0,52 de F1 macro; E5-small presenta el mayor recobrado de cualquier daño, 0,74. Una política de Qwen3–LoRA, calibrada en validación, envía el 97 % de los fragmentos dañinos a alerta o revisión y remite el 60 % del total al supervisor. Estas métricas corresponden al contrato ejecutado de cuatro salidas de daño con estado seguro derivado. La implementación reproducible posterior incorpora SEGURO como quinta salida aprendida y exclusiva; su rendimiento queda pendiente de reentrenamiento y recalibración. El sistema prioriza fragmentos, conserva evidencia temporal y deriva los casos inciertos. El bloqueo o la sanción automáticos quedan fuera del alcance evaluado.

Index Terms—moderación semiautomática, procesamiento del lenguaje natural, supervisión humana, clasificación multietiqueta, modelos de lenguaje de gran escala, Transformer, YouTube

I. INTRODUCCIÓN

La moderación de contenido no consiste solo en asignar una etiqueta. También determina qué se revisa primero, qué evidencia ve la persona moderadora y qué errores pueden pasar inadvertidos. A escala de plataforma, estas decisiones combinan reglas, trabajo humano y sistemas automáticos, con dificultades de contexto, transparencia y responsabilidad [1]. Los sistemas semiautomáticos permiten dirigir a revisión casos inciertos y reducir trabajo manual

[2]. En un video largo, además, una alerta necesita mostrar el fragmento y el instante que la originan.

Hoy, revisar manualmente miles de fragmentos dificulta localizar a tiempo los que merecen atención; se busca priorizarlos con rapidez sin perder el texto ni el instante que sustentan cada alerta. Esta tarea se complica por el español local, la ironía, las citas, los errores de subtítulo y el desbalance, que impiden decisiones simples y uniformes; estos obstáculos también aparecen en pruebas funcionales, estudios de sesgo lingüístico y análisis de subtítulos automáticos [3]–[5]. Además, el proyecto requiere una solución local y reproducible que integre datos, modelos, alertas, incertidumbre y corrección humana. La Fig. 1 organiza este problema mediante la condición observable, los factores que la sostienen y la capacidad técnica requerida. Esta organización es un marco analítico de los autores; no se atribuye como taxonomía a la metodología de ciencia del diseño.

Con este punto de partida, el estudio diseña, evalúa y empaqueta un moderador textual semiautomático para videos peruanos de YouTube. El artefacto compara alternativas de aprendizaje, prioriza daños con evidencia temporal y deriva a un supervisor las decisiones inciertas. Su propósito general es construir y evaluar esa solución mediante investigación de ciencia del diseño, o DSR por sus siglas en inglés [6], [7], y mantener trazabilidad entre la situación descrita, los datos, los experimentos y la operación.

El trabajo aporta cuatro resultados: 1) un corpus versionado de subtítulos públicos, enriquecido para daños minoritarios y separado por video; 2) una comparación común de modelos clásicos, Transformers compactos y el modelo de lenguaje de gran escala Qwen3–0.6B con estructuras planas y jerárquicas; 3) una política selectiva calibrada en validación, con carga de revisión y falsos negativos explícitos; y 4) un demostrador que acepta texto o una URL, conserva evidencia temporal, ofrece comparación o consenso 2 de 3 y registra correcciones para reentrenamiento. El sistema reduce el material que debe inspeccionar el supervisor y muestra dónde aparece el posible daño. La persona a cargo acepta, modifica o rechaza cada alerta. El bloqueo o la sanción sin revisión quedan fuera de la evaluación.




Figura 1. Problema estudiado en tres niveles. El estado deseado no es sancionar automáticamente, sino reducir la búsqueda y conservar una decisión humana informada. Elaboración propia.

II. BASES TEÓRICAS Y ANTECEDENTES

II-A. Moderación, datos y contexto

La moderación de una plataforma combina reglas, trabajo humano y sistemas automáticos. La predicción de un modelo no resuelve por sí sola la política, la interpretación ni la responsabilidad de una decisión [1]. La calidad de un clasificador de lenguaje abusivo depende de cómo se define el daño, cómo se toma la muestra y quién asigna las etiquetas; los errores de esas etapas pueden pasar al modelo [8]. Los *data statements* y las *data cards* proponen documentar el origen, el idioma, la recolección, la anotación, los usos previstos y los límites de un conjunto de datos [9], [10].

Los corpus previos muestran distintas formas de construir la tarea. Wulczyn *et al.* estudian ataques personales a gran escala [11]; HateXplain añade el blanco del abuso y explicaciones [12]; y HateCheck muestra que una métrica agregada puede ocultar fallas funcionales [3]. La literatura también muestra que las marcas de identidad o las variedades lingüísticas pueden confundirse con toxicidad [4]. En YouTube, un estudio analiza lenguaje abusivo en comentarios en inglés [13]; este trabajo, en cambio, usa subtítulos en español. Para español, HatEval [14], OffendES [15], DETOXIS [16] y EXIST [17] son antecedentes de odio, ofensa, toxicidad y sexismo. Ninguno forma parte del entrenamiento de este proyecto.

NaijaHate compara datos representativos con conjuntos enriquecidos y muestra que el desempeño y la carga de revisión pueden cambiar entre ambos regímenes [18]. Por eso, los resultados del test enriquecido del proyecto no se interpretan como prevalencia ni carga natural de YouTube. Los datos y el modelo de NaijaHate no forman parte del estudio.

Para ordenar el espacio de daño se parte de dos distinciones académicas. Waseem *et al.* separan el abuso dirigido a una persona o entidad del dirigido a un grupo, y el abuso explícito del implícito [19]. Banko *et al.* recomiendan categorías finas, criterios de inclusión y excepciones; su tipología distingue, entre otros, ataque por identidad, insulto, doxeo, agresión sexual y amenaza de violencia [20]. El proyecto combina estas distinciones generales con antecedentes sociales e institucionales pertinentes al contexto peruano.

II-A1. Aportes para la adaptación al contexto peruano: Para racismo y discriminación, Juan Carlos Callirgos examinó la construcción del otro en el racismo peruano, y Gonzalo Portocarrero relacionó racismo y mestizaje con prácticas e imaginarios sociales [21], [22]. Víctor Vich sintetizó la propuesta de Portocarrero mediante el fundamento invisible, el fantasma del patrón y la utopía del blanqueamiento, tres formas de explicar cómo la jerar-

quización persiste y cambia en el Perú [23]. Virginia Zavala y Roberto Zariquiey estudiaron la segregación discursiva justificada mediante supuestas carencias de educación o cultura, mientras el volumen editado por Virginia Zavala y Michele Back reunió análisis sobre los vínculos entre racismo y lenguaje [24], [25]. En espacios políticos y digitales, Virginia Zavala y Claudia Almeida mostraron que “motoso” y “terruco” pueden racializar y silenciar a actores políticos; Roberto Brañez Medina documentó el uso de la ortografía para construir las identidades “amixer” y “no-amixer” y justificar racismo cultural; y Verónica Salem describió cómo el insulto, la parodia, la ironía y el humor reproducen estereotipos raciales en Facebook [26]–[28]. Estos aportes orientaron las distinciones entre racismo étnico explícito, racialización lingüística, clasismo racial, discriminación regional y racismo encubierto.

Para género, Francisco Rodríguez-Sánchez y coautores aportan el esquema computacional de EXIST para identificar sexismo en redes, y Philine Zeinert, Nanna Inie y Leon Derczynski proponen criterios de anotación de misoginia en línea [17], [29]. Christian Monge-Olivarria, Juan Guerra-Corales y Fernando Bringas-Castro analizan la feminización como insulto y formas de acoso directo, invasión de privacidad y exclusión en Twitter; su estudio aporta mecanismos generales de violencia digital que complementan las fuentes locales [30]. En el ámbito peruano, Denisse Albornoz y Marieliv Flores caracterizan modalidades, consecuencias y respuestas frente a la violencia de género en línea, y la Defensoría del Pueblo sistematiza su tipología, impactos y vías institucionales de atención [31], [32]. Estas fuentes orientan misoginia/acoso de género y, junto con la tipología general, las distinciones sexuales explícitas, de cosificación y no consentidas.

Para orientación sexual e identidad de género, Bharathi Raja Chakravarthi construyó un corpus multilingüe de comentarios de YouTube y referencias de clasificación para homofobia y transfobia [33]. En Lima, Jan Marc Rottenbacher de Rojas relacionó conservadurismo e intolerancia a la ambigüedad con homofobia y prejuicio hacia grupos transgénero en una muestra universitaria [34]. Carolina Mirian Lovón-Cueva y Marco Lovón-Cueva identificaron en ciberforos peruanos un repertorio de lexemas lesbofóbicos y los interpretaron como violencia simbólica y actos de lenguaje de odio [35]. En conjunto, estas fuentes ofrecen un primer acercamiento al tratamiento del odio y la discriminación en entornos peruanos desde los estudios culturales, la sociolingüística, la psicología social, los estudios de género y la documentación institucional [25], [26], [31], [32], [34], [35]. Orientaron criterios de inclusión, exclusión y revisión; la cobertura exacta y los nombres finales constituyen una adaptación operacional del proyecto.

El odio implícito puede expresarse con lenguaje indirecto o codificado [36]; ironía y sarcasmo plantean una tarea específica de interpretación [37]; y un estudio peruano muestra insulto, parodia, ironía y humor en la construcción del estereotipo *amixer* [28]. La anotación de abuso también puede cambiar al disponer de mensajes circundantes [38]. Estos antecedentes motivan tres señales de revisión, distintas de las categorías de moderación. El informe sobre moderación en quechua documenta carencias de datos y capacidad de revisión para esa familia lingüística [39]; el corpus del proyecto se limita al español. Para contenido sexual, la tipología académica y las fuentes peruanas respaldan separar agresión sexual y difusión íntima no consentida [20], [31], [32]; la política de YouTube aporta la frontera operativa entre contenido explícito, sexualización no consentida y excepciones informativas o documentales [40]. En conjunto, estas fuentes sostienen una primera taxonomía operacional adaptada al estudio y preparada para validación experta posterior.

II-B. Modelos de texto y aprendizaje multitiqueta

II-B1. Modelos clásicos: TF-IDF representa cada texto mediante la frecuencia de sus términos y reduce el peso de los que aparecen en muchos documentos [41], [42]. Es rápido y conserva vocabulario visible, pero produce vectores dispersos y no modela el contexto. Sobre esos rasgos, la regresión logística estima una probabilidad mediante una frontera lineal; es eficiente y sus coeficientes son interpretables, aunque no capta relaciones no lineales sin crear nuevos rasgos [43]. La SVM busca un margen amplio entre clases y suele funcionar bien con texto disperso de alta dimensión; su salida no es una probabilidad y requiere calibración para interpretar el score [44]. Complement Naive Bayes corrige los conteos con información de las clases complementarias, lo que favorece datos textuales desbalanceados; su bajo costo se obtiene a cambio de una fuerte hipótesis de independencia entre rasgos [45].

La descomposición en valores singulares (SVD) proyecta TF-IDF a un espacio latente más pequeño [46]. Sobre esa proyección, *gradient boosting* combina árboles que corrigen errores sucesivos y puede modelar interacciones no lineales, pero aumenta el ajuste y pierde parte del detalle léxico [47]. *fastText* promedia representaciones de palabras y subpalabras antes de aplicar un clasificador lineal; las subpalabras ayudan ante variantes morfológicas y términos poco frecuentes, pero el promedio conserva poco orden y contexto distante [48].

II-B2. Transformers compactos: Los Transformers usan atención para representar cada token según los demás tokens del fragmento [49]; BERT establece el ajuste bidireccional de un modelo preentrenado para una tarea concreta [50]. Sentence-BERT obtiene un vector de oración que permite comparar y clasificar textos con menor costo que procesar cada par por separado [51]. MiniLM destila relaciones de autoatención de una red mayor y ofrece un codificador compacto [52]. El checkpoint multilingüe *sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2* transfiere ese espacio entre idiomas [53], [54]. Su ventaja es el equilibrio entre contexto y costo; sus

límites son la longitud finita de entrada y la pérdida de información al resumir el fragmento en un vector.

E5 aprende representaciones con contraste débilmente supervisado y separa consultas y textos mediante prefijos [55]. Su extensión multilingüe respalda *intfloat/multilingual-e5-small* y el prefijo *query*: usado en el proyecto [56], [57]. El entrenamiento contrastivo favorece similitud semántica con un tamaño moderado, pero el resultado depende del formato de entrada y el vector agrupado también actúa como cuello de botella.

II-B3. LLM Qwen3 con adaptación LoRA: Qwen3 es una familia de modelos de lenguaje autorregresivos con versiones densas y de mezcla de expertos, preentrenadas en varios idiomas [58]. El estudio usa el checkpoint denso *Qwen/Qwen3-0.6B-Base* por su escala, licencia e integración con Transformers [59]. Una cabeza multitiqueta convierte la representación final en scores de las categorías. LoRA introduce matrices de bajo rango en capas seleccionadas y permite ajustar una fracción pequeña de los parámetros [60]. Esta combinación ofrece más capacidad contextual que los modelos compactos, pero exige más memoria y tiempo, y sus scores todavía requieren calibración. *Qwen3-LoRA* designa este clasificador ajustado, no un sinónimo genérico de LLM.

El diseño experimental integra estas representaciones con las estructuras planas, en cascada y jerárquicas descritas en la metodología.

Un fragmento puede activar varias categorías de moderación, por lo que la tarea es multitiqueta [61], [62]. Las jerarquías pueden representar una puerta general y clases hijas [63]; los modelos conscientes de jerarquía motivan explotar dependencias entre etiquetas [64]. El aprendizaje multitarea puede compartir representaciones entre objetivos relacionados [65]. Sin embargo, esa estructura es una hipótesis a evaluar, no una garantía de mejora.

II-C. Selección, calibración y abstención

Precisión, recobrado y F1 resumen aspectos distintos de una matriz de confusión; ninguna medida basta para todos los tipos de clasificación [66]. En datos desbalanceados, las curvas precisión-recobrado describen la clase positiva de forma más informativa que las curvas ROC [67], [68]. El código usa *average_precision_score*: $AP = \sum_n (R_n - R_{n-1}) P_n$, donde P_n y R_n corresponden al umbral n [69]. El artículo la denomina *precisión promedio*; algunos artefactos preliminares usan el nombre PR-AUC, aunque calculan precisión promedio y no un área trapezoidal. Las salidas se calibran por etiqueta con regresión sigmoide [70], [71]; la calibración de redes modernas requiere comprobación empírica [72]. La regla de selección y los umbrales usan validación para limitar el sesgo de selección [73]. La exposición previa del test se trata como una limitación de validez.

Una clasificación selectiva puede abstenerse en casos dudosos [74], [75]; el aprendizaje con derivación extiende esa idea al decidir cuándo entregar el caso a una persona experta [76]. En la política del proyecto, el recobrado de enrutamiento es la fracción de chunks dañinos enviados a alerta o revisión; la precisión es la fracción dañina entre los enviados; la tasa de revisión es la fracción total enviada; y el valor predictivo negativo es la fracción realmente segura

entre los casos que permanecen en la ruta automática. El análisis también cuenta los falsos negativos. Estas definiciones se aplican al enrutamiento, no sustituyen las métricas por categoría ni la decisión del supervisor [66].

II-D. Ontología y trazabilidad terminológica

Una ontología explícita conceptos compartidos y sus relaciones [77]; OWL 2 formaliza clases, propiedades e individuos con significado definido [78]. El proyecto usa una ontología liviana para evitar que *etiqueta*, *predicción*, *alerta*, *seguro* y *decisión* se traten como sinónimos. La versión legible por máquina acompaña al artículo y define las relaciones necesarias para enlazar evidencia y artefactos versionados. Sus metadatos de trazabilidad aplican de forma parcial los principios FAIR de datos localizables, accesibles, interoperables y reutilizables [79]. El Apéndice D reúne el grafo y el vocabulario controlado que fijan esas relaciones.

III. PROBLEMAS Y OBJETIVOS

El problema general es la ausencia de una cadena local y reproducible que permita pasar de subtítulos públicos a alertas temporales comparables y, después, a una decisión humana informada. Cuatro problemas específicos vinculan esa situación con las acciones realizadas y con la evidencia que permite comprobar el cambio alcanzado.

Primero, el proyecto no cuenta con un corpus local versionado que conserve el texto, el intervalo temporal, la fuente, las categorías y la procedencia de cada etiqueta. Esta ausencia impide reconstruir qué observa cada modelo y comprobar que un mismo video no aparezca en entrenamiento y prueba. La definición del daño, el muestreo y la anotación condicionan el comportamiento posterior de los clasificadores de lenguaje abusivo [8]; además, los *data statements* y las *data cards* recomiendan documentar origen, recolección, anotación, usos y límites [9], [10]. Por ello se construye, depura y documenta un corpus de subtítulos públicos con particiones agrupadas por video. El corpus integrado, su manifiesto y la taxonomía verifican el artefacto de datos dentro del alcance del estudio.

Segundo, los resultados disponibles proceden de etapas y contratos distintos, por lo que no bastan para decidir qué familia o estructura separa mejor las categorías de moderación poco frecuentes. En conjuntos desbalanceados, las métricas agregadas pueden ocultar el desempeño de la clase positiva, y las curvas precisión-recobrado son más informativas para ese análisis que las curvas ROC [66], [67]. El objetivo consiste en entrenar y comparar modelos clásicos, MiniLM/E5 y el LLM Qwen3-0.6B en variantes planas, en cascada y jerárquicas, con una partición y un contrato comunes. La comparación común reduce la incertidumbre entre enfoques dentro de ese protocolo; confirmar la generalización requiere nuevas semillas y una cohorte temporal [73], [80].

Tercero, una etiqueta obligatoria oculta los casos dudosos y no muestra cuántos fragmentos debe revisar una persona ni cuántos daños quedan en la ruta automática. La clasificación selectiva permite abstenerse ante casos inciertos, y el aprendizaje para diferir extiende esa decisión al envío a una persona experta [74]–[76]. Por eso se establece como

objetivo calibrar los scores solo con validación y comparar candidatos al mismo recobrado de enrutamiento del 95 %, con precisión, tasa de revisión y falsos negativos. La política congelada, sus umbrales y la evaluación en test hacen verificable esa ruta de decisión: el sistema cuantifica la incertidumbre, los falsos negativos y la carga humana.

Cuarto, los modelos, las métricas y los archivos permanecen separados y no forman un artefacto que un supervisor pueda utilizar ni una memoria preparada para correcciones posteriores. DSR vincula la construcción de un artefacto con su demostración y evaluación iterativa [6], [7]; en moderación, además, la predicción automática no sustituye las reglas, el trabajo humano ni la responsabilidad sobre la decisión [1]. El objetivo consiste en empaquetar los modelos seleccionados, la evidencia temporal, el consenso, la revisión humana y el registro estadístico en un mismo flujo. El frontend 05, el registro de modelos, la base de datos y la ontología muestran que el prototipo integra los resultados en un flujo semiautomático trazable. Así se resuelve el aislamiento técnico en el nivel de demostrador; su eficacia bajo tráfico real todavía requiere un piloto supervisado.

La Tabla I resume esta relación entre los cuatro problemas, las acciones realizadas y la evidencia que permite comprobarlas.

IV. METODOLOGÍA

IV-A. Diseño de investigación

DSR busca construir y evaluar artefactos relevantes con rigor [6]. El estudio sigue las seis actividades de Peffers *et al.*: identificar la necesidad, definir objetivos, diseñar y desarrollar, demostrar, evaluar y comunicar [7]. La Fig. 2 muestra cómo cada evaluación alimenta una nueva iteración. Los cuadernos preliminares de Qwen con cinco categorías de moderación y de Transformers jerárquicos que no producen resultados se registran como diseños abandonados, no como experimentos ejecutados.

IV-B. Fuentes y criterios de selección


El universo de adquisición comprende videos públicos de YouTube vinculados con el contexto peruano. La búsqueda abarca registros políticos, periodísticos, humorísticos, de farándula, entretenimiento, deportes, gastronomía y viajes para no confundir un único estilo con daño. Un video es elegible si tiene subtítulos en español, al menos 200 caracteres útiles y metadatos suficientes para identificarlo. El corpus utilizado por los experimentos se reporta siempre mediante su total integrado final.

El corpus construido y utilizado en los experimentos corresponde al esquema 2.0 y al corte del 27 de julio de 2026. La Tabla II presenta sus totales finales. El Apéndice E detalla las fuentes, la procedencia de las etiquetas y los canales. Un manifiesto registra el hash SHA-256 del corpus, según el estándar de hash seguro [81], y la información necesaria para reconstruir la procedencia de cada fila. El corpus todavía no tiene DOI ni una licencia que autorice la redistribución de los textos.

La adquisición combina un catálogo de canales con búsquedas dirigidas a clases minoritarias. La muestra es intencional: prioriza fuentes con mayor rendimiento previo de categorías de moderación y consultas temáticas. La

Tabla I
SÍNTESIS DE PROBLEMAS, OBJETIVOS Y EVIDENCIA DE VERIFICACIÓN

	Problema específico	Objetivo específico	Evidencia de verificación
P1/O1	No existe un corpus local versionado y separado por video.	Construir y documentar el corpus integrado.	117 244 chunks, 3 230 videos, manifiesto, taxonomía y particiones agrupadas.
P2/O2	Falta una comparación común entre familias y estructuras.	Comparar clásicos, MiniLM/E5 y Qwen en diseños planos y estructurados.	14 configuraciones evaluadas sobre el mismo test activo de cuatro categorías.
P3/O3	Las decisiones forzadas ocultan incertidumbre, carga y omisiones.	Calibrar en validación y comparar al 95 % de recobrado de enrutamiento.	Umbrales congelados; precisión, revisión y falsos negativos reportados.
P4/O4	Los resultados no forman un flujo utilizable y reentrenable.	Integrar modelos, evidencia, consenso, revisión y registro.	Frontend 05, registro de modelos, base de datos y ontología.



Cada evaluación devolvió evidencia a la siguiente iteración; un resultado no ejecutado se conserva como plan, no como hallazgo.

Figura 2. Ciclo DSR y evidencia producida por las iteraciones del proyecto. Elaboración propia basada en las seis actividades de Peffers *et al.* [7].

Tabla II
TAMAÑO Y DISTRIBUCIÓN DEL CORPUS INTEGRADO FINAL

Componente	Total
Videos	3 230
Chunks (máx. observado: 170 palabras)	117 244
Etiquetas	
Seguro	110 181
Algún daño	7 063
RACISMO	1 856
ATAQUE-G/I	1 961
ACOSO-AMENAZA	3 028
SEXUAL	2 282

Nota: el máximo observado cuenta palabras separadas por espacios en el corpus final; la segmentación se cierra a los 30 segundos o 600 caracteres y no fija un máximo de palabras. Las cuatro categorías subordinadas son incidencias multietiqueta y no suman “algún daño”. ACOSO-AMENAZA es la unión de acoso personal y amenaza directa; 514 chunks contienen ambos subtipos. Los conteos proceden del corpus canónico.

selección informativa y el balance en aprendizaje activo son antecedentes generales [82], [83]; la regla concreta de búsqueda es una heurística del proyecto. El proceso excluye videos ya procesados, videos sin subtítulos, textos demasiado cortos, fallas de extracción y duplicados por `video_id` o hash normalizado. El análisis utiliza texto y metadatos, sin descargar audio ni imagen. La Tabla II reporta el corpus integrado final como una sola unidad.

El Apéndice E desagrega las categorías de fuente y la procedencia de las etiquetas. También presenta individualmente los canales con más de dos videos y agrupa los canales con uno o dos, cuyas direcciones permanecen en

los metadatos del corpus.

IV-C. Subtítulos, limpieza y chunks

La fuente textual comprende pistas de subtítulos públicas, manuales o automáticas según disponibilidad. La extracción usa VTT con `yt-dlp` [84] y, cuando hace falta, YouTube Transcript API [85]. El sistema intenta la familia `es-PE/es-419/es`; los manifiestos preservan el método, los identificadores y los hashes del resultado. El proyecto usa las pistas existentes y no realiza reconocimiento automático de voz propio.

La limpieza aplica normalización Unicode NFKC [86], unifica espacios y ajusta texto y tiempos. Antes de agrupar, elimina hasta 12 palabras repetidas entre segmentos VTT consecutivos. Después cierra cada chunk al alcanzar 30 segundos o 600 caracteres y exige al menos 90 caracteres. La regla de segmentación es propia del proyecto y genera chunks sin solapamiento intencional. Tras deduplicar y retirar decisiones no elegibles, el único total reportado para el corpus es el de la Tabla II.

IV-D. Taxonomía y evolución del contrato

El archivo `archivo/taxonomia_v1_3/para_equietado_LLM` conserva el paquete histórico de anotación manual o asistida: guía v1.3, taxonomía, instrucciones, entrada y ejemplos de salida. El vocabulario fino y los criterios operativos coinciden con las copias auditadas del proyecto. Para los lotes anotados por API, el sistema combinó el prompt compacto v1.1, la taxonomía completa y las reglas técnicas de salida; sus manifiestos conservan la versión del prompt. El Anexo A reproduce ese texto y delimita las corridas que acredita. La auditoría muestra 14 etiquetas finas: 12 fenómenos de daño y dos estados seguros, además

de tres flags transversales. La separación entre blanco individual/grupal y daño explícito/implícito sigue el marco de Waseem *et al.* [19]; las definiciones generales de ataque por identidad, doxeo, insulto, agresión sexual y amenaza se contrastan con Banko *et al.* [20]. La Tabla III documenta la adaptación y sus límites. No se atribuye a esos autores la lista exacta del proyecto.

La Fig. 3 sintetiza la relación entre categorías operativas, fenómenos finos, estados seguros y señales de revisión. La Fig. 4 enlaza esa taxonomía con la adquisición, la preanotación, la adjudicación y la evaluación; ambas se sitúan aquí para acompañar la primera explicación del método.

El contrato usado para los resultados de este artículo contiene cuatro salidas de daño: RACISMO, ATAQUE-G/I, ACOSO-AMENAZA y SEXUAL. ACOSO-AMENAZA une acoso personal y amenaza directa mediante OR/máximo: la amenaza directa tiene menor soporte (688 incidencias frente a 2854 de acoso personal), de modo que la unión aumenta el soporte, pero no establece equivalencia semántica o legal. En ese baseline, **SEGURO** se derivó cuando ninguna salida de daño cruzó su umbral.

El contrato reproducible v2.1 corrige esa asimetría: entrena cinco salidas desde el inicio, **SEGURO**, RACISMO, ATAQUE-G/I, ACOSO-AMENAZA y SEXUAL. La salida canónica **ATAQUE_POR_GENERO_IDENTIDAD** explicita que se clasifica daño dirigido por género, orientación o identidad; no presupone que todo caso sea acoso ni exige demostrar intención de odio. **SEGURO** tiene ejemplos, score, umbral y métricas propios y es mutuamente excluyente con cualquier daño; las cuatro salidas de daño siguen siendo multietiqueta. Un conflicto **SEGURO**+daño, ninguna salida o un score próximo al umbral obliga revisión. Los casos indeterminados usan `needs_review=true` y `training_eligible=false`; no forman una sexta clase ni se convierten en seguros. Esta revisión de contrato no altera retrospectivamente las métricas del baseline: requiere una cabeza nueva, reentrenamiento y recalibración.

La carpeta de diseño contiene la entrada, el esquema de salida y 60 casos de verificación que cumplen el formato previsto. La guía 1.3 se conserva como parte del protocolo de anotación y la Tabla III presenta por separado el sustento académico de las categorías.

En modelos clásicos y Transformers compactos, las finas y flags se reservaron para derivación o auditoría. En Qwen fueron objetivos auxiliares predichos desde texto, nunca variables *gold* entregadas como entrada. Las reglas que limitan confianza a 0,65 ante ironía/contexto y activan revisión por debajo de 0,70 también pertenecen al protocolo local; no son umbrales tomados de la literatura.

IV-E. Preanotación y adjudicación

El flujo completo combina preanotación, revisión dirigida y adjudicación. DeepSeek Flash realiza la preanotación amplia y DeepSeek Pro revisa de forma selectiva las propuestas con daño, baja confianza o flags, además de un control reproducible de seguros y negativos difíciles. Buscar rótulos posiblemente erróneos responde a un riesgo conocido [87], pero la minería concreta de este proyecto es

una auditoría heurística propia. Los casos todavía inciertos pasan a revisión final asistida.

La cola final presenta la propuesta de Pro durante la revisión y conserva la decisión resultante. La procedencia del corpus es 93 636 chunks Flash (80 %), 20 516 Pro o minería Pro (18 %) y 3 092 revisiones humanas asistidas (2,6 %); los porcentajes se redondean de forma independiente. La precedencia es revisión humana final > Pro de minería > Pro > Flash.

El Apéndice C muestra la vista final usada para contrastar el texto, su intervalo y la propuesta del LLM antes de aceptar, rechazar o modificar la decisión.

IV-F. Particiones y control contra fuga

Para la comparación común se conservan todos los casos con daño y cuatro seguros elegidos por hash por cada caso positivo. La muestra resultante contiene 20 % de daño y, por ello, no representa la distribución natural de la plataforma [18], [88]. Las particiones se forman por video con proporción 70/15/15, de modo que ningún video se comparte entre entrenamiento, validación y prueba [89]. Las puertas binarias incorporan negativos adicionales solo desde videos asignados a entrenamiento; las otras particiones no se reutilizan para ajustar modelos.

IV-G. Iteraciones preliminares de cinco categorías de moderación

La rama preliminar permite diagnosticar los datos y la arquitectura:

1. **Referencia clásica.** Un clasificador Dummy de scikit-learn [90], ComplementNB [45], regresión logística [43], SVM palabra-carácter [44] y *HistGradientBoosting* sobre SVD [46], [47] usan 48 927/10 633/10 293 chunks.
2. **Mejoras.** Nueve configuraciones probaron contexto concatenado, pesos de pseudoetiqueta, regularización, umbrales de alto recobrado y AEDA, que inserta signos de puntuación [91].
3. **Ampliación incremental.** Se comparó la misma SVM antes y después de añadir videos, con y sin AEDA.
4. **Clásicos optimizados y Transformers.** SVM, logística y fastText [48] pasaron una búsqueda agrupada; MiniLM [52] y E5 [55], [56] se ajustaron completamente durante hasta tres épocas con AdamW [92].
5. **Jerarquía clásica.** SVM y logística se evalúan como modelos planos, cascadas y jerarquías probabilísticas compartidas, con fastText como referencia plana. La jerarquía se examina como hipótesis basada en antecedentes de clasificación jerárquica [63].

Estas iteraciones no forman una única curva de aprendizaje porque cambiaron corpus y test. Sirven para explicar por qué se ampliaron datos, se consolidó la taxonomía y se probaron modelos contextuales.

IV-H. Baseline ejecutado de cuatro daños y contrato reproducible v2

La Fig. 5 organiza las familias. Los modelos clásicos combinan TF-IDF de palabras y caracteres con SVM




Figura 3. Contrato activo v2: **SEGURO** y cuatro categorías de daño se entrenan como cinco salidas; las 14 etiquetas finas y tres señales transversales se conservan. La fusión de acoso personal y amenaza es una decisión operativa, no una equivalencia legal. Elaboración propia informada por tipologías de abuso y contenido dañino [19], [20] y por fuentes peruanas citadas en la Tabla III.




Figura 4. Flujo de adquisición, preanotación, adjudicación y evaluación. La evaluación no retorna al corpus evaluado; la revisión operativa solo puede originar una versión futura y separada. Elaboración propia.

o regresión logística, y se evalúan en forma plana, con puerta en cascada y con jerarquía compartida. Sus scores se calibran con pliegues agrupados por video [93], mediante calibración sigmoide [70], [71].

La implementación combina scikit-learn para los modelos clásicos [90] y PyTorch con Transformers para las redes preentrenadas [94], [95]. Los cuadernos y manifiestos conservan las configuraciones completas para reproducción.

MiniLM y E5 se ajustan con AdamW durante un máximo de tres épocas y emplean parada temprana [92], [96]. Los checkpoints son `sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2` y `intfloat/multilingual-e5-small` [54], [57]; E5 conserva el prefijo de entrada indicado por su tarjeta. Los cuadernos, manifiestos y resultados conservados permiten reconstruir las configuraciones evaluadas.

Los modelos planos reportados parten de checkpoints ajustados en la rama preliminar de cinco categorías de daño. Para el baseline de cuatro daños, el proceso une acoso personal y amenaza directa y vuelve a estimar los umbrales. Las variantes E5 estructuradas parten del mismo linaje e incorporan una puerta o un objetivo multitarea

motivado por antecedentes de aprendizaje compartido y consistencia jerárquica [64], [65]. Esta procedencia se considera al comparar las configuraciones. El contrato v2 reutiliza encoders compatibles, pero crea una cabeza principal nueva de cinco salidas y recalibra sus cinco umbrales; no considera **SEGURO** como descarte.

El estudio selecciona **Qwen/Qwen3-0.6B-Base** como LLM por cuatro razones: es la escala densa de 0,6 mil millones de parámetros de la familia, Qwen3 declara preentrenamiento en 119 idiomas y dialectos, el checkpoint se publica con licencia Apache 2.0 y puede cargarse con Transformers [58], [59]. Su tamaño permite probar ajuste eficiente con el cómputo disponible. La elección responde a esas condiciones de ingeniería y no a una comparación entre familias de LLM.

Qwen3-0.6B se ajusta con LoRA, que modifica una fracción pequeña de los parámetros del modelo [60]. En el baseline ejecutado, una cabeza multitiqueta aprende cuatro daños junto con etiquetas finas y señales de revisión; el entrenamiento completa cuatro épocas con AdamW en CUDA [92]. Las variantes en cascada y multitarea se entrenan sobre las salidas congeladas de Qwen3-LoRA, sin

Tabla III
DEFINICIÓN Y SUSTENTO DE LA TAXONOMÍA OPERATIVA MULTIETIQUETA

Salida / señal	Etiquetas finas	Inclusión operacional y exclusiones	Antecedentes que orientan la decisión
RACISMO	racismo_etnico_explicito, racismo_linguistico, clasismo_racial, discriminacion_regional, racismo_encubierto	Ataque o inferiorización por identidad étnico-racial, origen regional, variedad lingüística o clase racializada; incluye formas encubiertas tras criterios de educación/cultura. Una mención identitaria, el español andino o una crítica no degradante no bastan.	Callirgos; Zavala y Zariquiey; Zavala y Back; Brañez; Zavala y Almeida; Salem; Portocarrero/Vich [21]–[28].
ATAQUE-G/I	misoginia_acoso_genero, homofobia_transfobia	Ataque, misoginia o machismo hostil, degradación sexualizada o exclusión por ser mujer, por género, orientación sexual, identidad o expresión. No activa por informar, apoyar o mencionar a una población. Puede coexistir con ACOSO-AMENAZA si además hay ataque interpersonal.	EXIST; Zeinert <i>et al.</i> ; Albornozy Flores; Defensoría; Chakravarthi; Rottenbacher; Lovón-Cueva y Lovón-Cueva [17], [29], [31]–[35].
ACOSO-AMENAZA	acoso_personal, amenaza_directa	Ataque dirigido a una persona identificable o exposición de datos privados; expresión de intención de daño físico y, por regla local, legal o económico. Una crítica aislada no degradante o una noticia que cita una amenaza sin respaldarla requiere contexto y no activa automáticamente.	Ataque dirigido, doxeo y amenaza [11], [19], [20], [32]. La extensión a daño legal/económico y la fusión son decisiones locales.
SEXUAL	sexual_explicito, sexual_cosificacion, sexual_no_consensual	Descripción sexual gráfica sin fin informativo, reducción de una persona a objeto sexual o referencia a material íntimo sin consentimiento. No toda mención sexual es daño; se excluye el uso educativo, periodístico, documental, científico o artístico cuando el contexto lo sustenta. El sistema observa texto, no desnudez visual.	Tipología de daño, misoginia, violencia peruana en línea y política de plataforma [20], [29], [31], [32], [40].
SEGURO	seguro, seguro_ironia_marcada	Categoría aprendida, mutuamente excluyente con daño. El segundo estado fino exige que la ironía tenga por blanco una institución, política o situación y no ataque a una persona o grupo protegido. Una lista de daños vacía no basta para asignarla.	Regla operacional del proyecto; no es una categoría experta ni legal.
Flags	ironia_ambigua, humor_encubridor, contexto_necesario	Señalan sentido incierto, humor que acompaña daño o evidencia insuficiente en el chunk. Solo se conservan junto a un daño sustentado y activan revisión humana; no son clases de daño.	Abuso implícito, ironía, humor racializado y dependencia del contexto [19], [28], [36]–[39].

repetir el ajuste completo del LLM. La implementación v2 define una cabeza de cinco salidas y entrenamiento reanudable en CPU, CUDA, ROCm o XPU; sus métricas no se reportan hasta ejecutar el nuevo protocolo.

Las redes usan entropía cruzada binaria con ponderación de clases calculada en entrenamiento [97]. Los umbrales por categoría se eligen en validación para maximizar F1 [66]. Qwen completa cuatro épocas para comparar checkpoints, mientras los Transformers compactos usan parada temprana [96].

IV-I. Indicadores de evaluación

La evaluación usa precisión, recobrado, F1 y precisión promedio (AP) porque describen aspectos distintos de una clasificación con categorías poco frecuentes [66], [67]. Para una categoría, la precisión $TP/(TP + FP)$ indica qué fracción de las alertas es correcta; una precisión baja aumenta

la revisión innecesaria. El recobrado $TP/(TP + FN)$ indica qué fracción de los casos positivos se detecta; es central cuando omitir un caso dañino tiene mayor costo. F1 es la media armónica de precisión y recobrado, $2PR/(P + R)$, y resume su equilibrio para un umbral concreto [66].

La precisión promedio resume la curva precisión–recobrado a través de los umbrales: $AP = \sum_n (R_n - R_{n-1})P_n$ [69]. A diferencia de F1, no depende de un único corte y permite valorar el orden de los scores. Las curvas precisión–recobrado son más informativas que ROC cuando la clase positiva es escasa [67], [68]. El promedio macro calcula cada indicador por categoría y luego les asigna el mismo peso; así, una categoría frecuente no oculta el desempeño de otra con menor soporte. Ningún indicador basta por sí solo: AP guía la selección en validación, F1 compara decisiones umbralizadas y el recobrado, la




Figura 5. Familias y estructuras evaluadas en el baseline de cuatro daños. El contrato v2 conserva las familias y sustituye la cabeza principal por cinco salidas. Elaboración propia.

precisión, la tasa de revisión y los falsos negativos describen la utilidad del enrutamiento humano.

IV-J. Protocolo de selección y evaluación

El criterio principal es AP macro de las cuatro categorías de moderación en validación; los umbrales por clase también se fijan allí. La regla de selección usa métricas de validación. Una evaluación previa de la época 2 sobre test impide tratar la comparación final como ciega y se considera al interpretar sus resultados. Para las diferencias pareadas preliminares, el análisis remuestrea videos completos como conglomerados en 1000 réplicas bootstrap [98], [99]. Este análisis mide variación entre videos, no entre semillas.

Para Qwen, cada checkpoint candidato produce cuatro logits. En validación se ajusta una regresión logística univariada por etiqueta como escalamiento de Platt; sobre esos scores se fijan los cuatro umbrales y un corte del margen de riesgo para enrutamiento humano [70], [71]. La misma validación sirve para calibrar y seleccionar, sin una partición anidada. La evaluación final de la época 3 se ejecuta después de congelar adaptador, calibradores, umbrales y corte. La exposición previa del test en la época 2 se considera al interpretar el resultado.

Para Qwen, la regla automática compara los dos mejores checkpoints usando solo validación y el mismo objetivo de 95 % de recobrado de enrutamiento. Elige el que alcanza el objetivo con menor tasa de revisión y, luego, mayor precisión. La época 2 maximiza AP, mientras la regla selectiva elige la época 3 para la operación.

IV-K. Artefacto de demostración

El cuaderno histórico 05 construyó una carpeta desplegable con el mejor clásico, el mejor Transformer compacto y el Qwen operativo, además del backend, HTML, ayudas y base de datos. Una sola caja detecta frase o URL. Una URL sin subtítulos se rechaza; si es válida, se generan chunks con tiempos, se incrusta el video y cada alerta enlaza el instante problemático. La pantalla permite un modelo individual, comparación o consenso. Una categoría se activa con al menos dos de tres votos, no por unanimidad. Todo desacuerdo se deriva a revisión. Los conjuntos de clasificadores y el voto mayoritario tienen antecedentes propios [100], [101], pero la regla 2 de 3 es una decisión

operacional de este prototipo y aún debe evaluarse. El frontend activo se orquesta desde `flujo/04_produccion/04_01_frontend_produccion.ipynb` y no habilita inferencia v2 sin un registro de modelo compatible.

Las decisiones *aceptar*, *rechazar* o *modificar*, junto con modelo, categoría, versión y evidencia, se almacenan en una base SQLite y en registros JSONL versionados. Estos formatos permiten calcular estadísticas y preparar futuros lotes de reentrenamiento. El sistema es un demostrador local o para modo sombra; no una autorización para afectar usuarios.

La Fig. 6 resume la separación entre preparación, inferencia, consenso y decisión humana. El Apéndice C muestra el demostrador después de analizar un chunk real de validación con puntuación alta de daño.

V. RESULTADOS

Todos los valores de esta sección corresponden al corte ejecutado de cuatro salidas de daño con **SEGURO** derivado. El contrato v2 de cinco salidas aprendidas se documenta como implementación posterior y no hereda estas métricas.

V-A. Resultado de construcción del corpus

La construcción produce el corpus resumido en la Tabla II. La Fig. 4 integra adquisición, segmentación, supervisión escalonada y separación por video; el Apéndice E desagrega la composición y la procedencia de las etiquetas. En conjunto, estos resultados muestran un corpus trazable y una comparación sin videos compartidos entre particiones. La muestra enriquecida sirve para comparar modelos, no para estimar la prevalencia natural de YouTube.

V-B. Herramientas y entorno de cómputo

La Tabla IV distingue las etapas ejecutadas en una computadora de consumo de las realizadas en Google Colab. La adquisición, la preparación y los modelos clásicos se ejecutan localmente; los Transformers activos y las últimas épocas de Qwen3-LoRA usan CUDA en una GPU NVIDIA L4 según la bitácora del equipo. Las herramientas principales son Jupyter y pandas para el flujo de datos, scikit-learn y fastText para los modelos clásicos, y PyTorch, Transformers y PEFT/LoRA para los neuronales [48], [60], [90], [94], [95], [102], [103]. La tabla conserva el detalle




Figura 6. Arquitectura operacional del demostrador. El consenso es 2 de 3 y la decisión humana queda separada de la predicción. Elaboración propia.

suficiente para distinguir recursos y alcance sin tratar estas ejecuciones como un benchmark de hardware.

En este artículo, *recursos asequibles* significa que el equipo no necesita poseer una GPU de centro de datos: combina una computadora de consumo con sesiones bajo demanda de Colab y produce un paquete de inferencia compatible con CPU. El estudio no mide el costo monetario total, el consumo energético ni la latencia en el equipo objetivo; por ello esta formulación no implica que Colab sea gratuito, garantizado o la opción más barata.

V-C. Resultados preliminares y baseline de cuatro daños

La primera iteración compara cinco categorías de moderación: RACISMO, ATAQUE-G/I, acoso personal, amenaza directa y SEXUAL. Una referencia que siempre predice seguro alcanza 0,95 de coincidencia exacta, pero su recobrado de cualquier daño es cero; este contraste confirma que la coincidencia agregada oculta la clase minoritaria en datos desbalanceados [66], [67]. La SVM inicial obtiene $AP = 0,23$ y $F1$ macro de 0,28. En otro corte 4:1, no comparable de forma directa, MiniLM y E5 alcanzan AP de 0,46 y 0,44. AEDA y el contexto concatenado no muestran una mejora consistente. Estos resultados preliminares orientan la ampliación del corpus y el uso de modelos contextuales, pero no forman una sola curva de aprendizaje porque cambian los datos y las particiones.

La amenaza directa reúne 688 incidencias frente a 2854 de acoso personal. Para aumentar el soporte de la salida menos frecuente y mantener una comparación operativa estable, el contrato ejecutado unió ambas salidas mediante OR/máximo en ACOSO-AMENAZA. Esta fusión redujo de cinco a cuatro daños y conservó los subtipos para auditoría. Es una decisión estadística y operativa del proyecto; no establece equivalencia semántica o legal entre acoso y amenaza. El contrato v2 mantiene la unión, añade **SEGURO** como salida aprendida y queda pendiente de evaluación.

V-D. Comparación final de cuatro categorías de moderación

La Tabla V contiene las 14 configuraciones sobre el mismo test enriquecido 4:1 de 5290 chunks. Qwen3-LoRA plano presenta la mayor estimación puntual de AP y $F1$; E5 plano lidera el recobrado de cualquier daño y deja 42 chunks dañinos menos como **SEGURO**. Ningún diseño

jerárquico supera a su referencia plana en las tres métricas principales, aunque alguna puerta eleva la precisión a costa del recobrado. La auditoría fina cubre 13 modelos porque excluye la referencia E5 *post hoc*; esa es la diferencia entre 13 modelos auditados y 14 filas comparadas. Confirmar una diferencia estadística entre Qwen3-LoRA y E5 requiere varias semillas y una prueba pareada final [80].

La Tabla VI aplica el mismo criterio por categoría: selecciona el modelo mediante AP en validación y consulta el test solo después de congelar esa elección. Qwen3-LoRA plano resulta ganador en RACISMO, ATAQUE-G/I y ACOSO-AMENAZA; la cabeza multitarea entrenada sobre sus salidas congeladas obtiene el mayor AP de validación en SEXUAL. Esta diferencia muestra que el mejor promedio general no tiene que dominar cada categoría.

Tabla IV
HERRAMIENTAS Y RECURSOS DE CÓMPUTO ACREDITADOS POR ETAPA

Etapa	Herramientas principales	Entorno	Resultado / alcance
Adquisición y corpus	Python/Jupyter, <code>yt-dlp</code> , YouTube Transcript API y pandas	Equipo local Windows	Corpus integrado final
Etiquetado asistido	DeepSeek Flash/Pro; prueba local LM Studio/ <code>llama.cpp</code>	Orquestación local; servicio DeepSeek remoto de hardware desconocido; prueba local en CPU	Tres niveles: Flash → Pro → revisión final asistida; el modelo local fue exploratorio
Clásicos y rama preliminar	scikit-learn, fastText, joblib; PyTorch 2.6.0+cpu	Ryzen 7 8845HS, 8C/16T, 29 GiB; CPU, sin CUDA	SVM, regresión logística y experimentos preliminares de cinco categorías
Transformers activos	PyTorch, Transformers, NumPy y pandas	Google Colab con CUDA; NVIDIA L4 según bitácora	MiniLM/E5 planos y estructurados
Qwen3-LoRA	Transformers, PEFT/LoRA y PyTorch	Primeras épocas en CPU local; últimas épocas en Colab/CUDA	Adaptador compacto; época 3 seleccionada para operación
Auditoría y paquete	SciPy/scikit-learn, NumPy, SQLite, HTML/JavaScript	Equipo local; inferencia empaquetada compatible con CPU	Comparación, métricas, trazabilidad y frontend con retroalimentación

Tabla V
COMPARACIÓN FINAL SOBRE TEST COMÚN ENRIQUECIDO 4:1 DE CUATRO CATEGORÍAS DE MODERACIÓN

Modelo y estructura	AP macro de daños	F1 macro de daños	Recobrado de algún daño	Daños como SEGURO
Qwen3-0.6B LoRA, época 3				
<i>Plana</i>	0,55	0,52	0,70	312
Qwen3-LoRA congelado				
<i>Cascada calibrada</i>	0,54	0,52	0,63	385
Qwen3-LoRA congelado				
<i>Cabeza multitarea</i>	0,53	0,52	0,64	375
E5 preliminar unido 5→4				
<i>Referencia post hoc</i>	0,49	0,52	0,64	378
MiniLM multilingüe				
<i>Plana</i>	0,48	0,50	0,65	362
E5-small multilingüe				
<i>Plana</i>	0,48	0,52	0,74	270
SVM palabra + carácter				
<i>Plana calibrada</i>	0,45	0,46	0,59	428
SVM calibrada				
<i>Cascada</i>	0,44	0,45	0,54	481
Regresión logística calibrada				
<i>Plana</i>	0,44	0,46	0,62	395
SVM calibrada				
<i>Jerarquía compartida</i>	0,43	0,42	0,43	591
Regresión logística calibrada				
<i>Cascada</i>	0,43	0,43	0,59	431
E5				
<i>Cascada Transformer</i>	0,42	0,41	0,36	666
E5				
<i>Jerarquía multitarea</i>	0,41	0,42	0,40	629
Regresión logística calibrada				
<i>Jerarquía compartida</i>	0,41	0,41	0,45	575

Tabla VI
GANADOR POR CATEGORÍA SELECCIONADO MEDIANTE AP EN VALIDACIÓN Y DESEMPEÑO CONGELADO EN EL TEST COMÚN

Categoría	Modelo seleccionado	AP validación	AP test	Precisión test	Recobrado test	F1 test
RACISMO	Qwen3-LoRA plano	0,63	0,56	0,52	0,59	0,56
ATAQUE-G/I	Qwen3-LoRA plano	0,46	0,48	0,39	0,52	0,45
ACOSO-AMENAZA	Qwen3-LoRA plano	0,45	0,48	0,43	0,57	0,49
SEXUAL	Qwen3-LoRA, cabeza multitarea congelada	0,63	0,66	0,62	0,62	0,62

La Fig. 7 concentra los ganadores desplegables por familia y hace visible la compensación principal: Qwen3-LoRA encabeza AP y F1, mientras E5 recupera una mayor fracción de chunks con daño.

En Qwen3-LoRA, la época 2 presenta el máximo AP de validación (0,54). La época 3 queda a 0,00072, mantiene 0,95 de recobrado selectivo y los mismos 53 falsos negativos, pero eleva la precisión de 0,30 a 0,32 y reduce la revisión de 64 % a 61 %. La regla selecciona la época 3 usando únicamente esos valores de validación; aun así, la selección no es ciega porque ya existe la evaluación de test de la época 2.

Con ese corte, la política selectiva cumple el propósito de alto recobrado: obtiene en test 0,97 (IC95 % de Wilson 0,96–0,98 [104]), con 0,32 de precisión, 0,99 de valor predictivo negativo y 28 falsos negativos automáticos. Remite 60 % de los chunks al supervisor y excede en 0,40 puntos porcentuales el control de tasa de revisión ≤ 60 %, la única puerta no satisfecha. La cifra convierte el resultado en una carga humana explícita para un piloto semiautomático, en lugar de ocultarla detrás del recobrado.

La Tabla VII desagrega el desempeño ordinario de Qwen3-LoRA. Contenido sexual presenta el mayor F1 y ataque por género/identidad el menor, lo que impide resumir la utilidad del modelo con una sola métrica macro.

El Anexo B muestra extractos de tres chunks con valoración segura muy alta y tres por cada daño grueso. Son ilustraciones *post hoc* de validación y no casos de prueba ni evidencia adicional de desempeño. En cada daño se informa el score calibrado de su salida; para los casos seguros se informa una medida descriptiva derivada, $1 - \max_k s_k$, porque **SEGURO** no es una quinta cabeza aprendida.

V-E. Jerarquía, fenómenos finos y lectura cualitativa

La mejor variante jerárquica de Qwen3-LoRA es la cabeza conjunta: frente al plano cambia AP en $-0,017$, F1 en $-0,0077$, recobrado en $-0,061$ y añade 63 chunks con daño clasificados como **SEGURO**. En clásicos y E5 aparece el mismo patrón general: una puerta puede elevar precisión




Figura 7. Ganador desplegable de cada enfoque. Qwen3-LoRA presenta las mayores estimaciones puntuales de ranking y F1; E5 recupera más daños. Elaboración propia desde la comparación final.

Tabla VII
DESEMPEÑO ORDINARIO DE QWEN3-LoRA PLANO POR CATEGORÍA

Categoría	Precisión	Recobrado	F1
RACISMO	0,52	0,59	0,56
ATAQUE-G/I	0,39	0,52	0,45
ACOSO-AMENAZA	0,43	0,57	0,49
SEXUAL	0,63	0,59	0,61

al filtrar casos, pero también impide que una categoría hija recupere un positivo rechazado antes. En este corpus, las jerarquías no reemplazan a los modelos planos.

La auditoría por fenómeno revela dónde se pierde información. Qwen3-LoRA obtiene recobrado 0,70 en racismo étnico explícito ($n = 128$), 0,46 en racismo encubierto ($n = 44$), 0,33 en racismo lingüístico ($n = 6$), 0,65 en acoso personal ($n = 326$), 0,64 en amenaza directa ($n = 103$) y 0,11 en contenido sexual no consensual ($n = 9$). En misoginia/acoso de género obtiene 0,47 ($n = 159$); la especificidad de ironía segura marcada es 0,72 ($n = 36$). Los soportes pequeños impiden inferencias estables, pero orientan nueva anotación.

Una inspección exploratoria identifica cuatro situaciones recurrentes: 1) una noticia cita una amenaza; 2) el sentido depende del fragmento anterior o de una imagen; 3) la ironía y el humor encubren el blanco; y 4) las expresiones locales raras tienen poco soporte. DeepSeek Pro propone daño en 245 de los 2000 seguros más sospechosos (12 %), por lo que la depuración dirigida localiza casos útiles para revisión. Estas observaciones orientan nuevas muestras y una ablación con la misma arquitectura y semilla.

VI. DISCUSIÓN

VI-A. Capacidad tecnológica conseguida

El artefacto aporta la capacidad antes ausente: transforma una frase o un video con subtítulos en chunks trazables, compara tres enfoques, enlaza alertas con tiempos y registra correcciones. El clasificador Qwen3-LoRA, basado en un LLM, presenta la mayor estimación puntual de AP y F1; E5 presenta el mayor recobrado de cualquier daño bajo los umbrales ordinarios; SVM ofrece una referencia más

pequeña. La elección depende del costo de falsos negativos, revisión y cómputo. Además, las métricas agregadas no sustituyen las pruebas por fenómeno: trabajos como Hate-Check y los análisis de sesgo de Sap *et al.* muestran por qué conviene examinar conductas y grupos concretos [3], [4].

La fusión operativa de acoso personal y amenaza directa aumenta el soporte y simplifica el contrato, pero pierde granularidad y no establece equivalencia conceptual o legal. Las etiquetas finas preservan esa distinción para auditoría y Qwen3-LoRA, aunque no deben presentarse como salidas operativas validadas. Del mismo modo, el consenso 2 de 3 es una regla implementada, no una mejora demostrada: necesita evaluación prospectiva.

VI-B. Alcance operativo conseguido y camino a producción

El artefacto puede ensayarse fuera de línea o en modo sombra—sin actuar sobre usuarios—como moderador semiautomático: prioriza fragmentos, muestra el instante y el texto que originan cada alerta y entrega un diagnóstico preliminar a un supervisor. Este reparto entre modelo y persona es coherente con sistemas de moderación asistida y aprendizaje para diferir decisiones inciertas [2], [76]. La política selectiva presenta en la Sección VI una cobertura alta junto con su carga de revisión. Esa capacidad se consigue con modelos compactos, entrenamiento combinado entre CPU de consumo y Colab/CUDA, y un paquete de inferencia compatible con CPU; por ello el artefacto puede ensayarse sin poseer infraestructura GPU de centro de datos.

La derivación de seis de cada diez chunks cuantifica la capacidad humana que ese ensayo debe prever. Su recobrado corresponde al *enrutamiento*, no al acierto en cada categoría; la Tabla V muestra el desempeño ordinario por separado. El test es enriquecido y sus rótulos son mayormente asistidos, por lo que todavía no estima prevalencia ni carga natural de YouTube; el cambio entre una muestra construida y la distribución de uso puede alterar el desempeño [18], [105]. El siguiente paso es un piloto prospectivo supervisado que mida latencia, costo, capacidad de revisión, seguridad y deriva en el hardware objetivo. El bloqueo, la sanción o la aprobación sin intervención humana no forman parte del propósito ni del alcance validado; la moderación que afecta usuarios requiere además reglas de gobierno y rendición de cuentas [1].

VII. LIMITACIONES Y TRABAJO FUTURO

Las limitaciones centrales corresponden a tres aspectos que todavía condicionan el alcance de la solución.

1. **Corpus y categorías.** El muestreo dirigido permite entrenar con categorías poco frecuentes, pero no estima su prevalencia ni la carga de revisión en YouTube. Una nueva cohorte temporal, recogida en condiciones naturales y sometida a doble revisión independiente, permitirá medir el acuerdo, comprobar la estabilidad de las categorías y ampliar fenómenos locales con poco soporte [3], [105], [106].
2. **Comparación y calibración.** La comparación común se basa en una ejecución por modelo y en un

test consultado durante iteraciones previas. La generalización y la ventaja entre familias deben confirmarse mediante varias semillas, una partición independiente para calibración, comparaciones pareadas por video y un test temporal no utilizado durante el desarrollo [73], [80], [99].

3. **Operación semiautomática.** La evaluación selectiva se realiza fuera de producción y solo sobre texto de videos con subtítulos; por tanto, todavía no establece la carga real del supervisor ni el efecto de cambios en el contenido. Un piloto en modo sombra debe medir falsos negativos, consenso 2 de 3, capacidad de revisión, deriva, latencia, privacidad y seguridad, manteniendo la decisión final bajo control humano [1], [5], [107].

VIII. CONCLUSIONES

El trabajo construye y evalúa un moderador semiautomático que localiza fragmentos con posibles daños, conserva el instante y el texto que sustentan cada alerta y entrega la decisión final a un supervisor. Esta capacidad se obtiene con una computadora de consumo, sesiones de Colab y un paquete de inferencia compatible con CPU. Por ello, la distancia inicial entre revisar videos completos y contar con un diagnóstico preliminar localizado se reduce de forma sustancial, aunque no desaparece la necesidad de revisión humana.

El corpus documentado en la Tabla II, con fuentes, precedencia de etiquetas y partición por video, resuelve la ausencia de datos locales organizados dentro del alcance experimental. La comparación común también se resuelve para el test disponible: Qwen3-LoRA plano presenta las mayores estimaciones puntuales de AP (0,55) y F1 (0,52), mientras E5 plano alcanza el mayor recobrado de cualquier daño (0,74). Las cascadas y jerarquías no mejoran de forma consistente sus referencias planas. Estas conclusiones comparativas no eliminan la incertidumbre fuera de la muestra enriquecida ni sustituyen nuevas semillas y una cohorte temporal independiente.

La calibración en validación y un enrutamiento común de alto recobrado establecen una regla explícita para derivar casos inciertos. Qwen3-LoRA envía a alerta o revisión 97 % de los chunks dañinos y deja 28 en la ruta automática segura; al mismo tiempo, remite 60 % del total al supervisor. Estas dos cantidades delimitan el equilibrio alcanzado entre falsos negativos y carga de revisión.

El prototipo resuelve el aislamiento entre resultados experimentales y uso práctico dentro de su nivel de demostración: una sola interfaz acepta texto o URL, presenta evidencia temporal, compara tres enfoques, aplica consenso 2 de 3, registra correcciones y conserva datos para análisis posterior. Falta demostrar su desempeño en operación natural; por eso no corresponde usarlo para bloquear, sancionar o aprobar contenido sin intervención humana.

Las acciones prioritarias son construir una cohorte temporal en condiciones naturales con doble revisión para comprobar las categorías, repetir la comparación y la calibración con varias semillas y un test no utilizado durante el desarrollo, y ejecutar un piloto en modo sombra. Ese piloto debe medir falsos negativos, consenso, capacidad

de revisión, deriva, latencia, privacidad y seguridad antes de ofrecer acceso externo o iniciar ciclos de reentrenamiento.

Como resultado de la auditoría de reproducibilidad, el flujo activo queda organizado en cuatro etapas incrementales y adopta cinco salidas entrenadas: **SEGURO** y cuatro daños. Esta decisión corrige el uso previo de seguro como complemento, pero no constituye un resultado comparativo nuevo. La aceptación del contrato v2 exige reentrenar la cabeza, recalibrar los cinco umbrales y reportar desempeño por salida, falsos seguros, conflictos y carga de revisión.

DISPONIBILIDAD Y ÉTICA

Los datos, cuadernos, scripts, documentación y artefactos entrenados están disponibles en https://github.com/lkoc/Trabajo_PLN-MIA-Grupo4 y en el repositorio de Google Drive con acceso controlado; el Apéndice F resume su contenido, formato y condiciones de reutilización. Los textos proceden de subtítulos públicos; toda redistribución debe revisar licencias, términos de plataforma, privacidad y derechos sobre los subtítulos [107], [108]. Antes de abrir el corpus también corresponde documentar la evaluación ética institucional. En coherencia con el alcance semiautomático, una alerta informa al supervisor y la decisión final permanece bajo control humano.

APÉNDICE A

PROMPT OPERATIVO DE ETIQUETADO POR API

El texto siguiente es una transcripción estructurada y completa del prompt histórico v1.1, preservado en `archivo/contrato_4_danos_seguro_derivado/03_2_etiquetado_llm_api/`. Una copia idéntica reside en el archivo de la implementación local anterior. El prompt declara que compila la guía, las instrucciones de transporte y la taxonomía; acredita las corridas históricas, no el contrato v2.

Rol

Clasificar chunks de subtítulos de YouTube peruano para priorizar revisión humana, sin actuar como moderador final. Evaluar el efecto del mensaje sobre el blanco aunque el hablante niegue intención o lo presente como humor. La clasificación es multietiqueta e indica todas las categorías aplicables. No usar políticas genéricas de toxicidad, conocimiento previo como taxonomía alternativa ni coincidencias simples de palabras; no inventar etiquetas. Si un modismo o el chunk aislado no se entiende, conservar un daño plausible solo cuando haya evidencia y añadir `contexto_necesario`.

Etiquetas permitidas

Seguro. `seguro`: información, descripción, narración u opinión sin inferiorización, ataque o amenaza a una persona o grupo. `seguro_ironia_marcada`: ironía o parodia cuyo blanco es una institución, política o situación abstracta y que no daña a un grupo humano. Una etiqueta segura no coexiste con daño ni con la otra etiqueta segura. Una cita dañina solo puede considerarse segura cuando el hablante se opone claramente a ella.

Racismo y discriminación.

- `racismo_etnico_explicito`: término étnico usado para degradar o inferiorizar, como “serrano”, “cholo”, “negro”, “indio”, “chino”, “cholito”, “camba” o “motoso” usados como insulto.
- `racismo_linguistico`: burla del acento andino, motoseo, español influido por quechua u ortografía de migrantes o provincianos; esas variedades no son daño por sí mismas.
- `clasismo_racial`: inferiorización por clase con carga étnica, consumo, apariencia o conducta asociada a migrantes o clase baja; incluye, según contexto, “amixer”, “huachafa”, “chusma”, “cholería” o “gente de barrio”.
- `discriminacion_regional`: ataque o inferiorización por ser provinciano, serrano, del interior o de fuera de Lima; incluye centralismo que presenta a Lima como superior.
- `racismo_encubierto`: discriminación étnica o regional presentada como diferencia de educación, cultura, civismo o mérito.

Estas etiquetas pueden coexistir. Las fuentes que el prompt nombra para estos criterios son Callirgos, Zavala y Back, Almeida y Zavala, Brañez Medina, Zavala y Zariquiey, y Portocarrero; sus aportes y referencias se desarrollan en la Sec. II-B.

Acoso.

- `misoginia_acoso_genero`: ataque por ser mujer, insulto sexualizado, exclusión por género o feminización usada para degradar a un hombre.
- `homofobia_transfobia`: insulto, amenaza, patologización o deslegitimación por orientación sexual o identidad de género.
- `acoso_personal`: ataque dirigido a una persona identificable por nombre, cargo, rol o datos; incluye doxeo, campaña o llamado a terceros. Una crítica política o profesional argumentada no es automáticamente acoso.
- `amenaza_directa`: intención explícita o implícita, pero clara, de daño físico, legal o económico; suele coexistir con acoso personal.

Contenido sexual.

- `sexual_explicito`: descripción gráfica de actos sexuales sin necesidad informativa o periodística.
- `sexual_cosificacion`: reducción del valor de una persona a su cuerpo, apariencia o utilidad sexual.
- `sexual_no_consensual`: material íntimo, grabación, filtración o distribución sin consentimiento.

Flags permitidos

Los flags acompañan un daño, nunca lo reemplazan y siempre activan `needs_review=true`. `ironia_ambigua` indica que no puede decidirse si el texto critica el daño o lo reproduce con distancia; `humor_encubridor`, que el tono jocoso minimiza un daño que permanece al retirar el humor; y `contexto_necesario`, que falta antecedente, referente, final de frase, modismo o contexto cultural o audiovisual. Ironía ambigua y contexto necesario limitan la confianza a 0,65. Los tres valores aparecen solo en `flags`; si no hay daño sustentable, se eliminan y se usa `labels=["seguro"]`.

Decisión obligatoria en siete pasos

1. Identificar el blanco, el hablante o tono y el posible humor, ironía o exageración; el humor no descarta daño.
2. Comprobar si el texto es seguro; una opinión negativa sin inferiorización o ataque puede serlo, y la ironía solo es segura cuando su blanco no es un grupo humano ni produce daño colateral.
3. Revisar por separado los cinco subtipos de racismo y discriminación y asignar todos los aplicables.
4. Revisar misoginia, homofobia o transfobia, ataque a una persona identificable y amenaza.

5. Revisar contenido sexual explícito, cosificación y ausencia de consentimiento, considerando el contexto periodístico.
6. Añadir los flags aplicables; humor e ironía no eliminan un daño sustentado.
7. Verificar que `labels` no esté vacío; que seguro no coexista con daño; que se hayan incluido todas las etiquetas aplicables; que cualquier flag o score menor que 0,70 active revisión; que ironía o contexto limiten el score a 0,65; y que la justificación sea concreta y breve.

Español peruano y términos sensibles

- “cholo/a” puede funcionar como identidad, reappropriación o insulto y se decide por contexto; si no es concluyente, se conserva el daño plausible con el flag correspondiente.
- “causa” y “pata” suelen ser jerga amistosa, no acoso.
- “terrucos” suele ser derogatorio: activa acoso personal si identifica a alguien y puede sumar racismo étnico cuando racializa a una persona o grupo andino.
- “amixer” usado de forma despectiva hacia migrantes andinos activa clasismo racial.
- “motoso/a” como burla activa racismo lingüístico y puede sumar racismo étnico o regional según el blanco.
- Los canales irónicos requieren revisar el blanco y el género humorístico no concede inmunidad.

Salida y ejemplos mínimos

Para cada fragmento, devolver su identificador, las etiquetas y señales aplicables, la necesidad de revisión, una puntuación de confianza y una justificación breve. Conservar el orden, usar solo el vocabulario permitido y limitar la puntuación al intervalo $[0, 1]$. Cualquier señal, puntuación menor que 0,70 o duda justificada activa la revisión. La salida omite texto repetido, metadatos innecesarios y razonamiento interno.

El prompt incluye ocho casos mínimos: una votación como segura; ironía sobre una política como segura marcada; burla al habla andina como racismo lingüístico, étnico y regional con humor encubridor; inferiorización cultural de personas de la sierra como racismo encubierto y regional; mandato de volver a cocinar como misoginia; advertencia de conocer el domicilio como acoso y amenaza; atribución de empleo al cuerpo como cosificación y posible misoginia; y circulación de fotos íntimas como contenido no consensual y posible acoso personal.

Ensamblaje y alcance acreditado

El proceso antepone la identidad del clasificador, inserta este prompt y la taxonomía completa, y añade reglas para lotes, salida estructurada, orden de identificadores, vocabulario literal y límites de longitud. La llamada usa temperatura 0 y razonamiento desactivado. Los manifiestos de los lotes anotados por API registran la versión del prompt. Este prompt guía la anotación y no forma parte de la entrada textual del clasificador Qwen3-LoRA.

APÉNDICE B

EJEMPLOS DE CHUNKS CON PUNTUACIONES ALTAS DE QWEN3-LoRA

Advertencia de contenido: los extractos siguientes reproducen lenguaje discriminatorio, hostil o sexual únicamente para documentar el comportamiento del clasificador; no expresan la posición de los autores. Se seleccionan *post hoc* entre los 5 324 chunks de validación, sin consultar test. Las puntuaciones proceden del Qwen3-LoRA operacional, en el orden RACISMO, ATAQUE-G/I, ACOSO-AMENAZA y SEXUAL. Los umbrales son 0,225; 0,200; 0,225 y 0,300. Cada ejemplo presenta una sola categoría tanto en la referencia como en la predicción. Los 15 casos priorizan puntuaciones altas y limitan el aporte a un chunk por canal. Se muestran dos cifras significativas; los puntos suspensivos solo acortan el texto.

Valoración segura muy alta

En el baseline ilustrado, **SEGURO** se derivaba al no activar ningún daño: se exigieron referencia segura y cuatro scores bajo umbral, y se ordenó por el menor margen $\min_k(\theta_k - s_k)$. El valor mostrado es $1 - \max_k s_k$, no una probabilidad calibrada por una cabeza segura. Esta construcción no representa la quinta salida aprendida del contrato v2.

1. **Canal:** *Líbero Deportes*; > 0,99: “Este sábado se juega un partidazo en Matute”.
2. **Canal:** *Buen Viaje*; > 0,99: “lo que hemos podido aprender de este destino es que [...] tiene unos objetivos en cuidar el medio ambiente”.
3. **Canal:** *Misias pero viajeras*; > 0,99: “es un centro de exhibición de diferentes tipos de artesanía [...] aproximadamente 150 familias [...] se soportan en base a las donaciones y a las compras”.

Racismo y discriminación

1. **Canal:** *Panamericana Noticias*; 0,96: “esta es la típica narrativa de que pobrecito el serrano que no piensa, que no sabe nada [...] me molesta esta superioridad”.
2. **Canal:** *Juanito y Richard*; 0,95: “ese indio no [...] habla”.
3. **Canal:** *ATV Noticias*; 0,83: “Es los venezolanos [...] ellos son los que hacen”.

Ataque por género e identidad

1. **Canal:** *Todo Good*; 0,81: “eso no te hace ser una chica [...] no me sentiría cómoda ni segura que en el baño de niñas entren hombres [...] que [...] se perciban chicas”.
2. **Canal:** *Sin Guion con Rosa Maria Palacios*; 0,68: “O tienes mucho enclosetado ahí adentro [...] están todos son gays, menos yo”.
3. **Canal:** *Magaly TV La Firme*; 0,45: “tiene el vicio de sacar la vuelta y estar con diferentes hombres”.

Acoso y amenaza

1. **Canal:** *Arde Troya con Juliana Oxenford*; 0,90: “Pienso que es un cobarde [...] hoy eres un cobarde”.
2. **Canal:** *Perú Actual*; 0,87: “te voy a matar”.
3. **Canal:** *Nunca MAS*; 0,87: “yo te encuentro con alguien yo te mato [...] pero ya estás muerta”.

Contenido sexual

1. **Canal:** *Hablando Huevadas*; 0,94: “cuando duermo con ella [...] tengo la mano en su pote”.
2. **Canal:** *Goblinciano*; 0,38: “compartieron un audio [...] en pleno polvo [...] pedía a una flaca que diga su nombre mientras cachaban”.
3. **Canal:** *Nada Espacial*; 0,37: “empezó a pasar calato [...] por toda la pichula”.

Estos ejemplos ilustran señales que el modelo ordenó por encima de los umbrales. Score alto significa salida calibrada alta respecto del corte, no certeza humana ni probabilidad literal de que la referencia sea correcta. Las referencias provienen de supervisión asistida; los ejemplos no estiman desempeño por subtipo, no sustituyen las métricas sobre test y no autorizan decisiones automáticas sobre personas o videos.

APÉNDICE C

INTERFACES DE ANOTACIÓN Y OPERACIÓN

La Fig. 8 muestra la versión final del entorno de revisión humana con un chunk real del corpus. La propuesta de DeepSeek Pro aparece antes de decidir y deja tres acciones explícitas: aceptarla, rechazar el caso o modificar las categorías y señales antes de guardar la versión humana. El contador corresponde a la campaña integrada que alimenta esta interfaz. La Fig. 9 compara cuatro ejecuciones reales del servidor con texto y video, mediante Qwen3-LoRA y consenso 2 de 3.

Validación humana · 3 114 casos

Categorías gruesas · propuesta Pro visible · flags transversales separados

3063/3114 resueltos · incluidos 3012 · excluidos 51

Vista: Todas

Iniciales REV Guía

Descargar final

Flujo rápido: la propuesta del LLM ya está visible y precargada. **Aceptar** la incluye tal cual; **rechazar** excluye el chunk del entrenamiento; si cambias categorías o flags, usa **guardar versión humana**. Las decisiones anteriores se conservan como decisiones humanas migradas.

Segunda corrida / ampliación (1,779) Sin abrir

1/1 · Arde Troya con Juliana Oxenford · ARDE TROYA WITH JULIANA OXFENFORD: JUNE 10, 2026 PROGRAM · 48:41-49:13 · validation [Abrir video](#)

CONTEXTO ANTERIOR

de estado, ¿no? Y habiendo explicado este asunto juristas no solamente nacionales sino internacionales con suma facilidad [resoplido] y que la prensa sigue en eso. La prensa fue la que permanentemente buscó dar el golpe de estado, ¿no?, con el Congreso de la República contra Pedro Castillo. Esa es la verdad. Claro que este cumpliendo un deseo de la ultraderecha que no podía ver a Pedro Castillo sentado en el sillón presidencial. Esa es la verdad.

CHUNK A VALIDAR

sillón presidencial. Esa es la verdad. Hablar lo contrario, ¿no? A la verdad, a lo que está demostrado, lo que está acreditado nacional e internacionalmente lo hace quedar mal al Perú. Porque vemos allí, ¿no?, a un entrevistador, periodista y a un entrevistado diciendo lo que está demostrando que no es. Es como ver allí, ¿no?, a un entrevistador que realmente se presenta como un macaco y el entrevistado como otro macaco, repitiendo lo mismo, lo mismo, lo mismo

CONTEXTO POSTERIOR

repitiendo lo mismo, lo mismo, lo mismo y lo mismo. Eso es lo que vemos en el Perú. ¿Qué fue entonces lo que vimos todos? ¿Qué fue lo que escuchamos? que Pedro Castillo leyó ese discurso que no constituye este delito de rebelión, no constituye este golpe de estado, no se ha demostrado en el proceso de que haya habido conspiración, porque por conspiración quiere decir que se reúnen dos o tres por lo menos no para acordar levantarse en armas. Bueno, estaba

Propuesta del LLM · DeepSeek Pro visible antes de decidir

RACISMO DISCRIMINACION ACOSO PERSONAL

Confianza declarada: 0.95

Etiquetas finas (solo referencia): racismo_ético_explicito, acoso_personal

Justificación: El término 'macaco' es un insulto racial dirigido a personas, en este caso al entrevistador y entrevistado, inferiorizándolos por su apariencia o comportamiento asociado a estereotipos étnicos (Calligros, 1993). Además, al ser dirigido a individuos identificables en el contexto del programa, constituye acoso personal.

Notas Pro: Uso de 'macaco' como insulto racial y ataque a periodista y entrevistado.

Origen de selección: Adquisición: high_yield_channel · objetivo: ACOSO_PERSONAL|AMENAZA_DIRECTA

✓ Aceptar LLM e incluir

✗ Rechazar y excluir

Guardar versión modificada por humano

Aceptar y rechazar avanzan al siguiente pendiente. Para modificar, cambia primero las opciones precargadas.

CATEGORÍA BASE

☐ SEGURO

No hay ataque, amenaza ni sexualización de finis; lo citado, informativo o crítico sin dañar también es seguro.

☒ RACISMO DISCRIMINACION

Inferiorización o exclusión por etnia, rasgo racializados, acento, clase asociada o procedencia regional.

☐ ACOSO GENERO IDENTIDAD

Ataque o degradación por género, identidad, orientación sexual o identidad de género.

☒ ACOSO PERSONAL

Insulto, hostigamiento o degradación dirigido a una persona identificable.

☐ AMENAZA DIRECTA

Intención explícita o inequívoca de causar daño físico, sexual, patrimonial o equivalente.

☐ CONTENIDO SEXUAL

Contenido sexual explícito de finis, codificación sexual o material no consensual.

FLAGS TRANSVERSALES (SOLO CON DAÑO)

☐ ironía ambigua

La ironía no permite decidir con seguridad si hay daño genuino.

☐ humor encubridor

El humor funciona como cobertura para normalizar o minimizar el daño.

☐ contexto necesario

Aun con los vecinos mostrados, se requiere revisar más contexto del video.

NOTA HUMANA OPCIONAL

Útil para justificar una modificación o una exclusión.

← Anterior

Diferir con nota

Siguiente pendiente

Atajos: [A] aceptar · [R] rechazar · [Ctrl] + [Enter] guardar modificación · [↵] navegar.

Figura 8. Entorno final de revisión humana: texto y contexto, propuesta visible del LLM y controles para aceptar, rechazar o modificar. Captura local del artefacto del proyecto con un registro real.

casi escuchándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o tengo la mano en su poto. Qué rico. Tú también. Yo también. O cuchare o quitándole carquita debajo de la teta también. Las chicas

Qwen fine-tuned Texto - forzado **Analizar**

Análisis terminado y estadísticas guardadas localmente.

1 de 1 chunks con alguna alerta · qwen

Alerta texto_0000

casi escuchándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o tengo la mano en su poto. Qué rico. Tú también. Yo también. O cuchare o quitándole carquita debajo de la teta también. Las chicas tienen carcas.

Qwen3-0.6B LoRA · época operativa 3 Confianza baja Revisión necesaria

Contenido sexual

Motivo: Ruta alto recall, Cerca del umbral

▼ Scores por categoría

Racismo discriminacion	0.01
Género	0.19
Acoso amenaza	0.04
Contenido sexual	0.94

(a) Texto con Qwen3-LoRA

1 de 1 chunks con alguna alerta · consensus

Alerta texto_0000

casi escuchándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o te...

SVM lineal calibrado palabra+carácter · Plano Confianza baja Revisión necesaria Género Contenido sexual	Multilingual E5-small (linaje MiniLM) Confianza baja Revisión necesaria Género Contenido sexual
Qwen3-0.6B LoRA · época operativa 3 Confianza baja Revisión necesaria Contenido sexual	Consenso mayoritario de los tres modelos Confianza baja Revisión necesaria Género Contenido sexual

Motivo: Desacuerdo entre modelos, Algún modelo activa revisión

▼ Scores por categoría

Racismo discriminacion	0.06
Género	0.44
Acoso amenaza	0.09
Contenido sexual	0.95

(b) Texto con consenso 2 de 3

https://www.youtube.com/watch?v=mTlMfx4SyH8

Qwen fine-tuned YouTube + subtítulos - forzado **Analizar**

Análisis terminado y estadísticas guardadas localmente.

10 de 25 chunks con alguna alerta · qwen - subtítulos es-orig (automatic)

Alerta mTlMfx4SyH8_0001 0:45-1:16 [Abrir fragmento ↗](#)

esta es la voz que atormentó por varios meses a sus víctimas llamada tras llamada hasta dejarlas así ya tenga miedo de dormir parece que está en mi lado a aparecer me va a matar este hombre va a ser un daño muy grande a mi familia y ahora tengo miedo de dormir parece que está en mi

Qwen3-0.6B LoRA · época operativa 3 Confianza alta Revisión necesaria

Acoso amenaza

Motivo: Ruta alto recall

▼ Scores por categoría

Racismo discriminacion	0.00
Género	0.04
Acoso amenaza	0.70
Contenido sexual	0.01

(c) Video real con Qwen3-LoRA

16 de 25 chunks con alguna alerta · consensus - subtítulos es-orig (automatic)

Alerta mTlMfx4SyH8_0001 0:45-1:16 [Abrir fragmento ↗](#)

esta es la voz que atormentó por varios meses a sus víctimas llamada tras llamada hasta dejarlas así ya tenga miedo de dormir parece que está e...

SVM lineal calibrado palabra+carácter · Plano Confianza baja Revisión necesaria Seguro	Multilingual E5-small (linaje MiniLM) Confianza baja Revisión necesaria Acoso amenaza
Qwen3-0.6B LoRA · época operativa 3 Confianza alta Revisión necesaria Acoso amenaza	Consenso mayoritario de los tres modelos Confianza baja Revisión necesaria Acoso amenaza

Motivo: Desacuerdo entre modelos, Algún modelo activa revisión

▼ Scores por categoría

Racismo discriminacion	0.05
Género	0.14
Acoso amenaza	0.57
Contenido sexual	0.06

(d) El mismo video con consenso 2 de 3

Figura 9. Panel de ejecuciones reales del servidor del paquete desplegable: (a) chunk de validación al que Qwen3-LoRA asigna 0,94 en contenido sexual; (b) el mismo texto con consenso 2 de 3; (c) URL del video *Alias “El Wichi”: extorsionaba a sus víctimas bajo amenaza de muerte*, del canal Panorama, procesada en 25 chunks de subtítulos automáticos con Qwen3-LoRA; y (d) la misma URL con consenso 2 de 3. Los recortes conservan entrada, resumen, fragmento, categorías y puntajes; omiten el reproductor y controles secundarios.

La Fig. 10 presenta la ontología del proyecto. Su función es semántica y de trazabilidad: cada predicción refiere a una categoría y a un chunk de evidencia; una decisión humana es un evento posterior, no otra palabra para predicción. El archivo `ontologia_moderacion.ttl` expresa clases y propiedades en OWL 2, sintaxis RDF/Turtle y definiciones SKOS [78], [109], [110].




Figura 10. Grafo ontológico de trazabilidad. Línea continua: relación de proceso; discontinua: especialización o retorno a una iteración futura. Elaboración propia con base conceptual en [77], [78].

La Tabla VIII fija la definición operacional y la regla de trazabilidad de cada término usado en el grafo.

Tabla VIII
VOCABULARIO CONTROLADO Y REGLA DE USO EN EL ARTÍCULO

Término	Definición operacional	Regla de trazabilidad / fundamento
Video público	Recurso de YouTube aceptado por los criterios de adquisición.	Conserva video_id ; no implica muestra representativa.
Pista de subtítulos	Texto manual o automático con tiempos, disponible para el video.	No se denomina transcripción de audio propia; el proyecto no usó ASR.
Chunk	Unidad textual cerrada al alcanzar 30 s o 600 caracteres, con mínimo 90; antes se depura repetición VTT de hasta 12 palabras.	Toda alerta debe enlazar chunk_id , video e intervalo. No existe solapamiento intencional entre chunks.
Anotación	Asignación versionada de conceptos a un chunk.	Distinguir Flash, Pro y revisión final asistida; documentar población y procedencia [9].
Daño operativo	Una o más de cuatro categorías activables.	Es multietiqueta [61]; no equivale a infracción legal.
Fenómeno fino / flag	Subtipo descriptivo o indicador transversal de ambigüedad.	Un flag no es daño; gold fino no entra como predictor.
SEGURO	En el baseline fue un estado derivado; en el contrato v2 es una quinta salida aprendida y exclusiva.	La migración histórica solo la asigna si existe una decisión segura explícita; no prueba ausencia universal de daño.
Score / umbral	Salida continua y corte fijado en validación.	No llamar probabilidad sin calibración [71].
AP	$\sum_n (R_n - R_{n-1})P_n$, macro entre daños.	Precisión promedio no interpolada; los archivos dicen PR-AUC [69].
Alerta / revisión	Enrutamiento selectivo de una predicción incierta o dañina.	No es sanción; el supervisor acepta, rechaza o modifica [2], [74]–[76].
Operación semiautomática	Servicio que prioriza, presenta evidencia y registra la decisión del supervisor.	Es el alcance implementado por el frontend; afectar usuarios exige validación prospectiva y gobierno operativo.
Artefacto DSR	Conjunto de corpus, modelos, reglas, interfaz, registros y documentación.	Se construye y evalúa iterativamente [6], [7].

APÉNDICE E
DETALLE DE FUENTES DEL CORPUS

La Tabla IX desagrega el tipo de contenido registrado en los metadatos del corpus integrado. “Muestreo dirigido” describe un régimen de adquisición y no un género editorial; por ello no debe interpretarse como prevalencia de YouTube. La identidad se reconstruye mediante el `channel_id` y las URL preservadas en los metadatos de adquisición. Después de unificar alias y variantes de escritura, los 3 230 videos proceden de 250 canales únicos.

Tabla IX
CHUNKS Y DAÑOS POR CATEGORÍA DE FUENTE

Categoría de fuente	Chunks	Videos	Algún daño	RACISMO	ATAQUE-G/I	ACOSO-AMENAZA	SEXUAL
Muestreo dirigido	47 395	1 374	3 450	793	948	1 687	1 325
Humor streaming	11 812	72	1 621	395	688	232	758
Política actualidad	9 212	449	102	32	8	69	0
Política análisis	7 858	150	233	32	21	193	3
Política periodismo	7 583	150	89	13	13	68	0
Humor podcast	6 223	69	108	22	39	20	39
Política opinión	5 895	173	282	59	42	194	21
Streaming opinión	5 155	148	879	378	128	462	76
Viajes	4 877	149	3	2	0	0	1
Viajes gastronomía	4 404	150	10	3	3	2	3
Deportes informal	1 867	66	4	2	1	1	0
Humor comedia	1 673	74	158	98	44	39	22
Farándula digital	1 478	44	32	5	4	12	12
Farándula	1 092	75	88	21	20	48	22
Deportes	448	74	4	1	2	1	0
Gastronomía	272	13	0	0	0	0	0

La Tabla X separa la fuente de adquisición de la procedencia de supervisión. Los casos con daño, baja confianza o discrepancias pasan a DeepSeek Pro o a revisión humana asistida.

Tabla X
PROCEDENCIA DE LAS ETIQUETAS DEL CORPUS INTEGRADO

Fuente de etiqueta	Chunks	Seguro	Daño	Incidencias	Multidaño	Peso base
Flash pseudoetiqueta	93 636	93 636	0	0	0	0,50 × confianza
Pro y minería Pro	20 516	15 959	4 557	5 426	834	1
Revisión final asistida	3 092	586	2 506	3 701	961	1
Total	117 244	110 181	7 063	9 127	1 795	

Las filas de revisión humana final conservan la decisión y su procedencia para mantener la trazabilidad del corpus.

Canales incluidos y direcciones web

El inventario se limita a los videos presentes en el corpus integrado. La Tabla XI presenta por separado los canales con más de dos videos y reúne los canales con uno o dos en una fila final denominada “Otros”. El conteo permite comprobar la concentración por canal; las direcciones individuales de los canales agrupados permanecen en los metadatos del corpus.

Tabla XI: Canales con más de dos videos en el corpus final y agrupación de canales con uno o dos

Canal	Dirección web principal	Videos
24 Horas	https://www.youtube.com/channel/UCsakKsRww3J7pM6DavkrAIQ	18
A24com	https://www.youtube.com/channel/UCR9120YBAqMfntqgRTKmkjQ	3
AGENCIA EFE	https://www.youtube.com/channel/UCvJS-YNYaWyOucx8bGrHVvw	3
América Noticias	https://www.youtube.com/channel/UCPhm2I2wk4vqjENwhn3px8A	18
América Televisión	https://www.youtube.com/channel/UCGGry4kGWZUqIfG6LLNhOmg	8
Arde Troya con Juliana Oxenford	https://www.youtube.com/channel/UCgEabnv1xth8-qeWqMsTmDw	185
ATV Noticias	https://www.youtube.com/channel/UCYG5uXS3xdsoaXIxum1pAEw	137
Buen Viaje	https://www.youtube.com/channel/UCpTyTnL_1Hs6LyfD4L2rkw	74
Buenos Días Perú	https://www.youtube.com/channel/UCFnOwPrJ-Skrzk_GPNBV5tg	70
Caso Cerrado	https://www.youtube.com/channel/UCGbofRR0opWrumVob5w61OA	3

Continúa en la página siguiente

Tabla XI (continuación)

Canal	Dirección web principal	Videos
Chimi chimi	https://www.youtube.com/channel/UCt42aXXEokQWROe3CdVx3bA	4
Ciudadaniassx	https://www.youtube.com/channel/UCt78tVTNhK4hd9l0Io3vTtg	3
Cocina Cajamarquina	https://www.youtube.com/channel/UC2lyekNE9NOGWu1R0L8046A	13
Cosmos Televisión	https://www.youtube.com/channel/UC_ept7M1UXlCfvcUrK49Ziw	10
CTV Perú Oficial	https://www.youtube.com/channel/UCy4UKhdd5U0cUru_sBn-DGA	3
DÍA D	https://www.youtube.com/channel/UCmrzeYkbupPuvrXH8roR__w	8
Diario El Popular	https://www.youtube.com/channel/UCC25ArAc6QI7yj1UQG8lqxA	4
El Búho pe	https://www.youtube.com/channel/UC6xAnp5ygm8oNoBDCgu70UQ	3
El diario de Curwen	https://www.youtube.com/channel/UCHUD6A_lv3OXbzgVXwomtkw	73
El Dominical de Panamericana	https://www.youtube.com/channel/UCMfcN0OV7d61cWPLYm5qHpw	8
El Universal	https://www.youtube.com/channel/UC2SEk1w7DgoHs_G3w1biz-w	6
enlacenacional	https://www.youtube.com/channel/UC_Zpz_cv69p4oL0hDEJz4lA	6
EXCELSIOR	https://www.youtube.com/channel/UCIqo4ZAAZ01HQdCTlovCgkA	3
Exitosa Noticias	https://www.youtube.com/channel/UCxgO_rak_BKZP8VNVmYqbWg	97
Farandula Política	https://www.youtube.com/channel/UCPEPKBntK_q0AXblXJtDUNhg	3
Goblinciano	https://www.youtube.com/channel/UCO0cdOFdG-3hxa_VPG8imnw	236
Hablando Huevadas	https://www.youtube.com/channel/UCba1vMvOHWMddLARS382Zw	182
Instarandula	https://www.youtube.com/channel/UC2EkQJU0Ani3SLAVS07MBJg	42
Juanito y Richard	https://www.youtube.com/channel/UCfiBnBtw8iNbX8vL4f6cp0Q	181
L1MAX	https://www.youtube.com/channel/UCGVHVLd7Nzw0zdIwbVhE3vw	66
La República - LR+	https://www.youtube.com/channel/UC-B7Xv56uNRDkj0vC3QW8Cg	16
Latina Noticias	https://www.youtube.com/channel/UCpSJ5fGhmAME9Kx2D3ZvN3Q	193
Latina Televisión	https://www.youtube.com/channel/UC3rDtLrcgr3JS3_3JOW4BAw	11
Líbero Deportes	https://www.youtube.com/channel/UCk2OZrA0E6q6xp4bBKtf9KA	74
LP - Pasión por el Derecho	https://www.youtube.com/channel/UCDscRICxHhJBIvVpBmA	12
Magaly TV La Firme	https://www.youtube.com/channel/UCF6s3gpbZEQKqZ38VvQ0gLA	162
Marco Sifuentes / Ocram	https://www.youtube.com/channel/UCP0AJJeNkFBYzegTTVbKhPg	75
Misias pero viajeras	https://www.youtube.com/channel/UCknQM__AyaqSdxunkpavDg	75
Nada Espacial	https://www.youtube.com/channel/UCfwkQ4IY6UO-6K_REQ8CnNQ	69
Noticias Caracol	https://www.youtube.com/channel/UC2Xq2PK-got3Rtz9ZJ32hLQ	3
Nunca MAS	https://www.youtube.com/channel/UCFqwxsa2Wp6Y5FkUAcGShGA	13
Panamericana Noticias	https://www.youtube.com/channel/UCOyD-kV3zB8Cm4LI4qtd9tA	75
Panamericana Televisión	https://www.youtube.com/channel/UCngb4rxO4iUE6BrIs29WXwA	6
Panorama	https://www.youtube.com/channel/UCBiq92lt_ufNO-ktZigVXgg	92
QUE HAY DE NUEVO PERU	https://www.youtube.com/channel/UCRl1-oM_NM-BtCEyTFd-aRA	5
RPP Noticias	https://www.youtube.com/channel/UC5j8-2FT0ZMMBkmK72R4aeA	122
Sin Guion con Rosa Maria Palacios	https://www.youtube.com/channel/UCdyaE7KCDAD3NY19r9C69-g	75
SOL TV Perú	https://www.youtube.com/channel/UCT3jhhKbEV4ZslzhZ26hPw	3
Tío Lenguado y Descocaos	https://www.youtube.com/channel/UCvPVK5xvxJRY1obR9XRrMfw	75
Todo Good	https://www.youtube.com/channel/UC-f4h9oSW5JreShkauu0m1A	148
TVPerú Noticias	https://www.youtube.com/channel/UCkZCoc42IipR1ucqJmIehsA	54
Viaja y Prueba	https://www.youtube.com/channel/UCD8fpCkckYmYj_qm6hhE4jw	75
Wayka	https://www.youtube.com/channel/UCQmo59tWId4OHTdl4W320DQ	7
Willax Television	https://www.youtube.com/channel/UCort3mldTtMErPqprSISfng	102
Otros (196 canales con uno o dos videos)	Direcciones canónicas conservadas en los metadatos del corpus	218

APÉNDICE F
DISPONIBILIDAD Y REUTILIZACIÓN

La Tabla XII separa las dos ubicaciones del proyecto. GitHub ofrece el código y el historial de cambios; Drive preserva los bytes empleados por los experimentos y los pesos que no se versionan en Git. El acceso a Drive requiere autorización del equipo.

Tabla XII
UBICACIÓN, CONTENIDO Y CONDICIONES DE ACCESO DE LOS ARTEFACTOS

Sitio	Enlace	Contenido y formatos	Acceso
GitHub	https://github.com/lkoc/Trabajo_PLN-MIA-Grupo4	Scripts Python, cuadernos IPYNB, documentación y archivos de datos versionables.	Público; sin licencia explícita de reutilización
Google Drive	https://drive.google.com/drive/folders/1H3PKr7CWd-RwavZgEnfLhh94eq-NO9P3	Corpus, modelos entrenados, resultados y demás artefactos de mayor tamaño.	Controlado; requiere permiso del equipo

Los datos, cuadernos y scripts pueden recuperarse desde esos repositorios manteniendo la estructura de carpetas documentada. Los artefactos de mayor tamaño se conservan en Drive; el flujo activo se ejecuta en orden desde `flujo/01_datos/` hasta `flujo/04_produccion/`, mientras el cuaderno 05 anterior permanece archivado. La accesibilidad técnica no concede por sí sola permiso de reutilización: deben comprobarse las licencias de modelos y herramientas, los términos de YouTube, la privacidad y los derechos sobre los subtítulos [107], [108].

REFERENCIAS

- [1] R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>
- [2] J. S. Andersen, O. Zukunft, and W. Maalej, "REM: Efficient semi-automated real-time moderation of online forums," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2021, pp. 142–149. [Online]. Available: <https://aclanthology.org/2021.acl-demo.17/>
- [3] P. Röttger, B. Vidgen, D. Nguyen *et al.*, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>
- [4] M. Sap, D. Card, S. Gabriel *et al.*, "The risk of racial bias in hate speech detection," in *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2019, pp. 1668–1678. [Online]. Available: <https://aclanthology.org/P19-1163/>
- [5] R. Tatman, "Gender and dialect bias in YouTube's automatic captions," in *Proceedings of the First ACL Workshop on Ethics in Natural Language Processing*. Association for Computational Linguistics, 2017, pp. 53–59. [Online]. Available: <https://aclanthology.org/W17-1606/>
- [6] A. R. Hevner, S. T. March, J. Park *et al.*, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>
- [7] K. Peffers, T. Tuunanen, M. A. Rothenberger *et al.*, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.
- [8] B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0243300>
- [9] E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: <https://aclanthology.org/Q18-1041/>
- [10] M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: https://facctconference.org/static/pdfs_2022/facct-22-3533231.pdf
- [11] E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399.
- [12] B. Mathew, P. Saha, S. M. Yimam *et al.*, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14867–14875. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17745>
- [13] T. Bertaglia, A. Grigoriu, M. Dumontier *et al.*, "Abusive Language on Social Media Through the Legal Looking Glass," in *Proceedings of the Fifth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2021, pp. 191–200. [Online]. Available: <https://aclanthology.org/2021.woah-1.20/>
- [14] V. Basile, C. Bosco, E. Fersini *et al.*, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://aclanthology.org/S19-2007/>
- [15] F. M. Plaza-del Arco, A. Montejó-Ráez, L. A. Ureña-López *et al.*, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: <https://aclanthology.org/2021.ranlp-1.123/>
- [16] M. Taulé, A. Ariza, M. Nofre *et al.*, "Overview of DETOXIS at IberLEF 2021: DETection of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6390>
- [17] F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza *et al.*, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>
- [18] M. Tonneau, P. Quinta De Castro, K. Lasri *et al.*, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://aclanthology.org/2024.acl-long.488/>
- [19] Z. Waseem, T. Davidson, D. Warmesley *et al.*, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>
- [20] M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>
- [21] J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993.
- [22] G. Portocarrero Maisch, *Racismo y mestizaje y otros ensayos*. Lima: Fondo Editorial del Congreso del Perú, 2009, reimpresión de la edición de 2007.
- [23] V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>
- [24] V. Zavala and R. Zariquiey, "“Yo te segrego a ti porque tu falta de educación me ofende”: una aproximación al discurso racista en el Perú contemporáneo," in *Racismo y discurso en América Latina*, T. A. van Dijk, Ed. Barcelona: Gedisa, 2007, pp. 333–370.
- [25] V. Zavala and M. Back, Eds., *Racismo y lenguaje*. Lima: Fondo Editorial de la Pontificia Universidad Católica del Perú, 2017. [Online]. Available: <https://repositorio.pucp.edu.pe/index/handle/123456789/170315>
- [26] V. Zavala and C. Almeida, "“Motoso y terruco”: ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/lexis/article/view/26332>
- [27] R. F. Brañez Medina, "La construcción discursiva de las identidades “amixer” y “no-amixer” en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú, 2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositori o/handle/20.500.12404/1618>
- [28] V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf
- [29] P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://aclanthology.org/2021.acl-long.247/>
- [30] C. Monge-Olivarria, J. Guerra-Corrales, and F. Bringas-Castro, "Violencia de género en Twitter: feminización como forma de insulto en la conversación digital," *Orkopata. Revista de Lingüística, Literatura y Arte*, vol. 2, no. 2, pp. 7–16, 2023. [Online]. Available: <https://revistas.inudi.edu.pe/ro/es/article/view/425>
- [31] D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnore sistencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf

- [32] Defensoría del Pueblo del Perú, “Violencia de género contra las mujeres en línea,” Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>
- [33] B. R. Chakravarthi, “Detection of homophobia and transphobia in YouTube comments,” *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s41060-023-00400-0>
- [34] J. M. Rottenbacher de Rojas, “Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima,” *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>
- [35] C. M. Lovón-Cueva and M. Lovón-Cueva, “Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums,” *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://whatever.cirque.unipi.it/index.php/journal/article/view/156>
- [36] M. ElSherief, C. Ziems, D. Muchlinski *et al.*, “Latent hatred: A benchmark for understanding implicit hate speech,” in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 345–363. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.29/>
- [37] S. Ilić, E. Marrese-Taylor, J. Balazs *et al.*, “Deep contextualized word representations for detecting sarcasm and irony,” in *Proceedings of the 9th Workshop on Computational Approaches to Subjectivity, Sentiment and Social Media Analysis*. Association for Computational Linguistics, 2018, pp. 2–7. [Online]. Available: <https://aclanthology.org/W18-6202/>
- [38] T. Bourgeade, Z. Li, F. Benamara *et al.*, “Humans need context, what about machines? investigating conversational context in abusive language detection,” in *Proceedings of the 2024 Joint International Conference on Computational Linguistics, Language Resources and Evaluation (LREC-COLING 2024)*. ELRA and ICCL, 2024, pp. 8438–8452. [Online]. Available: <https://aclanthology.org/2024.lrec-main.740/>
- [39] D. Thakur, “Moderación de contenido en quechua en redes sociales,” Center for Democracy & Technology, Tech. Rep., Jun. 2025. [Online]. Available: <https://cdt.org/wp-content/uploads/2025/06/2025-Quechua-Report-Spanish-final-1.pdf>
- [40] YouTube, “Política sobre desnudos y contenido sexual,” Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>
- [41] K. Spärck Jones, “A statistical interpretation of term specificity and its application in retrieval,” *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>
- [42] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.
- [43] D. R. Cox, “The regression analysis of binary sequences,” *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.
- [44] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995.
- [45] J. D. M. Rennie, L. Shih, J. Teevan *et al.*, “Tackling the poor assumptions of naive bayes text classifiers,” in *Proceedings of the 20th International Conference on Machine Learning*, 2003, pp. 616–623. [Online]. Available: <https://people.csail.mit.edu/jrennie/papers/icml03-nb.pdf>
- [46] S. Deerwester, S. T. Dumais, G. W. Furnas *et al.*, “Indexing by latent semantic analysis,” *Journal of the American Society for Information Science*, vol. 41, no. 6, pp. 391–407, 1990.
- [47] J. H. Friedman, “Greedy function approximation: A gradient boosting machine,” *The Annals of Statistics*, vol. 29, no. 5, pp. 1189–1232, 2001.
- [48] A. Joulin, E. Grave, P. Bojanowski *et al.*, “Bag of tricks for efficient text classification,” in *Proceedings of the 15th Conference of the European Chapter of the Association for Computational Linguistics: Volume 2, Short Papers*. Association for Computational Linguistics, 2017, pp. 427–431. [Online]. Available: <https://aclanthology.org/E17-2068/>
- [49] A. Vaswani, N. Shazeer, N. Parmar *et al.*, “Attention is all you need,” in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>
- [50] J. Devlin, M.-W. Chang, K. Lee *et al.*, “BERT: Pre-training of deep bidirectional transformers for language understanding,” in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Association for Computational Linguistics, 2019, pp. 4171–4186. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [51] N. Reimers and I. Gurevych, “Sentence-BERT: Sentence embeddings using siamese BERT-networks,” in *Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing*. Association for Computational Linguistics, 2019, pp. 3982–3992. [Online]. Available: <https://aclanthology.org/D19-1410/>
- [52] W. Wang, F. Wei, L. Dong *et al.*, “MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers,” in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [53] N. Reimers and I. Gurevych, “Making monolingual sentence embeddings multilingual using knowledge distillation,” in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2020, pp. 4512–4525. [Online]. Available: <https://aclanthology.org/2020.emnlp-main.365/>
- [54] Sentence Transformers, “Model card: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2,” Hugging Face Hub, 2026, checkpoint revision used: e8f8c211226b894fcb81acc59f3b34ba3efd5f42; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2/blob/e8f8c211226b894fcb81acc59f3b34ba3efd5f42/README.md>
- [55] L. Wang, N. Yang, X. Huang *et al.*, “Text embeddings by weakly-supervised contrastive pre-training,” *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>
- [56] —, “Multilingual E5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>
- [57] intfloat, “Model card: intfloat/multilingual-e5-small,” Hugging Face Hub, 2026, checkpoint revision used: 614241f622f53c4eeff9890bdc4f31cfec418b3; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/intfloat/multilingual-e5-small/blob/614241f622f53c4eeff9890bdc4f31cfec418b3/README.md>
- [58] A. Yang, A. Li, B. Yang *et al.*, “Qwen3 technical report,” *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>
- [59] Qwen Team, “Model card: Qwen/Qwen3-0.6B-Base,” Hugging Face Hub, 2025, checkpoint revision used: da87bfb608c14b7cf20ba1ce41287e8de496c0cd; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/Qwen/Qwen3-0.6B-Base/blob/da87bfb608c14b7cf20ba1ce41287e8de496c0cd/README.md>
- [60] E. J. Hu, Y. Shen, P. Wallis *et al.*, “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>
- [61] G. Tsoumakas and I. Katakis, “Multi-label classification: An overview,” *International Journal of Data Warehousing and Mining*, vol. 3, no. 3, pp. 1–13, 2007.
- [62] M.-L. Zhang and Z.-H. Zhou, “A review on multi-label learning algorithms,” *IEEE Transactions on Knowledge and Data Engineering*, vol. 26, no. 8, pp. 1819–1837, 2014.
- [63] C. N. J. Silla and A. A. Freitas, “A survey of hierarchical classification across different application domains,” *Data Mining and Knowledge Discovery*, vol. 22, no. 1–2, pp. 31–72, 2011.
- [64] J. Zhou, C. Ma, D. Long *et al.*, “Hierarchy-aware global model for hierarchical text classification,” in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 1106–1117. [Online]. Available: <https://aclanthology.org/2020.acl-main.104/>

- [65] R. Caruana, "Multitask learning," *Machine Learning*, vol. 28, pp. 41–75, 1997.
- [66] M. Sokolova and G. Lapalme, "A systematic analysis of performance measures for classification tasks," *Information Processing & Management*, vol. 45, no. 4, pp. 427–437, 2009.
- [67] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>
- [68] J. Davis and M. Goadrich, "The relationship between precision-recall and ROC curves," in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240.
- [69] scikit-learn developers, "scikit-learn average precision score api," scikit-learn API Reference, 2026, accessed: 2026-07-29. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.metrics.average_precision_score.html
- [70] J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, A. J. Smola, P. L. Bartlett, B. Schölkopf *et al.*, Eds. Cambridge, MA, USA: MIT Press, 1999, pp. 61–74.
- [71] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning*. Association for Computing Machinery, 2005, pp. 625–632.
- [72] C. Guo, G. Pleiss, Y. Sun *et al.*, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning Research*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>
- [73] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>
- [74] C. K. Chow, "On optimum recognition error and reject tradeoff," *IEEE Transactions on Information Theory*, vol. 16, no. 1, pp. 41–46, 1970.
- [75] Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>
- [76] H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/mozannar20b.html>
- [77] T. R. Gruber, "A translation approach to portable ontology specifications," *Knowledge Acquisition*, vol. 5, no. 2, pp. 199–220, 1993.
- [78] W3C OWL Working Group, "OWL 2 Web Ontology Language: Document overview (second edition)," World Wide Web Consortium, W3C Recommendation, Dec. 2012, 11 December 2012. [Online]. Available: <https://www.w3.org/TR/owl2-overview/>
- [79] M. D. Wilkinson, M. Dumontier, I. J. Aalbersberg *et al.*, "The FAIR guiding principles for scientific data management and stewardship," *Scientific Data*, vol. 3, p. 160018, 2016. [Online]. Available: <https://www.nature.com/articles/sdata201618>
- [80] R. Dror, G. Baumer, S. Shlomov *et al.*, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>
- [81] National Institute of Standards and Technology, "Secure hash standard (SHS)," U.S. Department of Commerce, FIPS PUB 180-4, Aug. 2015. [Online]. Available: <https://csrc.nist.gov/pubs/fips/180-4/upd1/final>
- [82] B. Settles, "Active learning literature survey," University of Wisconsin–Madison, Department of Computer Sciences, Tech. Rep. 1648, 2009. [Online]. Available: <https://minds.wisconsin.edu/handle/1793/60660>
- [83] Y. Fairstein, O. Kalinsky, Z. Karnin *et al.*, "Class balancing for efficient active learning in imbalanced datasets," in *Proceedings of the 18th Linguistic Annotation Workshop*. Association for Computational Linguistics, 2024, pp. 77–86. [Online]. Available: <https://aclanthology.org/2024.law-1.8/>
- [84] yt-dlp contributors, "yt-dlp: A feature-rich command-line audio/video downloader," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/yt-dlp/yt-dlp>
- [85] J. Depoix and contributors, "YouTube Transcript API: Python api for retrieving youtube transcripts and subtitles," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/jdepoix/youtube-transcript-api>
- [86] Unicode Consortium, "Unicode normalization forms," Unicode Consortium, Unicode Standard Annex #15 Revision 57, Jul. 2025, ed. Ken Whistler; Unicode 17.0.0; Jul. 30, 2025. [Online]. Available: <https://www.unicode.org/reports/tr15/tr15-57.html>
- [87] C. E. Brodley and M. A. Friedl, "Identifying mislabeled training data," *Journal of Artificial Intelligence Research*, vol. 11, pp. 131–167, 1999.
- [88] Y. Huang, B. Giledereli, A. Köksal *et al.*, "Balancing methods for multi-label text classification with long-tailed class distribution," in *Proceedings of the 2021 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2021, pp. 8153–8161. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.643/>
- [89] scikit-learn developers, "scikit-learn GroupShuffleSplit api," scikit-learn API Reference, 2026, accessed Jul. 29, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupShuffleSplit.html
- [90] F. Pedregosa, G. Varoquaux, A. Gramfort *et al.*, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- [91] A. Karimi, L. Rossi, and A. Prati, "AEDA: An easier data augmentation technique for text classification," in *Findings of the Association for Computational Linguistics: EMNLP 2021*. Association for Computational Linguistics, 2021, pp. 2748–2754. [Online]. Available: <https://aclanthology.org/2021.findings-emnlp.234/>
- [92] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019. [Online]. Available: <https://openreview.net/forum?id=Bkg6RiCqY7>
- [93] scikit-learn developers, "scikit-learn GroupKFold api," scikit-learn API Reference, 2026, accessed Jul. 29, 2026. [Online]. Available: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.GroupKFold.html
- [94] A. Paszke, S. Gross, F. Massa *et al.*, "PyTorch: An imperative style, high-performance deep learning library," in *Advances in Neural Information Processing Systems*, vol. 32, 2019, pp. 8024–8035. [Online]. Available: <https://proceedings.neurips.cc/paper/2019/hash/bdbca288fec7f92f2bfa9f7012727740-Abstract.html>
- [95] T. Wolf, L. Debut, V. Sanh *et al.*, "Transformers: State-of-the-art natural language processing," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations*. Association for Computational Linguistics, 2020, pp. 38–45. [Online]. Available: <https://aclanthology.org/2020.emnlp-demos.6/>
- [96] L. Prechelt, "Early stopping—but when?" in *Neural Networks: Tricks of the Trade*, ser. Lecture Notes in Computer Science, G. B. Orr and K.-R. Müller, Eds. Berlin, Heidelberg: Springer, 1998, vol. 1524, pp. 55–69. [Online]. Available: https://doi.org/10.1007/3-540-49430-8_3
- [97] PyTorch contributors, "BCEWithLogitsLoss api," PyTorch documentation, 2026, accessed Jul. 29, 2026. [Online]. Available: <https://docs.pytorch.org/docs/stable/generated/torch.nn.BCEWithLogitsLoss.html>
- [98] B. Efron, "Bootstrap methods: Another look at the jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- [99] C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.
- [100] T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.
- [101] L. Lam and C. Y. Suen, "Application of majority voting to pattern recognition: An analysis of its behavior and performance,"

- IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997.
- [102] T. Kluyver, B. Ragan-Kelley, F. Pérez *et al.*, “Jupyter notebooks—a publishing format for reproducible computational workflows,” in *Positioning and Power in Academic Publishing: Players, Agents and Agendas*. IOS Press, 2016, pp. 87–90.
 - [103] W. McKinney, “Data structures for statistical computing in python,” in *Proceedings of the 9th Python in Science Conference*, 2010, pp. 56–61.
 - [104] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.
 - [105] J. G. Moreno-Torres, T. Raeder, R. Alaiz-Rodríguez *et al.*, “A unifying view on dataset shift in classification,” *Pattern Recognition*, vol. 45, no. 1, pp. 521–530, 2012.
 - [106] R. Artstein and M. Poesio, “Inter-coder agreement for computational linguistics,” *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.
 - [107] a. s. franzke, A. Bechmann, M. Zimmer *et al.*, “Internet research: Ethical guidelines 3.0,” Association of Internet Researchers, Tech. Rep., 2020, approved by the AoIR membership Oct. 6, 2019. [Online]. Available: <https://aoir.org/reports/ethics3.pdf>
 - [108] YouTube, “Terms of service,” YouTube official terms, Nov. 2023, effective Nov. 6, 2023; accessed Jul. 29, 2026. [Online]. Available: <https://www.youtube.com/t/terms>
 - [109] W3C RDF Working Group, “RDF 1.1 turtle: Terse RDF triple language,” World Wide Web Consortium, W3C Recommendation, Feb. 2014. [Online]. Available: <https://www.w3.org/TR/turtle/>
 - [110] A. Miles and S. Bechhofer, “SKOS simple knowledge organization system reference,” World Wide Web Consortium, W3C Recommendation, Aug. 2009. [Online]. Available: <https://www.w3.org/TR/skos-reference/>