

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos, Transformers, Qwen y ensembles

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano

Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

La propuesta convierte horas de video en evidencia revisable

22 684

chunks en test natural

674 videos; prevalencia de daño 7,94 %

0,846

BA a cobertura completa

compuerta ANY_DAMAGE congelada

0,940

BA en ruta automática

65,2 % de cobertura; revisión 34,8 %

Valor técnico

Texto y tiempo trazables, cinco salidas calibradas, comparación reproducible y abstención explícita.

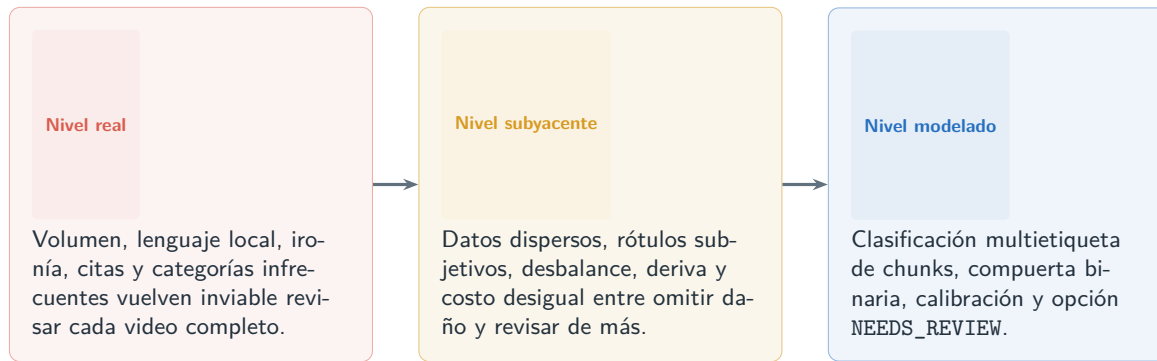
Valor operativo

Prioriza revisión humana; no automatiza sanciones ni oculta incertidumbre.

Lectura clave: El producto no reemplaza al moderador: reduce el espacio de búsqueda y entrega evidencia localizada para decidir.

Evidencia externa: Moderación y responsabilidad [1]; clasificación selectiva [2, 3]. | Resultado propio: test_final_abierto_una_vez.json, test natural.

La problemática existe en tres niveles conectados



Lectura clave: El problema a resolver es una cadena reproducible que pase de subtítulos públicos a alertas temporales y, finalmente, a una decisión humana informada.

Evidencia externa: Definición, muestreo y anotación condicionan el clasificador [4]; el abuso puede ser dirigido/generalizado y explícito/implícito [5,6].

El objeto de estudio conserva contexto, procedencia y decisión

Objeto de estudio

Expresiones potencialmente dañinas en subtítulos de videos vinculados con el Perú.

Unidad de análisis

Chunk temporal con `video_id`, texto, inicio, fin y contexto vecino.

Objeto modelado

Cinco salidas: `SEGURO` excluyente y cuatro daños que pueden coexistir.

Objeto de decisión

Alerta, evidencia temporal, incertidumbre y motivo de revisión para un supervisor.

Lectura clave: La predicción nunca se separa del fragmento que la originó ni de la persona que resuelve el caso.

Evidencia externa: Documentación de datos [7,8]; responsabilidad humana en moderación [1].

Los objetivos producen cuatro capacidades verificables

Corpus local reproducible → 173 240 chunks elegibles, cinco salidas y particiones separadas por video.



Comparación común → 28 individuos + 5 ensembles bajo el mismo snapshot y criterio de validation.



Incertidumbre operable → calibración, compuerta ANY_DAMAGE y política de revisión congelada.



Artefacto utilizable → frontends, evidencia temporal, correcciones y registros append-only.

Lectura clave: La contribución es el sistema completo: datos + etiquetas + modelos + selección + supervisión.

Evidencia externa: Diseño y evaluación iterativa de artefactos [9, 10].

El estado del arte confirma una tarea difícil y dependiente del corpus

Español

HatEval estudia odio contra mujeres e inmigrantes; EXIST, sexismo; DETOXIS, toxicidad; OffendES, ofensa en redes. Las etiquetas y plataformas no son intercambiables [11, 12, 13, 14].

Muestreo real

NaijaHate muestra AP de 0,34 en muestra representativa frente a 0,83–0,90 en conjuntos enriquecidos: la evaluación puede sobreestimar la operación [17].

Contexto y explicación


HateXplain incorpora blanco y racionales; HateCheck demuestra que una cifra agregada puede ocultar fallas funcionales [15, 16].

Brecha abordada

Faltaba una cadena para subtítulos peruanos, categorías localizadas, comparación multifamilia y derivación humana trazable.

Lectura clave: La ventaja no es prometer una métrica universal: es evaluar explícitamente el cambio entre benchmark enriquecido y test de prevalencia natural.

Del video público al corpus auditable: una cadena de diseño



173 240

chunks elegibles

de 182 461 observados

4 906

videos efectivos

322 canales en el alcance

5


salidas operativas

cuatro daños y SEGURO

Lectura clave: La unidad de modelado es el chunk; la unidad de separación y bootstrap es el video. Así se reduce la fuga entre fragmentos correlacionados.

Evidencia externa: Documentación de datos y separación por grupos [7,8]; selección de modelo sin sesgo [18]. | Resultado propio: auditoria_estado_final_182461.json.

El corpus preserva la prevalencia natural y hace visible el desbalance



Frecuencias de etiquetas; los daños pueden coexistir en un chunk.

Daño observado

14 163 chunks con al menos un daño; 2 709 son multietiqueta.

Entrenamiento

123 239 chunks; 3 478 videos.

Validación

27 317 chunks; 754 videos.

Test sellado

22 684 chunks; 674 videos.

Lectura clave: El conjunto no oculta el caso difícil: la clase SEGURO domina y las cuatro categorías de daño son heterogéneas.

Resultado propio: Auditoría final del corpus v2.1; partición efectiva 71,1/15,8/13,1 % por chunks, agrupada por video.

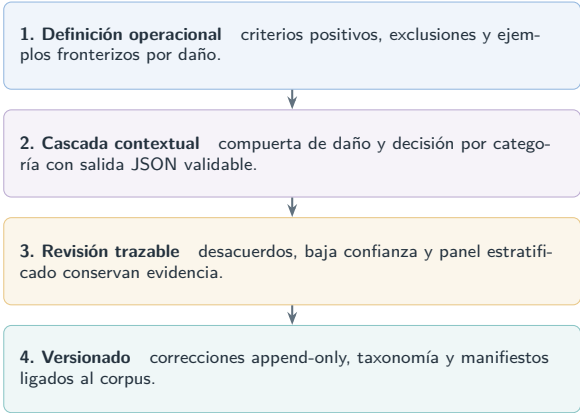
La taxonomía traduce daño social en cinco decisiones modelables



Lectura clave: Es una taxonomía multietiqueta: SEGURO es excluyente, pero un mismo chunk puede activar más de una categoría de daño.

Evidencia externa: Contexto peruano sobre racismo y violencia digital [19,20,21,22]; contrato interno: Taxonomía v2.

El etiquetado combina contexto normativo, cascada y auditoría



Lectura clave: La fortaleza está en la trazabilidad: definición, predicción, revisión y corrección pueden reconstruirse.

Evidencia externa: Acuerdo y anotación deben reportarse con su diseño [23,4]. | Resultado propio: docs/METODOLOGIA_ETIQUETADO_CASCADA.md y auditoría v2.1.

Video, texto y tramo temporal se

Categorías explícitas y observaciones

La acción queda vinculada a usuario

La comparación cubre cuatro familias con sesgos inductivos distintos

Modelos clásicos

TF-IDF y clasificadores lineales: rápidos, interpretables y competitivos cuando las señales léxicas son fuertes [24, 25, 26].

Qwen + LoRA

Adaptación eficiente de un modelo Qwen para capturar lenguaje y categorías con más contexto, actualizando una fracción de parámetros [31, 32].

Transformers

MiniLM/E5 y cascadas: representaciones contextuales con distinta relación entre costo y capacidad [27, 28, 29, 30].

Ensembles

Combinan probabilidades o decisiones de miembros diversos para reducir errores no coincidentes [33, 34].

28 candidatos individuales

5 ensembles

33 comparados en validation

Lectura clave: No se apuesta por una sola arquitectura: se explota la complementariedad entre léxico, representación contextual y adaptación generativa.

Resultado propio: Inventario verificable de `comparacion_individual_ensemble_validation.json`; arquitectura: `docs/ARQUITECTURAS_MODELOS_03.md`.

El entrenamiento separa ajuste, selección y prueba final



Unidad de grupo

Un video completo pertenece a un solo split o fold.

Métricas adecuadas


AUPRC para daños raros; BA para compuerta binaria desbalanceada [35, 36, 37].

Evidencia temporal

La selección queda firmada antes de consultar test.

Lectura clave: El test no decide el ganador: estima una vez el desempeño de la política ya congelada.

Qwen aporta contexto; LoRA mantiene viable la adaptación



0,831

BA binaria OOF

mejor Qwen individual

0,516

macro-AUPRC OOF

cuatro categorías de daño

0,553


macro-F1

daños en validation

Lectura clave: Qwen fue el mejor individuo por familia y también una fuente de diversidad para el ensemble ganador.

Evidencia externa: Adaptación eficiente [32]; familia Qwen [31]. | Resultado propio: Candidato qwen_lora-4aa5ce04df05, métricas OOF de validation.

El ensemble ganador promedia evidencia complementaria



Fusión suave

Conserva intensidad probabilística; no fuerza a que todos los miembros voten igual.

Cobertura completa para ranking

La derivación a humano se evalúa después, bajo una capacidad declarada.

Lectura clave: El producto combina tres fuentes distintas; su ventaja es cuantitativa y también

La selección evita premiar una sola métrica redundante

1. **Criterio primario:** mayor balanced accuracy de ANY_DAMAGE con predicciones OOF y cobertura completa.
2. **Salvaguarda:** macro-AUPRC de los cuatro daños dentro de un margen de no inferioridad predeclarado.
3. **Frontera de Pareto:** descarta opciones dominadas en sensibilidad/especificidad y desempeño por categoría.
4. **Desempate:** menor riesgo $R_{0,67}$ y luego mayor macro-AUPRC.
5. **Incertidumbre:** 2 000 réplicas pareadas por video y ajuste de Holm.

Por qué BA

Pondera sensibilidad y especificidad por igual ante desbalance [37].

Por qué AUPRC


Resume calidad de ranking donde el positivo es raro [35, 36].

Por qué por video

Respeto correlación entre chunks del mismo contenido [38].

Lectura clave: El ganador se congela por un protocolo reproducible; un empate estadístico se declara, no se convierte artificialmente en superioridad.

El ensemble soft mean encabeza el ranking de validation



0,840

BA OOF

ANY_DAMAGE; cobertura completa

0,555

macro-AUPRC OOF

cuatro daños


0,568

macro-F1

cuatro daños

Lectura clave: El mejor punto global integra clásico + Transformer + Qwen; el resultado respalda la diversidad de la cartera, no una arquitectura única.

El mejor representante mejora al subir de familia y al combinar



accuracy binaria OOF, validation. Eje truncado para mostrar diferencias.

Ganador de tipo	mAP daño	macro-F1
Regresión logística	0,479	0,503
Cascade v2	0,449	0,519
Qwen + LoRA	0,516	0,553
Soft mean	0,555	0,568

Ganancia acumulada


El ensemble supera al mejor clásico en +3,86 puntos de BA y +7,62 puntos de macro-AUPRC.

Lectura honesta

Las diferencias entre familias no prueban causalidad arquitectónica: resumen los mejores candidatos ejecutados.

Resultado propio: 03_07a, mejores_por_tipo_validation.csv; cifras sin redondear conservadas en el archivo fuente.

El ganador es operativo, pero la superioridad no es concluyente



Selección congelada

ensemble_soft_mean ocupa el mejor punto lexicográfico y pasa la salvaguarda.

Rival más cercano

El ensemble ponderado queda a $-0,00166$ de BA.

Incertidumbre

IC95 % pareado: $[-0,00437; 0,00083]$;
 $p_{Holm} = 0,229$.

Lectura clave: El estado correcto es *empate estadístico o evidencia inconclusa*: se elige un artefacto reproducible sin afirmar una superioridad no demostrada.

En test natural, la compuerta congelada conserva alta sensibilidad

0,846

balanced accuracy

cobertura completa

0,906

recall de daño

omite 9,43 % del daño

0,530

AP de daño

prevalencia natural 7,94 %

	Pred. daño	Pred. seguro
Daño real	1 632	170
Seguro real	4 466	16 416

Matriz de confusión de la compuerta ANY_DAMAGE.

Costo del recall

La especificidad es 0,786: la política prioriza detectar daño y envía más falsos positivos a revisión.


Desempeño por daños

Macro-AUPRC = 0,415; macro-F1 = 0,435 sobre cuatro categorías.

Lectura clave: A prevalencia natural, el sistema encuentra 1 632 de 1 802 chunks dañinos; su función es priorizar, no sancionar automáticamente.

Resultado propio: 03_07, test_final_abierto_una_vez.json; 22 684 chunks de 674 videos.

La abstención convierte incertidumbre en una cola humana explícita



65,2 %

cobertura automática

14 795 chunks resueltos sin derivación

34,8 %

carga de revisión

7 889 chunks derivados


Política congelada

$\delta = 0,03$; revisa cercanía a umbrales e incoherencias entre compuerta y categorías.

Lectura clave: 0,940 de BA aplica solo al 65,2 % automático; el 34,8 % restante es precisamente la salvaguarda humana.

Evidencia externa: Clasificación selectiva y aprendizaje con derivación [2,3]; calibración [41].

El test natural revela fortalezas y categorías aún difíciles



Mayor desempeño

CONTENIDO SEXUAL: AUPRC 0,580 y F1 0,570.

Zona intermedia

ACOSO/AMENAZA: AUPRC 0,450 y F1 0,454.


Prioridad de mejora

GÉNERO/IDENTIDAD: AUPRC 0,274 y F1 0,328.

Lectura clave: El promedio no basta: género/identidad y racismo requieren más ejemplos fronterizos, auditoría localizada y análisis de deriva.

Resultado propio: Test natural; métricas de la predicción congelada por categoría, `metricas_por_categoria_test.csv`.

No existe un único ganador para todas las categorías



Categoría	Mejor AUPRC	Valor
Racismo	Qwen ctx256	0,571
Género	Qwen ctx256	0,402
Acoso	Ensemble ponderado	0,614
Sexual	Soft mean	0,688

Ganadores por F1

Qwen ctx256 gana racismo; hard majority, género; union ensemble, acoso y sexual.


Decisión de producto

Se congela un ganador global para operación reproducible y se conservan especialistas como evidencia para futuras rutas por categoría.

Lectura clave: La diversidad tiene valor observable: Qwen domina categorías semánticas difíciles y los ensembles lideran acoso/sexual.

Resultado propio: Validation, ganadores_por_categoria_validation.csv; estas selecciones descriptivas no reabren el test.

El desempeño cae dentro del rango publicado, con una tarea propia más amplia



este trabajo usa vista test 4:1 y compuerta binaria congelada.

Posición contextual

F1 = 0,656: comparable con DETOXIS (0,646) y HateXplain (0,687).

No es una liga común

HatEval 0,730; OffendES 0,784; EXIST 0,794, pero cambian corpus, idioma, prevalencia, etiquetas y partición.

Mayor amplitud local

Aquí se integran cuatro daños peruanos, multietiqueta, marcas temporales y derivación humana.

Lectura clave: La evidencia permite afirmar competitividad contextual, no superioridad directa: el sistema queda en el rango publicado mientras resuelve un alcance operativo más amplio.

Evidencia externa: DETOXIS [13]; HateXplain [15]; HatEval [11]; OffendES [14]; EXIST [12].

La prevalencia natural es parte del resultado, no un detalle



average precision reportado

Por qué AP

La línea base de un ranking aleatorio cambia con la prevalencia; AP es informativa, pero no inmune al diseño muestral.

Hallazgo externo

NaijaHate obtiene AP 0,34 en una muestra representativa y 0,83–0,90 en conjuntos enriquecidos [17].

Hallazgo propio

En test natural, con 7,94 % de daño, la compuerta obtiene AP 0,530.

Interpretación

No son datasets comparables; juntos muestran por qué reportar prevalencia y mantener una vista natural es una fortaleza metodológica.

Lectura clave: El producto se evalúa donde operará: sobre abundancia de contenido seguro, no únicamente sobre un benchmark artificialmente balanceado.

El frontend de producción entrega evidencia, no solo una etiqueta

Moderador local Estadísticas Ayuda

¿Qué quieres analizar?

Escríbelo una frase o pega un enlace de YouTube. El tipo se detecta automáticamente.

casi escudándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o tengo la mano en su pecho. Qué rico. Yo también. O cuchara o quitándole camuflaje de la teta también. Las chicas tienen carcas. Ay, no secan, no secan nada. Por favor, amigo, llega hoy día a tu casa. Hola, Holanda. Levántale la teta a tu mujer y húbale. Y húbale. Ahí, Mí, qué boga huele más rico.

Quevedo 3-68 LeRA - época operativa 1 Confianza baja Necesita revisión

Contenido sexual

Notas: Ruta alto nivel. Cerca del análisis

▼ Scores por categoría

Razonamiento disciplinado	0.021
Ofensa	0.119
Acción negativa	0.024
Contenido sexual	0.036

Aceptar Rechazar Modificar

Resultado accionable

Categoría, probabilidad y tramo temporal permiten localizar el contenido.

Humano en control

Los casos inciertos se derivan mediante `NEEDS_REVIEW`; no hay sanción automática.

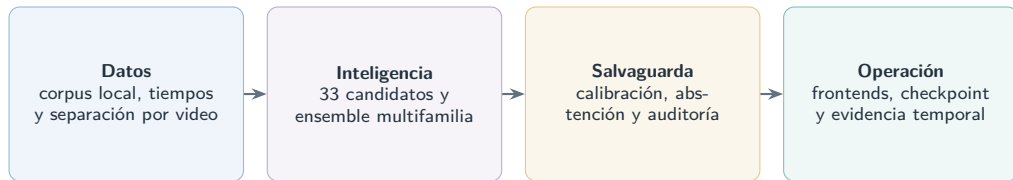
Ciclo de mejora

La corrección autorizada alimenta auditoría y reentrenamiento versionado.

Lectura clave: La salida útil es una decisión respaldada por contexto, incertidumbre y procedencia; eso vuelve al modelo gobernable.

Evidencia externa: Gobernanza de moderación [1]; derivación humano-IA [3]. | Resultado propio: Captura histórica; paridad del frontend activo en docs/PARIDAD_FRONTENDS_ACTIVOS.md.

La propuesta ya reúne los componentes de un producto verificable



Escalable

La ruta automática procesa 65,2 % del test con BA 0,940.

Especializable

Los ganadores por categoría revelan rutas futuras con Qwen y ensembles.

Auditable

Dataset, selección, prueba y correcciones conservan versión y procedencia.

Lectura clave: La principal bondad es sistémica: desempeño competitivo, evidencia local, supervisión humana y reproducibilidad conviven en un solo flujo.

Evidencia externa: Un artefacto de investigación debe ser útil y evaluado [9,10]; documentación de datasets/modelos [7,8].

Conclusiones I: del objetivo general al desempeño verificable

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
General Diseñar un sistema semiautomático	BA 0,846 a cobertura completa; BA 0,940 en 65,2 % automático; 34,8 % derivado.	Se logró una cadena humano-IA funcional: prioriza daño con alto recall y conserva revisión para incertidumbre.
OE1 Construir corpus local trazable	173 240 chunks elegibles, 4 906 videos, cinco salidas; 22 684 chunks en test natural.	El objeto de estudio mantiene prevalencia, contexto temporal y separación por video, condiciones necesarias para una evaluación creíble.
OE2 Comparar familias de modelos	28 individuos + 5 ensembles; soft mean: BA 0,840 y macro-AUPRC 0,555 OOF.	La complementariedad supera a los mejores representantes aislados; Qwen es el mejor individuo y aporta valor semántico.

Lectura clave: El objetivo general se cumple con una solución medible y utilizable: no solo clasifica, también sabe cuándo pedir ayuda.

Evidencia externa: Clasificación selectiva [2, 3]. | Resultado propio: Auditoría v2.1, comparación 03_07a y test 03_07 del 15-08-2026.

Conclusiones II: incertidumbre, integración y contribución

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
OE3 Calibrar y gobernar incertidumbre	2 000 bootstraps pareados por video; diferencia BA con rival $-0,00166$, IC95 % cruza cero; $p_{Holm} = 0,229$.	La selección es reproducible y honesta: congela un ganador operativo, declara el empate estadístico y reserva capacidad humana.
OE4 Integrar un flujo reutilizable	Dos frontends, manifiestos/checkpoints y 55 966 eventos trazables; panel congelado de 16 694 chunks.	El artefacto conecta etiquetado, entrenamiento, comparación, inferencia, revisión y corrección sin romper procedencia.
Contribución Competitividad contextual	F1 0,656 en vista 4:1, dentro del rango publicado 0,646–0,794 para tareas relacionadas.	El resultado es comparable en magnitud y más rico operacionalmente, aunque no constituye una comparación head-to-head.

Lectura clave: La contribución defendible es unir rigor experimental y operación humana sobre contenido peruano, con límites explícitos y evidencia reproducible.

Evidencia externa: Comparación contextual con [13, 15, 11, 14, 12].

Los límites identifican una ruta concreta de madurez

1. Categorías difíciles

Género (AUPRC 0,274) y racismo (0,357) requieren expansión focalizada, pruebas funcionales y revisión de falsos negativos [16].

2. Capacidad humana

34,8 % de revisión es una política eficaz, pero debe validarse contra dotación, tiempo y costo reales [3].

3. Generalización

YouTube peruano no representa automáticamente otras plataformas, países o periodos; medir deriva es parte del despliegue [4].

4. Validación humana

Formalizar doble anotación independiente y acuerdo por categoría fortalecerá la validez de las etiquetas [23].



Lectura clave: El sistema está listo como demostrador verificable; el siguiente salto es validar personas, costos y deriva en un piloto controlado.

Cierre: una moderación más rápida sin perder control humano

Detectar, explicar, derivar y aprender.

El sistema transforma subtítulos peruanos en alertas temporales mediante una cartera clásica–Transformer–Qwen y un ensemble congelado. La evaluación natural, la abstención y la trazabilidad hacen que el desempeño sea útil fuera del laboratorio.

BA 0,846 completa

BA 0,940 automática

4 daños + SEGURO

Propuesta de valor

Menos búsqueda manual, evidencia localizada y una cola de revisión priorizada.

Garantía metodológica

Separación por video, OOF, bootstrap y apertura única de test.

Principio operativo

La IA recomienda; el humano conserva la decisión.

Gracias. Preguntas y discusión.

Referencias utilizadas I



R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>



Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>



H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/mozannar20b.html>



B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0243300>



Z. Waseem, T. Davidson, D. Warmsley, and I. Weber, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>



M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>

Referencias utilizadas II



E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: <https://aclanthology.org/Q18-1041/>



M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: https://facctconference.org/static/pdfs_2022/facct22-3533231.pdf



A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>



K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.



V. Basile, C. Bosco, E. Fersini, D. Nozza, V. Patti, F. M. Rangel Pardo, P. Rosso, and M. Sanguinetti, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://aclanthology.org/S19-2007/>



F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza, J. Gonzalo, P. Rosso, M. Comet, and T. Donoso, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>

Referencias utilizadas III



M. Taulé, A. Ariza, M. Nofre, E. Amigó, and P. Rosso, "Overview of DETOXIS at IberLEF 2021: DEtection of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6390>



F. M. Plaza-del Arco, A. Montejo-Ráez, L. A. Ureña-López, and M.-T. Martín-Valdivia, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: <https://aclanthology.org/2021.ranlp-1.123/>



B. Mathew, P. Saha, S. M. Yimam, C. Biemann, P. Goyal, and A. Mukherjee, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14 867–14 875. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17745>



P. Röttger, B. Vidgen, D. Nguyen, Z. Waseem, H. Margetts, and J. Pierrehumbert, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>



M. Tonneau, P. Quinta De Castro, K. Lasri, I. Farouq, L. Subramanian, V. Orozco-Olvera, and S. Fraiberger, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://aclanthology.org/2024.acl-long.488/>

Referencias utilizadas IV



G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>



J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993.



V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>



D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnoresistencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf



Defensoría del Pueblo del Perú, "Violencia de género contra las mujeres en línea," Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%A9nea.pdf>



R. Artstein and M. Poesio, "Inter-coder agreement for computational linguistics," *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.



K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>

Referencias utilizadas V



D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.



C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.



A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>



W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>



L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>



L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>

Referencias utilizadas VI



A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, “Qwen3 technical report,” *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>



E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>



T. G. Dietterich, “Ensemble methods in machine learning,” in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.



L. Lam and C. Y. Suen, “Application of majority voting to pattern recognition: An analysis of its behavior and performance,” *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997.



T. Saito and M. Rehmsmeier, “The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets,” *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>



J. Davis and M. Goadrich, “The relationship between precision-recall and ROC curves,” in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240.

Referencias utilizadas VII



K. H. Brodersen, C. S. Ong, K. E. Stephan, and J. M. Buhmann, "The balanced accuracy and its posterior distribution," in *2010 20th International Conference on Pattern Recognition*. IEEE, 2010, pp. 3121–3124.



C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.



R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>



S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.



C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>