

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos, Transformers, Qwen y ensembles

Del corpus local al ensemble con revisión humana y evidencia temporal

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano

Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

01

CAPÍTULO 01

Problema y propuesta

Formulación del problema, objeto de estudio, objetivos y posición frente al estado del arte.

PROBLEMA REAL OBJETO DE ESTUDIO OBJETIVOS ESTADO DEL ARTE

Resultados principales del sistema

Desempeño competitivo con derivación humana explícita

22 684

chunks en test natural

674 videos; prevalencia de daño 7,94 %

0,846

exactitud balanceada (BA)

compuerta de cualquier da-
ño; cobertura completa

0,940

BA en ruta automática

65,2 % de cobertura; revisión 34,8 %

Valor técnico

Texto y tiempo trazables, cinco salidas calibradas, comparación reproducible y abstención explícita.

Valor operativo


Prioriza revisión humana; no automatiza sanciones ni oculta incertidumbre.

Síntesis: El producto no reemplaza al moderador: reduce el espacio de búsqueda y entrega evidencia localizada para decidir.

Evidencia externa: Moderación y responsabilidad [1]; clasificación selectiva [2,3]. | Resultado propio: test_final_abierto_una_vez.json, test natural.

Formulación del problema en tres niveles

Necesidad operativa, causas subyacentes y representación computacional



Síntesis: El problema a resolver es una cadena reproducible que pase de subtítulos públicos a alertas temporales y, finalmente, a una decisión humana informada.

Evidencia externa: Definición, muestreo y anotación condicionan el clasificador [4]; el abuso puede ser dirigido/generalizado y explícito/implícito [5,6].

Objeto de estudio y unidad de análisis

Texto contextualizado, procedencia y decisión supervisada

Objeto de estudio

Expresiones potencialmente dañinas en subtítulos de videos vinculados con el Perú.

Objeto modelado

Cinco salidas: SEGURO excluyente y cuatro daños que pueden coexistir.

Unidad de análisis

Chunk temporal con video_id, texto, inicio, fin y contexto vecino.

Objeto de decisión

Alerta, evidencia temporal, incertidumbre y motivo de revisión para un supervisor.

Síntesis: La predicción nunca se separa del fragmento que la originó ni de la persona que resuelve el caso.

Evidencia externa: Documentación de datos [7,8]; responsabilidad humana en moderación [1].

Objetivos y capacidades evaluadas

Del corpus local a un flujo verificable de operación

Corpus local reproducible → 173 240 chunks elegibles, cinco salidas y particiones separadas por video.



Comparación común → 28 individuos + 5 ensembles bajo la misma instantánea y criterio de validación.



Incertidumbre operable → calibración, compuerta ANY_DAMAGE y política de revisión congelada.



Artefacto utilizable → frontends, evidencia temporal, correcciones y registros append-only.

Síntesis: La contribución es el sistema completo: datos + etiquetas + modelos + selección + supervisión.

Evidencia externa: Diseño y evaluación iterativa de artefactos [9, 10].

Estado del arte: tareas, corpus y evaluación

La evaluación realista constituye una ventaja metodológica

Español

HatEval estudia odio contra mujeres e inmigrantes; EXIST, sexismo; DETOXIS, toxicidad; OffendES, ofensa en redes. Las etiquetas y plataformas no son intercambiables [11, 12, 13, 14].

Muestreo real

NaijaHate muestra precisión promedio (AP) de 0,34 en muestra representativa frente a 0,83–0,90 en conjuntos enriquecidos: la evaluación puede sobreestimar la operación [17].

Contexto y explicación

HateXplain incorpora blanco y racionales; HateCheck demuestra que una cifra agregada puede ocultar fallas funcionales [15, 16].

Brecha abordada

Faltaba una cadena para subtítulos peruanos, categorías localizadas, comparación multifamilia y derivación humana trazable.

Síntesis: La evaluación distingue explícitamente entre un benchmark enriquecido y un test con prevalencia natural.

02

CAPÍTULO 02


Datos y etiquetado

Generación del corpus local, taxonomía, metodología de etiquetado y auditoría.

DATASET TAXONOMÍA ETIQUETADO FRONTEND

Generación del dataset y trazabilidad

Datos locales, marcas temporales y separación por video



173 240

chunks elegibles

de 182 461 observados

4 906

videos efectivos

322 canales en el alcance

5

salidas operativas


cuatro daños y SEGURO

Síntesis: La unidad de modelado es el chunk; la unidad de separación y bootstrap es el video. Así se reduce la fuga entre fragmentos correlacionados.

Evidencia externa: Documentación de datos y separación por grupos [7,8]; selección de modelo sin sesgo [18]. | Resultado propio: auditoria_estado_final_182461.json.

Distribución del corpus y particiones

La prevalencia natural se conserva como condición de uso



Frecuencias de etiquetas; los daños pueden coexistir en un chunk.

Daño observado

14 163 chunks con al menos un daño; 2 709 son multietiqueta.

Entrenamiento

123 239 chunks; 3 478 videos.

Validación

27 317 chunks; 754 videos.

Test sellado

22 684 chunks; 674 videos.

Síntesis: El conjunto no oculta el caso difícil: la clase SEGURO domina y las cuatro categorías de daño son heterogéneas.

Resultado propio: Auditoría final del corpus v2.1; partición efectiva 71,1/15,8/13,1 % por chunks, agrupada por video.

Taxonomía de clasificación

Cinco salidas para cubrir seguridad y cuatro tipos de daño



Síntesis: Es una taxonomía multietiqueta: SEGURO es excluyente, pero un mismo chunk puede activar más de una categoría de daño.

Evidencia externa: Marco general: Waseem et al. [5] y Banko et al. [6]. Adaptación peruana: Callirgos [19], Zavala y Zariquiey [20], Vich [21], Albornoz y Flores [22] y Defensoría del Pueblo [23].

Fundamento bibliográfico de la taxonomía

Cada salida adapta tipologías generales y antecedentes peruanos específicos

Componente	Autores y aportes utilizados
Marco general	Waseem et al. [5]: tipologías de abuso; Banko et al. [6]: taxonomía unificada de contenido dañino.
Racismo / discriminación	Callirgos [19]; Zavala y Zariquiey [20]; Zavala y Back [24]; Brañez [25]; Almeida y Zavala [26]; Salem [27]; y Vich [21].
Género / identidad	Rodríguez-Sánchez et al. [12]; Zeinert, Inie y Derczynski [28]; Albornoz y Flores [22]; Defensoría del Pueblo [23]; Chakravarthi et al. [29]; Rottenbacher [30]; y Lovón-Cueva y Lovón-Cueva [31].
Acoso / amenaza	Waseem et al. [5]; Wulczyn, Thain y Dixon [32]; Banko et al. [6]; y Defensoría del Pueblo [23].
Contenido sexual	Banko et al. [6]; Zeinert, Inie y Derczynski [28]; Albornoz y Flores [22]; Defensoría del Pueblo [23]; y la política de YouTube [33].

Síntesis: Las fuentes sustentan las dimensiones de daño; los nombres, fusiones y reglas de exclusión finales son decisiones operativas del proyecto.

Resultado propio: Correspondencia documentada en docs/TAXONOMIA_V2.md y en la sección metodológica del artículo.

Metodología de etiquetado

Definiciones operativas y revisión trazable reducen ambigüedad

1. Definición operacional criterios positivos, exclusiones y ejemplos fronterizos por daño.



2. Cascada contextual compuerta de daño y decisión por categoría con salida estructurada validable.



3. Revisión trazable desacuerdos, baja confianza y panel estratificado conservan evidencia.



4. Versionado correcciones append-only, taxonomía y manifiestos ligados al corpus.

55 966

eventos trazables

revisión humana/sistema registrados

16 694

panel congelado

muestreo estratificado auditable

10,18 %

cobertura combinada


17 635 chunks elegibles auditados

Síntesis: La fortaleza está en la trazabilidad: definición, predicción, revisión y corrección pueden reconstruirse.

Evidencia externa: Acuerdo y anotación deben reportarse con su diseño [34,4]. | Resultado propio: docs/METODOLOGIA_ETIQUETADO_CASCADA.md y auditoría v2.1.

Frontend de etiquetado

El criterio de anotación se aplica en una interfaz auditable



Contexto visible

Video, texto y tramo temporal se revisan juntos.

Decisión estructurada

Categorías explícitas y observaciones reducen ambigüedad operativa.

Trazabilidad

La acción queda vinculada a usuario, instante y versión.

Síntesis: El frontend implementa la taxonomía mediante una decisión estructurada, repetible y auditable.

Resultado propio: Captura histórica del frontend; la paridad funcional del frontend activo v2.1 está documentada en docs/PARIDAD_FRONTENDS_ACTIVOS.md.

03

CAPÍTULO 03

Entrenamiento y ensembles

Comparación de familias, adaptación de Qwen y estrategias de combinación de modelos.

MODELOS CLÁSICOS TRANSFORMERS QWEN ENSEMBLES

Familias de modelos evaluadas

Una cartera diversa equilibra costo, contexto y desempeño

Modelos clásicos

Frecuencia de término–frecuencia inversa de documento (TF–IDF) y clasificadores lineales: rápidos, interpretables y competitivos con señales léxicas fuertes [35, 36, 37].

Qwen + LoRA

Adaptación de bajo rango (LoRA) de un modelo Qwen para capturar lenguaje y categorías con más contexto, actualizando una fracción de parámetros [42, 43].

Transformers

MiniLM/E5 y cascadas: representaciones contextuales con distinta relación entre costo y capacidad [38, 39, 40, 41].

Ensembles

Combinan probabilidades o decisiones de miembros diversos para reducir errores no coincidentes [44, 45].

28 candidatos individuales

5 ensembles

33 comparados en validación

Síntesis: La comparación conjunta aprovecha la complementariedad entre señales léxicas, representaciones contextuales y Qwen adaptado.

Resultado propio: Inventario verificable de `comparacion_individual_ensemble_validation.json`; arquitectura: `docs/ARQUITECTURAS_MODELOS_03.md`.

Diseño del entrenamiento y evaluación

Selección sin fuga y test abierto una sola vez



Unidad de grupo

Un video completo pertenece a un solo split o fold.

Métricas adecuadas

Área bajo la curva precisión-sensibilidad (AUPRC) para daños raros; BA para la compuerta desbalanceada [46, 47, 48].


Evidencia temporal

La selección queda firmada antes de consultar test.

Síntesis: El test no decide el ganador: estima una vez el desempeño de la política ya congelada.

Adaptación de Qwen mediante LoRA

El mejor modelo individual combina contexto y adaptación eficiente



0,831

BA binaria OOF

mejor Qwen individual

0,516

macro-AUPRC OOF

cuatro categorías de daño

0,553

F1 macro


media armónica de precisión y sensibilidad

Síntesis: Qwen fue el mejor individuo por familia y también una fuente de diversidad para el ensemble ganador.

Evidencia externa: Adaptación eficiente [43]; familia Qwen [42]. | Resultado propio: Candidato `qwen_lora-4aa5ce04df05`, métricas OOF de validación.

Metodología del ensemble por promedio de probabilidades

Tres familias complementarias respaldan la decisión final



Fusión suave

Conserva intensidad probabilística; no fuerza a que todos los miembros voten igual.

Cobertura completa para ranking

La derivación a humano se evalúa después, bajo una capacidad declarada.

Síntesis: El producto combina tres fuentes distintas; su ventaja es cuantitativa y también arquitectónica: reduce dependencia de un único tipo de modelo.

Evidencia externa: Los ensembles explotan errores diversos [44, 45]; implementación interna: promedio de probabilidades por categoría.

Estrategias de ensemble evaluadas

Cinco reglas combinan los mismos tres miembros con distintos criterios

Clásico

Regresión logística con $C = 0,5$.

Transformer

Arquitectura cascade v2.

Qwen

Qwen adaptado mediante LoRA.

Regla	Operación por categoría	BA	macro-AUPRC	F1 macro
Promedio simple	Media de las tres probabilidades.	0,840	0,555	0,568
Promedio ponderado	Pesos 0,332 / 0,311 / 0,357, proporcionales a macro-AUPRC.	0,838	0,556	0,569
Unión	Máxima probabilidad entre los tres miembros.	0,833	0,524	0,565
Mayoría	Promedio de decisiones binarias calibradas.	0,829	0,461	0,572
Intersección	Mínima probabilidad entre los tres miembros.	0,824	0,516	0,538

Síntesis: El promedio simple gana por exactitud balanceada; el ponderado es el rival más cercano y la mayoría obtiene el mayor F1 macro entre ensembles.

Resultado propio: 03_07a, validación OOF; implementación en `ensemble_evaluation.py`; los cinco ensembles usan exactamente los mismos tres miembros.

Criterio de selección y análisis estadístico

Desempeño, salvaguardas e incertidumbre en un solo protocolo

1. **Criterio primario:** mayor exactitud balanceada de ANY_DAMAGE con predicciones OOF y cobertura completa.
2. **Salvaguarda:** macro-AUPRC de los cuatro daños dentro de un margen de no inferioridad predeclarado.
3. **Frontera de Pareto:** descarta opciones dominadas en sensibilidad/especificidad y desempeño por categoría.
4. **Desempate:** menor riesgo $R_{0,67}$ y luego mayor macro-AUPRC.
5. **Incetidumbre:** 2000 réplicas pareadas por video y ajuste de Holm.

Por qué BA

Pondera sensibilidad y especificidad por igual ante desbalance [48].

Por qué AUPRC

Resume calidad de ranking donde el positivo es raro [46, 47].

Por qué por video

Respeto correlación entre chunks del mismo contenido [49].

Síntesis: El ganador se congela por un protocolo reproducible; un empate estadístico se declara, no se convierte artificialmente en superioridad.

Evidencia externa: Comparación múltiple y significancia [50, 51]; criterio interno: docs/CRITERIO_SELECCION_MODELOS_03.md.

04

CAPÍTULO 04

Resultados finales

Ganadores globales, por tipo y por categoría; test natural y comparación externa.

VALIDACIÓN


TEST NATURAL

CATEGORÍAS

ESTADO DEL ARTE

Ranking global en validación

La combinación multifamilia obtiene el mejor resultado global



0,840

BA OOF

ANY_DAMAGE; cobertura completa

0,555

macro-AUPRC OOF

cuatro daños

0,568

macro-F1


cuatro daños

Síntesis: El mejor punto global integra clásico + Transformer + Qwen; el resultado respalda la diversidad de la cartera, no una arquitectura única.

Resultado propio: 03_07a, ranking_validation.csv; ganador congelado: ensemble_soft_mean.

Mejor modelo por tipo

La mejora se mantiene desde los modelos clásicos hasta el ensemble



Ganador de tipo	macro-AUPRC	F1 macro
Regresión logística	0,479	0,503
Cascade v2	0,449	0,519
Qwen + LoRA	0,516	0,553
Soft mean	0,555	0,568

Ganancia acumulada

El ensemble supera al mejor clásico en +3,86 puntos de BA y +7,62 puntos de macro-AUPRC.


Lectura honesta

Las diferencias entre familias no prueban causalidad arquitectónica: resumen los mejores candidatos ejecutados.

Resultado propio: 03_07a, mejores_por_tipo_validation.csv; cifras sin redondear conservadas en el archivo fuente.

Frontera de Pareto e incertidumbre estadística

Selección reproducible con una diferencia estadística no concluyente



Selección congelada

ensemble_soft_mean ocupa el mejor punto lexicográfico y pasa la salvaguarda.

Rival más cercano

El ensemble ponderado queda a $-0,00166$ de BA.

Incetidumbre

Intervalo de confianza del 95 % (IC95 %) pareado:
 $[-0,00437; 0,00083]$; $p_{Holm} = 0,229$.

Síntesis: El estado correcto es *empate estadístico o evidencia inconclusa*: se elige un artefacto reproducible sin afirmar una superioridad no demostrada.

Evidencia externa: Bootstrap agrupado [49]; pruebas pareadas y ajuste múltiple [50, 51].

Resultados en test de prevalencia natural

Alta sensibilidad sobre 22 684 chunks en condiciones naturales

0,846

exactitud balanceada

cobertura completa

0,906

sensibilidad al daño

omite 9,43 % del daño

0,530

AP de daño

prevalencia natural 7,94 %

	Pred. daño	Pred. seguro
Daño real	1 632	170
Seguro real	4 466	16 416

Matriz de confusión de la compuerta ANY_DAMAGE.

Costo de la sensibilidad

La especificidad es 0,786: la política prioriza detectar daño y envía más falsos positivos a revisión.

Desempeño por daños


Macro-AUPRC = 0,415; macro-F1 = 0,435 sobre cuatro categorías.

Síntesis: A prevalencia natural, el sistema encuentra 1 632 de 1 802 chunks dañinos; su función es priorizar, no sancionar automáticamente.

Resultado propio: 03_07, test_final_abierto_una_vez.json; 22 684 chunks de 674 videos.

Política de revisión humana

Los casos inciertos se reservan para supervisión humana



65,2 %

cobertura automática

14795 chunks resueltos sin derivación

34,8 %

carga de revisión

7889 chunks derivados

Política congelada


$\delta = 0,03$; revisa cercanía a umbrales e incoherencias entre compuerta y categorías.

Síntesis: 0,940 de BA aplica solo al 65,2 % automático; el 34,8 % restante es precisamente la salvaguarda humana.

Evidencia externa: Clasificación selectiva y aprendizaje con derivación [2,3]; calibración [52].

Resultados por categoría en test natural

Contenido sexual y acoso presentan los mejores resultados



Mayor desempeño

CONTENIDO SEXUAL: AUPRC 0,580 y F1 0,570.

Zona intermedia

ACOSO/AMENAZA: AUPRC 0,450 y F1 0,454.

Prioridad de mejora


GÉNERO/IDENTIDAD: AUPRC 0,274 y F1 0,328.

Síntesis: El promedio no basta: género/identidad y racismo requieren más ejemplos fronterizos, auditoría localizada y análisis de deriva.

Resultado propio: Test natural; métricas de la predicción congelada por categoría, `metricas_por_categoria_test.csv`.

Mejor modelo por categoría en validación

Qwen y los ensembles se especializan en daños distintos



Categoría	Mejor AUPRC	Valor
Racismo	Qwen contexto 256	0,571
Género	Qwen contexto 256	0,402
Acoso	Ensemble ponderado	0,614
Sexual	Soft mean	0,688

Ganadores por F1

Qwen con contexto 256 gana racismo; voto mayoritario, género; ensemble por unión, acoso y sexual.

Decisión de producto


Se congela un ganador global para operación reproducible y se conservan especialistas como evidencia para futuras rutas por categoría.

Síntesis: La diversidad tiene valor observable: Qwen domina categorías semánticas difíciles y los ensembles lideran acoso/sexual.

Resultado propio: Validación, ganadores_por_categoria_validation.csv; estas selecciones descriptivas no reabren el test.

Comparación contextual con el estado del arte

Resultados del mismo orden que trabajos publicados relacionados



este trabajo usa vista test 4:1 y compuerta binaria congelada.

Posición contextual

F1 = 0,656: comparable con DETTOXIS (0,646) y HateXplain (0,687).

No es una liga común

HatEval 0,730; OffendES 0,784; EXIST 0,794, pero cambian corpus, idioma, prevalencia, etiquetas y partición.

Mayor amplitud local

Aquí se integran cuatro daños peruanos, multietiqueta, marcas temporales y derivación humana.

Síntesis: La evidencia permite afirmar competitividad contextual, no superioridad directa: el sistema queda en el rango publicado mientras resuelve un alcance operativo más amplio.

Evidencia externa: DETTOXIS [13]; HateXplain [15]; HatEval [11]; OffendES [14]; EXIST [12].

Efecto del diseño muestral sobre la evaluación

La evaluación natural reduce el riesgo de sobreestimar el desempeño



average precision reportado

Por qué AP

La línea base de un ranking aleatorio cambia con la prevalencia; AP es informativa, pero no inmune al diseño muestral.

Hallazgo externo

NaijaHate obtiene AP 0,34 en una muestra representativa y 0,83–0,90 en conjuntos enriquecidos [17].

Hallazgo propio

En test natural, con 7,94 % de daño, la compuerta obtiene AP 0,530.

Interpretación

No son datasets comparables; juntos muestran por qué reportar prevalencia y mantener una vista natural es una fortaleza metodológica.

Síntesis: El producto se evalúa donde operará: sobre abundancia de contenido seguro, no únicamente sobre un benchmark artificialmente balanceado.

05

CAPÍTULO 05


Producto y conclusiones

Interfaces, capacidades del sistema y cumplimiento cuantitativo de los objetivos.

OPERACIÓN TRAZABILIDAD OBJETIVOS TRABAJO FUTURO

Frontend de producción

Categoría, probabilidad y evidencia temporal en una sola vista



Resultado accionable

Categoría, probabilidad y tramo temporal permiten localizar el contenido.

Humano en control

Los casos inciertos se derivan mediante `NEEDS_REVIEW`; no hay sanción automática.

Ciclo de mejora


La corrección autorizada alimenta auditoría y reentrenamiento versionado.

Síntesis: La salida útil es una decisión respaldada por contexto, incertidumbre y procedencia; eso vuelve al modelo gobernable.

Evidencia externa: Gobernanza de moderación [1]; derivación humano-IA [3]. | Resultado propio: Captura histórica; paridad del frontend activo en docs/PARIDAD_FRONTENDS_ACTIVOS.md.

Componentes del producto

Datos, modelos, salvaguardas y operación integrados



Escalable

La ruta automática procesa 65,2 % del test con BA de 0,940.

Especializable

Los ganadores por categoría revelan rutas futuras con Qwen y ensembles.

Auditable

Dataset, selección, prueba y correcciones conservan versión y procedencia.

Síntesis: La principal bondad es sistémica: desempeño competitivo, evidencia local, supervisión humana y reproducibilidad conviven en un solo flujo.

Evidencia externa: Un artefacto de investigación debe ser útil y evaluado [9,10]; documentación de datasets/modelos [7,8].

Conclusiones vinculadas a los objetivos I

Cumplimiento del objetivo general y los objetivos específicos 1 y 2

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
General Diseñar un sistema semiautomático	BA 0,846 a cobertura completa; BA 0,940 en 65,2 % automático; 34,8 % derivado.	Se logró una cadena humano-IA funcional: prioriza daño con alta sensibilidad y conserva revisión para incertidumbre.
Específico 1 Construir corpus local trazable	173 240 chunks elegibles, 4 906 videos, cinco salidas; 22 684 chunks en test natural.	El objeto de estudio mantiene prevalencia, contexto temporal y separación por video, condiciones necesarias para una evaluación creíble.
Específico 2 Comparar familias de modelos	28 individuos + 5 ensembles; soft mean: BA 0,840 y macro-AUPRC 0,555 OOF.	La complementariedad supera a los mejores representantes aislados; Qwen es el mejor individuo y mejora la representación contextual.

Síntesis: El objetivo general se cumple con una solución medible y utilizable que clasifica y deriva los casos inciertos.

Evidencia externa: Clasificación selectiva [2, 3]. | Resultado propio: Auditoría v2.1, comparación 03_07a y test 03_07 del 15-08-2026.

Conclusiones vinculadas a los objetivos II

Cumplimiento de los objetivos específicos 3 y 4

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
Específico 3 Calibrar y gobernar incertidumbre	2 000 bootstraps pareados por video; diferencia BA con rival $-0,00166$, IC95 % cruza cero; $p_{Holm} = 0,229$.	La selección es reproducible y honesta: congela un ganador operativo, declara el empate estadístico y reserva capacidad humana.
Específico 4 Integrar un flujo reutilizable	Dos frontends, manifiestos/checkpoints y 55 966 eventos trazables; panel congelado de 16 694 chunks.	El artefacto conecta etiquetado, entrenamiento, comparación, inferencia, revisión y corrección sin romper procedencia.
Contribución Competitividad contextual	F1 0,656 en vista 4:1, dentro del rango publicado 0,646–0,794 para tareas relacionadas.	El resultado es comparable en magnitud y más rico operacionalmente, aunque no constituye una comparación head-to-head.

Síntesis: La contribución defendible es unir rigor experimental y operación humana sobre contenido peruano, con límites explícitos y evidencia reproducible.

Evidencia externa: Comparación contextual con [13,15,11,14,12].

Limitaciones y trabajo futuro

Mejoras focalizadas para avanzar a un piloto controlado

1. Categorías difíciles

Género (AUPRC 0,274) y racismo (0,357) requieren expansión focalizada, pruebas funcionales y revisión de falsos negativos [16].

2. Capacidad humana

34,8 % de revisión es una política eficaz, pero debe validarse contra dotación, tiempo y costo reales [3].

3. Generalización

YouTube peruano no representa automáticamente otras plataformas, países o periodos; medir deriva es parte del despliegue [4].

4. Validación humana

Formalizar doble anotación independiente y acuerdo por categoría fortalecerá la validez de las etiquetas [34].



Síntesis: El sistema está listo como demostrador verificable; la siguiente etapa es validar capacidad humana, costos y deriva en un piloto controlado.

Conclusiones finales

Desempeño verificable, revisión humana y trazabilidad

Resultado del proyecto

El sistema transforma subtítulos peruanos en alertas temporales mediante una cartera clásica–Transformer–Qwen y un ensemble congelado. La evaluación natural, la abstención y la trazabilidad hacen que el desempeño sea útil fuera del laboratorio.

BA 0,846 completa

BA 0,940 automática

4 daños + SEGURO

Propuesta de valor

Menos búsqueda manual, evidencia localizada y una cola de revisión priorizada.

Garantía metodológica

Separación por video, OOF, bootstrap y apertura única de test.

Principio operativo

La IA recomienda; el humano conserva la decisión.

Gracias. Preguntas y discusión.

06

CAPÍTULO 06

Referencias

Fuentes académicas y documentos utilizados para fundamentar métodos y comparaciones.

MODERACIÓN DATOS MODELOS EVALUACIÓN

Referencias utilizadas I



R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>



Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>



H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/mozannar20b.html>



B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0243300>



Z. Waseem, T. Davidson, D. Warmley, and I. Weber, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>



M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>



E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: <https://aclanthology.org/Q18-1041/>



M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: https://facctconference.org/static/pdfs_2022/facct22-3533231.pdf

Referencias utilizadas II



A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>



K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.



V. Basile, C. Bosco, E. Fersini, D. Nozza, V. Patti, F. M. Rangel Pardo, P. Rosso, and M. Sanguinetti, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://aclanthology.org/S19-2007/>



F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza, J. Gonzalo, P. Rosso, M. Comet, and T. Donoso, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>



M. Taulé, A. Ariza, M. Nofre, E. Amigó, and P. Rosso, "Overview of DETOXIS at IberLEF 2021: DETection of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6390>



F. M. Plaza-del Arco, A. Montejo-Ráez, L. A. Ureña-López, and M.-T. Martín-Valdivia, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: <https://aclanthology.org/2021.ranlp-1.123/>



B. Mathew, P. Saha, S. M. Yimam, C. Biemann, P. Goyal, and A. Mukherjee, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14 867–14 875. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17745>

Referencias utilizadas III



P. Röttger, B. Vidgen, D. Nguyen, Z. Waseem, H. Margetts, and J. Pierrehumbert, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>



M. Tonneau, P. Quinta De Castro, K. Lasri, I. Farouq, L. Subramanian, V. Orozco-Olvera, and S. Fraiberger, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://aclanthology.org/2024.acl-long.488/>



G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>



J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993.



V. Zavala and R. Zariquiey, "'Yo te segrego a ti porque tu falta de educación me ofende': una aproximación al discurso racista en el Perú contemporáneo," in *Racismo y discurso en América Latina*, T. A. van Dijk, Ed. Barcelona: Gedisa, 2007, pp. 333–370.



V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>



D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnoresistencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf



Defensoría del Pueblo del Perú, "Violencia de género contra las mujeres en línea," Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>

Referencias utilizadas IV



V. Zavala and M. Back, Eds., *Racismo y lenguaje*. Lima: Fondo Editorial de la Pontificia Universidad Católica del Perú, 2017. [Online]. Available: <https://repositorio.pucp.edu.pe/index/handle/123456789/170315>



R. F. Brañez Medina, "La construcción discursiva de las identidades "amixer" y "no-amixer" en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú, 2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/1618>



V. Zavala and C. Almeida, "'Motoso y terruco': ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/lexis/article/view/26332>



V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf



P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://aclanthology.org/2021.acl-long.247/>



B. R. Chakravarthi, "Detection of homophobia and transphobia in YouTube comments," *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s41060-023-00400-0>



J. M. Rottenbacher de Rojas, "Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima," *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>

Referencias utilizadas V



C. M. Lovón-Cueva and M. Lovón-Cueva, "Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums," *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://whatever.cirque.unipi.it/index.php/journal/article/view/156>



E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399.



YouTube, "Política sobre desnudos y contenido sexual," Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>



R. Artstein and M. Poesio, "Inter-coder agreement for computational linguistics," *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.



K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>



D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.



C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.



A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>

Referencias utilizadas VI



W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>



L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>



L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>



A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, "Qwen3 technical report," *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>



E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>



T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.



L. Lam and C. Y. Suen, "Application of majority voting to pattern recognition: An analysis of its behavior and performance," *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997.

Referencias utilizadas VII



T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>



J. Davis and M. Goadrich, "The relationship between precision-recall and ROC curves," in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240.



K. H. Brodersen, C. S. Ong, K. E. Stephan, and J. M. Buhmann, "The balanced accuracy and its posterior distribution," in *2010 20th International Conference on Pattern Recognition*. IEEE, 2010, pp. 3121–3124.



C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.



R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>



S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.



C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>