

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Del corpus local al ensemble con revisión humana y evidencia temporal

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano

Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

Índice

Siete capítulos para recorrer el problema, la evidencia y el producto

01 · Problema y propuesta

Problema real, objeto de estudio, objetivos y alcance de la solución.

02 · Estado del arte y enfoques

Métodos vigentes, benchmarks y decisiones que orientan la solución.

03 · Datos y etiquetado

Corpus final, canales, taxonomía, tamaño de chunk y revisión trazable.

04 · Entrenamiento y ensembles

Familias de modelos, adaptación de Qwen, combinaciones y criterio de ranking.

05 · Resultados finales

Ganadores globales, por tipo y categoría; test natural y revisión humana.

06 · Comparación externa

Resultados publicados y análisis crítico de comparabilidad.

07 · Producto y conclusiones

Frontends, cumplimiento de objetivos, límites y siguientes pasos.

01

CAPÍTULO 01

Problema y propuesta

Formulación del problema, objeto de estudio, objetivos y alcance de la solución.

PROBLEMA REAL OBJETO DE ESTUDIO OBJETIVOS PROPUESTA

Resultados principales del sistema

Desempeño competitivo con derivación humana explícita

22 684

chunks en test natural

674 videos; prevalencia de daño 7,94 %

0,846

exactitud balanceada (BA)

compuerta de cualquier da-
ño; cobertura completa

0,925

BA en ruta automática

72,7 % de cobertura; revisión 27,3 %

Valor técnico

Texto y tiempo trazables, cinco salidas calibradas, comparación reproducible y abstención explícita.

Valor operativo

Prioriza revisión humana; no automatiza sanciones ni oculta incertidumbre.

Síntesis: El producto no reemplaza al moderador: reduce el espacio de búsqueda y entrega evidencia localizada para decidir.

Evidencia externa: Moderación y responsabilidad [1]; clasificación selectiva [2,3]. | Resultado propio: test_final_abierto_una_vez.json, test natural.

Por qué moderar subtítulos no es solo clasificar texto

Escala, contexto y responsabilidad deben resolverse al mismo tiempo

Daño heterogéneo

Discriminación, ataques por identidad, acoso, amenazas y sexualización pueden coexistir o expresarse de modo implícito.

Contexto ambiguo

Una noticia puede citar una amenaza; el humor puede encubrir un blanco; una expresión peruana cambia de sentido según hablante y entorno.

Decisión auditable

Revisar cada video completo no escala; una alerta sin texto, intervalo, incertidumbre ni procedencia tampoco permite decidir responsablemente.

Subtítulo + tiempo + procedencia

Cinco scores + compuerta + calibración


Evidencia y motivo para revisión humana

Síntesis: El problema es priorizar contenido sin perder el contexto que explica la alerta ni trasladar al modelo la responsabilidad final.

Evidencia externa: Moderación y responsabilidad [1]; abuso explícito/implícito y dirigido/generalizado [4,5]; contexto peruano [6].

Formulación del problema en tres niveles

Necesidad operativa, causas subyacentes y representación computacional



Síntesis: El problema a resolver es una cadena reproducible que pase de subtítulos públicos a alertas temporales y, finalmente, a una decisión humana informada.

Evidencia externa: Definición, muestreo y anotación condicionan el clasificador [7]; el abuso puede ser dirigido/generalizado y explícito/implícito [4, 5].

Objeto de estudio y unidad de análisis

Texto contextualizado, procedencia y decisión supervisada

Objeto de estudio

Expresiones potencialmente dañinas en subtítulos de videos vinculados con el Perú.

Objeto modelado

Cinco salidas: SEGURO excluyente y cuatro daños que pueden coexistir.

Unidad de análisis

Chunk temporal con video_id, texto, inicio, fin y contexto vecino.

Objeto de decisión

Alerta, evidencia temporal, incertidumbre y motivo de revisión para un supervisor.

Síntesis: La predicción nunca se separa del fragmento que la originó ni de la persona que resuelve el caso.

Evidencia externa: Documentación de datos [8,9]; responsabilidad humana en moderación [1].

Objetivos y capacidades evaluadas

Del corpus local a un flujo verificable de operación

Corpus local reproducible → 173 240 chunks elegibles, cinco salidas y particiones separadas por video.



Comparación común → 28 individuos + 5 reglas base + 2 mezclas optimizadas bajo la misma instantánea.



Incertidumbre operable → calibración, compuerta ANY_DAMAGE y política de revisión congelada.




Artefacto utilizable → frontends, evidencia temporal, correcciones y registros append-only.

Síntesis: La contribución es el sistema completo: datos + etiquetas + modelos + selección + supervisión.

Evidencia externa: Diseño y evaluación iterativa de artefactos [10,11].

DSR conecta cada brecha con evidencia verificable

La construcción y la evaluación forman un solo ciclo del artefacto



Datos

Corpus y taxonomía versionados;
particiones por video y procedencia de
cada chunk.

Modelos

Comparación común, optimización
anidada, calibración y test separado.

Operación

Frontend, evidencia temporal,
derivación humana y eventos trazables.

Síntesis: Los resultados finales no son una segunda fase aislada: evalúan el mismo artefacto construido y motivan la siguiente iteración sin reusar test para seleccionar.

Evidencia externa: Ciencia del diseño y proceso DSR [10, 11]; separación de selección y evaluación [12].

02

CAPÍTULO 02


Estado del arte y enfoques de solución

Cómo se resuelve el problema: datos, representación, combinación, evaluación y supervisión.

MÉTODOS BENCHMARKS EXPLICABILIDAD OPERACIÓN

Cómo aborda el estado del arte este problema

La solución actual es una cadena de decisiones, no un único algoritmo



Primera generación

Léxicos, bolsa de palabras, TF-IDF y clasificadores lineales: bajo costo y señales transparentes.

Generación contextual

Transformers y adaptación eficiente: mejor lectura semántica, con mayor costo y necesidad de calibración.

Sistema contemporáneo

Ensembles, evidencia, evaluación natural y humano en control: desempeño integrado con gobernanza.

Síntesis: La propuesta adopta esta evolución completa: conserva un clásico eficiente, suma Transformer y Qwen, combina probabilidades y deriva la incertidumbre.

Antecedentes en español I: toxicidad y odio

Toxicidad y odio dirigido: cercanía temática con unidades de análisis distintas

Trabajo	Ámbito	Diseño y resultado publicado	Semejanza / diferencia
DETOXIS Taulé et al. (2021)	España; comentarios en español a noticias sobre inmigración	NewsCom-TOX: 4 359 comentarios; detección binaria de toxicidad. Mejor $F1 = 0,6461$.	Coincide en español y contenido dañino. Cambia el dominio: comentarios escritos sobre noticias, una etiqueta binaria y muestra temática.
HatEval Basile et al. (2019)	Twitter; español e inglés; mujeres e inmigrantes como blancos	Tarea compartida: odio binario y rasgos de agresividad/blanco. Mejor macro-F1 español = 0,730.	Comparte racismo y género. No usa transcripciones, taxonomía peruana ni cuatro daños coexistentes; su muestreo fue orientado al blanco.

Aplicación DETOXIS

Priorizar o clasificar toxicidad en la conversación que sigue a noticias de inmigración.

Aplicación HatEval

Detectar odio contra mujeres e inmigrantes y caracterizar agresividad y tipo de blanco.

Síntesis: Ambos trabajos justifican una referencia cuantitativa, pero no una competencia directa: la unidad, la prevalencia y el contrato de etiquetas cambian.

Evidencia externa: DETOXIS [21]; HatEval [22].

Antecedentes en español II: ofensa y sexismo

Ofensa y sexismo: mayor proximidad de plataforma o categoría, no equivalencia de tarea

Trabajo	Ámbito	Diseño y resultado publicado	Semejanza / diferencia
OffendES Plaza-del-Arco et al. (2021)	España / español; YouTube, Instagram y Twitter alrededor de influencers jóvenes	47 128 comentarios manualmente anotados; línea base binaria de ofensa con macro-F1 = 0,7839.	Es el antecedente más próximo por YouTube y español. Clasifica comentarios de usuarios, no habla transcrita ni evidencia temporal; ofensa es una categoría más amplia.
EXIST Rodríguez-Sánchez et al. (2021)	Contexto internacional; español e inglés; Twitter y Gab	Más de 11 000 textos; identificación y categorización de sexismo. Mejor F1 español en identificación = 0,7944.	Se aproxima a género/identidad y usa supervisión de expertas. Cambian plataforma, balance, unidad y alcance: sexismo no cubre los cuatro daños del proyecto.

Aplicación OffendES

Investigar y detectar lenguaje ofensivo en interacciones sociales en español.

Aplicación EXIST

Identificar sexismo explícito o sutil y categorizar su forma en redes sociales.

Síntesis: OffendES aporta cercanía de plataforma; EXIST, cercanía conceptual. El presente trabajo integra ambas dimensiones con localización peruana y multietiqueta.

Evidencia externa: OffendES [23]; EXIST [24].

Explicabilidad, muestreo y evidencia

Dos trabajos que orientan cómo interpretar el producto, además de cuánto puntúa

HateXplain · India/Alemania; inglés

Cerca de 20 mil posts de Twitter y Gab, con tres clases, blanco y racionales humanos. BERT-HateXplain alcanza macro-F1 0,687, pero el artículo muestra que clasificar bien no garantiza explicaciones plausibles o fieles [25].

Relación con este trabajo

Ambos vinculan la decisión con evidencia; aquí la explicación es el tramo temporal y el texto fuente. HateXplain opera sobre posts en inglés y racionales token a token, no videos peruanos.

NaijaHate · Nigeria; Twitter

35 976 tuits nigerianos y una muestra representativa. El mismo tipo de detector obtiene AP cercana a 0,34 en muestra aleatoria frente a 0,83–0,90 en muestras enriquecidas [19].

Relación con este trabajo

Comparte la preocupación por idioma local, dominio y prevalencia real. Aquí se conserva un test natural peruano; las AP absolutas no son comparables porque cambian país, idioma, etiqueta y muestra.

Síntesis: La ventaja del proyecto no es solo un F1 competitivo: presenta evidencia temporal y mide el sistema bajo abundancia real de contenido seguro.

03

CAPÍTULO 03

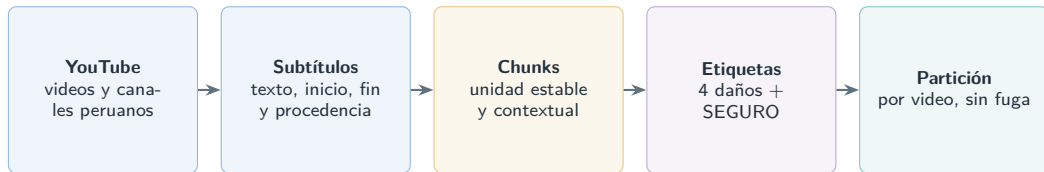
Datos y etiquetado

Generación del corpus local, taxonomía, metodología de etiquetado y auditoría.

DATASET TAXONOMÍA ETIQUETADO FRONTEND

Generación del dataset y trazabilidad

Datos locales, marcas temporales y separación por video



173 240

chunks elegibles

de 182 461 observados

4 906

videos efectivos

276 canales; 322 en el alcance inicial

5

salidas operativas


cuatro daños y SEGURO

Síntesis: La unidad de modelado es el chunk; la unidad de separación y bootstrap es el video. Así se reduce la fuga entre fragmentos correlacionados.

Evidencia externa: Documentación de datos y separación por grupos [8,9]; selección de modelo sin sesgo [12]. | Resultado propio: auditoria_estado_final_182461.json.

Distribución del corpus y particiones

La prevalencia natural se conserva como condición de uso



Frecuencias de etiquetas; los daños pueden coexistir en un chunk.

Daño observado

14 163 chunks con al menos un daño; 2 709 son multietiqueta.

Entrenamiento

123 239 chunks; 3 478 videos.

Validación

27 317 chunks; 754 videos.

Test sellado

22 684 chunks; 674 videos.

Síntesis: El conjunto no oculta el caso difícil: la clase SEGURO domina y las cuatro categorías de daño son heterogéneas.

Resultado propio: Auditoría final del corpus v2.1; partición efectiva 71,1/15,8/13,1 % por chunks, agrupada por video.

Radiografía del dataset final

El universo efectivo se distingue del alcance previo a exclusiones




Dimensión	Distribución	Lectura descriptiva
Seguridad / daño	159 077 SEGURO (91,82 %) y 14 163 con daño (8,18 %)	Relación 11,23:1; la exactitud ordinaria puede ocultar fallas sobre daño.
Multietiqueta	17 052 asignaciones de daño; 2 709 chunks dañinos con más de una categoría	Las frecuencias por etiqueta no deben sumarse como casos únicos.
Videos	media 35,3; mediana 19; máximo 767 chunks	La mediana describe mejor el video típico que la media.
Canales	media 627,7; mediana 25,5; máximo 33 203 chunks	La diferencia media–mediana revela alta concentración por fuente.

Síntesis: El dataset final no es una muestra uniforme: conserva la prevalencia natural y exige métricas, particiones y remuestreo que respeten su desbalance.

Resultado propio: docs/artefactos/auditoria_estado_final_182461.json; snapshot v2.1.0, corte 09-08-2026.

Canales principales y concentración del corpus

La diversidad de fuentes convive con una cola larga de canales pequeños



Ocho canales con más chunks elegibles; nombres abreviados solo para visualización.

Canal principal

Hablando Huevadas aporta 19,17 % del corpus elegible.

Concentración

Los cinco primeros reúnen 41,13 %; los diez primeros, 55,90 %.

Composición exploratoria

Noticias/comentario 40,1 %; entretenimiento/comedia 36,7 %; otro/mixto 23,3 %.

Síntesis: La cobertura temática es amplia, pero la concentración obliga a separar por video y a medir después generalización por canal.

Resultado propio: Auditoría v2.1. La composición por tipo es una heurística descriptiva del proyecto, no metadato editorial de YouTube.

Dificultades de construcción y tamaño de chunk

Controles concretos para disponibilidad, sesgo y contexto lingüístico

Disponibilidad y limpieza

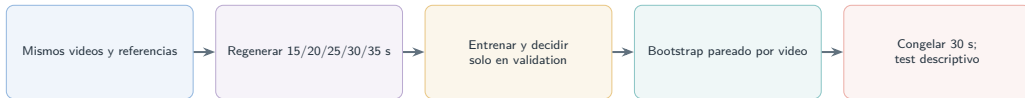
Subtítulos ausentes o incompletos, duplicados, segmentos demasiado cortos y cambios de disponibilidad exigieron materialización canónica y exclusiones trazables.

Desbalance y concentración

SEGURO representa 91,82 %; el daño más frecuente supera 3,55 veces al menos frecuente y pocos canales aportan gran volumen.

Ambigüedad contextual

Ironía, citas, habla peruana, fronteras temporales y coexistencia de daños requieren contexto vecino y revisión humana.



Síntesis: Se conservaron 30 segundos: lideraron el perfil clásico robusto (AP macro de daño 0,123; IC95 % 0,110–0,145) y las comprobaciones neuronales no demostraron superioridad suficiente para cambiar el contrato.

Evidencia externa: Selección sin reutilizar test [12]; curvas precisión–sensibilidad ante desbalance [17]. | Resultado propio: docs/OPTIMIZACION_LONGITUD_CHUNKS.md y docs/ROBUSTEZ_NEURONAL_LONGITUD_CHUNKS.md.

Taxonomía de clasificación

Cinco salidas para cubrir seguridad y cuatro tipos de daño



Síntesis: Es una taxonomía multietiqueta: SEGURO es excluyente, pero un mismo chunk puede activar más de una categoría de daño.

Evidencia externa: Marco general: Waseem et al. [4] y Banko et al. [5]. Adaptación peruana: Callirgos [26], Zavala y Zariquiey [27], Vich [28], Albornoz y Flores [29] y Defensoría del Pueblo [6].

Fundamento bibliográfico de la taxonomía

Cada salida adapta tipologías generales y antecedentes peruanos específicos

Componente	Autores y aportes utilizados
Marco general	Waseem et al. [4]: tipologías de abuso; Banko et al. [5]: taxonomía unificada de contenido dañino.
Racismo / discriminación	Callirgos [26]; Zavala y Zariquiey [27]; Zavala y Back [30]; Brañez [31]; Almeida y Zavala [32]; Salem [33]; y Vich [28].
Género / identidad	Rodríguez-Sánchez et al. [24]; Zeinert, Inie y Derczynski [34]; Albornoz y Flores [29]; Defensoría del Pueblo [6]; Chakravarthi et al. [35]; Rottenbacher [36]; y Lovón-Cueva y Lovón-Cueva [37].
Acoso / amenaza	Waseem et al. [4]; Wulczyn, Thain y Dixon [38]; Banko et al. [5]; y Defensoría del Pueblo [6].
Contenido sexual	Banko et al. [5]; Zeinert, Inie y Derczynski [34]; Albornoz y Flores [29]; Defensoría del Pueblo [6]; y la política de YouTube [39].

Síntesis: Las fuentes sustentan las dimensiones de daño; los nombres, fusiones y reglas de exclusión finales son decisiones operativas del proyecto.

Resultado propio: Correspondencia documentada en docs/TAXONOMIA_V2.md y en la sección metodológica del artículo.

Metodología de etiquetado

Definiciones operativas y revisión trazable reducen ambigüedad

1. Definición operacional criterios positivos, exclusiones y ejemplos fronterizos por daño.



2. Cascada contextual compuerta de daño y decisión por categoría con salida estructurada validable.



3. Revisión trazable desacuerdos, baja confianza y panel estratificado conservan evidencia.



4. Versionado correcciones append-only, taxonomía y manifiestos ligados al corpus.

55 966

eventos trazables

revisión humana/sistema registrados

16 694

panel congelado

muestreo estratificado auditable

10,18 %

cobertura combinada

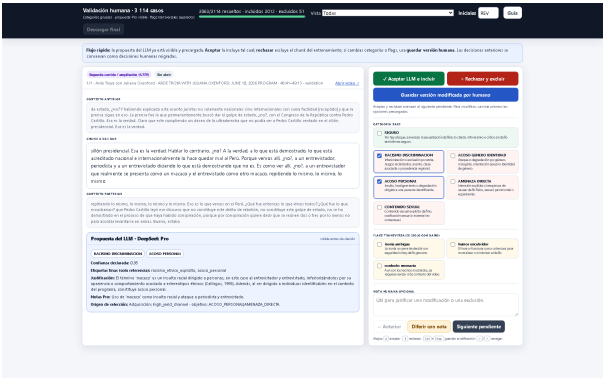
17 635 chunks elegibles auditados

Síntesis: La fortaleza está en la trazabilidad: definición, predicción, revisión y corrección pueden reconstruirse.

Evidencia externa: Acuerdo y anotación deben reportarse con su diseño [40, 7]. | Resultado propio: docs/METODOLOGIA_ETIQUETADO_CASCADA.md y auditoría v2.1.

Frontend de etiquetado

El criterio de anotación se aplica en una interfaz auditable



Contexto visible

Video, texto y tramo temporal se revisan juntos.

Decisión estructurada

Categorías explícitas y observaciones reducen ambigüedad operativa.

Trazabilidad

La acción queda vinculada a usuario, instante y versión.

Síntesis: El frontend implementa la taxonomía mediante una decisión estructurada, repetible y auditable.

Resultado propio: Captura histórica del frontend; la paridad funcional del frontend activo v2.1 está documentada en docs/PARIDAD_FRONTENDS_ACTIVOS.md.

04

CAPÍTULO 04

Entrenamiento y ensembles

Comparación de familias, adaptación de Qwen y estrategias de combinación de modelos.

MODELOS CLÁSICOS TRANSFORMERS QWEN ENSEMBLES

Familias de modelos evaluadas

Una cartera diversa equilibra costo, contexto y desempeño

Modelos clásicos

Frecuencia de término–frecuencia inversa de documento (TF–IDF) y clasificadores lineales: rápidos, interpretables y competitivos con señales léxicas fuertes [13, 41, 42].

Qwen + LoRA

Adaptación de bajo rango (LoRA) de un modelo Qwen para capturar lenguaje y categorías con más contexto, actualizando una fracción de parámetros [46, 47].

Transformers

MiniLM/E5 y cascadas: representaciones contextuales con distinta relación entre costo y capacidad [14, 43, 44, 45].

Ensembles

Combinan probabilidades o decisiones de miembros diversos para reducir errores no coincidentes [15, 16].

28 candidatos individuales

5 reglas + 2 optimizadas

validación anidada por vídeo

Síntesis: La comparación conjunta aprovecha la complementariedad entre señales léxicas, representaciones contextuales y Qwen adaptado.

Resultado propio: Inventario verificable de `comparacion_individual_ensemble_validation.json`; arquitectura: `docs/ARQUITECTURAS_MODELOS_03.md`.

Diseño del entrenamiento y evaluación

Selección sin fuga y test abierto una sola vez



Unidad de grupo

Un video completo pertenece a un solo split o fold.

Métricas adecuadas

Área bajo la curva precisión-sensibilidad (AUPRC) para daños raros; BA para la compuerta desbalanceada [17, 48, 49].

Evidencia temporal

La selección queda firmada antes de consultar test.

Síntesis: El test no decide el ganador: estima una vez el desempeño de la política ya congelada.

Qwen y MiniLM: escala, ajuste y precisión numérica

LoRA reduce los parámetros ajustados; BF16 no equivale a cuantización

Qwen3-0.6B-Base

596,05 millones de parámetros de base; 28 capas, dimensión 1024 y atención agrupada 16Q/8KV. Contexto nativo 32768; entrada operativa 256 tokens [46,50].

MiniLM-L12-v2

117 662 230 parámetros con la cabeza local de 22 salidas; 12 capas, dimensión 384, 12 cabezas y entrada de 128 tokens [43,51].

Adaptación LoRA

Rango 8, $\alpha = 16$, *dropout* 0,05 y matrices Q/K/V/O. Se ajustan 2316288 parámetros (0,39 %); adaptador FP32 de 9,29 MB [47].

Ajuste completo

El candidato de 03_07 ajusta toda la red; solo el piloto de longitud congela el encoder. BA OOF 0,814 y macro-AUPRC 0,476.

0,831

BA binaria OOF

mejor individuo del ranking

Sin cuantización

Ninguno usa 4/8 bits, NF4 ni QLoRA. BF16 es precisión mixta de cálculo en GPU; en CPU la carga estándar queda sin cuantizar.

Síntesis: Qwen logra el mejor resultado individual ajustando menos de 0,4 % del clasificador; MiniLM ofrece una referencia compacta, aunque no integra el ensemble final.

Resultado propio: Conteos verificados en los tensores y configuraciones locales. El miembro Transformer del ensemble es la cascada E5 v2, no MiniLM.

Entrenamientos Qwen realizados

La longitud y la pérdida cambian; el backbone y el contrato permanecen fijos

03_05 · LoRA base, 128 tokens

BCE ponderada y 22 logits enmascarados; 10^{-4} , lote efectivo 8 y hasta cuatro épocas. El ajuste paró tras la época 3 y restauró la época 2. **Ganador Qwen y mejor individuo:** BA 0,831; AUPRC 0,516.

03_05 · LoRA continuado, 256

Warm-start del anterior, optimizador nuevo y hasta cuatro épocas adicionales. Reduce truncamiento de 56,1 % a 0,002 %; AUPRC 0,523 y F1 0,572, pero BA 0,830.

03_06 · barrido LoRA estructurado

Tres continuaciones de una época, 2×10^{-5} y $\lambda = 0/0,02/0,05$ para penalizar SEGURO+daño. Gana $\lambda = 0,05$ dentro del barrido: BA 0,819; AUPRC 0,500.

03_06 · ajuste completo histórico


Única ruta **sin LoRA**: cuatro épocas y $\lambda = 0,2$. Fue más costosa y rindió peor: AUPRC 0,243; falso seguro 0,775. Se conserva como antecedente descartado.

Síntesis: El mejor Qwen no fue el más largo: el LoRA base maximiza BA; el contexto 256 mejora categorías específicas y los estructurados no compensan la pérdida global.

Resultado propio: Los dos identificadores de contexto 256 del ranking reproducen las mismas métricas; no constituyen réplicas independientes. El ensemble usa el LoRA base.

Metodología del ensemble optimizado

Calibración por miembro y pesos aprendidos sin consultar test



1 · Ajuste interno

En cada train externo, 5 pliegues por vídeo generan scores OOF; allí se ajustan Platt y umbrales, y se evalúan 861 ternas no negativas de paso 0,025.

2 · Estimación externa

Se elige por BA $\uparrow$, $R_{0,67} \downarrow$ y macro-AUPRC $\uparrow$; los pesos se aplican al quinto externo intacto. Los 5 quintos forman el ranking anidado.

Síntesis: Se optimizan todas las mezclas parametrizadas; unión e intersección no reciben coeficientes artificiales.

Evidencia externa: Calibración [52]; selección anidada [12]; combinación aprendida [53,54]. Malla y objetivo lexicográfico: propuesta propia.

Estrategias de ensemble evaluadas

Cinco reglas base y dos variantes optimizadas bajo el mismo protocolo

Clásico

Regresión logística con $C = 0, 5$.

Transformer

Arquitectura cascade v2.

Qwen

Qwen adaptado mediante LoRA.

Regla	Operación / pesos C–T–Q	BA	$R_{.67}$	AP	F1
Suave optimizado	0,100 / 0,650 / 0,250.	0,8366	0,1587	0,5506	0,5618
Ponderado AUPRC	0,332 / 0,311 / 0,357.	0,8360	0,1612	0,5614	0,5675
Unión	Máximo; sin coeficientes.	0,8334	0,1684	0,5369	0,5621
Promedio simple	1/3 / 1/3 / 1/3.	0,8328	0,1673	0,5604	0,5703
Duro optimizado	0,300 / 0,325 / 0,375 sobre votos.	0,8272	0,1731	0,4547	0,5584
Mayoría dura	1/3 / 1/3 / 1/3 sobre votos.	0,8272	0,1731	0,4415	0,5638
Intersección	Mínimo; sin coeficientes.	0,8149	0,1887	0,5131	0,5373

Síntesis: La optimización cambia el ganador: se congela únicamente la mezcla suave 0,10/0,65/0,25.

Resultado propio: 03_07b, validación OOF externa anidada; cuaderno local ejecutado y hashes de entrada verificados.

Métricas de ranking: qué miden

BA es la métrica principal; macro-AUPRC protege los daños y F1 describe umbrales

Métrica	Definición operativa	Qué significa	Mejor
Exactitud balanceada (BA)	$\frac{1}{2}$ (sensibilidad + especificidad) en ANY_DAMAGE	Promedia la capacidad de detectar daño y reconocer contenido seguro sin dejar que la clase mayoritaria domine.	↑
Macro-AUPRC de daño	Media no ponderada de las cuatro áreas bajo la curva precisión-sensibilidad	Evalúa el ordenamiento de positivos a través de todos los umbrales y da igual peso a cada daño raro.	↑
Macro-F1 de daño	Media del F1 por daño; $F1 = \frac{2PR}{P + R}$	Resume precisión y sensibilidad después de fijar umbrales; no incorpora verdaderos negativos.	↑
$R_{0,67}$	$0,67 \text{ FNR} + 0,33 \text{ FPR}$	FNR: daño omitido; FPR: falsa alerta. Penaliza la omisión $0,67/0,33 \simeq 2,03$ veces y se minimiza.	↓
Carga de revisión	Fracción enviada a NEEDS_REVIEW	Capacidad humana necesaria; siempre se interpreta junto con BA/riesgo de la ruta automática.	↓

Síntesis: La métrica principal es BA de ANY_DAMAGE OOF a cobertura completa. Además, $R_{0,50} = 1 - \text{BA}$; usar 0,67 desplaza el desempate hacia evitar daño omitido.

Evidencia externa: BA ante desbalance [49]; precisión-sensibilidad [17,48]; criterio local completo en docs/CRITERIO_SELECCION_MODELOS_03.md.

Cómo leer el ranking y por qué no usar otras métricas

La interpretación evita convertir porcentajes distintos en una sola “nota”

BA 0,8366

No significa “83,66 % de chunks correctos”: es el promedio de sensibilidad y especificidad de la compuerta binaria, estimado en pliegues externos.

No accuracy ni micro-F1

La abundancia de SEGURO puede producir una cifra alta aun cuando se omita daño; micro/weighted privilegia las etiquetas con mayor soporte.

Macro-AUPRC 0,5506

No significa “55,06 % de aciertos”: es el área precisión–sensibilidad media de los cuatro daños; solo se compara sobre el mismo panel y prevalencia.

No ROC-AUC como criterio principal

Con positivos raros, precisión–sensibilidad muestra mejor cuántas alertas relevantes aparecen entre las predicciones positivas [17, 48].

Macro-F1 0,5618

Describe las decisiones por categoría en umbrales aprendidos dentro de cada pliegue; una categoría rara pesa lo mismo que una frecuente.

No suma de indicadores

BA ya contiene FNR y FPR; sumarlos contaría dos veces errores correlacionados. Calibración y carga humana tienen escalas y utilidades distintas.

Síntesis: El ranking es lexicográfico con salvaguardas: primero equilibrio DAÑO–SEGURO, luego desempeño multietiqueta, frontera de Pareto y costos como desempate.

Criterio de selección y análisis estadístico

Desempeño, salvaguardas e incertidumbre en un solo protocolo

1. **Criterio primario:** mayor exactitud balanceada de ANY_DAMAGE con predicciones OOF y cobertura completa.
2. **Salvaguarda:** macro-AUPRC de los cuatro daños dentro de un margen de no inferioridad predeclarado.
3. **Frontera de Pareto:** descarta opciones dominadas en sensibilidad/especificidad y desempeño por categoría.
4. **Desempate:** menor riesgo $R_{0,67}$ y luego mayor macro-AUPRC.
5. **Incetidumbre:** 2000 réplicas pareadas por video; se reportan IC y p sin inflar la evidencia.

1 · BA decide

Suave optimizado 0,8366; ponderado 0,8360; promedio simple 0,8328.

2 · Salvaguarda

AUPRC 0,5506; el ponderado alcanza 0,5614, pero no desplaza al líder del criterio primario.

3 · Riesgo y pesos

$R_{0,67} = 0,1587$; ajuste final C/T/Q = 0,10/0,65/0,25.

Síntesis: El suave optimizado es el único seleccionado; frente al ponderado, $\Delta BA = +0,00059$, IC95 % $[-0,00367; 0,00509]$, $p = 0,804$: ventaja inconclusa.

Evidencia externa: Bootstrap pareado por video [55]; criterio interno: docs/CRITERIO_SELECCION_MODELOS_03.md.

05

CAPÍTULO 05


Resultados finales

Ganadores globales, por tipo y por categoría; test natural y revisión humana.

VALIDACIÓN TEST NATURAL CATEGORÍAS REVISIÓN

Ranking global en validación

La combinación multifamilia obtiene el mejor resultado global



Exactitud balanceada anidada de las siete variantes de ensemble.

0,8366
BA anidada
ANY_DAMAGE; cobertura completa

0,5506
macro-AUPRC OOF
cuatro daños


0,5618
macro-F1
cuatro daños

Síntesis: El mejor punto global integra clásico + Transformer + Qwen; el resultado respalda la diversidad de la cartera, no una arquitectura única.

Resultado propio: 03_07b, optimizacion_ensembles_validation.json; único ganador actual: ensemble_soft_optimized.

Mejor modelo por tipo

La mejora se mantiene desde los modelos clásicos hasta el ensemble



Exactitud balanceada binaria OOF, validación. Eje truncado para mostrar diferencias.

Ganador de tipo	macro-AUPRC	F1 macro
Regresión logística	0,479	0,503
Cascade v2	0,449	0,519
Qwen + LoRA	0,516	0,553
Suave optimizado	0,551	0,562

Ganancia acumulada

El ensemble supera al mejor clásico en +3,51 puntos de BA y +7,16 puntos de macro-AUPRC.


Lectura honesta

Las diferencias entre familias no prueban causalidad arquitectónica: resumen los mejores candidatos ejecutados.

Resultado propio: 03_07a, mejores_por_tipo_validation.csv; cifras sin redondear conservadas en el archivo fuente.

Frontera de Pareto e incertidumbre estadística

Selección reproducible con una diferencia estadística no concluyente



Selección vigente

ensemble_soft_optimized ocupa el rango uno y es el único ganador actual.

Rival más cercano

El ponderado por AUPRC queda a $-0,00059$ de BA.

Incertidumbre

IC95 % pareado para ganador menos rival:
[$-0,00367$; $0,00509$]; $p = 0,804$. Pesos suaves variables entre pliegues.

Síntesis: Hay un único seleccionado por la regla; su ventaja estadística permanece inconclusa y se reporta como limitación.

Evidencia externa: Bootstrap agrupado [55]; pruebas pareadas y ajuste múltiple [56,57].

Resultados en test de prevalencia natural

Alta sensibilidad sobre 22 684 chunks en condiciones naturales

0,846

exactitud balanceada

cobertura completa

0,894

sensibilidad al daño

omite 10,60 % del daño

0,531

AP de daño

prevalencia natural 7,94 %

	Pred. daño	Pred. seguro
Daño real	1 611	191
Seguro real	4 221	16 661

Matriz de confusión de la compuerta ANY_DAMAGE.

Compromiso actualizado

La especificidad sube a 0,798 frente al promedio simple, mientras la sensibilidad baja; BA cambia solo +0,00004.

Desempeño por daños


Macro-AUPRC = 0,412; macro-F1 = 0,423 sobre cuatro categorías.

Síntesis: A prevalencia natural, el sistema encuentra 1 611 de 1 802 chunks dañinos; el test evalúa la fórmula, no vuelve a escogerla.

Resultado propio: 03_07, test_final_abierto_una_vez.json; 22 684 chunks de 674 videos.

Política de revisión humana

Los casos inciertos se reservan para supervisión humana



72,7 %

cobertura automática

16 500 chunks resueltos sin derivación

27,3 %

carga de revisión

6 184 chunks derivados

Política congelada


$\delta = 0,03$; revisa cercanía a umbrales e incoherencias entre compuerta y categorías.

Síntesis: 0,925 de BA aplica al 72,7 % automático; el 27,3 % restante es la salvaguarda humana.

Evidencia externa: Clasificación selectiva y aprendizaje con derivación [2,3]; calibración [20].

Resultados por categoría en test natural

Contenido sexual y acoso presentan los mejores resultados



Mayor desempeño

CONTENIDO SEXUAL: AUPRC 0,575 y F1 0,571.

Zona intermedia

ACOSO/AMENAZA: AUPRC 0,446 y F1 0,453.

Prioridad de mejora


GÉNERO/IDENTIDAD: AUPRC 0,268 y F1 0,310.

Síntesis: El promedio no basta: género/identidad y racismo requieren más ejemplos fronterizos, auditoría localizada y análisis de deriva.

Resultado propio: Test natural; métricas de la predicción congelada por categoría, `metricas_por_categoria_test.csv`.

Mejor modelo por categoría en validación

Qwen y los ensembles se especializan en daños distintos



Categoría	Mejor AUPRC	Valor
Racismo	Qwen contexto 256	0,571
Género	Qwen contexto 256	0,402
Acoso	Ensemble ponderado	0,614
Sexual	Promedio simple (pantalla)	0,688

Ganadores por F1

Qwen con contexto 256 gana racismo; voto mayoritario, género; ensemble por unión, acoso y sexual.

Decisión de producto

Se congela un ganador global para operación reproducible y se conservan especialistas como evidencia para futuras rutas por categoría.

Síntesis: La diversidad tiene valor observable: Qwen domina categorías semánticas difíciles y los ensembles lideran acoso/sexual.

Resultado propio: Validación, ganadores_por_categoria_validation.csv; estas selecciones descriptivas no reabren el test.

06

CAPÍTULO 06


Comparación externa

Contraste de resultados publicados y análisis crítico de comparabilidad.

MÉTRICAS CONTEXTO RESULTADOS BRECHAS

Comparación contextual con el estado del arte

Resultados del mismo orden que trabajos publicados relacionados



F1 reportado; este trabajo usa vista test 4:1 y compuerta binaria congelada.

Posición contextual

$F1 = 0,662$: comparable con DETOXIS (0,646) y HateXplain (0,687).

No es una liga común

HatEval 0,730; OffendES 0,784; EXIST 0,794, pero cambian corpus, idioma, prevalencia, etiquetas y partición.

Mayor amplitud local


Aquí se integran cuatro daños peruanos, multietiqueta, marcas temporales y derivación humana.

Síntesis: La evidencia permite afirmar competitividad contextual, no superioridad directa: el sistema queda en el rango publicado mientras resuelve un alcance operativo más amplio.

Evidencia externa: DETOXIS [21]; HateXplain [25]; HatEval [22]; OffendES [23]; EXIST [24].

Efecto del diseño muestral sobre la evaluación

La evaluación natural reduce el riesgo de sobreestimar el desempeño



average precision reportado

Por qué AP

La línea base de un ranking aleatorio cambia con la prevalencia; AP es informativa, pero no inmune al diseño muestral.

Hallazgo externo

NaijaHate obtiene AP 0,34 en una muestra representativa y 0,83–0,90 en conjuntos enriquecidos [19].

Hallazgo propio

En test natural, con 7,94 % de daño, la compuerta obtiene AP 0,531.

Interpretación

No son datasets comparables; juntos muestran por qué reportar prevalencia y mantener una vista natural es una fortaleza metodológica.

Síntesis: El producto se evalúa donde operará: sobre abundancia de contenido seguro, no únicamente sobre un benchmark artificialmente balanceado.

Análisis crítico: ¿el trabajo está en el estado del arte?

Competitivo como sistema aplicado; la supremacía en benchmark aún requiere evidencia externa

Sí es comparable en alcance científico

Aborda clasificación de lenguaje dañino en contenido social, reporta F1/BA/AUPRC y obtiene F1 0,662 en una vista 4:1: magnitud próxima a DETOXIS y HateXplain.

No demuestra un nuevo récord común

Los papers cambian país, idioma, plataforma, unidad, prevalencia, etiquetas y partición. Por ello la gráfica contextualiza magnitud, no establece superioridad head-to-head.

Alineado con buenas prácticas actuales

Incluye splits y bootstrap por video, predicciones fuera de muestra (OOF), test natural sellado, cinco familias de salida, evidencia temporal y revisión humana.

Qué falta para una afirmación fuerte

Evaluación en benchmark externo compartido, réplica temporal y por canales no vistos, doble anotación independiente, estabilidad entre semillas y análisis multimodal.

Diferenciación favorable

El corpus peruano, la taxonomía localizada y la integración clásico-Transformer-Qwen resuelven un vacío que los benchmarks importados no cubren juntos.

Qué falta para madurez operativa

Validar carga, costo, latencia y error humano residual en un piloto; monitorear deriva y desempeño por grupos/canales.

Síntesis: Conclusión crítica: el trabajo es competitivo y está metodológicamente alineado con el estado del arte aplicado; todavía no prueba ser el mejor modelo de un benchmark internacional común.

Evidencia externa: Comparabilidad contextual [21,25,22,23,24]; muestreo realista [19]; pruebas funcionales [18].

07

CAPÍTULO 07

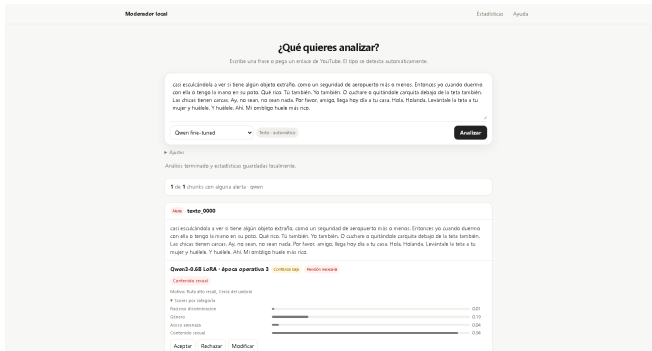
Producto y conclusiones

Interfaces, capacidades del sistema y cumplimiento cuantitativo de los objetivos.

OPERACIÓN TRAZABILIDAD OBJETIVOS TRABAJO FUTURO

Frontend de producción

Categoría, probabilidad y evidencia temporal en una sola vista



Resultado accionable

Categoría, probabilidad y tramo temporal permiten localizar el contenido.

Humano en control

Los casos inciertos se derivan mediante `NEEDS_REVIEW`; no hay sanción automática.

Ciclo de mejora


La corrección autorizada alimenta auditoría y reentrenamiento versionado.

Síntesis: La salida útil es una decisión respaldada por contexto, incertidumbre y procedencia; eso vuelve al modelo gobernable.

Evidencia externa: Gobernanza de moderación [1]; derivación humano-IA [3]. | Resultado propio: Captura histórica; paridad del frontend activo en docs/PARIDAD_FRONTENDS_ACTIVOS.md.

Componentes del producto

Datos, modelos, salvaguardas y operación integrados



Escalable

La ruta automática procesa 72,7 % del test con BA de 0,925.

Especializable

Los ganadores por categoría revelan rutas futuras con Qwen y ensembles.

Auditable

Dataset, selección, prueba y correcciones conservan versión y procedencia.

Síntesis: La principal bondad es sistémica: desempeño competitivo, evidencia local, supervisión humana y reproducibilidad conviven en un solo flujo.

Evidencia externa: Un artefacto de investigación debe ser útil y evaluado [10, 11]; documentación de datasets/modelos [8, 9].

Conclusiones vinculadas a los objetivos I

Cumplimiento del objetivo general y los objetivos específicos 1 y 2

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
General Diseñar un sistema semiautomático	BA 0,846 a cobertura completa; BA 0,925 en 72,7 % automático; 27,3 % derivado.	Se logró una cadena humano-IA funcional: prioriza daño con alta sensibilidad y conserva revisión para incertidumbre.
Específico 1 Construir corpus local trazable	173 240 chunks elegibles, 4 906 videos, cinco salidas; 22 684 chunks en test natural.	El objeto de estudio mantiene prevalencia, contexto temporal y separación por video, condiciones necesarias para una evaluación creíble.
Específico 2 Comparar familias de modelos	28 individuos + 5 reglas base + 2 optimizadas; ganador: BA 0,8366 y macro-AUPRC 0,5506 anidadas.	La complementariedad supera a los mejores representantes aislados; Qwen es el mejor individuo y mejora la representación contextual.

Síntesis: El objetivo general se cumple con una solución medible y utilizable que clasifica y deriva los casos inciertos.

Evidencia externa: Clasificación selectiva [2, 3]. | Resultado propio: Auditoría v2.1, comparación 03_07b y test actualizado sin reinferencia, 17-08-2026.

Conclusiones vinculadas a los objetivos II

Cumplimiento de los objetivos específicos 3 y 4

Objetivo	Evidencia cuantitativa	Conclusión cualitativa
Específico 3 Calibrar y gobernar incertidumbre	2 000 bootstraps pareados por video; diferencia BA ganador-rival +0,00059, IC95 % cruza cero; $p = 0,804$.	La selección es reproducible: congela un único ganador por la regla y declara que su ventaja estadística es inconclusa.
Específico 4 Integrar un flujo reutilizable	Dos frontends activos, manifiestos/checkpoints y 55 966 eventos trazables; panel congelado de 16 694 chunks.	El artefacto conecta etiquetado, entrenamiento, comparación, inferencia de producción, revisión y corrección sin romper procedencia.
Contribución Competitividad contextual	F1 0,662 en vista 4:1, dentro del rango publicado 0,646–0,794 para tareas relacionadas.	El resultado es comparable en magnitud y más rico operacionalmente, aunque no constituye una comparación head-to-head.

► [Abrir servidor de etiquetado](#)

► [Abrir servidor de producción](#)

Síntesis: La contribución defendible es unir rigor experimental y operación humana sobre contenido peruano, con límites explícitos y evidencia reproducible.

Evidencia externa: Comparación contextual con [21, 25, 22, 23, 24].

Limitaciones y trabajo futuro

Mejoras focalizadas para avanzar a un piloto controlado

1. Categorías difíciles

Género (AUPRC 0,268) y racismo (0,358) requieren expansión focalizada, pruebas funcionales y revisión de falsos negativos [18].

2. Capacidad humana

27,3 % de revisión sigue siendo material y debe validarse contra dotación, tiempo y costo reales [3].

3. Generalización

YouTube peruano no representa automáticamente otras plataformas, países o periodos; medir deriva es parte del despliegue [7].

4. Validación humana

Formalizar doble anotación independiente y acuerdo por categoría fortalecerá la validez de las etiquetas [40].

Ampliar casos frontera



Validar capacidad humana



Monitorear deriva



Piloto operativo controlado

Síntesis: El sistema está listo como demostrador verificable; la siguiente etapa es validar capacidad humana, costos y deriva en un piloto controlado.

Conclusiones finales

Desempeño verificable, revisión humana y trazabilidad

Resultado del proyecto

El sistema transforma subtítulos peruanos en alertas temporales mediante una cartera clásica–Transformer–Qwen y un ensemble congelado. La evaluación natural, la abstención y la trazabilidad hacen que el desempeño sea útil fuera del laboratorio.

BA 0,846 completa

BA 0,925 automática

4 daños + SEGURO

Propuesta de valor

Menos búsqueda manual, evidencia localizada y una cola de revisión priorizada.

Garantía metodológica

Separación por video, OOF, bootstrap y apertura única de test.

Principio operativo

La IA recomienda; el humano conserva la decisión.

Gracias. Preguntas y discusión.

08

CAPÍTULO 08

Referencias

Fuentes académicas y documentos utilizados para fundamentar métodos y comparaciones.

MODERACIÓN DATOS MODELOS EVALUACIÓN

Referencias utilizadas I



R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>



Y. Geifman and R. El-Yaniv, "Selective classification for deep neural networks," in *Advances in Neural Information Processing Systems*, vol. 30, 2017. [Online]. Available: <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>



H. Mozannar and D. Sontag, "Consistent estimators for learning to defer to an expert," in *Proceedings of the 37th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 119. PMLR, 2020, pp. 7076–7087. [Online]. Available: <https://proceedings.mlr.press/v119/mozannar20b.html>



Z. Waseem, T. Davidson, D. Warmley, and I. Weber, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>



M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>



Defensoría del Pueblo del Perú, "Violencia de género contra las mujeres en línea," Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>



B. Vidgen and L. Derczynski, "Directions in abusive language training data, a systematic review: Garbage in, garbage out," *PLOS ONE*, vol. 15, no. 12, p. e0243300, 2020. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0243300>



E. M. Bender and B. Friedman, "Data statements for natural language processing: Toward mitigating system bias and enabling better science," *Transactions of the Association for Computational Linguistics*, vol. 6, pp. 587–604, 2018. [Online]. Available: <https://aclanthology.org/Q18-1041/>

Referencias utilizadas II



M. Pushkarna, A. Zaldivar, and O. Kjartansson, "Data cards: Purposeful and transparent dataset documentation for responsible AI," in *Proceedings of the 2022 ACM Conference on Fairness, Accountability, and Transparency*. Association for Computing Machinery, 2022, pp. 1776–1826. [Online]. Available: https://facctconference.org/static/pdfs_2022/facct22-3533231.pdf



A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>



K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.



G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>



K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>



A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>



T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.



L. Lam and C. Y. Suen, "Application of majority voting to pattern recognition: An analysis of its behavior and performance," *IEEE Transactions on Systems, Man, and Cybernetics—Part A: Systems and Humans*, vol. 27, no. 5, pp. 553–568, 1997.



T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>

Referencias utilizadas III



P. Röttger, B. Vidgen, D. Nguyen, Z. Waseem, H. Margetts, and J. Pierrehumbert, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>



M. Tonneau, P. Quinta De Castro, K. Lasri, I. Farouq, L. Subramanian, V. Orozco-Olvera, and S. Fraiberger, "NaijaHate: Evaluating hate speech detection on nigerian twitter using representative data," in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2024, pp. 9020–9040. [Online]. Available: <https://aclanthology.org/2024.acl-long.488/>



C. Guo, G. Pleiss, Y. Sun, and K. Q. Weinberger, "On calibration of modern neural networks," in *Proceedings of the 34th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 70, 2017, pp. 1321–1330. [Online]. Available: <https://proceedings.mlr.press/v70/guo17a.html>



M. Taulé, A. Ariza, M. Nofre, E. Amigó, and P. Rosso, "Overview of DETOXIS at IberLEF 2021: DEtection of TOXicity in comments in spanish," *Procesamiento del Lenguaje Natural*, no. 67, pp. 209–221, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6390>



V. Basile, C. Bosco, E. Fersini, D. Nozza, V. Patti, F. M. Rangel Pardo, P. Rosso, and M. Sanguinetti, "SemEval-2019 task 5: Multilingual detection of hate speech against immigrants and women in twitter," in *Proceedings of the 13th International Workshop on Semantic Evaluation*. Association for Computational Linguistics, 2019, pp. 54–63. [Online]. Available: <https://aclanthology.org/S19-2007/>



F. M. Plaza-del Arco, A. Montejó-Ráez, L. A. Ureña-López, and M.-T. Martín-Valdivia, "OffendES: A new corpus in spanish for offensive language research," in *Proceedings of the International Conference on Recent Advances in Natural Language Processing*. INCOMA Ltd., 2021, pp. 1096–1108. [Online]. Available: <https://aclanthology.org/2021.ranlp-1.123/>



F. Rodríguez-Sánchez, J. Carrillo-de Albornoz, L. Plaza, J. Gonzalo, P. Rosso, M. Comet, and T. Donoso, "Overview of EXIST 2021: sEXism identification in social networks," *Procesamiento del Lenguaje Natural*, no. 67, pp. 195–207, 2021. [Online]. Available: <https://journal.sepln.org/sepln/ojs/ojs/index.php/pln/article/view/6389>

Referencias utilizadas IV



B. Mathew, P. Saha, S. M. Yimam, C. Biemann, P. Goyal, and A. Mukherjee, "HateXplain: A benchmark dataset for explainable hate speech detection," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 17, 2021, pp. 14 867–14 875. [Online]. Available: <https://ojs.aaai.org/index.php/AAAI/article/view/17745>



J. C. Callirgos, *El racismo: la cuestión del otro (y de uno)*. Lima: DESCO, 1993.



V. Zavala and R. Zariquiey, ""Yo te segrego a ti porque tu falta de educación me ofende": una aproximación al discurso racista en el Perú contemporáneo," in *Racismo y discurso en América Latina*, T. A. van Dijk, Ed. Barcelona: Gedisa, 2007, pp. 333–370.



V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>



D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnoresistencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf



V. Zavala and M. Back, Eds., *Racismo y lenguaje*. Lima: Fondo Editorial de la Pontificia Universidad Católica del Perú, 2017. [Online]. Available: <https://repositorio.pucp.edu.pe/index/handle/123456789/170315>



R. F. Brañez Medina, "La construcción discursiva de las identidades "amixer" y "no-amixer" en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú, 2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/1618>



V. Zavala and C. Almeida, ""Motoso y terruco": ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/lexis/article/view/26332>

Referencias utilizadas V



V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf



P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://aclanthology.org/2021.acl-long.247/>



B. R. Chakravarthi, "Detection of homophobia and transphobia in YouTube comments," *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s41060-023-00400-0>



J. M. Rottenbacher de Rojas, "Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima," *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>



C. M. Lovón-Cueva and M. Lovón-Cueva, "Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums," *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://whatever.cirque.unipi.it/index.php/journal/article/view/156>



E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399.



YouTube, "Política sobre desnudos y contenido sexual," Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>



R. Artstein and M. Poesio, "Inter-coder agreement for computational linguistics," *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.



D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.

Referencias utilizadas VI



C. Cortes and V. Vapnik, "Support-vector networks," *Machine Learning*, vol. 20, pp. 273–297, 1995.



W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>



L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>



L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, "Multilingual E5 text embeddings: A technical report," *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>



A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, "Qwen3 technical report," *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>



E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, "LoRA: Low-rank adaptation of large language models," in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFY9>



J. Davis and M. Goadrich, "The relationship between precision-recall and ROC curves," in *Proceedings of the 23rd International Conference on Machine Learning*. Association for Computing Machinery, 2006, pp. 233–240.



K. H. Brodersen, C. S. Ong, K. E. Stephan, and J. M. Buhmann, "The balanced accuracy and its posterior distribution," in *2010 20th International Conference on Pattern Recognition*. IEEE, 2010, pp. 3121–3124.

Referencias utilizadas VII



Qwen Team, "Model card: Qwen/Qwen3-0.6B-Base," Hugging Face Hub, 2025, checkpoint revision used: da87bfb608c14b7cf20ba1ce41287e8de496c0cd; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/Qwen/Qwen3-0.6B-Base/blob/da87bfb608c14b7cf20ba1ce41287e8de496c0cd/README.md>



Sentence Transformers, "Model card: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2," Hugging Face Hub, 2026, checkpoint revision used: e8f8c211226b894fcb81acc59f3b34ba3efd5f42; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2/blob/e8f8c211226b894fcb81acc59f3b34ba3efd5f42/README.md>



J. C. Platt, "Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods," in *Advances in Large Margin Classifiers*, A. J. Smola, P. L. Bartlett, B. Schölkopf, and D. Schuurmans, Eds. Cambridge, MA, USA: MIT Press, 1999, pp. 61–74.



D. H. Wolpert, "Stacked generalization," *Neural Networks*, vol. 5, no. 2, pp. 241–259, 1992.



M. J. van der Laan, E. C. Polley, and A. E. Hubbard, "Super learner," *Statistical Applications in Genetics and Molecular Biology*, vol. 6, no. 1, 2007.



C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.



R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>



S. Holm, "A simple sequentially rejective multiple test procedure," *Scandinavian Journal of Statistics*, vol. 6, no. 2, pp. 65–70, 1979.