

Análisis de Sentimiento en Redes Sociales

Detección de Sentimientos en Comentarios en Español

Grupo 4:

Koc Góngora, Luis Enrique
Mancilla Antay, Alex Felipe
Melendez Garcia, Herbert Antonio
Paitan Cano, Dennis Jack

Maestría en Inteligencia Artificial
Universidad Nacional de Ingeniería (UNI)
Procesamiento de Lenguaje Natural

Semestre 2026-1

Problemática y Brecha de Investigación

Problema

Las redes sociales concentran grandes volúmenes de comentarios, opiniones y reacciones de usuarios. Sin embargo, interpretar manualmente estos textos es costoso, lento y poco escalable.

Brecha de Investigación

- Muchos sistemas de análisis de sentimiento dependen de APIs externas o modelos de gran escala.
- Existe la necesidad de modelos más ligeros, reproducibles y ejecutables localmente.
- En español, y especialmente en contextos latinoamericanos, los textos presentan modismos, ironía, abreviaturas y lenguaje informal.

Objetivo del Proyecto

Objetivo General

Desarrollar un modelo de análisis de sentimiento para comentarios en redes sociales en español, utilizando modelos de lenguaje preentrenados y técnicas de ajuste fino.

Objetivos Específicos

- Recolectar o seleccionar datasets públicos de comentarios en español.
- Preprocesar textos provenientes de redes sociales.
- Entrenar y evaluar modelos basados en BERT o variantes ligeras.
- Comparar el desempeño de los modelos según métricas de clasificación.

Fuentes de Datos

- **TASS / InterTASS:** corpus de tweets en español etiquetados para análisis de sentimiento.
- **SemEval:** tareas compartidas de análisis de sentimiento en Twitter.
- **Hugging Face Datasets:** repositorio de datasets públicos para NLP.
- **API oficial de X:** alternativa para recolectar publicaciones públicas respetando límites y políticas de uso.

Criterio Metodológico

Se priorizará el uso de datasets públicos y APIs oficiales. Se evitará el scraping no autorizado de plataformas como X, Instagram o TikTok.

- ➊ **Recolección de datos:** datasets públicos o API oficial.
- ➋ **Limpieza:** eliminación de URLs, menciones, emojis irrelevantes y duplicados.
- ➌ **Normalización:** minúsculas, manejo de hashtags, abreviaturas y signos.
- ➍ **Etiquetado:** positivo, negativo y neutral.
- ➎ **Entrenamiento:** fine-tuning de modelos preentrenados.
- ➏ **Evaluación:** accuracy, precision, recall y F1-score.

Modelos Base

- **mBERT**: BERT multilingüe, útil como línea base.
- **BETO**: modelo BERT entrenado específicamente en español.
- **DistilBERT**: alternativa más ligera y rápida.
- **Modelo BERT ajustado a sentimiento**: modelo previamente fine-tuned como punto de comparación.

Enfoque

La estrategia principal será aplicar *fine-tuning* sobre modelos preentrenados, en lugar de entrenar un modelo desde cero.

Trabajos Relevantes

- [Devlin et al., 2018]: introduce BERT y el preentrenamiento bidireccional basado en Transformers.
- [Rosenthal et al., 2017]: presenta una tarea de referencia para análisis de sentimiento en Twitter.
- [dos Santos & Gatti, 2014]: aplica redes neuronales profundas al análisis de sentimiento en textos cortos.
- [Cañete et al., 2020]: propone BETO, un modelo BERT preentrenado para español.

Métricas

- **Accuracy:** proporción de clasificaciones correctas.
- **Precision:** proporción de predicciones positivas correctas.
- **Recall:** proporción de casos positivos detectados.
- **F1-score:** equilibrio entre precision y recall.

Comparación

Se comparará el desempeño entre modelos base, modelos ajustados y, si corresponde, métodos tradicionales como TF-IDF + SVM.

Limitaciones y Consideraciones Éticas

- Los comentarios en redes sociales pueden contener ironía, sarcasmo, ambigüedad y lenguaje ofensivo.
- Los datasets pueden presentar sesgos geográficos, culturales o lingüísticos.
- La recolección de datos debe respetar privacidad, términos de uso y límites de las plataformas.
- El modelo no reemplaza el análisis humano, sino que sirve como apoyo para clasificar grandes volúmenes de texto.

Referencias Bibliográficas I



Devlin, J., Chang, M. W., Lee, K., & Toutanova, K. (2018).
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
arXiv preprint arXiv:1810.04805.



Rosenthal, S., Farra, N., & Nakov, P. (2017).
SemEval-2017 Task 4: Sentiment Analysis in Twitter.
Proceedings of the 11th International Workshop on Semantic Evaluation, 502–518.



dos Santos, C., & Gatti, M. (2014).
Deep Convolutional Neural Networks for Sentiment Analysis of Short Texts.
Proceedings of COLING 2014, 69–78.

Referencias Bibliográficas II



Cañete, J., Chaperon, G., Fuentes, R., Ho, J. H., Kang, H., & Pérez, J. (2020).

Spanish Pre-trained BERT Model and Evaluation Data.
PML4DC at ICLR 2020.



Zhang, L., & Liu, B. (2014).

Aspect and Entity Extraction for Opinion Mining.
En W. W. Chu (Ed.), *Data Mining and Knowledge Discovery for Big Data*. Springer.