

Moderador de Contenido en Videos de YouTube

Corpus peruano, etiquetado humano y clasificador local de riesgo textual

corpus peruano | etiquetado humano | clasificador local

Grupo 4

Koc Góngora, Luis Enrique Mancilla Antay, Alex Felipe

Melendez Garcia, Herbert Antonio Paitan Cano, Dennis Jack

Idea Central del Trabajo

El trabajo construye un moderador textual para videos peruanos, con corpus propio, anotación humana y evidencia visible para revisión.

Objeto de estudio

Videos públicos

Política y farándula analizadas desde título, descripción, subtítulos y transcripción.

Problema aplicado

Revisión lenta

El volumen crece y el lenguaje depende del contexto peruano, con ironía y modismos.

Artefacto

Flujo local

Scraping, chunks, etiquetado, entrenamiento e inferencia sin servicios externos.

sin APIs externas

datos trazables

decisión con revisión humana

Contexto y Problemática

Dónde aparece la dificultad

Fuente
YouTube

Opinión política, noticias, entrevistas, clips y entretenimiento en un flujo continuo.

Lenguaje
Local

Modismos, ironía, apodos y referencias culturales que cambian el sentido del texto.

Riesgo
No auditable

Un dictamen automático sin fragmentos activadores no permite revisar ni corregir.

Videos públicos



Texto transcrito



Riesgo textual



Revisión humana

Brecha y Formulación del Problema

Brecha

Existen clasificadores de toxicidad y odio, pero el proyecto requiere un corpus local, una guía de anotación sencilla y un flujo reproducible que funcione sin servicios externos.


Problema general

¿Cómo construir un moderador textual local que clasifique fragmentos de videos peruanos y entregue evidencia verificable para apoyar la revisión humana?

Problemas específicos

- ▶ ¿Qué fuentes y categorías usar?
- ▶ ¿Cómo crear chunks auditables?
- ▶ ¿Cómo entrenar un baseline defendible?
- ▶ ¿Cómo agregar riesgo por video?

Propuesta de Solución: Artefacto



Producto verificable

El artefacto no reemplaza al moderador humano. Prioriza fragmentos, asigna categorías sugeridas, muestra texto activador y permite auditar errores.

Restricción de implementación

La recolección, etiquetado, entrenamiento e inferencia se ejecutan localmente. No se usan APIs para obtener etiquetas ni para clasificar contenido.

Canales Sugeridos para Scraping

La recolección debe mezclar fuentes de lenguaje formal, opinión, humor, farándula y viajes para que el clasificador no aprenda un solo registro.

01 Formal

Noticias, entrevistas y periodismo con dicción más estable.

02 Opinión

Debate político, sátira y explicaciones con lenguaje local.

03 Farándula

Conflicto público, rumores, ataques personales y contexto sensible.

04 Viajes

Lenguaje descriptivo y limpio para balancear clases seguras.

priorizar subtítulos | audio claro | episodios completos | validar canal oficial

Candidatos Principales para Descarga

Lista operativa alineada con el cuaderno 01

Política **Análisis**

- ▶ Marco Sifuentes / Ocram
- ▶ El diario de Curwen
- ▶ Sin Guion / Rosa María Palacios
- ▶ RPP, Canal N, Exitosa
- ▶ Willax y opinión

Humor / streaming **Contexto**

- ▶ Hablando Huevadas
- ▶ Todo Good
- ▶ Clips de entrevistas
- ▶ Conversación informal

Farándula **Contraste**

- ▶ Magaly TV La Firme
- ▶ Amor y Fuego
- ▶ América Hoy
- ▶ Programas de espectáculo

Candidatos Complementarios y Verificación

Por confirmar

URL oficial

- ▶ Cacas / El Cacas
- ▶ Goblinciano
- ▶ Instarándula
- ▶ Otros clips virales

Viajes

Clase segura

- ▶ Misias pero viajeras
- ▶ Buen Viaje
- ▶ Viaja y Prueba
- ▶ Canales regionales

Regla de descarga

Usar solo canales públicos con URL oficial verificada, audio claro y episodios completos. Registrar descartes por copyright, duplicados o baja calidad.

Categorías MVP de Moderación

El primer modelo debe usar pocas clases para mejorar acuerdo entre anotadores y reducir ruido en el entrenamiento.

Clase 0
Seguro

Texto normal,
informativo o humor
sin ataque directo.

Clase 1
Acoso

Insulto, burla,
humillación o ataque
personal.

Clase 2
Sexual

Lenguaje sexual
explícito o acoso
sexual.

Clase 3
Racismo

Ataque por origen,
etnia, nacionalidad o
color de piel.

MVP defendible | mejor acuerdo humano | menos solapamiento

Extensiones Controladas

Las clases nuevas se agregan solo cuando haya ejemplos suficientes y reglas de anotación estables.

Riesgo alto

- ▶ Odio o discriminación general.
- ▶ Amenaza o incitación a violencia.
- ▶ Privacidad / doxxing.

Riesgo contextual

- ▶ Desinformación dañina.
- ▶ Spam o estafa.
- ▶ Cita, ironía, noticia o parodia.

Control de Calidad Humana

Muestra

2 anotadores

Revisión independiente de una parte del corpus.

Consenso

Casos dudosos

Discusión documentada para ejemplos ambiguos.

Acuerdo


Kappa

Reporte de Cohen's kappa antes del entrenamiento final.

Regla metodológica

Antes de ampliar etiquetas, se revisan errores, desacuerdos y sesgos por tipo de canal.
La guía se actualiza con ejemplos reales.

Unidad de Análisis



Qué se etiqueta

La unidad mínima es el fragmento textual. El video conserva metadatos, fuente y evidencias para auditar el resultado agregado.

Regla de Decisión por Video

Chunk

Etiqueta

Cada fragmento recibe categoría, probabilidad y texto activador.

Video

Riesgo

Se marca si varios chunks cruzan umbral o uno crítico es muy alto.

Salida


Evidencia

Tabla con video, categoría, score y fragmentos revisables.

Principio

La decisión automática prioriza revisión humana; no sanciona contenido por sí sola.

Cuadernos Iniciales



Entrada y curaduría

yt-dlp y Selenium generan metadatos, subtítulos y chunks trazables. No se usan APIs ni etiquetas automáticas externas.

Salida del artefacto

El flujo produce dataset etiquetado, baseline local, métricas y frontend de inferencia para revisión humana.

Modelo y Entrenamiento

Baseline obligatorio

- ▶ TF-IDF con unigramas y bigramas.
- ▶ Linear SVM o Logistic Regression.
- ▶ One-vs-rest si se conserva multi-etiqueta.
- ▶ Explicable mediante términos con mayor peso.

Extensión avanzada

- ▶ BETO o RoBERTa en español.
- ▶ Fine-tuning solo si el dataset etiquetado es suficiente.
- ▶ Comparación contra baseline, no reemplazo directo.

Criterio de defensa: primero funciona el baseline; el Transformer solo se justifica si mejora F1 macro, recall de riesgo y análisis de errores.

Evaluación




Métricas

- ▶ F1 macro para clases desbalanceadas.
- ▶ Precision y recall por categoría.
- ▶ Matriz de confusión.
- ▶ Precisión de top-fragmentos revisados.

Calidad humana

- ▶ Dos anotadores para una muestra.
- ▶ Revisión de desacuerdos.
- ▶ Guía de etiquetas con ejemplos.
- ▶ Registro de casos ambiguos.

Estructura del Paper / Informe



Hilo conductor

Lenguaje local en videos peruanos → riesgo textual difícil de revisar manualmente → corpus anotado → clasificador local → evidencia para moderación humana.

Alcances y Límites

Alcance

- ▶ Moderación textual, no visual.
- ▶ Videos públicos de política y farándula.
- ▶ Chunks de transcripción o subtítulos.
- ▶ Clasificación local con evidencia.

Límites

- ▶ No afirma verdad o falsedad absoluta.
- ▶ No sustituye evaluación legal ni editorial.
- ▶ Puede fallar con ironía, sarcasmo y citas.
- ▶ Requiere balance y revisión de sesgos.

Principio ético

La salida del sistema es alerta y priorización, no sanción automática.

Plan de Trabajo

Semana 1 **Diseño**

Canales, categorías MVP, guía de anotación y criterios de descarte.

Semana 2 **Corpus**

Scraping, subtítulos, transcripción local y creación de chunks.

Semana 3 **Etiquetado**

Anotación humana, revisión de desacuerdos y dataset final.

Semana 4 **Demo**

Baseline, métricas, análisis de errores y frontend de producción.

Mejora propuesta

Mantener un registro de decisiones: por qué se incluye cada canal, por qué se descarta cada video y qué regla resolvió cada caso ambiguo.

Referencias y Fuentes Base

-  Radford, A. et al. (2022).
Robust Speech Recognition via Large-Scale Weak Supervision.
arXiv:2212.04356.
-  Devlin, J. et al. (2018).
BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding.
arXiv:1810.04805.
-  Cañete, J. et al. (2020).
Spanish Pre-Trained BERT Model and Evaluation Data.
PML4DC at ICLR.
-  Ribeiro, M. T. et al. (2020).
Beyond Accuracy: Behavioral Testing of NLP Models with CheckList.
ACL, 4902–4912.
-  Canales públicos de YouTube revisables: RPP Noticias, TVPerú Noticias, El Comercio, La República, La Encerrona, Epicentro TV, Magaly TV La Firme, Amor y Fuego, América Hoy.