

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano

Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

Texto + tiempo

Cinco salidas

Decisión humana

Ruta de la presentación



Lectura clave: El hilo conductor sigue los productos que alimentan la etapa siguiente: datos → etiquetas → modelos → evidencia para una persona.

La moderación de YouTube combina escala y contexto

Contenido dañino

Violencia, acoso, discriminación, ataques por identidad y sexualización pueden aparecer en redes y videos.

Contexto

Una noticia puede citar una amenaza; el humor puede encubrir un blanco; una expresión local cambia el sentido.


Decisión

Revisar el video completo no escala. Una alerta sin texto ni tiempo tampoco permite auditar la sugerencia.

Lectura clave: El problema no es solo clasificar texto: es priorizar sin perder contexto, incertidumbre, procedencia ni responsabilidad humana.

Fuente: Gorwa, Binns y Katzenbach (2020); Waseem, Davidson, Warmley y Weber (2017); Banko et al. (2020); Defensoría del Pueblo (2021).

El problema se manifiesta en tres niveles



Problema general. Existe la necesidad de construir y evaluar un artefacto reproducible que transforme subtítulos públicos en alertas temporales trazables y mantenga la decisión bajo supervisión humana.

Fuente: Moderación: Gorwa et al. (2020). DSR: Hevner et al. (2004) y Peffers et al. (2007).

Las brechas específicas delimitan la construcción

Datos dispersos. Los subtítulos públicos carecen de una adquisición, depuración y segmentación común que preserve video, texto, tiempo y procedencia.

Criterios heterogéneos. Falta aplicar un contrato operacional contextualizado al Perú que distinga daño, seguridad explícita e incertidumbre sin convertir la selección del canal en etiqueta.

Etiquetas incompletas. El historial recuperable y los casos nuevos requieren consolidación incremental, trazable, económica y supervisable.

Evidencia no comparable. Las familias clásicas y neuronales requieren un mismo snapshot, partición por video, calibración y evaluación pareada.

Decisión desconectada. Los scores deben convertirse en evidencia temporal y motivos de revisión, sin automatizar sanciones ni ocultar la intervención humana.

Lectura clave: Son brechas necesarias para construir el artefacto; publicarlo o presentarlo es una tarea de comunicación, no un problema de investigación.

Qué se estudia y qué se modela

Problema de estudio

Moderación semiautomática del daño expresado en subtítulos.

Objeto de estudio

Expresiones potencialmente dañinas en videos vinculados con el Perú.

Objeto modelado

Fragmento temporal con cinco salidas, 14 etiquetas finas y tres flags.


Unidad de análisis

Chunk con `video_id`, texto e intervalo inicial/final.

Lectura clave: El sistema observa texto, no imagen ni audio; una ausencia de daño cubierto no demuestra seguridad universal.

Fuente: Contrato activo: taxonomía v2.1.0 y contrato de datos del proyecto.


Los objetivos encadenan entradas y productos verificables



Objetivo general. Diseñar y evaluar el artefacto completo; la metodología DSR explica cómo construir, demostrar, medir y rediseñar cada producto.

Fuente: Hevner et al. (2004); Peffers et al. (2007); guía IEEE/DSR del proyecto.


La taxonomía se informa con evidencia general y peruana



Taxonomía operativa informada por literatura y fuentes institucionales; **no** es clasificación legal ni validación por un panel experto peruano.

Fuente: Waseem et al. (2017); Banko et al. (2020); Zavala y Almeida (2022); Albornoz y Flores (2018); Defensoría del Pueblo (2021); matriz de evidencia v2.1.

DSR convierte la brecha técnica en iteraciones evaluables



Lectura clave: Una evaluación inconclusa no se oculta: conserva la referencia, delimita el aprendizaje y motiva la siguiente iteración.

Fuente: Hevner et al. (2004); Peffers et al. (2007).

La muestra combina diversidad temática y búsqueda dirigida

336 canales

Política, periodismo, humor, farándula, entretenimiento, deportes, gastronomía, viajes y otros contextos vinculados con el Perú.

1. **Semillas:** catálogo de canales y consultas generales.

2. **Déficits:** soporte por videos de train+validation, nunca test.


3. **Expansión:** consultas temáticas y un salto por nuevos canales.

4. **Selección:** round-robin ponderado e intercalado por canal.

`target_category` explica por qué se buscó un video; nunca se copia como etiqueta verdadera.

Fuente: Metodología de scraping; aprendizaje activo desbalanceado como antecedente general: Settles (2009). Índice vigente: 336 canales, 339 archivos por canal y 5 002 videos.

Scraping incremental: adquirir texto sin repetir éxitos



Fuente: yt-dlp (documentación oficial); YouTube Transcript API; metodología de scraping del proyecto. No se descarga audio/video ni se ejecuta ASR.

Corpus textual vigente: corte reproducible del troceador v2.2.0

5 002

transcripciones

texto completo disponible

4 992

videos

con al menos un chunk

166 940

chunks

identificadores únicos

1 451.17

horas

duración acumulada


Indicador	Resultado
videos sin chunk	10
chunks por video, mediana	18
duración por chunk, mediana	31.16 s
caracteres por chunk, mediana	483
palabras por chunk, mediana	87

Fuente: chunk_materialization_manifest.json, 7 de agosto de 2026.

Límite de inferencia

El muestreo es dirigido y depende de disponibilidad de subtítulos. El corpus no estima prevalencia natural de daño en YouTube ni en el Perú.

Limpieza y troceado conservan texto, tiempo y procedencia



Lectura clave: Una reconstrucción total crea respaldo; el modo normal recalcula solo transcripciones nuevas o modificadas.

Fuente: Unicode Standard Annex 15; NIST FIPS 180-4; materialización y contrato del troceador v2.2.0.

La longitud se eligió con una jerarquía predeclarada

Decisorio clásico: 5 longitudes $\times$ 3 modelos $\times$ 5 cohortes = 75 ajustes; 1 000 bootstrap por video.

Sensibilidad neuronal: MiniLM continuo y Gemma 3 4B estructurado; sus métricas no se promedian.

Cierre 20/30: 750 videos fuera de pliegue y 5 000 bootstrap por video.

Decisión: 30 s

AP 0.12

IC 95 % [0.11, 0.14]

Única longitud no inferior en el perfil clásico.

20 s fue no inferior a 30 s en MiniLM (Δ AP 0.024; IC $[-0.0090, 0.059]$), pero no superior. La jerarquía conserva 30 s.

Fuente: Salton y Buckley (1988); Rennie et al. (2003); Wang et al. (2020); tarjeta Gemma 3 4B; Efron (1979); Field y Welsh (2007); informes de optimización de longitud.

Cinco salidas gruesas y señales que obligan revisión

Salida	Criterio operacional breve
SEGURO	Evaluable sin ninguno de los cuatro daños; excluyente.
RACISMO_ DISCRIMINACION	Ataque/exclusión por racialización, etnia, lengua, origen o clase racializada.
ATAQUE_POR_GENERO_ IDENTIDAD	Daño dirigido por género, orientación, identidad o expresión.
ACOSO_AMENAZA	Ataque personal, hostigamiento o anuncio plausible de daño.
CONTENIDO_SEXUAL	Sexual explícito cubierto, cosificación o material no consentido.

14 etiquetas finas

12 fenómenos de daño + 2 estados seguros; agrupación 5/2/2/3 para los cuatro daños.


3 flags

Ironía ambigua, humor encubridor y contexto necesario: no son daños y activan revisión.

Lectura clave: Las etiquetas se aceptan sin distinguir mayúsculas/minúsculas y se almacenan en forma canónica; una abstención no se fuerza a SEGURO.

Fuente: Taxonomía operativa v2.1.0 y matriz de evidencia de categorías.

Etiquetado semiautomático: recuperar, completar y revisar



No razonador thinking=disabled

JSON validado raíz annotations

Reanudable fsync, cuarentena,
chunk_id

Fuente: DeepSeek API: catálogo V4 y documentación oficial; metodología de cascada del proyecto. Prompt operacional v2.

El etiquetado activo mide rapidez, caché y costo

52 244

Flash recuperados

74.79 % del histórico

9 912

Pro recuperados

73.85 % del histórico

14 399

nuevos válidos

corte 8 ago. 2026, 13:15

En progreso

867.28

chunks/min

primera pasada Flash

Calibración (1 000 c/u)	Flash	Pro
tiempo	97.25 s	122.59 s
velocidad (chunks/min)	616.97	489.42
caché de entrada	64.22 %	53.72 %
costo (US\$)	0.073	0.27


Costo observado

US\$0.91 para el tramo nuevo; US\$0.063 por 1 000 válidos. Proyección temprana Flash completa: **US\$7.24.**

Caché Flash acumulada: 75.17 %. Una respuesta con ID/orden alterado fue rechazada y permaneció pendiente.

Fuente: Corte documentado de la campaña Flash→Pro, 8 de agosto de 2026. Tarifas: DeepSeek, tabla oficial de precios.

La calibración sirve para enrutar, no para afirmar verdad humana



Estado: inconcluso con umbral conservador 0.95. Se superó el criterio binario, pero no el límite inferior predeclarado de 90 % para acuerdo exacto.

Lectura clave: Pro es una referencia operacional más fuerte, no un *gold standard*. La exactitud, cobertura y eficacia humanas requieren adjudicación independiente.

Fuente: Wilson (1927); Efron (1979); Field y Welsh (2007); Schroeder, Roy y Kabbara (2025); artefacto `calibration_flash_vs_pro.json`.

El frontend humano conserva contexto y procedencia

Por actualizar con la última versión

Acciones

aceptar, modificar, diferir o
excluir

Contexto

anterior, chunk, posterior y
enlace temporal


Control

sugerencia ocultable, eventos
append-only y reanudación

The screenshot shows a web interface titled 'Validación humana' with a dark header. It displays a proposal for LLM inclusion with a status of '3003/0114 resultados' and 'excluidos: 51'. The main content area is divided into several sections: a top bar with 'Aceptar LLM a incluir' and 'Rechazar y excluir' buttons; a 'Guardar versión modificada por humano' button; a 'Contexto' section with a text area for justification; a 'Control' section with checkboxes for 'Incluir en la base de datos', 'Incluir en la base de datos', and 'Incluir en la base de datos'; and a 'Nota para el usuario' section with a text area for additional notes. The interface is designed for human review and decision-making on LLM proposals.

Fuente: Captura de la interfaz histórica ejecutada. El HTML activo ya implementa el contrato v2.1, pero la captura y los conteos se reemplazarán al materializar la campaña de 02_04.

El dataset entrenable se congela después de la decisión humana



Tamaño y distribución v2.1: En progreso

Se completarán con 02_05; los diferidos y rechazados no entrarán al entrenamiento.

Fuente: Contratos de datos, etapa 02 y cierre humano del flujo activo.

Se compararán seis ramas bajo el mismo snapshot v2.1

En progreso

Rama	Modelos exactos	Propósito y salida
Clásicos TF-IDF	Dummy, ComplementNB, regresión logística, SVM lineal, SGD logístico	Baseline ligero; cinco candidatos calibrados.
Transformers planos	MiniLM-L12-v2 y multilingual-e5-small	Contexto semántico compacto; cinco scores directos.
Cascada Transformer	E5: compuerta de daño + cuatro salidas	Separar detección general de tipificación.
Multitarea	E5: cinco gruesas + 14 finas + 3 flags	Compartir representación y auditar fenómenos.
Qwen LoRA	Qwen3-0.6B-Base, adaptadores rango 8	Ajuste eficiente de un modelo generativo compacto como clasificador.
Qwen estructurado	Qwen3 con penalización SEGURO+daño	Incorporar la exclusividad al objetivo local.

Fuente: Implementación v2.1: `experiments.py` y cuadernos 03_01-03_06. Checkpoints fijados en los manifiestos.

Cada familia responde a una necesidad distinta

TF-IDF + lineales

Fundamento: pesos léxicos y fronteras lineales.

Ventaja: velocidad, CPU, inspección.

Límite: contexto y lenguaje implícito.

MiniLM / E5

Fundamento: atención y representación multilingüe.

Ventaja: semántica compacta.

Límite: fine-tuning, GPU y deriva.

Qwen3 + LoRA


Fundamento: adaptadores de bajo rango.

Ventaja: capacidad con pocos parámetros ajustables.

Límite: mayor costo y variación entre semillas.

Fuente: Salton y Buckley (1988); Cortes y Vapnik (1995); Vaswani et al. (2017); Wang et al. (2020); Reimers y Gurevych (2020); Wang et al. (2024); Hu et al. (2022); Yang et al. (2025).

La comparación separa ajuste, selección y reporte



Lectura clave: El split se agrupa por `video_id`; bootstrap y comparaciones pareadas también respetan esa dependencia.

Fuente: Saito y Rehmsmeier (2015); Cawley y Talbot (2010); Dror et al. (2018); Field y Welsh (2007).

La evidencia de modelos disponible pertenece al contrato histórico

Por actualizar con la última versión				
Modelo histórico, test común 4:1	AP macro	F1 macro	Recobrado daño	Daños como seguro
Qwen3-0.6B LoRA plano	0.55	0.52	0.70	312
E5-small multilingüe plano	0.48	0.52	0.74	270
SVM palabra+carácter plano	0.45	0.46	0.59	428
Qwen3-LoRA cabeza conjunta	0.53	0.52	0.64	375

Baseline ejecutado de **cuatro daños con SEGURO derivado**; 5 290 chunks en test enriquecido 4:1. No se transfiere al contrato v2.1 de cinco salidas aprendidas.

Lectura clave: Históricamente Qwen lideró AP/F1 y E5 el recobrado binario; falta comprobar si ese patrón persiste en el snapshot actual.

Fuente: CSV histórico comparacion_todos_modelos_4.csv; paper, comparación final. Estimaciones puntuales, sin prueba formal entre familias.


El ensamble y el frontend productivo operarán en modo sombra

Captura histórica

The screenshot shows a web application titled 'Moderador local' with a header containing 'Estadísticas' and 'Ayuda'. The main heading is '¿Qué quieres analizar?' with a subtext 'Escribe una frase o pega un enlace de YouTube. El tipo se detecta automáticamente.' Below this is a text input area containing a sample text about a person's behavior. A dropdown menu shows 'Qwen fine-tuned' and 'Todos - automático'. A black 'Analizar' button is to the right. Below the input area, it says 'Análisis terminado y estadísticas guardadas localmente.' and '1 de 1 chunk(s) con alguna alerta - qwen'. The analysis results are displayed in a table with columns 'Alerta' and 'texto: 5000'. The first row shows a 'Contenido sexual' alert with a score of 0.98. Below the table are three horizontal progress bars for 'Modificado (Ruta alta local)', 'Modificado (Ruta alta local)', and 'Modificado (Ruta alta local)', with values 0.01, 0.19, and 0.04 respectively. At the bottom are buttons for 'Aceptar', 'Rechazar', and 'Modificar'.

Fuente: Captura histórica de demostración. El frontend v2.1 está implementado, pero el registro actual se publicará después de 03_07. Ensamblajes: Dietterich (2000); regla 2/3, decisión local.

En progreso



Texto o URL; cinco scores y umbrales; chunk e instante; aceptar, rechazar o modificar. No bloquea, elimina ni sanciona.

Estado de resultados por producto del artefacto

Producto	Resultado disponible	Estado
Scraping	5 002 transcripciones; 336 canales; adquisición reanuable sin audio/video	Actual
Troceado	4 992 videos; 166 940 chunks; 1 451.17 horas; 30 s conservados	Actual
Etiquetado	52 244 Flash + 9 912 Pro recuperados; 14 399 nuevos al corte; US\$0.91	En progreso
Snapshot v2.1	Distribución, split y elegibilidad finales se materializan en 02_05	En progreso
Entrenamiento v2.1	Arquitecturas y protocolo listos; faltan candidatos del snapshot nuevo	Por actualizar con la última versión
Interfaces	Validación humana y frontend local implementados; registro productivo v2.1 pendiente	En progreso

Lectura clave: El proyecto ya produce datos y etiquetado medible; la comparación final y la eficacia del piloto solo se cerrarán con el snapshot y registro nuevos.

Comparaciones cuantitativas que ya pueden defenderse

Longitud

30 s: AP 0.12, IC [0.11, 0.14], única no inferior en el perfil decisorio. 20 s no fue superior en MiniLM.

Etiquetado

Flash: 867.28 chunks/min en el corte; US\$0.063/1 000; 75.17 % de caché acumulada.

Acuerdo

80.41 % exacto y 99.77 % binario a umbral 0.95; inconcluso para el criterio exacto.

Aún no disponible: tamaño final por salida v2.1, desempeño train/validation/test de las seis ramas, comparación estadística final, carga humana real y eficacia prospectiva.

Fuente: Informes de optimización de longitud y corte de etiquetado del 8 de agosto de 2026.

Conclusiones: la brecha se reduce, pero no desaparece

Datos: reducida

El corpus y sus manifiestos convierten subtítulos dispersos en chunks trazables, reanudables y separados por video.

Etiquetas: reducida

La cascada recupera historial, procesa solo pendientes y mide costo/acuerdo; la verdad humana independiente permanece abierta.

Modelos: pendiente

El protocolo v2.1 evita mezclar snapshots, pero la comparación final espera el cierre del etiquetado.

El artefacto integra texto, tiempo, incertidumbre, modelos e intervención humana. Su uso defendible es un demostrador o piloto en modo sombra; afectar contenido o usuarios sin revisión no fue evaluado.

Límites visibles y trabajo futuro accionable

Límites

- ▶ pseudoetiquetas y sugerencia visible: riesgo de anclaje;
- ▶ sin *gold* humano ciego, doble anotación ni kappa;
- ▶ muestreo dirigido y subtítulos disponibles, no prevalencia natural;
- ▶ solo texto: faltan señales visuales y acústicas;
- ▶ resultados neuronales actuales con una semilla y test históricamente consultado.

Siguientes iteraciones

- ▶ cerrar Flash, Pro, revisión humana y snapshot v2.1;
- ▶ ejecutar seis ramas, cinco umbrales y comparación pareada por video;
- ▶ crear holdout temporal de prevalencia natural con doble revisión;
- ▶ repetir semillas y pruebas conductuales/adversariales;
- ▶ medir deriva, subgrupos, latencia, privacidad, seguridad y capacidad humana en modo sombra.

Fuente: Artstein y Poesio (2008); Röttger et al. (2021); Cawley y Talbot (2010); Gorwa et al. (2020); AoIR (2020).

Referencias y recursos reproducibles

Fuentes esenciales

DSR y moderación: Hevner et al. (2004); Peffers et al. (2007); Gorwa et al. (2020).

Taxonomía/contexto: Waseem et al. (2017); Banko et al. (2020); Zavala y Almeida (2022); Albornoz y Flores (2018); Defensoría del Pueblo (2021).

Datos: yt-dlp; YouTube Transcript API; Unicode UAX 15; NIST FIPS 180-4.

Modelos: Salton y Buckley (1988); Cortes y Vapnik (1995); Vaswani et al. (2017); Wang et al. (2020, 2024); Reimers y Gurevych (2020); Hu et al. (2022); Yang et al. (2025).

Evaluación: Saito y Rehmsmeier (2015); Efron (1979); Field y Welsh (2007); Cawley y Talbot (2010).

Servicios de etiquetado: documentación oficial DeepSeek V4, precios y formato JSON.

Metadatos completos, DOI, URL y revisiones de checkpoints: bibliografía y cuadernos del proyecto.

GitHub público

Código, cuadernos, documentación, manifiestos y artefactos autorizados.

github.com/lkoc/Trabajo_PLN-MIA-Grupo4

Drive controlado

Bundles y resultados con acceso autorizado; no contiene claves API.

Gracias