

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano


Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Curso de Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

Texto + evidencia temporal

Decisión humana

Trazabilidad

Tres niveles delimitan el problema



Lectura clave: El modelo filtra y diagnostica preliminarmente; el supervisor recibe el fragmento y el instante necesarios para decidir.

Fuente: Gorwa, Binns y Katzenbach (2020); Andersen, Zukunft y Maalej (2021); paper, Sec. I y Fig. 1.

El problema central orienta cuatro objetivos verificables

Alcance de la indagación

El estudio examinó cómo diseñar, evaluar y empaquetar un moderador semiautomático que señalara daños, conservara evidencia temporal y derivara la incertidumbre a un supervisor.

O1 · Datos. Construir un corpus trazable, una taxonomía y particiones sin fuga por video.


O2 · Modelos. Comparar familias y estructuras bajo una evaluación común.

O3 · Decisión. Calibrar con validación y medir una política selectiva de alto recobrado operativo.

O4 · Artefacto. Integrar evidencia, consenso, intervención humana y registro reentrenable.

Fuente: paper, Secs. I y III.

DSR: construir, evaluar y volver a diseñar



Cada evaluación devolvió evidencia a la siguiente iteración; un resultado no ejecutado se conserva como plan, no como hallazgo.

Lectura clave: La comparación final reúne 13 configuraciones activas y una referencia E5 preliminar post hoc; lo no ejecutado permanece como plan.

Fuente: Peffers et al. (2007); Hevner et al. (2004); paper, Sec. IV-A.

El corpus se usa como un conjunto integrado

Corpus final deduplicado

Unidad	Total
Videos	3,230
Chunks	117,244
Seguro	110,181
Algún daño	7,063
Incidencias de daño	9,127
Canales únicos	250

Fuentes principales

Política, periodismo, humor, farándula, viajes, deportes y otros contextos vinculados con el Perú.

Incluye

Contenido público vinculado con el Perú; subtítulos en español; ≥ 200 caracteres útiles.

Excluye

Videos ya vistos, IDs o hashes duplicados, subtítulos insuficientes y filas no elegibles.


Modalidad

Solo texto de subtítulos públicos; no audio ni imagen.

El muestreo dirigido busca cobertura de daños; no estima su prevalencia en YouTube.


Fuente: Cifras y criterios: paper, Tabla II y Apéndice D. Sobre muestras enriquecidas: Tonneau et al. (2024). Solo se procesó texto de subtítulos públicos en español.

De los subtítulos al corpus supervisado y versionado




Fuente: Paper, Secs. IV-B-IV-D y V-A; corpus y manifiestos canónicos.

Matriz de datos: escala, procedencia y evaluación común



Procedencia de la etiqueta



Partición por video_id



revisión humana asistida conserva cada decisión y su procedencia.

sin videos compartidos

Fuente: Cifras: paper, Secs. IV-B–IV-D. Anotación asistida y acuerdo: Schroeder, Roy y Kabbara (2025); Artstein y Poesio (2008).

Entrenamiento accesible: CPU local + Colab/CUDA

Equipo local Windows

CPU de consumo · 29 GiB de RAM

Ejecución: adquisición y corpus, modelos clásicos, rama preliminar y primeras épocas de Qwen3–LoRA.

Google Colab

NVIDIA L4 · CUDA


Ejecución: MiniLM/E5 activos, variantes estructuradas y últimas épocas de Qwen3–LoRA.

Python/Jupyter · scikit-learn · PyTorch · Transformers · PEFT/LoRA · SQLite · HTML/JavaScript

Lectura clave: El entrenamiento combinó una CPU de consumo y Colab bajo demanda; el paquete final admite inferencia en CPU. No se midieron costos monetarios ni se asume que Colab sea gratuito.

Fuente: paper, Sec. V-B. La GPU L4 procede de la bitácora del equipo.

El contrato v2.1 aprende SEGURO como quinta salida




Regla. SEGURO es mutuamente excluyente con cualquier daño. Conflicto, abstención o proximidad a un umbral deriva a revisión.

Evidencia. Las métricas publicadas siguen siendo del baseline. El rendimiento v2 queda pendiente de reentrenamiento y recalibración.

Fuente: paper, Secs. IV-C y V. La transición de contrato no cambia métricas retrospectivamente.

La taxonomía combina conceptos generales y evidencia peruana



Racismo y lengua

Zavala, Almeida, Brañez y Salem:
racialización y variación local.

Ataques por género

Albornoz y Flores; Defensoría: violencia
digital en el Perú.


Orientación e identidad

Rottenbacher y Lovón-Cueva: prejuicio y
léxico peruano.

Lectura clave: adaptación operacional con 12 fenómenos de daño, dos estados seguros y tres señales de revisión.

Fuente: Marco general: Waseem et al. (2017) y Banko et al. (2020). Evidencia peruana: Zavala y Almeida (2022), Brañez (2012), Salem (2016), Albornoz y Flores (2018), Defensoría del Pueblo (2021), Rottenbacher (2012) y Lovón-Cueva y Lovón-Cueva (2022). Paper, Sec. II-A y Tabla III.

Tres enfoques × tres estructuras de decisión



Clásicos rápidos y explicables

MiniLM / E5 semántica compacta


LLM Qwen3-0.6B Qwen3-LoRA:

0.39 % ajustado

Elección del LLM. El checkpoint Qwen/Qwen3-0.6B-Base ofrecía una escala compatible con el cómputo disponible, preentrenamiento multilingüe, licencia Apache 2.0 e integración con Transformers/LoRA. Llamamos **Qwen3-LoRA** al clasificador ajustado; no se compararon otras familias de LLM.

Fuente: Spärck Jones (1972); Cortes y Vapnik (1995); Wang et al. (2020, 2022, 2024); Vaswani et al. (2017); Hu et al. (2022); Yang et al. (2025); tarjeta fijada de Qwen3-0.6B; paper, Sec. IV-E.


Las iteraciones preliminares explican el artefacto final



Los resultados preliminares usan contratos y conjuntos de prueba distintos: orientan el diseño, pero **no forman una única curva de aprendizaje**.


Fuente: paper, Sec. V-A.

Comparación final: 13 activas + una referencia post hoc



Fuente: paper, tabla de comparación final. Test enriquecido 4:1, no balanceado; E5 preliminar es solo referencia post hoc.

Ganadores: AP/F1 vs. recobrado de cualquier daño



SVM AP 0.45

Base ligera y explicable.

E5 recobrado daño 0.74

Menos daños omitidos: 270.

Qwen3-LoRA AP 0.55

Mayor AP/F1 observado; falta repetir semillas para medir su incertidumbre.

Fuente: paper, Sec. V-B y Tabla V. La barra verde es recobrado de cualquier daño, no recobrado micro. La comparación reporta estimaciones puntuales y no incluyó una prueba formal entre modelos.

El ganador cambia en contenido sexual

Categoría	Modelo elegido con validación	AP validación	AP test
Racismo	Qwen3–LoRA plano	0.63	0.56
Ataque género/identidad	Qwen3–LoRA plano	0.46	0.48
Acoso–Amenaza	Qwen3–LoRA plano	0.45	0.48
Contenido sexual	Qwen3–LoRA, cabeza multitarea congelada	0.63	0.66

Lectura clave: La selección por categoría usa AP de validación. El test solo informa el resultado después de congelar cada ganador.

Fuente: Paper, tabla de ganadores por categoría; métricas del test común.

Qwen3-LoRA: la época 3 redujo la carga al mismo recobrado objetivo

Época 2 · best_adapter

0.54

AP macro en validación

Recobrado de enrutamiento	0.95
Precisión	0.30
Revisión	64 %
Omisiones	53



misma

cobertura

Época 3 · operativa

0.54


AP macro en validación (−0.00070)

Recobrado de enrutamiento	0.95
Precisión	0.32
Revisión	61 %
Omisiones	53

Lectura clave: La regla eligió la época 3 con validación. Como el test de la época 2 ya existía, la comparación se reporta como análisis operativo y no como selección ciega.

Fuente: paper, Sec. V-C y Tabla VI.

La política selectiva envía los casos dudosos a revisión



Lectura clave: El recobrado de enrutamiento es 0.97: esos casos llegan a alerta o revisión. La tasa de revisión es 60 % y excede la meta en 0.40 puntos porcentuales; así dimensiona el piloto supervisado. No es recobrado por categoría.

Fuente: Clasificación selectiva y derivación: Chow (1970); Geifman y El-Yaniv (2017); Mozannar y Sontag (2020). Cifras: paper, Sec. V-C; IC95 % de Wilson.


Las jerarquías no superaron al clasificador plano

Plano



Cada categoría conserva una ruta directa.

Cascada / jerarquía



Un error temprano no se recupera después.


Mejor Qwen3-LoRA jerárquico conjunto frente a Qwen3-LoRA plano

Métrica	Plano	Conjunto	Δ
AP macro	0.55	0.53	-0.017
F1 macro	0.52	0.52	-0.0077
Recobrado de cualquier daño	0.70	0.64	-0.061
Daños omitidos	312	375	+63

Lectura clave: Al perder 0.061 de recobrado de cualquier daño y sumar 63 omisiones, ninguna jerarquía se adoptó.

Fuente: Paper, Sec. V-D. Las variantes estructuradas reutilizan las salidas congeladas del Qwen3-LoRA ajustado.


El análisis fino muestra qué categorías requieren más datos



Lectura clave: Las categorías con 6 o 9 ejemplos producen estimaciones inestables; son prioridad para la siguiente ronda de anotación.

Fuente: paper, Sec. V-E.

El artefacto integra tres modelos y consenso 2 de 3




Entrada mínima texto o URL

Evidencia chunk + tiempo

Corrección aceptar / modificar /
rechazar

Fuente: Diseño local: paper, Sec. IV-H. Moderación semiautomática con revisión humana: Gorwa et al. (2020); Andersen et al. (2021). Una URL sin subtítulos se rechaza; no se analiza audio ni imagen.

La ontología distingue predicción, alerta y decisión humana



Lectura clave: Versionar datos, modelo, puntaje, umbral y decisión permite revisar errores y convertir correcciones en evidencia reentrenable.

Fuente: Gruber (1993); W3C, OWL 2 (2012); paper, Sec. IV-I y ontología OWL/RDF entregada.

Limitaciones actuales y agenda de validación

Etiquetas

La siguiente evaluación incorpora una cohorte temporal con doble revisión independiente.

Alcance

Solo texto de subtítulos: hay ruido, sesgo de disponibilidad y ausencia de señales visuales o acústicas.

Muestra

El test está enriquecido 4:1: no es balanceado ni representa prevalencia real. Hace falta evaluación prospectiva.

Operación

Faltan semillas repetidas, deriva, latencia, seguridad, privacidad, capacidad humana y evaluación del consenso.

Lectura clave: El asistente integra alerta, evidencia y decisión supervisada. El siguiente paso es medir su carga en un piloto *shadow* con revisión independiente.

Fuente: Anotación asistida: Schroeder et al. (2025). Muestreo: Tonneau et al. (2024). Subtítulos automáticos: Tatman (2017). Ética: AoIR (2020) y condiciones de YouTube (2023). Paper, Sec. VI.

Conclusiones: cada objetivo deja un logro y una condición

	Logro verificable	Condición para avanzar
O1	117,244 chunks, 3,230 videos, taxonomía y split sin fuga.	Mejorar supervisión humana y representatividad.
O2	13 configuraciones activas + E5 post hoc: Qwen3-LoRA da el mayor punto AP/F1; E5, recobrado de daño.	Falta una prueba estadística y repetir semillas.
O3	Enrutamiento selectivo: 0.97 del daño llega a alerta o revisión; 28 omisiones.	La carga de 60 % define el trabajo del supervisor; no es recobrado categórico.
O4	Prototipo con SVM, E5, Qwen3-LoRA, consenso 2/3, evidencia y correcciones.	Validar en modo sombra, sin actuar sobre usuarios, y gobernar el reentrenamiento.

Se implementó moderación semiautomática con recursos asequibles para el proyecto: CPU de consumo y Colab bajo demanda. Los modelos alertan y el supervisor conserva la decisión.

Fuente: paper, Sec. VII.

Referencias y recursos reproducibles

Citas esenciales de las diapositivas

DSR: Hevner et al. (2004); Peffers et al. (2007).

Moderación: Gorwa et al. (2020); Andersen et al. (2021).

Datos: Vidgen y Derczynski (2020); Tonneau et al. (2024); Schroeder et al. (2025); Tatman (2017).

Taxonomía: Waseem et al. (2017); Banko et al. (2020); ElSherief et al. (2021); Bourgeade et al. (2024); Defensoría del Pueblo (2021).

Modelos: Spärck Jones (1972); Cortes y Vapnik (1995); Vaswani et al. (2017); Wang et al. (2020, 2022, 2024); Hu et al. (2022); Yang et al. (2025).

Selección humana: Chow (1970); Geifman y El-Yaniv (2017); Mozannar y Sontag (2020).

Ética: AoIR (2020); YouTube, *Terms of Service* (2023).

Referencias completas, DOI y URL: bibliografía del paper.

Artefactos del proyecto

GitHub público

Datos, cuadernos, scripts y artefactos reproducibles.

github.com/lkoc/Trabajo_PLN-MIA-Grupo4

Google Drive controlado

Corpus, modelos y resultados; requiere autorización.

Abrir bundle canónico 04 en Drive

La disponibilidad no sustituye licencias, términos de YouTube ni controles de privacidad.

Gracias

Paper IEEE, guía de reutilización y bibliografía completa en el repositorio