

Moderación semiautomática de videos peruanos de YouTube mediante modelos clásicos y neuronales de procesamiento del lenguaje natural

Luis Enrique Koc Góngora · Alex Felipe Mancilla Antay
Herbert Antonio Meléndez García · Dennis Jack Paitán Cano


Maestría en Inteligencia Artificial · Universidad Nacional de Ingeniería
Procesamiento de Lenguaje Natural · Grupo 4 · 2026–1

Texto + tiempo

Cinco salidas

Decisión humana

Ruta de la presentación



Lectura clave: El hilo conductor sigue los productos que alimentan la etapa siguiente: datos → etiquetas → modelos → evidencia para una persona.

La moderación de YouTube combina escala y contexto

Contenido dañino

Violencia, acoso, discriminación, ataques por identidad y sexualización pueden aparecer en redes y videos.

Contexto

Una noticia puede citar una amenaza; el humor puede encubrir un blanco; una expresión local cambia el sentido.


Decisión

Revisar el video completo no escala. Una alerta sin texto ni tiempo tampoco permite auditar la sugerencia.

Lectura clave: El problema no es solo clasificar texto: es priorizar sin perder contexto, incertidumbre, procedencia ni responsabilidad humana.

Evidencia externa: Moderación y responsabilidad [1]; tipologías de abuso y daño [2, 3]; contexto institucional peruano [4].

El problema se manifiesta en tres niveles



Problema general. Existe la necesidad de construir y evaluar un artefacto reproducible que transforme subtítulos públicos en alertas temporales trazables y mantenga la decisión bajo supervisión humana.

Evidencia externa: Moderación de contenido [1]; diseño y evaluación del artefacto mediante DSR [5, 6].

Las brechas específicas delimitan la construcción

Datos dispersos. Los subtítulos públicos carecen de una adquisición, depuración y segmentación común que preserve video, texto, tiempo y procedencia.

Criterios heterogéneos. Falta aplicar un contrato operacional contextualizado al Perú que distinga daño, seguridad explícita e incertidumbre sin convertir la selección del canal en etiqueta.

Etiquetas incompletas. El historial recuperable y los casos nuevos requieren consolidación incremental, trazable, económica y supervisable.

Evidencia no comparable. Las familias clásicas y neuronales requieren un mismo snapshot, partición por video, calibración y evaluación pareada.

Decisión desconectada. Los scores deben convertirse en evidencia temporal y motivos de revisión, sin automatizar sanciones ni ocultar la intervención humana.

Lectura clave: Son brechas necesarias para construir el artefacto; publicarlo o presentarlo es una tarea de comunicación, no un problema de investigación.

Qué se estudia y qué se modela

Problema de estudio

Moderación semiautomática del daño expresado en subtítulos.

Objeto de estudio

Expresiones potencialmente dañinas en videos vinculados con el Perú.

Objeto modelado

Fragmento temporal con cinco salidas, 14 etiquetas finas y tres flags.


Unidad de análisis

Chunk con `video_id`, texto e intervalo inicial/final.

Lectura clave: El sistema observa texto, no imagen ni audio; una ausencia de daño cubierto no demuestra seguridad universal.

Decisión del artefacto: Contrato v2.1.0: fragmento temporal, cinco salidas, etiquetas finas y flags; alcance restringido a texto.


Los objetivos encadenan entradas y productos verificables



Objetivo general. Diseñar y evaluar el artefacto completo; la metodología DSR explica cómo construir, demostrar, medir y rediseñar cada producto.

Evidencia externa: Ciencia del diseño y proceso DSR [5, 6]. La cadena concreta de productos es diseño local.

La taxonomía traduce conocimiento experto en reglas auditables



Las publicaciones aportan conceptos y límites; el equipo define su codificación. **No hubo panel experto peruano ni validación jurídica de la taxonomía.**

Evidencia externa: Fuentes primarias y estudios institucionales citados junto a cada aporte. La combinación final es una decisión local pendiente de doble anotación independiente.

Racismo/discriminación exige leer racialización, no palabras aisladas

Marco general

Waseem et al. distinguen blanco individual o grupal y abuso explícito o implícito [2].

Banko et al. separan ataque por identidad, insulto y otras modalidades con criterios y excepciones [3].

Aportes sobre el Perú

Zavala y Almeida: “motoso/terruco” y racialización política en redes [7].

Brañez y Salem: ortografía, clase, “amixer”, parodia e ironía como jerarquización [10, 11].

Vich: inferiorización y exclusión pueden operar sin declaración racial literal [8].

Lectura clave: La salida local cubre etnia, lengua, procedencia y clase racializada; una identidad, variedad lingüística o región mencionada neutralmente no activa daño.

Decisión del artefacto: Cinco fenómenos finos conservan la diferencia entre insulto explícito, racismo lingüístico, clasismo racializado, discriminación regional y forma encubierta.

El ataque por género o identidad se define por el blanco del daño

Conceptos computacionales

Zeinert et al. distinguen blanco, acoso, descrédito, estereotipo y cosificación en misoginia [12].

Chakravarthi modela homofobia y transfobia en comentarios de YouTube [13].

Evidencia peruana

Albornoz–Flores y Defensoría: ataques, hostigamiento, amenazas y violencia sexual mediada por tecnología [9, 4].

Lovón–Cueva y Rottenbacher: lesbofobia en foros peruanos y prejuicio hacia grupos trans en una muestra de Lima [14, 15].

Lectura clave: ATAQUE_POR_GENERO_IDENTIDAD explicita que debe existir degradación, exclusión o ataque por género, orientación, identidad o expresión; la mera mención es neutral.


Decisión del artefacto: La categoría puede coexistir con acoso/amenaza o contenido sexual; cada salida exige evidencia propia.

Acoso, amenaza y sexualidad conservan fronteras distintas

Fenómeno	Base experta externa	Frontera operacional local
Ataque personal	Wulczyn et al. estudian ataques personales a escala; Waseem et al. separan abuso dirigido y generalizado [16, 2].	Un ataque aislado grave puede entrar; no se presume reiteración desde un chunk.
Amenaza	Banko et al. distinguen amenaza de violencia de insulto y otras conductas [3]; Defensoría documenta modalidades coexistentes en Perú [4].	Una amenaza implícita requiere blanco, daño plausible y contexto; si falta evidencia, se difiere.
Sexual	Zeinert et al. fundamentan cosificación [12]; Defensoría e Hiperderecho documentan material íntimo no consentido [4, 9].	Sexual explícito sigue la frontera y excepciones de la política de YouTube [17]; el texto no permite inferir desnudez visual ni delito.

Lectura clave: ACOSO_AMENAZA une soporte para entrenar, no equivalencia semántica o jurídica; CONTENIDO_SEXUAL es riesgo de moderación, no condena de toda sexualidad.

DSR convierte la brecha técnica en iteraciones evaluables



Lectura clave: Una evaluación inconclusa no se oculta: conserva la referencia, delimita el aprendizaje y motiva la siguiente iteración.

Evidencia externa: Hevner et al. y Peffers et al. [5,6].

La muestra combina diversidad temática y búsqueda dirigida

336 canales

Política, periodismo, humor, farándula, entretenimiento, deportes, gastronomía, viajes y otros contextos vinculados con el Perú.

1. **Semillas:** catálogo de canales y consultas generales.

2. **Déficits:** soporte por videos de train+validation, nunca test.


3. **Expansión:** consultas temáticas y un salto por nuevos canales.

4. **Selección:** round-robin ponderado e intercalado por canal.

`target_category` explica por qué se buscó un video; nunca se copia como etiqueta verdadera.

Evidencia externa: Aprendizaje activo como antecedente general [18]. | Resultado propio: Índice vigente: 336 canales, 339 archivos por canal y 5 002 videos.

Scraping incremental: adquirir texto sin repetir éxitos



Evidencia externa: Documentación oficial de yt-dlp y YouTube Transcript API [19,20]; términos de YouTube [21]. | Resultado propio: Arquitectura incremental: no descarga audio/video ni ejecuta ASR; umbrales, pausas y recuperación son configuración local.

Corpus textual vigente: corte reproducible del troceador v2.2.0




Indicador	Resultado
videos sin chunk	10
chunks por video, mediana	18
duración por chunk, mediana	31.16 s
caracteres por chunk, mediana	483
palabras por chunk, mediana	87

Resultado propio: Manifiesto de materialización del corpus, corte del 7 de agosto de 2026.

Límite de inferencia

El muestreo es dirigido y depende de disponibilidad de subtítulos. El corpus no estima prevalencia natural de daño en YouTube ni en el Perú.

Limpieza y troceado conservan texto, tiempo y procedencia



Lectura clave: Una reconstrucción total crea respaldo; el modo normal recalcula solo transcripciones nuevas o modificadas.

Evidencia externa: Normalización Unicode [22] y hash SHA-256 [23]. | Resultado propio: Troceador v2.2.0: ventana, solapamiento, ID y reconstrucción incremental.

La longitud se eligió con una jerarquía predeclarada

Decisorio clásico: 5 longitudes $\times$ 3 modelos $\times$ 5 cohortes = 75 ajustes; 1 000 bootstrap por video.

Sensibilidad neuronal: MiniLM continuo y Gemma 3 4B estructurado; sus métricas no se promedian.

Cierre 20/30: 750 videos fuera de pliegue y 5 000 bootstrap por video.

Decisión: 30 s

AP 0.12


IC 95 % [0.11, 0.14]

Única longitud no inferior en el perfil clásico.

20 s fue no inferior a 30 s en MiniLM (Δ AP 0.024; IC [-0.0090, 0.059]), pero no superior. La jerarquía conserva 30 s.

Evidencia externa: TF-IDF [24,25], ComplementNB [26], MiniLM [27,28], Gemma 3 [29,30] y bootstrap [31,32]. | Resultado propio: Experimentos de longitud y regla predeclarada de no inferioridad.

Tres arquitecturas prueban si la decisión de 30 s es robusta



Lectura clave: Las métricas no se promedian: el perfil clásico decide; MiniLM y Gemma intentan refutar la elección con representaciones y salidas diferentes.

Resultado propio: 75 ajustes clásicos, 25 cabezas MiniLM, 500 respuestas Gemma y seguimiento 20/30 con 750 videos fuera de pliegue.

Cinco salidas gruesas y señales que obligan revisión

Salida	Criterio operacional breve
SEGURO	Evaluable sin ninguno de los cuatro daños; excluyente.
RACISMO_ DISCRIMINACION	Ataque/exclusión por racialización, etnia, lengua, origen o clase racializada [2, 7].
ATAQUE_POR_GENERO_ IDENTIDAD	Daño dirigido por género, orientación, identidad o expresión [12, 4].
ACOSO_AMENAZA	Ataque personal, hostigamiento o anuncio plausible de daño [16, 3].
CONTENIDO_SEXUAL	Sexual explícito cubierto, cosificación o material no consentido [12, 17].

14 etiquetas finas

12 fenómenos de daño + 2 estados seguros; agrupación 5/2/2/3 para los cuatro daños.


3 flags

Ironía ambigua, humor encubridor y contexto necesario: no son daños y activan revisión.

Lectura clave: Las etiquetas se aceptan sin distinguir mayúsculas/minúsculas y se almacenan en forma canónica; una abstención no se fuerza a SEGURO.

Decisión del artefacto: Contrato v2.1.0: cuatro daños multietiqueta; SEGURO aprendido y excluyente; etiquetas canónicas insensibles a mayúsculas/minúsculas; abstención fuera del entrenamiento.

Etiquetado semiautomático: recuperar, completar y revisar



No razonador thinking=disabled

JSON validado raíz annotations

Reanudable fsync, cuarentena,
chunk_id

Evidencia externa: DeepSeek V4 Flash/Pro, modo no razonador, JSON y caché [36,37,38,39,40]. | Resultado propio: Regla presupuestada: revisiones Pro previas preservadas, selección crítica y control aleatorio del 1 %; prompt, umbrales y precedencia son locales.

Flash y Pro comparten arquitectura, pero cumplen roles distintos



Lectura clave: La economía proviene de reutilizar el prefijo y reservar Pro para incertidumbre o riesgo; Pro sigue siendo pseudoetiqueta, no verdad humana.

Evidencia externa: Parámetros y arquitectura declarados por DeepSeek [36]; formato y operación de la API [38, 37, 39].

El etiquetado activo mide rapidez, caché y costo

En progreso

52 244

Flash recuperados

74.79 % del histórico

9 912

Pro recuperados

73.85 % del histórico

14 399

nuevos válidos

corte 8 ago. 2026, 13:15

867.28

chunks/min

primera pasada Flash

Calibración (1 000 c/u)	Flash	Pro
tiempo	97.25 s	122.59 s
velocidad (chunks/min)	616.97	489.42
caché de entrada	64.22 %	53.72 %
costo (US\$)	0.073	0.27


Costo observado

US\$0.91 para el tramo nuevo; US\$0.063 por 1 000 válidos. Proyección temprana Flash completa: **US\$7.24**.

Caché Flash acumulada: 75.17 %. Una respuesta con ID/orden alterado fue rechazada y permaneció pendiente.

Evidencia externa: Tarifas y caché de DeepSeek [40, 39]. | Resultado propio: Corte de la campaña Flash→Pro, 8 de agosto de 2026; tiempos, velocidades, tasas y costos proceden de registros de ejecución.

La calibración sirve para enrutar, no para afirmar verdad humana



Estado: inconcluso con umbral conservador 0.95. Se superó el criterio binario, pero no el límite inferior predeclarado de 90 % para acuerdo exacto.

Lectura clave: Pro es una referencia operacional más fuerte, no un *gold standard*. La exactitud, cobertura y eficacia humanas requieren adjudicación independiente.

Evidencia externa: Intervalo de Wilson [41], bootstrap [31, 32] y riesgo de influencia LLM en anotación [42]. | Resultado propio: Panel pareado y registro de calibración Flash-Pro.

El frontend humano conserva contexto y procedencia

[illegible]

Por actualizar con la última versión

Acciones

aceptar, modificar, diferir o
excluir

Contexto


anterior, chunk, posterior y
enlace temporal

Control

sugerencia ocultable, eventos
append-only y reanudación

Resultado propio: Captura de la interfaz histórica ejecutada. El HTML activo implementa el contrato v2.1; la imagen y los conteos se reemplazarán al materializar la campaña humana actual.

El dataset entrenable se congela después de la decisión humana



Tamaño y distribución v2.1: En progreso

Se completarán con 02_05; los diferidos y rechazados no entrarán al entrenamiento.

Decisión del artefacto: Precedencia humano > Pro > Flash; diferidos y rechazados quedan fuera. El tamaño y los splits se reportarán desde el snapshot cerrado.


Se compararán seis ramas bajo el mismo snapshot v2.1

En progreso

Rama	Modelos exactos	Propósito y salida
Clásicos TF-IDF	Dummy, ComplementNB, logística, SVM lineal y SGD [24, 26, 33, 43, 34]	Baseline ligero; cinco candidatos calibrados.
Transformers planos	MiniLM-L12-v2 y multilingual-e5-small [27, 28, 44]	Contexto semántico compacto; cinco scores directos.
Cascada Transformer	E5: compuerta de daño + cuatro salidas [45]	Separar detección general de tipificación.
Multitarea	E5: cinco gruesas + 14 finas + 3 flags [46, 47]	Compartir representación y auditar fenómenos.
Qwen LoRA	Qwen3-0.6B-Base, adaptadores rango 8 [48, 49]	Ajuste eficiente de un decoder compacto como clasificador.
Qwen estructurado	Qwen3 con penalización SEGURO+daño [48]	Incorporar la exclusividad al objetivo local.

Decisión del artefacto: Las seis ramas, sus cabezas, pérdidas, umbrales y comparación común pertenecen al artefacto v2.1; cada familia y checkpoint conserva su referencia externa.

La rama clásica convierte texto disperso en cinco fronteras binarias




Ventaja: rápida, reproducible, apta para CPU e inspeccionable.

Límite: depende de evidencia léxica; capta peor el contexto implícito.

Evidencia externa: Fundamentos y autores indicados en cada bloque; el ensamble de rasgos, One-vs-Rest y cinco umbrales es la implementación local.

MiniLM y E5 usan encoders Transformer compactos



MiniLM-L12-v2

Wang et al. comprimen autoatención mediante destilación [27]; Reimers–Gurevych transfieren embeddings entre idiomas [28]. Checkpoint exacto [53].


multilingual-e5-small

Wang et al. preentrenan embeddings contrastivos multilingües con pares de texto y luego ajustan con datos etiquetados [54, 44]. Checkpoint exacto [55].

Lectura clave: ambos aprenden cinco salidas directamente; MiniLM prioriza compacidad y E5 una representación contrastiva multilingüe.


Cascada y multitarea cambian la cabeza, no la evidencia de entrada

Cascada E5



Jerarquía como antecedente [45]; compuerta y multiplicación locales.

Multitarea E5



Representación compartida: Caruana [46]; salida multietiqueta [47].

Lectura clave: la cascada separa detección y tipificación; la multitarea usa señales finas y flags como supervisión auxiliar. Ambas deben vencer al plano bajo el mismo snapshot.

Qwen3 se adapta como clasificador mediante LoRA o pérdida estructurada

Backbone exacto

Qwen Team / Yang et al.:
Qwen3-0.6B-Base, decoder causal
denso [48, 56].

28 capas; 0.6B parámetros; GQA 16
cabezas Q / 8 KV; contexto 32,768 [56].

Rama LoRA

Hu et al. aproximan la
actualización como matrices de
bajo rango [49].

Local: $r = 8$, $\alpha = 16$, dropout
0.05 sobre q, k, v, o ; cabeza de
cinco logits.

Rama estructurada


Ajuste del clasificador Qwen con
BCE y penalización local de
conflicto:

$\mathcal{L} =$
 $\text{BCE} + 0.2 p_{\text{seg}} \max_k p_{\text{daño}, k}.$

Lectura clave: LoRA reduce parámetros entrenables; la pérdida estructurada incorpora exclusividad.
Ninguna ventaja se asume: ambas se seleccionan en validation.

Evidencia externa: Arquitectura Qwen3 [48], checkpoint exacto [56] y LoRA [49]. Rangos, módulos, cabeza y penalización son decisiones locales.

La comparación separa ajuste, selección y reporte



Lectura clave: El split se agrupa por `video_id`; bootstrap y comparaciones pareadas también respetan esa dependencia.

Evidencia externa: Curvas precisión-recobrado [57]; sesgo de selección [58]; significancia en NLP [59]; bootstrap por conglomerados [32].

La evidencia de modelos disponible pertenece al contrato histórico

Por actualizar con la última versión

Modelo histórico, test común 4:1	AP macro	F1 macro	Recobrado daño	Daños como seguro
Qwen3-0.6B LoRA plano	0.55	0.52	0.70	312
E5-small multilingüe plano	0.48	0.52	0.74	270
SVM palabra+carácter plano	0.45	0.46	0.59	428
Qwen3-LoRA cabeza conjunta	0.53	0.52	0.64	375

Baseline ejecutado de **cuatro daños con SEGURO derivado**; 5 290 chunks en test enriquecido 4:1. No se transfiere al contrato v2.1 de cinco salidas aprendidas.

Lectura clave: Históricamente Qwen lideró AP/F1 y E5 el recobrado binario; falta comprobar si ese patrón persiste en el snapshot actual.

Resultado propio: Comparación histórica ejecutada sobre 5 290 chunks del test enriquecido 4:1; estimaciones puntuales sin prueba formal entre familias.

El ensamble y el frontend productivo operarán en modo sombra

Captura histórica

Modificador local

Estadísticas Ayuda

¿Qué quieres analizar?

Escribe una frase o pega un enlace de YouTube. El tipo se detecta automáticamente.

cat escúchándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o tengo la mano en su pecho. Qué rico. Tú también. Yo también. O cuchara o quitándole carquita debajo de la teta también. Las chicas tienen carcas. Ay, no se van, no se van nada. Por favor, amigo, llega hoy día a tu casa. Hela, Hela. Levántale la teta a tu mujer y húbale. Y húbale. Ah. Mi carabiga huele más rico.

Qwen fine-tuned

Analizar

Aplicar

Análisis terminado y estadísticas guardadas localmente.

1 de 1 chunks con alguna alerta: qwen

Has texto: 6000

cat escúchándola a ver si tiene algún objeto extraño, como un seguridad de aeropuerto más o menos. Entonces yo cuando duermo con ella o tengo la mano en su pecho. Qué rico. Tú también. Yo también. O cuchara o quitándole carquita debajo de la teta también. Las chicas tienen carcas. Ay, no se van, no se van nada. Por favor, amigo, llega hoy día a tu casa. Hela, Hela. Levántale la teta a tu mujer y húbale. Y húbale. Ah. Mi carabiga huele más rico.

Qwen3-2.0B Lora - época operativa 3 Confianza baja. Posición normal.

Comentarios: 100%

Modificó (Rata alta recu) Cero del control

▼ Ejemplo por integración

Resumen de la información

Qwen3


ACOS 0.000000

Confianza: 100%

Aceptar Rechazar Modificar

Evidencia externa: Diversidad de ensambles como antecedente [60]. | Resultado propio: Captura histórica ejecutada y paridad funcional v2.1 verificada; mayoría 2/3 y derivación al supervisor son decisiones locales aún pendientes de evaluación prospectiva.

En progreso



Implementado: texto o URL; consulta individual, comparación y consenso 2/3; cinco scores; revisión; estadísticas y reentrenamiento. No sanciona contenido.

Estado de resultados por producto del artefacto

Producto	Resultado disponible	Estado
Scraping	5 002 transcripciones; 336 canales; adquisición reanuable sin audio/video	Actual
Troceado	4 992 videos; 166 940 chunks; 1 451.17 horas; 30 s conservados	Actual
Etiquetado	52 244 Flash + 9 912 Pro recuperados; 14 399 nuevos al corte; US\$0.91	En progreso
Snapshot v2.1	Distribución, split y elegibilidad finales se materializan en 02_05	En progreso
Entrenamiento v2.1	Arquitecturas y protocolo listos; faltan candidatos del snapshot nuevo	Por actualizar con la última versión
Interfaces	Validación humana y frontend local implementados; registro productivo v2.1 pendiente	En progreso

Lectura clave: El proyecto ya produce datos y etiquetado medible; la comparación final y la eficacia del piloto solo se cerrarán con el snapshot y registro nuevos.

Comparaciones cuantitativas que ya pueden defenderse

Longitud

30 s: AP 0.12, IC [0.11, 0.14], única no inferior en el perfil decisorio. 20 s no fue superior en MiniLM.

Etiquetado

Flash: 867.28 chunks/min en el corte; US\$0.063/1 000; 75.17 % de caché acumulada.

Acuerdo

80.41 % exacto y 99.77 % binario a umbral 0.95; inconcluso para el criterio exacto.

Aún no disponible: tamaño final por salida v2.1, desempeño train/validation/test de las seis ramas, comparación estadística final, carga humana real y eficacia prospectiva.

Resultado propio: Experimentos de longitud y registros de la campaña de etiquetado, corte del 8 de agosto de 2026.

Conclusiones: la brecha se reduce, pero no desaparece

Datos: reducida

El corpus y sus manifiestos convierten subtítulos dispersos en chunks trazables, reanudables y separados por video.

Etiquetas: reducida

La cascada recupera historial, procesa solo pendientes y mide costo/acuerdo; la verdad humana independiente permanece abierta.

Modelos: pendiente

El protocolo v2.1 evita mezclar snapshots, pero la comparación final espera el cierre del etiquetado.

El artefacto integra texto, tiempo, incertidumbre, modelos e intervención humana. Su uso defendible es un demostrador o piloto en modo sombra; afectar contenido o usuarios sin revisión no fue evaluado.

Límites visibles y trabajo futuro accionable

Límites

- ▶ pseudoetiquetas y sugerencia visible: riesgo de anclaje;
- ▶ sin *gold* humano ciego, doble anotación ni kappa;
- ▶ muestreo dirigido y subtítulos disponibles, no prevalencia natural;
- ▶ solo texto: faltan señales visuales y acústicas;
- ▶ resultados neuronales actuales con una semilla y test históricamente consultado.

Siguientes iteraciones

- ▶ cerrar Flash, Pro, revisión humana y snapshot v2.1;
- ▶ ejecutar seis ramas, cinco umbrales y comparación pareada por video;
- ▶ crear holdout temporal de prevalencia natural con doble revisión;
- ▶ repetir semillas y pruebas conductuales/adversariales;
- ▶ medir deriva, subgrupos, latencia, privacidad, seguridad y capacidad humana en modo sombra.

Evidencia externa: Acuerdo entre anotadores [61]; pruebas conductuales [62]; selección de modelos [58]; gobernanza de moderación [1]; ética de investigación en Internet [63].

Las fuentes externas y los resultados propios quedan separados

Conocimiento externo

Definiciones, contexto peruano, arquitecturas, algoritmos, métricas, software y políticas llevan citas IEEE junto a la afirmación.

Las diapositivas siguientes contienen los metadatos completos, DOI y URL de las fuentes citadas.

GitHub público

Código, cuadernos, documentación, manifiestos y artefactos autorizados.

github.com/lkoc/Trabajo_PLN-MIA-Grupo4

Resultados propios

Conteos, tiempos, costos, métricas, capturas y decisiones se trazan a manifiestos y registros ejecutados; no se convierten en autorreferencias bibliográficas.

Drive controlado

Bundles y resultados con acceso autorizado; no contiene claves API.

Gracias

Preguntas y demostración en modo sombra

Referencias externas citadas I

- [1] R. Gorwa, R. Binns, and C. Katzenbach, "Algorithmic content moderation: Technical and political challenges in the automation of platform governance," *Big Data & Society*, vol. 7, no. 1, 2020. [Online]. Available: <https://journals.sagepub.com/doi/10.1177/2053951719897945>
- [2] Z. Waseem, T. Davidson, D. Warmley, and I. Weber, "Understanding abuse: A typology of abusive language detection subtasks," in *Proceedings of the First Workshop on Abusive Language Online*. Association for Computational Linguistics, 2017, pp. 78–84. [Online]. Available: <https://aclanthology.org/W17-3012/>
- [3] M. Banko, B. MacKeen, and L. Ray, "A unified taxonomy of harmful content," in *Proceedings of the Fourth Workshop on Online Abuse and Harms*. Association for Computational Linguistics, 2020, pp. 125–137. [Online]. Available: <https://aclanthology.org/2020.alw-1.16/>
- [4] Defensoría del Pueblo del Perú, "Violencia de género contra las mujeres en línea," Defensoría del Pueblo del Perú, Documento de Trabajo n.º 001-2021-DP/ADM, Aug. 2021. [Online]. Available: <https://www.defensoria.gob.pe/wp-content/uploads/2021/08/Documento-de-trabajo-01-Violencia-de-g%C3%A9nero-contra-las-mujeres-en-l%C3%ADnea.pdf>
- [5] A. R. Hevner, S. T. March, J. Park, and S. Ram, "Design science in information systems research," *MIS Quarterly*, vol. 28, no. 1, pp. 75–105, 2004. [Online]. Available: <https://aisel.aisnet.org/misq/vol28/iss1/6/>
- [6] K. Peffers, T. Tuunanen, M. A. Rothenberger, and S. Chatterjee, "A design science research methodology for information systems research," *Journal of Management Information Systems*, vol. 24, no. 3, pp. 45–77, 2007.
- [7] V. Zavala and C. Almeida, "'Motoso y terruco': ideologías lingüísticas y racialización en la política peruana," *Lexis*, vol. 46, no. 2, pp. 481–521, 2022. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/lexis/article/view/26332>
- [8] V. Vich, "Dinámicas de racismo en el Perú: la perspectiva cultural de Gonzalo Portocarrero," *Debates en Sociología*, no. 47, pp. 219–232, 2018. [Online]. Available: <https://revistas.pucp.edu.pe/index.php/debatesensociologia/article/view/22090>
- [9] D. Albornoz and M. Flores, "Conocer para resistir: violencia de género en línea en Perú," *Hiperderecho*, Lima, Perú, Tech. Rep., 2018. [Online]. Available: https://hiperderecho.org/tecnorendencias/wp-content/uploads/2019/01/violencia_genero_linea_peru_2018.pdf
- [10] R. F. Brañez Medina, "La construcción discursiva de las identidades "amixer" y "no-amixer" en el espacio virtual: un caso de racismo cultural justificado a través de la ortografía," Tesis de licenciatura, Pontificia Universidad Católica del Perú, 2012. [Online]. Available: <https://tesis.pucp.edu.pe/repositorio/handle/20.500.12404/1618>
- [11] V. Salem, "Amixer está en Facebook: una investigación de la choledad virtual," *Revista Chilena de Antropología Visual*, no. 27, pp. 69–88, 2016. [Online]. Available: https://www.antropologiavisual.cl/sites/default/files/2016_27_art04_salem.pdf

Referencias externas citadas II

- [12] P. Zeinert, N. Inie, and L. Derczynski, "Annotating online misogyny," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 3181–3197. [Online]. Available: <https://aclanthology.org/2021.acl-long.247/>
- [13] B. R. Chakravarthi, "Detection of homophobia and transphobia in YouTube comments," *International Journal of Data Science and Analytics*, vol. 18, pp. 49–68, 2024. [Online]. Available: <https://link.springer.com/article/10.1007/s41060-023-00400-0>
- [14] C. M. Lovón-Cueva and M. Lovón-Cueva, "Lesbian lexicon: The construction of a repertoire of hate in peruvian cyberforums," *Whatever. A Transdisciplinary Journal of Queer Theories and Studies*, vol. 5, no. 1, pp. 43–70, 2022. [Online]. Available: <https://whatever.cirque.unipi.it/index.php/journal/article/view/156>
- [15] J. M. Rottenbacher de Rojas, "Conservadurismo político, homofobia y prejuicio hacia grupos transgénero en una muestra de estudiantes y egresados universitarios de Lima," *Pensamiento Psicológico*, vol. 10, no. 1, pp. 23–37, 2012. [Online]. Available: <https://www.redalyc.org/pdf/801/80124028002.pdf>
- [16] E. Wulczyn, N. Thain, and L. Dixon, "Ex machina: Personal attacks seen at scale," in *Proceedings of the 26th International Conference on World Wide Web*. International World Wide Web Conferences Steering Committee, 2017, pp. 1391–1399.
- [17] YouTube, "Política sobre desnudos y contenido sexual," Ayuda oficial de YouTube, 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://support.google.com/youtube/answer/2802002?hl=es-419>
- [18] B. Settles, "Active learning literature survey," University of Wisconsin–Madison, Department of Computer Sciences, Tech. Rep. 1648, 2009. [Online]. Available: <https://minds.wisconsin.edu/handle/1793/60660>
- [19] yt-dlp contributors, "yt-dlp: A feature-rich command-line audio/video downloader," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/yt-dlp/yt-dlp>
- [20] J. Depoix and contributors, "YouTube Transcript API: Python api for retrieving youtube transcripts and subtitles," GitHub repository, 2026, accessed: 2026-07-29; the corpus notebooks did not persist the installed revision. [Online]. Available: <https://github.com/jdepoix/youtube-transcript-api>
- [21] YouTube, "Terms of service," YouTube official terms, Nov. 2023, effective Nov. 6, 2023; accessed Jul. 29, 2026. [Online]. Available: <https://www.youtube.com/t/terms>
- [22] Unicode Consortium, "Unicode normalization forms," Unicode Consortium, Unicode Standard Annex #15 Revision 57, Jul. 2025, ed. Ken Whistler; Unicode 17.0.0; Jul. 30, 2025. [Online]. Available: <https://www.unicode.org/reports/tr15/tr15-57.html>

Referencias externas citadas III

- [23] National Institute of Standards and Technology, "Secure hash standard (SHS)," U.S. Department of Commerce, FIPS PUB 180-4, Aug. 2015. [Online]. Available: <https://csrc.nist.gov/pubs/fips/180-4/upd1/final>
- [24] K. Spärck Jones, "A statistical interpretation of term specificity and its application in retrieval," *Journal of Documentation*, vol. 28, no. 1, pp. 11–21, 1972. [Online]. Available: <https://doi.org/10.1108/eb026526>
- [25] G. Salton and C. Buckley, "Term-weighting approaches in automatic text retrieval," *Information Processing & Management*, vol. 24, no. 5, pp. 513–523, 1988.
- [26] J. D. M. Rennie, L. Shih, J. Teevan, and D. R. Karger, "Tackling the poor assumptions of naive bayes text classifiers," in *Proceedings of the 20th International Conference on Machine Learning*, 2003, pp. 616–623. [Online]. Available: <https://people.csail.mit.edu/jrennie/papers/icml03-nb.pdf>
- [27] W. Wang, F. Wei, L. Dong, H. Bao, N. Yang, and M. Zhou, "MiniLM: Deep self-attention distillation for task-agnostic compression of pre-trained transformers," in *Advances in Neural Information Processing Systems*, vol. 33, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html>
- [28] N. Reimers and I. Gurevych, "Making monolingual sentence embeddings multilingual using knowledge distillation," in *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing*. Association for Computational Linguistics, 2020, pp. 4512–4525. [Online]. Available: <https://aclanthology.org/2020.emnlp-main.365/>
- [29] Gemma Team, "Gemma 3 Technical Report," *arXiv preprint arXiv:2503.19786*, 2025, complete consortium author list in the canonical arXiv record. [Online]. Available: <https://arxiv.org/abs/2503.19786>
- [30] Ollama, "Model card: gemma3:4b," Ollama Model Library, 2026, accessed: Aug. 6, 2026. [Online]. Available: <https://ollama.com/library/gemma3:4b>
- [31] B. Efron, "Bootstrap methods: Another look at the jackknife," *The Annals of Statistics*, vol. 7, no. 1, pp. 1–26, 1979.
- [32] C. A. Field and A. H. Welsh, "Bootstrapping clustered data," *Journal of the Royal Statistical Society: Series B (Statistical Methodology)*, vol. 69, no. 3, pp. 369–390, 2007.
- [33] D. R. Cox, "The regression analysis of binary sequences," *Journal of the Royal Statistical Society: Series B (Methodological)*, vol. 20, no. 2, pp. 215–232, 1958.
- [34] L. Bottou, "Large-scale machine learning with stochastic gradient descent," in *Proceedings of COMPSTAT'2010*. Physica-Verlag HD, 2010, pp. 177–186.
- [35] Ollama, "Structured outputs," Ollama Documentation, 2026, accessed: Aug. 5, 2026. [Online]. Available: <https://docs.ollama.com/capabilities/structured-outputs>
- [36] DeepSeek, "DeepSeek V4 Preview Release," DeepSeek API Documentation, Apr. 2026, accessed: Jul. 29, 2026. [Online]. Available: <https://api-docs.deepseek.com/news/news260424/>

Referencias externas citadas IV

- [37] —, “Thinking Mode,” DeepSeek API Documentation, 2026, accessed: Aug. 8, 2026. [Online]. Available: https://api-docs.deepseek.com/guides/thinking_mode/
- [38] —, “JSON Output,” DeepSeek API Documentation, 2026, accessed: Aug. 8, 2026. [Online]. Available: https://api-docs.deepseek.com/guides/json_mode/
- [39] —, “Context Caching,” DeepSeek API Documentation, 2026, accessed: Aug. 8, 2026. [Online]. Available: https://api-docs.deepseek.com/guides/kv_cache/
- [40] —, “Models and pricing,” DeepSeek API Documentation, 2026, accessed: Aug. 7, 2026. [Online]. Available: https://api-docs.deepseek.com/quick_start/pricing
- [41] E. B. Wilson, “Probable inference, the law of succession, and statistical inference,” *Journal of the American Statistical Association*, vol. 22, no. 158, pp. 209–212, 1927.
- [42] H. Schroeder, D. Roy, and J. Kabbara, “Just put a human in the loop? investigating LLM-assisted annotation for subjective tasks,” in *Findings of the Association for Computational Linguistics: ACL 2025*. Association for Computational Linguistics, 2025, pp. 25 771–25 795. [Online]. Available: <https://aclanthology.org/2025.findings-acl.1323/>
- [43] C. Cortes and V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, pp. 273–297, 1995.
- [44] L. Wang, N. Yang, X. Huang, L. Yang, R. Majumder, and F. Wei, “Multilingual E5 text embeddings: A technical report,” *arXiv preprint arXiv:2402.05672*, 2024. [Online]. Available: <https://arxiv.org/abs/2402.05672>
- [45] C. N. J. Silla and A. A. Freitas, “A survey of hierarchical classification across different application domains,” *Data Mining and Knowledge Discovery*, vol. 22, no. 1–2, pp. 31–72, 2011.
- [46] R. Caruana, “Multitask learning,” *Machine Learning*, vol. 28, pp. 41–75, 1997.
- [47] G. Tsoumakas and I. Katakis, “Multi-label classification: An overview,” *International Journal of Data Warehousing and Mining*, vol. 3, no. 3, pp. 1–13, 2007.
- [48] A. Yang, A. Li, B. Yang, B. Zhang, B. Hui, B. Zheng, B. Yu, C. Gao, C. Huang, C. Lv, C. Zheng, D. Liu, F. Zhou, F. Huang, F. Hu, H. Ge, H. Wei, H. Lin, J. Tang, J. Yang, J. Tu, J. Zhang, J. Yang, J. Yang, J. Zhou, J. Zhou, J. Lin, K. Dang, K. Bao, K. Yang, L. Yu, L. Deng, M. Li, M. Xue, M. Li, P. Zhang, P. Wang, Q. Zhu, R. Men, R. Gao, S. Liu, S. Luo, T. Li, T. Tang, W. Yin, X. Ren, X. Wang, X. Zhang, X. Ren, Y. Fan, Y. Su, Y. Zhang, Y. Zhang, Y. Wan, Y. Liu, Z. Wang, Z. Cui, Z. Zhang, Z. Zhou, and Z. Qiu, “Qwen3 technical report,” *arXiv preprint arXiv:2505.09388*, 2025. [Online]. Available: <https://arxiv.org/abs/2505.09388>
- [49] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen, “LoRA: Low-rank adaptation of large language models,” in *International Conference on Learning Representations*, 2022. [Online]. Available: <https://openreview.net/forum?id=nZeVKeeFYf9>

Referencias externas citadas V

- [50] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://www.jmlr.org/papers/v12/pedregosa11a.html>
- [51] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017, pp. 5998–6008. [Online]. Available: <https://proceedings.neurips.cc/paper/7181-attention-is-all-you-need>
- [52] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1*. Association for Computational Linguistics, 2019, pp. 4171–4186. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [53] Sentence Transformers, "Model card: sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2," Hugging Face Hub, 2026, checkpoint revision used: e8f8c211226b894fcb81acc59f3b34ba3efd5f42; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/sentence-transformers/paraphrase-multilingual-MiniLM-L12-v2/blob/e8f8c211226b894fcb81acc59f3b34ba3efd5f42/README.md>
- [54] L. Wang, N. Yang, X. Huang, B. Jiao, L. Yang, D. Jiang, R. Majumder, and F. Wei, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2212.03533*, 2022. [Online]. Available: <https://arxiv.org/abs/2212.03533>
- [55] intfloat, "Model card: intfloat/multilingual-e5-small," Hugging Face Hub, 2026, checkpoint revision used: 614241f622f53c4eeff9890bdc4f31cfec418b3; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/intfloat/multilingual-e5-small/blob/614241f622f53c4eeff9890bdc4f31cfec418b3/README.md>
- [56] Qwen Team, "Model card: Qwen/Qwen3-0.6B-Base," Hugging Face Hub, 2025, checkpoint revision used: da87bfb608c14b7cf20ba1ce41287e8de496c0cd; accessed Jul. 29, 2026. [Online]. Available: <https://huggingface.co/Qwen/Qwen3-0.6B-Base/blob/da87bfb608c14b7cf20ba1ce41287e8de496c0cd/README.md>
- [57] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets," *PLOS ONE*, vol. 10, no. 3, p. e0118432, 2015. [Online]. Available: <https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0118432>
- [58] G. C. Cawley and N. L. C. Talbot, "On over-fitting in model selection and subsequent selection bias in performance evaluation," *Journal of Machine Learning Research*, vol. 11, pp. 2079–2107, 2010. [Online]. Available: <https://www.jmlr.org/papers/v11/cawley10a.html>
- [59] R. Dror, G. Baumer, S. Shlomov, and R. Reichart, "The hitchhiker's guide to testing statistical significance in natural language processing," in *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2018, pp. 1383–1392. [Online]. Available: <https://aclanthology.org/P18-1128/>

Referencias externas citadas VI

- [60] T. G. Dietterich, "Ensemble methods in machine learning," in *Multiple Classifier Systems*. Springer, 2000, pp. 1–15.
- [61] R. Artstein and M. Poesio, "Inter-coder agreement for computational linguistics," *Computational Linguistics*, vol. 34, no. 4, pp. 555–596, 2008.
- [62] P. Röttger, B. Vidgen, D. Nguyen, Z. Waseem, H. Margetts, and J. Pierrehumbert, "HateCheck: Functional tests for hate speech detection models," in *Proceedings of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing (Volume 1: Long Papers)*. Association for Computational Linguistics, 2021, pp. 41–58. [Online]. Available: <https://aclanthology.org/2021.acl-long.4/>
- [63] a. s. franzke, A. Bechmann, M. Zimmer, C. Ess, and Association of Internet Researchers, "Internet research: Ethical guidelines 3.0," Association of Internet Researchers, Tech. Rep., 2020, approved by the AoIR membership Oct. 6, 2019. [Online]. Available: <https://aoir.org/reports/ethics3.pdf>